



课程 COURSE

Big Data Analytics

大数据分析 [2026 国际商务]

Lecture 1 — Introduction 第一讲·导论
从大数据到生成式与代理式 AI

任课教师：戴谢尔 (Xieer Dai, David)

深圳大学 Shenzhen University · 第 8-14 周·星期四 11-12 节

上课地点：南 209

学分 2 · 选修课 (讲座式) | 答疑：预约制 | E-mail: Xieer.dai@szu.edu.cn


学习目标 Learning Objectives

完成本讲后，你应能够：

1. 定义大数据及其 5V 特征，区分结构化 / 半结构化 / 非结构化数据；
2. 说明数据分析工作流（CRISP-DM）与现代 MLOps/LLMOps 的对应关系；
3. 用「机器学习 1-2-3」框架描述任一分析任务（数据 → 模型 → 优化）；
4. 解释基础模型、推理模型、代理式 AI（Agentic AI）与 RAG 的基本原理；
5. 判断生成式 AI 的适用边界：幻觉、评测、成本与合规风险；
6. 独立完成一次端到端数据探索，并按规定声明 AI 工具的使用。

来源：课程组自编；术语与最新进展截至 2026 年，来源见各页脚注。

本讲路线图 Roadmap



主线：数据 → 特征 → 模型 → 评估 → 部署

本讲新增：GenAI / 推理模型 / Agentic AI / 监管与算力

课程须知 Course Guideline

课程名称: 大数据分析 [2026 国际商务] Big Data Analytics

任课教师: 戴谢尔 (Xieer Dai, David)

E-mail: Xieer.dai@szu.edu.cn

上课周次: 第 3-14 周

上课时间: 星期四第 11-12 节

上课地点: 南 209

答疑安排: 预约制 (by appointment)

办公室: 1310 明德楼

学分: 2

课程类型: 选修课 / 讲座式 (Selective, Lectures)

本课程对 AI 工具的态度

鼓励使用大语言模型 (LLM) 辅助学习与编码, 但必须 (1) 在作业中声明所用工具与提示词, (2) 对模型输出做人工核验, (3) 不得直接提交未经验证的模型生成内容。

先修要求与参考书 Prerequisites & Reading

先修要求

- ▶ 编程：至少掌握 C/C++/Java/Python/Matlab 之一（以 Python 为主）；建议会用 LLM 辅助编程；
- ▶ 数学：初等代数、线性代数、线性方程组、微积分、优化基础、概率；
- ▶ 统计：描述统计、推断统计、假设检验、估计量与拟合优度。

教材

- ▶ 无指定教材；每讲提供参考书与论文；
- ▶ McKinney (2018) *Python for Data Analysis*;
- ▶ Géron (2022) *Hands-On Machine Learning*;
- ▶ 陈强 (2021) 《机器学习及 Python 应用》

2025–2026 补充报告

- ▶ Stanford HAI, *AI Index Report 2026*;
- ▶ McKinsey, *The State of AI*;
- ▶ KPMG, *AI Pulse* (企业代理化) .

成绩、作业与 AI 使用规范

成绩构成： 10% 课堂展示 + 90% 项目（4 选 3 项大数据分析研究项目， ≤ 2 人组队）。项目报告需包含：主要步骤、方法、代码、基本结果与解释。

AI 使用声明（必须随作业提交）


- ▶ 使用了哪些工具（模型名 + 版本 + 日期）；
- ▶ 用途：代码、文字、数据分析、绘图；
- ▶ 关键提示词（提示词留档）；
- ▶ 你做的核验方式与修改说明。

不允许

- ▶ 直接提交模型生成而未核验的结论或代码；
- ▶ 用模型伪造数据、实验结果或文献引用；
- ▶ 未声明的代写（包含代码与报告文字）。

来源：课程组规定（2026 版）；各校/院学术规范若更严格，从其规定。

从数据到决策：DIKW 金字塔



数据分析的价值在于把原始记录逐层转化为可执行的决策，每一层都需要不同的方法与质量要求。

Value comes from the transformation chain, not from data volume itself.

大数据 5V Big Data Characteristics

特征	含义与 2026 视角
Volume 体量	从 TB 到 ZB 级；单次训练的语料与日志量远超传统数据库设计目标
Velocity 速度	流式数据（点击流、支付、传感器、日志）；实时决策窗口从小时缩到毫秒
Variety 多样性	结构化表格、文本、图像、音视频、图数据、时序信号
Veracity 真实性	噪声、缺失、标注偏差、合成数据带来的真实性风险
Value 价值	只有进入决策链路的数据才产生价值（分析 → 产品 → 收益）

来源：经典 3V 框架（Volume/Variety/Velocity）+ 后续扩展；数据形态与治理视角据近年实践整理。

数据形态 Data Modalities

结构化

表格/关系数据库；列有明确类型；直接可计算。

非结构化

文本、图像、音频、视频；需先转为向量或特征才能建模。

现代处理方式

- ▶ 传统方法：清洗 + 特征工程；
- ▶ 表示学习：把非结构化数据编码为嵌入向量；
- ▶ 多模态模型：文本/图像/音频统一表示。

半结构化


JSON / XML / 日志 / 网页；有自描述结构但模式不固定。

图与时空

关系网络（转账、社交）、轨迹与地理栅格数据。

Most big-data work is spent turning unstructured inputs into a usable numeric representation.

数据管道 Data Pipeline



工程要求: 可重跑 (idempotent)、可观测、数据契约 (schema contract)、血缘 (lineage)。

Without monitoring and feedback, models silently decay as the world changes.

现代数据栈 2026 The Modern Data Stack

计算与查询层 Query / Compute: 云数仓·Lakehouse ·DuckDB/Polars 本地分析

存储层 Storage: 对象存储 + 开放表格式 (Iceberg/Delta/Hudi)

转换与编排 Transform / Orchestration: dbt ·Airflow ·Spark ·Flink

机器学习与 AI 层: Feature Store ·向量数据库·模型服务·评测与护栏

治理与安全 Governance: 身份权限·数据目录·血缘·合规审计

趋势: 计算与存储解耦、开放表格式避免厂商锁定、AI 层与数据层直接打通 (RAG/特征共享)。

The AI layer now sits on top of the same governed data platform as BI.

分析层次 Four Levels of Analytics (+ 生成式与代理式)

层次	回答的问题	典型技术
描述性 Descriptive	发生了什么?	报表、看板、聚合统计
诊断性 Diagnostic	为什么发生?	下钻、相关性、因果推断
预测性 Predictive	将会发生什么?	回归、分类、时序预测
规范性 Prescriptive	应该怎么做?	优化、仿真、A/B 实验、决策规则
生成式 Generative	能否直接产出内容/答案?	LLM、多模态生成、RAG
代理式 Agentic	能否自主完成多步任务?	规划 + 工具调用 + 记忆 + 自省

传统四层解决“理解与决策”，生成式与代理式进一步承担“执行”。

分析 workflow: CRISP-DM 与 MLOps/LLMOps

阶段	CRISP-DM (经典)	MLOps / LLMOps (现代)
理解问题	业务理解、目标定义	指标定义 + 成功判据 + 风险清单
理解数据	数据理解、初步探索	数据目录、血缘、质量监控
准备数据	清洗、构造特征	特征平台、可重跑管道、数据契约
建模	选算法、训练	实验跟踪、版本化、自动调参
评估	离线指标	离线 + 在线 (A/B、影子部署) + 成本/延迟
部署	报告/交付	CI/CD 发布、灰度、回滚、护栏
监控	少见	漂移检测、提示词版本、人工复核回路


来源: CRISP-DM 流程与 MLOps/LLMOps 实践对照整理。

方法示例 A：房价预测为什么是「回归」

任务：根据房屋特征 x 预测连续价格 $y \in \mathbb{R}$ 。

- ▶ 目标变量连续 $\rightarrow$ 回归问题；
- ▶ 常用损失： $\ell(y, f(x)) = (y - f(x))^2$ ；
- ▶ 常用指标：RMSE、MAE、 R^2 ；
- ▶ 典型模型：线性回归 $\rightarrow$ 正则化回归 $\rightarrow$ 梯度提升树 $\rightarrow$ 神经网络。

关键：先确定“预测什么”（目标变量类型），再决定损失与评价指标。



方法示例 B：垃圾邮件识别为什么是「分类」

任务：判断邮件是否为垃圾邮件， $y \in \{0, 1\}$ 。

- ▶ 目标变量离散 → 分类问题；
- ▶ 特征：关键词计数、发件人特征、文本嵌入向量；
- ▶ 损失：0-1 损失（不可优化）→ 交叉熵（可优化）；
- ▶ 指标：精确率、召回率、F1、ROC-AUC（不能只看准确率）。

类别不平衡时，准确率会严重高估模型表现。

预测 \ 实际	$y = 1$ (垃圾)	$y = 0$ (正常)
$\hat{y} = 1$	TP	FP
$\hat{y} = 0$	FN	TN

精确率 = $\frac{TP}{TP+FP}$ ，召回率 = $\frac{TP}{TP+FN}$ 。

数据质量与偏差 Data Quality & Bias (数据工作占 60–80% 时间)

常见质量问题

- ▶ 缺失值 (随机缺失 / 系统性缺失);
- ▶ 异常值与录入错误;
- ▶ 重复记录与实体不一致;
- ▶ 单位、时间与时区不一致。

常见偏差来源

- ▶ 样本选择偏差 (只覆盖某类用户);
- ▶ 标签噪声与标注者不一致;
- ▶ 历史偏见被模型放大 (如信贷、招聘);
- ▶ 分布漂移: 训练世界 $\neq$ 部署世界。

实践建议

先做“数据体检” (profile) 再建模: 缺失率、取值域、时间覆盖、群体分布对比; 把数据质量指标纳入监控看板, 与模型指标同等对待。

来源: 数据质量与偏差清单据数据工程与公平性研究实践整理。

七个常见误区 Seven Common Pitfalls

1. **数据泄漏** (leakage): 用未来信息或目标信息的代理变量做特征;
2. **指标错配**: 优化了便于计算的指标, 而非业务真正关心的结果;
3. **相关当因果**: 把相关性结论直接用于干预决策;
4. **只看准确率**: 忽略类别不平衡、成本不对称与置信区间;
5. **过度调参**: 在测试集上反复调参 → 隐性过拟合;
6. **忽视成本与延迟**: 模型精度提升 1%, 成本上升 10 倍;
7. **无监控与回滚**: 上线即“失踪”, 漂移无人负责。

原则: 先建立可信基线, 再谈复杂模型。

Part 1 小结 Summary

- ▶ 大数据 = 体量 + 速度 + 多样 + 真实 + 价值，核心是价值进入决策链路；
- ▶ 数据管道与现代数据栈决定分析能否规模化、可复现；
- ▶ 分析层次从“理解”（描述/诊断）走向“预测/规范”，再延伸到生成式与代理式；
- ▶ 经典流程（CRISP-DM）与现代工程实践（MLOps/LLMOps）需要对应起来；
- ▶ 数据质量与偏差是模型成败的第一性问题，占工作量的主要部分。

自检清单

(1) 目标变量是连续还是离散？(2) 损失与评价指标是否匹配业务？(3) 有无泄漏？(4) 数据质量如何？(5) 上线后如何监控？


AI 版图 2026 The AI Landscape



传统机器学习以“人工特征 + 浅层模型”为主；深度学习把特征学习并入模型；基础模型把“预训练 + 适配”变成新范式。

Generative AI and agentic systems sit inside this landscape, not beside it.

机器学习 1-2-3 Machine Learning 1-2-3



$$\hat{L}(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i), \quad f^* = \arg \min_{f \in \mathcal{H}} \hat{L}(f).$$

第 2 步注入**先验知识** (模型形式与损失), 第 3 步是纯优化问题; 第 1 步决定上限。

Model class + loss encode prior knowledge; data and features bound achievable performance.

学习范式 Learning Paradigms

范式	数据形式	典型任务
监督学习 Supervised	有标签 (x_i, y_i)	回归、分类、排序、目标检测
无监督学习 Unsupervised	仅 x_i	聚类、降维、异常检测、主题模型
自监督学习 Self-supervised	从数据自身构造标签	语言建模、掩码重建、对比学习 (LLM 预训练)
强化学习 RL	与环境交互获得奖励	游戏、机器人、推荐、对齐 (RLHF/RLVR)

当前大模型的能力主要来自**自监督预训练** + **后训练对齐** (含人类反馈与可验证奖励)。

来源：范式划分据经典机器学习框架；后训练部分见 29 页。

训练·验证·测试 Train / Validation / Test

- ▶ 训练集：拟合参数；
- ▶ 验证集：选模型、调超参数、早停；
- ▶ 测试集：只用于最终报告，不可反复使用；
- ▶ 时间序列 / 分组数据需按时间或实体切分，避免泄漏。

小数据可用 k -折交叉验证；不平衡数据用分层抽样。


过拟合信号

- ▶ 训练误差远低于验证误差；
- ▶ 验证误差在选择模型后持续变差；
- ▶ 系数/特征数量随样本量不成比例增长。

缓解手段

正则化、早停、数据增强、简化模型、增加数据、集成。

偏差-方差与正则化 Bias-Variance & Regularization



$$\mathbb{E}[(y - f(x))^2] = \underbrace{\text{Bias}^2}_{\text{模型假设}} + \underbrace{\text{Var}}_{\text{估计误差}} + \underbrace{\sigma^2}_{\text{噪声}}$$

- ▶ 过简单：高偏差（欠拟合）；
- ▶ 过复杂：高方差（过拟合）；
- ▶ 正则化（L1/L2、dropout、早停）在两者间折中。

示意图（schematic）：纵轴为相对误差，仅用于说明趋势，非实测数据。

评估指标：分类 Classification Metrics

	$\hat{y} = 1$	$\hat{y} = 0$
$y = 1$	TP	FN
$y = 0$	FP	TN

$$\text{精确率 } P = \frac{TP}{TP+FP}, \text{ 召回率 } R = \frac{TP}{TP+FN},$$

$$F_1 = \frac{2PR}{P+R}.$$

- ▶ **ROC-AUC**: 排序能力, 对阈值不敏感;
- ▶ **PR-AUC**: 正类稀少时更敏感、更有用;
- ▶ **阈值选择**: 由业务成本决定 (漏判 vs 误判);
- ▶ **校准**: 预测概率是否可靠 (信用、医疗必备);
- ▶ **分层报告**: 不同群体上的指标差异 (公平性)。

不要只报告一个数字: 给出指标 + 阈值 + 置信区间 + 成本假设。

评估指标：回归与 LLM 评测

回归

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

RMSE 对大误差敏感；MAE 稳健； R^2 是相对基线的解释力。

LLM 评测（新增）

- ▶ 任务准确率 / 通过率（含代码执行验证）；
- ▶ 事实性：是否有依据、是否可溯源；
- ▶ 鲁棒性：改写、对抗、长上下文；
- ▶ 幻觉率与拒答率；
- ▶ 成本与延迟（token、时延）；
- ▶ 人工评审 + 自动评审结合。

来源：分类/回归指标据经典统计与机器学习教材；LLM 评测维度据 2025–2026 评测实践与评测可靠性讨论整理。


从特征工程到表示学习 Representation Learning

手工特征 (经典)

- ▶ 依赖领域知识：颜色直方图、 n -gram、技术指标；
- ▶ 可解释、数据需求小；
- ▶ 上限受设计者想象力限制。

学习特征 (现代)


- ▶ 模型直接从原始数据学习表示：图像、语音、文本嵌入；
- ▶ 需要大量数据与算力；
- ▶ 表示可迁移：预训练 → 微调 / 提示。



Deep Learning $\subseteq$ Representation Learning $\subseteq$ Machine Learning $\subseteq$ AI.


深度学习与反向传播 Deep Learning Basics

- ▶ 多层非线性变换: $h^{(l)} = \phi(W^{(l)}h^{(l-1)} + b^{(l)})$;
- ▶ 损失对参数的梯度由**反向传播** (链式法则) 高效计算;
- ▶ 优化: 随机梯度下降及其变体 (Momentum、AdamW);
- ▶ 工程要点: 初始化、归一化、学习率调度、混合精度、并行训练;
- ▶ 硬件: GPU/TPU 集群 + 高速互联, 训练受显存与带宽约束。



来源: 神经网络与反向传播的标准表述。

Transformer 与基础模型 Foundation Models



预训练：在海量文本上做自监督的“预测下一个 token”，学到通用语言与知识表示。

适配：提示词 (prompt)、检索增强 (RAG)、微调 (SFT/LoRA)、工具调用；上下文窗口从数千扩展到十万至百万 token 级。

来源：Transformer 架构 (Vaswani et al., 2017) 与基础模型范式标准表述；上下文长度量级据 2024–2026 公开模型规格。

对齐与后训练 Post-training & Alignment



后训练决定模型的”行为”：是否遵守指令、是否安全、是否愿意多步推理。RLVR（强化学习 + 可验证奖励）是 2024–2026 提升推理能力的关键手段。

Capability from pretraining, behaviour from post-training; verification makes reward signals scalable.

来源：后训练流程（SFT / RLHF / DPO / RLVR）据 2023–2026 公开技术报告整理。

推理模型与测试时计算 Reasoning Models & Test-time Compute

- ▶ 传统方式：一次前向输出答案；
- ▶ **推理模型**：先生成“思考”（思维链），再给结论；
- ▶ 用**更多推理算力**换取更高准确率（test-time compute scaling）；
- ▶ 代表：o 系列、GPT-5、Gemini Deep Think、DeepSeek-R 系列；
- ▶ 代价：延迟与 token 成本上升，需要按任务选择“思考预算”。





示意图 (schematic)：曲线为定性趋势，非具体模型实测数据。

来源：推理模型范式（OpenAI o 系列、GPT-5；DeepSeek-R 系列；Gemini Deep Think）据 2024–2026 公开资料。

代理式 AI 与工具协议 Agentic AI & MCP



- ▶ 代理 = 模型 + 循环控制 + 工具 + 记忆;
- ▶ 能力上限取决于工具质量与权限治理;
- ▶ 关键工程问题: 超时、重试、幂等、审计、成本上限;
- ▶ 多智能体协作: 分工 + 校验 (reviewer 角色)。

来源: Agentic AI 与工具协议 (MCP) 实践据 2025-2026 行业公开资料整理。

小模型与端侧 AI Small Models & On-device AI

为什么需要小模型

- ▶ 成本：API 调用量大时，边际成本决定可行性；
- ▶ 延迟：端侧推理免网络往返，适合实时交互；
- ▶ 隐私与合规：数据不出设备，降低合规风险；


实现手段

- ▶ 蒸馏、剪枝、量化 (int8/4bit)；
- ▶ 小参数 + 长思考 / 工具调用弥补能力；
- ▶ 混合架构：端侧处理高频任务，云端兜底。



来源：端侧与小模型趋势据 2026 年端侧 AI 与模型效率相关报道整理。

RAG: 把企业数据接入模型 Retrieval-Augmented Generation



作用：把“参数记忆”变成“可检索的外部记忆”，显著降低幻觉并支持引用溯源；难点：切分粒度、检索召回、上下文噪声、权限过滤。

RAG is the practical bridge between a foundation model and governed enterprise data.

来源：检索增强生成（RAG）标准流程据 2020 年后研究与 2025–2026 工程实践整理。

能力与边界 Capabilities & Limits

模型已经做得不错

- ▶ 文本总结、改写、翻译、代码补全；
- ▶ 结构化抽取、分类、信息检索；
- ▶ 在明确工具与验证下完成多步任务。


仍然薄弱或不可靠

- ▶ 事实性：会自信地编造（幻觉）；
- ▶ 因果与反事实推理；
- ▶ 长程规划与一致性（多步误差累积）；
- ▶ 数值精确计算、单位与时序推理。

工程结论

把模型当作**概率型组件**：设计验证环节（规则校验、单元测试、人工抽检），限制权限并记录日志。

时间轴：从 AlexNet 到代理式 AI (2012–2026)



三条主线交织：**规模**（数据/参数/算力）、**范式**（监督 → 自监督 → 后训练对齐）、**形态**（对话 → 推理 → 代理）。

Each wave changed what practitioners must know, not just what models can do.

来源：里程碑事件据各机构公开技术报告与发布说明整理；当前进展截至 2026 年。

2023：多模态起步与开源浪潮

闭源前沿

- ▶ 对话模型进入生产：长文问答、代码辅助普及；
- ▶ 多模态能力开始出现（图像输入）；
- ▶ 企业从“试验”转向“寻找场景”。

开源生态

- ▶ 开放权重模型出现并快速迭代（Llama 2、Qwen、Mistral）；
- ▶ 开源推理与部署工具链（量化、本地服务）成熟；
- ▶ 中文模型与多语言能力显著改善。

对分析工作的影响：文本抽取、摘要、代码生成开始进入日常数据流程。

2024：多模态、长上下文与“推理范式”开端

- ▶ **多模态**：文本 + 图像 + 音频/视频统一建模成为主流方向；
- ▶ **长上下文**：文档级甚至书级输入，改变 RAG 与检索的设计取舍；
- ▶ **推理范式**：o1 系列把“先思考再回答”（思维链 + 测试时算力）变成产品能力；
- ▶ **开源追赶**：Llama 3、Qwen2.5、DeepSeek-V3 等在多项任务上逼近闭源前沿；
- ▶ **工程化**：提示词工程 → 结构化输出（JSON schema）→ 工具调用 → 评测体系。

对数据分析的意义

数据分析从“写 SQL/ECharts”扩展到“用自然语言驱动数据管道与图表生成”；但结果需要**可验证**（数值校验、口径一致、可复现）。

2025 上半年：推理模型竞赛与 Agent 元年

- ▶ **推理模型竞赛**：DeepSeek-R1（开放权重、可复现推理训练流程）、o3、Claude 3.7/4 系列相继推出；
- ▶ **成本下降**：同等能力的价格快速下行，推理成本成为选型核心指标；
- ▶ **Agent 元年**：从“聊天”转向“完成任务”——浏览器/终端/办公工具调用；
- ▶ **工具协议标准化**：MCP 等协议让模型统一接入外部工具与数据源。

为什么这半年重要

- ▶ 证明**开放权重**可以接近前沿水平；
- ▶ 证明**测试时算力**可系统性换取准确率；
- ▶ 把“模型能力”问题转化为**系统与流程**问题。

来源：DeepSeek-R1 等开放权重推理模型与行业分析据 2025 年公开资料整理。

2025 下半年：新一代通用模型与代理化产品

- ▶ **GPT-5**: 通用推理与编码能力进一步提升，成为企业基线选项之一（OpenAI 发布说明）；
- ▶ **Claude Opus 4.5** (2025-11): 面向编码与长任务的代理能力成为竞争焦点（行业分析）；
- ▶ **Gemini 3 系列**: 多模态推理与“深度思考”模式（模型资料）；
- ▶ **代理化产品**: 编码助手、办公助手、数据分析助手开始“端到端交付任务”；
- ▶ **评测与安全**: 模型卡、红队测试、企业级权限与审计成为采购要求。

学生要关注的转变

竞争焦点从“谁的模型更强”转到“谁能把模型接入真实流程并保证可靠与合规”。

2026 现状：开源前沿收敛与能力同质化

- ▶ **开源前沿密集发布**：2026 年上半年，多家实验室在数周内相继推出接近前沿的开放权重模型，许可证分为**宽松**与**限制性**两类（报道）；
- ▶ **能力同质化**：主流模型在通用任务上的差距缩小，选择更多取决于成本、延迟、生态与合规；
- ▶ **价格下行**：推理单价持续下降，应用可行性边界不断外移。

开放权重 $\neq$ 开源数据

- ▶ “开放权重”只给参数，通常不给训练数据与完整训练流程；
- ▶ 许可证可能限制商用规模、再分发或蒸馏；
- ▶ 使用前必须核对许可条款与合规要求。


来源：开放权重前沿收敛与许可模式据 2026 年公开报道整理；具体条款以各模型官方许可为准。

模型对比（截至 2026 年，量级与定位）

模型	机构	定位与模态	访问方式 / 许可
GPT-5	OpenAI	通用推理、编码、工具调用；多模态	闭源 API / 产品
Gemini 3 系列	Google DeepMind	多模态推理、长文档、深度思考	闭源 API / 产品
Claude Opus 4.5	Anthropic	长任务代理、编码、文档	闭源 API / 产品
DeepSeek R / V 系列	DeepSeek	推理与通用对话，成本敏感场景	开放权重 + API
Qwen 系列	阿里	中文、多模态、尺寸齐全（含端侧）	开放权重 + API
Llama 系列	Meta	通用开源基座，便于自建	开放权重（社区许可）
Mistral 系列	Mistral AI	欧洲合规、轻量与高效推理	部分开放权重

来源：表格为定位性对比，规格与许可随版本变化，使用前请查阅官方文档。

能力与成本：同等能力越来越便宜



选择模型时按“任务-成本-延迟”三维评估，而不是只看排行榜。

成本结构 (LLM 调用)

- ▶ 输入 token (上下文、检索内容);
- ▶ 输出 token (含“思考”token);
- ▶ 提示词缓存命中率;
- ▶ 重试、工具调用与失败重跑;
- ▶ 自建部署: GPU 折旧 + 电力 + 运维。

示意图 (schematic): 曲线为定性趋势; 成本/能力的绝对值请以官方定价与实测为准。

算力与资本开支 Compute & Capex

≈\$745B

超大规模厂商 AI 资本开支 (2026 年
报道口径)

≈\$2.4T

数据中心运营商基础设施投入承诺
(报道口径)

GW 级

单体 AI 数据中心园区用电量级

算力已成为分析能力的约束条件：训练决定上限，推理决定成本。2024–2026 年资本开支从“芯片”扩展到**电力、冷却、选址、并网**。

Compute constraints now shape business decisions: which model, which latency, which unit cost —not just which algorithm.

来源：资本开支与基础设施投入量级据 2026 年公开报道整理

(<https://www.edgen.tech/es/news/post/hyperscalers-745b-ai-capex-fuels-semiconductor-supply-chain-demand>;

<https://www.kucoin.com/news/flash/top-4-data-center-operators-commit-2-4-trillion-in-ai-infrastructure-spending>)。

工程与商业约束

- ▶ 电力并网排队与电网改造周期成为选址首要因素；
- ▶ 高功率密度机柜 → 液冷与新型散热方案；
- ▶ 水、土地与社区关系进入项目评估；
- ▶ 绿电与碳排披露影响融资与合规。

对数据分析的启示

- ▶ 大模型使用有真实的环境与财务成本；
- ▶ ”用小模型解决问题”是工程美德，也是成本纪律；
- ▶ 评估方案时把**能耗与碳排**纳入指标（ESG报告需求）。

来源：数据中心设计、电力与冷却趋势据 2026 年行业报道整理。

数据、版权与合成数据 Data, Copyright & Synthetic Data

训练数据

- ▶ 来源：网页、图书、代码、对话与合成数据；
- ▶ 版权与许可争议仍在演进；
- ▶ 数据采购与授权成为企业成本项。

合成数据

- ▶ 用途：扩充稀缺标注、隐私保护、难例构造；
- ▶ 风险：模型自我强化偏差、分布失真；
- ▶ 建议：合成数据必须与真实数据交叉验证。

对你的项目而言

明确数据来源与授权 → 记录数据处理流程 → 在报告中声明数据边界与局限。

评测危机：排行榜不能代表真实能力

- ▶ **基准饱和**：主流榜单被“刷满”，区分度下降；
- ▶ **数据污染**：测试集内容可能出现在训练数据中，虚高成绩；
- ▶ **结构性虚构**：有研究指出当前评测难以识别模型在结构层面的编造行为（2026 研究）；
- ▶ **评测认识论问题**：指标之外的能力（可靠性、稳健性）难以测量（2026 研究）。

实践对策

- ▶ 自建**领域评测集**（真实业务样本 + 边界案例）；
- ▶ 报告分布而非单一分数（含失败案例）；
- ▶ 引入人工评审与执行验证（代码跑通、数值核对）；
- ▶ 记录模型版本与提示词版本，保证可复现。

来源：评测可靠性讨论据 2026 年公开研究整理。

幻觉与缓解 Hallucination & Mitigation

为什么会幻觉

- ▶ 语言模型优化的是“下一个 token 的概率”，而非“事实为真”；
- ▶ 训练数据本身含错误与过时信息；
- ▶ 缺少外部验证时，模型倾向生成“看起来合理”的内容。

工程缓解手段

- ▶ 检索增强 (RAG) + 强制引用来源；
- ▶ 结构化输出 + 规则/模式校验；
- ▶ 多模型交叉验证、“评审者”代理；
- ▶ 置信度阈值 + 人工复核；
- ▶ 明确拒答策略 (宁缺勿错)。

原则：任何进入决策的数字与结论，都必须能被追溯到可验证来源。

监管 (一): EU AI Act 时间线



对企业的要求集中在：风险分级、透明度（告知用户与内容标识）、技术文档、数据治理、人类监督与事后监测。

Risk-based obligations: the higher the risk, the heavier the documentation, testing and human-oversight duties.

来源：EU AI Act (Regulation (EU) 2024/1689) 时间线与义务框架据官方与法律实务解读整理：

<https://intelligence.dlapiper.com/artificial-intelligence/?t=01-law&c=EU>。

监管（二）：中国 AIGC 标识与合规清单

- ▶ 生成式 AI 服务与内容标识要求持续完善：标识办法于 2025 年 3 月发布、2025-09-01 起施行（显式标识 + 隐式/元数据标识）（法律解读）；
- ▶ 与欧盟的差异主要在标识范围、责任主体与元数据要求上（对比分析）；
- ▶ 企业出海需同时满足多地规则。

项目合规清单

- ▶ 数据来源合法、授权可查；
- ▶ 个人信息最小化与脱敏；
- ▶ 生成内容按规定标识；
- ▶ 模型与提示词版本留档；
- ▶ 人工复核与投诉渠道；
- ▶ 跨境数据流动合规评估。

来源：标识要求与中欧差异据 2025 年法规解读与对比分析整理；具体适用以最新官方文件为准。

企业采纳与 ROI Enterprise Adoption

- ▶ 代理式 AI 的企业采纳在 2025–2026 年显著加速，并开始出现 **可衡量的 ROI**（效率、成本、周期时间）（报道）；
- ▶ 领先企业的做法：从“试点场景”转向“流程重构”，配套治理与评测；
- ▶ 失败模式：无明确指标、无数据基础、无权限治理、只做演示不接入系统。

四类常见收益点

- ▶ 文档与知识工作：抽取、摘要、检索；
- ▶ 软件开发：代码生成、测试、审查；
- ▶ 客户交互：客服、营销内容、线索筛选；
- ▶ 决策支持：异常检测、风险提示、情景分析。

来源：企业采纳与 ROI 证据据 2025–2026 年行业调查与报道整理。

劳动力市场：收益真实但不均


- ▶ 企业高管调查 (2026-03) 显示多数企业计划继续扩大 AI 使用，重点是任务级替代与增强，而非整岗裁撤 (Atlanta Fed)；
- ▶ 研究证据：AI 带来的收益规模大且持续上升，但分配不均 (<https://cepr.org/index.php/voxeu/columns/ais-gains-are-large-and-rising-unevenly-shared>, CEPR)；
- ▶ 受影响最明显的是：文书处理、初级编码、常规客服与内容生产。

来源：企业调查与收益分配研究据 2026 年公开资料整理。

对能力建设的启示

- ▶ 稀缺的是“能定义问题、能验证结果、能搭系统”的人；
- ▶ 数据工程、评测、合规、领域知识是护城河；
- ▶ 会写提示词不是核心竞争力，会设计验证流程才是。

Part 3 小结：从模型竞赛到价值闭环



2023–2024：能力惊喜；2025：推理与代理；
2026：同质化 + 成本下行 + 治理要求。竞争
从“谁有模型”转向“谁能稳定交付价值”。

Model capability is increasingly a commodity;
engineering, evaluation and governance are
where the value is captured.

来源：本节事实来源见 35–51 页各脚注。

基础与分析

- ▶ 电子表格 (Excel / Sheets) + HTML 报表;
- ▶ Python 生态: pandas、NumPy、Polars、DuckDB;
- ▶ SQL (云数仓 / 本地分析);
- ▶ Notebook (Jupyter) 与 VS Code。

工程与 AI

- ▶ 版本控制: Git (数据与代码同源管理);
- ▶ 编排与转换: Airflow、dbt、Spark、Flink;
- ▶ 机器学习: scikit-learn、XGBoost、PyTorch;
- ▶ LLM 工具链: API、编排框架、向量库、评测与护栏。

选择顺序建议: 先用最简单能解决问题的工具 (SQL/表格), 当**规模**、**复现性或协作**成为瓶颈时再引入工程化组件。

语言与工具对比 Languages & Tools

工具	优势	局限	典型用途
Python	生态最全（数据分析 + ML + LLM），社区庞大	原生性能一般（靠向量化/编译库补齐）	数据清洗、建模、自动化、LLM 应用
R	统计与可视化极强，学术生态成熟	工程化与生产部署较弱	统计分析、计量、图表报告
SQL	声明式、执行优化好、贴近数据	复杂算法与迭代建模不便	数据抽取、聚合、特征构建
Julia	数值性能接近 C，语法现代	生态与人才相对少	高性能数值计算、仿真
MATLAB	工具箱完整、教学友好	商业许可成本、生态封闭	信号处理、控制系统、教学

现实答案通常是组合：SQL 做数据 + Python 做建模 + Git 做协作 + LLM 做加速。

来源：对比为教学用定位性总结，非性能基准测试结果。

可视化与 BI Visualization & Business Intelligence

- ▶ **BI 平台**: Tableau、Power BI ——自助分析、看板协作、权限管理;
- ▶ **代码可视化**: matplotlib / seaborn / plotly / ggplot2;
- ▶ **交互与部署**: Streamlit / Shiny / Dash 快速做内部工具;
- ▶ **AI 辅助**: 自然语言问数 (text-to-SQL / text-to-chart) 与自动洞察。

作图原则 (比工具更重要)

- ▶ 先定问题, 再选图型 (比较 / 分布 / 关系 / 构成 / 时间);
- ▶ 少用双纵轴与 3D, 坐标轴从 0 起 (比较量级时);
- ▶ 标注样本量与不确定性 (置信区间);
- ▶ 一图一结论: 标题写成结论句。

来源: 图表实践原则据可视化与数据新闻通用规范整理。

- ▶ **批处理**: Spark / 云数仓 (列式存储 + 向量化执行);
- ▶ **流处理**: Kafka + Flink (实时特征、实时风控);
- ▶ **转换与编排**: dbt (SQL 建模 + 测试)、Airflow (依赖调度);
- ▶ **存储**: 对象存储 + 开放表格式 (Iceberg/Delta/Hudi)。

云上成本控制

- ▶ 分区与文件大小 (小文件是大敌);
- ▶ 冷热分层、列裁剪、结果缓存;
- ▶ 预留实例 vs 按需 vs Spot;
- ▶ 把成本作为工程指标 (cost per query / per model run)。

数据工程决定分析能否**规模化与可复现**; 模型往往是项目中最容易替换的部分。

经典机器学习

- ▶ **scikit-learn**: 统一 API、管道 (Pipeline)、交叉验证;
- ▶ **XGBoost / LightGBM / CatBoost**: 表格数据的强基线;
- ▶ **特征工程与模型选择工具** (ColumnTransformer、GridSearchCV)。

深度学习与基础模型

- ▶ **PyTorch**: 研究与企业主流;
- ▶ **Hugging Face**: 模型/数据集/评测的统一入口;
- ▶ **微调工具**: LoRA/QLoRA 等参数高效微调;
- ▶ **服务化**: 批推理、流式推理、GPU 共享与排队。

先跑通表格基线 (如 LightGBM), 再评估是否需要深度模型或 LLM。

LLM 应用栈 The LLM Application Stack

应用层：数据分析助手·客服·文档处理·编码助手

编排层：工作流 / 代理循环·工具调用·状态与记忆·重试与超时

能力层：模型 API（闭源） / 自建或开放权重模型 / 微调适配 / 提示缓存

数据层：向量库·RAG 检索·企业数据库·特征与知识库

保障层：评测（evals）·护栏（guardrails）·可观测性·成本与权限控制

与经典 ML 栈的差别：多出提示词与上下文管理、工具与代理编排、在线评测与护栏三个环节。

Everything that makes an LLM product reliable lives in the bottom two layers.

- ▶ **版本管理**: 代码、配置、提示词、数据切分方案统一入 Git;
- ▶ **环境**: 锁定依赖版本 (requirements/lock 文件)、容器化;
- ▶ **随机性**: 固定随机种子, 记录硬件与库版本;
- ▶ **实验跟踪**: 参数、指标、产物一体记录 (MLflow/W&B 类工具)。

LLM 特有的记录项

- ▶ 模型名 + 版本 + 调用日期;
- ▶ 完整提示词与系统提示;
- ▶ 温度、最大 token、工具列表;
- ▶ 成本与延迟统计;
- ▶ 评测集版本与通过率。

可复现性 = 别人 (包括三个月后的你) 能重跑出同样结论。

成本与算力选择 Cost & Compute Choices

方式	适用场景	主要风险 / 成本
云 API (闭源模型)	快速验证、峰值弹性、无运维	单价高、数据外发合规、供应商依赖
云 GPU 自建推理	稳定高流量、需要微调或私有化	运维复杂、利用率不足时成本高
本地 / 端侧模型	隐私敏感、低延迟、离线	能力受限、需量化与工程调优
开放权重自部署	数据可控、成本可预测	许可证与合规、人力投入

决策公式 (口语版): **先算清每次调用的边际成本与合规边界, 再选技术路线。** 批处理、缓存、蒸馏与小模型替代是最常见的三条降本路径。

作业 1：工具安装与数据探索

第一步：环境（本讲课后完成）

- ▶ Python 环境（Anaconda 或 uv/venv）+ Jupyter / VS Code;
- ▶ 安装并运行：pandas、NumPy、scikit-learn、matplotlib；可选 Polars / DuckDB；
- ▶ 注册并试用任一 LLM 助手（记录模型名与版本）。

第二步：数据探索任务（个人完成）

- ▶ 自选一个公开数据集（建议 1–10 万行）；
- ▶ 完成：数据体检（缺失/异常/分布）、至少 3 张图、1 个基线模型；
- ▶ 报告需包含：**AI 使用声明**（工具、提示词、你做的核验与修改）。


来源：评分细则与提交格式见后续页（80 页）与课程平台通知。

Part 4 小结 Summary

- ▶ 工具选择服从**问题复杂度**：SQL/表格 → Python → 数据工程 → LLM 应用栈；
- ▶ 表格数据的强基线通常是梯度提升树，不必一上来就用大模型；
- ▶ LLM 应用栈的可靠性主要来自**评测、护栏、可观测性**这三层；
- ▶ 成本与合规是选型的硬约束，边际成本决定规模化可行性；
- ▶ 工程习惯（版本、日志、实验跟踪）决定项目能否被复现与信任。

工具会变，方法论与验证能力不会过时。

数据分析流程总览 End-to-end Workflow



越靠前的环节越决定上限：问题定义错了，后面做得多好都没用。

In practice you will loop: modeling reveals data problems, monitoring reveals design problems.

探索性数据分析 EDA

- ▶ **单变量**：分布形态、中心与离散度、长尾、缺失模式；
- ▶ **双变量**：散点、分组箱线、相关系数（含秩相关）；
- ▶ **多变量**：相关矩阵、PCA、聚类概览；
- ▶ **时间维度**：趋势、季节性、结构突变。

四类基本图与输出

- ▶ 直方图 / 密度图——看分布；
- ▶ 箱线图——看组间差异与异常；
- ▶ 散点图——看关系与非线性；
- ▶ 热力图——看相关与缺失结构。

EDA 的输出不是“图”，而是**可检验的假设清单** + 数据质量结论 + 建模建议。

特征选择与特征工程 Feature Selection & Engineering

特征选择

- ▶ 过滤法：方差、卡方、互信息、相关系数；
- ▶ 包裹法：递归特征消除 (RFE)；
- ▶ 嵌入法：L1/L2 正则、树模型重要性；
- ▶ 注意：选择必须在**训练集内部**做，否则泄漏。

特征工程

- ▶ 数值：对数/幂变换、分箱、标准化、缺失指示；
- ▶ 类别：独热、目标编码（需交叉拟合）、嵌入；
- ▶ 时间：滞后、滑动窗口、周期编码；
- ▶ 文本：TF-IDF、 n -gram、句向量；
- ▶ 交互项与领域特征（往往收益最大）。

经验：特征质量对表格数据的影响通常大于模型选择。


- ▶ **切分与规范化**: 分词 (中英文不同)、小写、去停用词 (慎用);
- ▶ **词频与对比**: TF、TF-IDF、类别间词频差异;
- ▶ **主题**: LDA / NMF / 神经主题模型;
- ▶ **表示**: 句向量 / 文档向量用于聚类、检索与分类;
- ▶ **LLM 辅助**: 零样本标注、摘要、实体抽取 (需抽样核验)。

风险提示

- ▶ 停用词可能携带关键情感 ("not"、"no");
- ▶ 领域词表与缩写必须人工确认;
- ▶ 用 LLM 做标注时, 先由人工标注 100-200 条作为对照, 报告一致率 (agreement)。

来源: 文本处理流程据经典文本挖掘实践; LLM 标注核验建议据近年评测经验整理。

建模阶梯 Modeling Ladder



顺序原则：**先简单后复杂**。每上一级都要证明“比上一级更好且值得其成本”。

Lecture 6 将详细推导线性回归与逻辑回归（线性分类器）的数学基础。

选择依据

样本量（小样本优先线性/正则化）、数据类型（表格 → 树；文本图像 → 神经/基础模型）、可解释性要求、延迟与成本预算、维护能力。

交叉验证与超参数调优 Cross-validation & Tuning

- ▶ k -折交叉验证 ($k = 5$ 或 10); 类别不平衡用分层折;
- ▶ 时间序列: 前向滚动切分 (walk-forward), 严禁随机打乱;
- ▶ 分组数据 (同一用户/患者): GroupKFold 防泄漏;
- ▶ 嵌套交叉验证: 调参在内层, 评估在外层 (避免乐观偏差)。

调参策略

- ▶ 随机搜索优于网格搜索 (维数高时);
- ▶ 贝叶斯优化适合昂贵模型;
- ▶ 早停 + 学习率调度 (深度模型);
- ▶ 记录每次试验 (参数-指标-成本), 避免“人肉过拟合”。

报告不确定性: 给出折间标准差或置信区间, 而不是单个最佳分数。

模型解释 Model Interpretation

- ▶ **全局**：系数符号与量级、特征重要性、PDP/ICE；
- ▶ **局部**：SHAP 值解释单条预测；
- ▶ **代理模型**：用简单模型近似复杂模型行为；
- ▶ **反事实**：改变哪些特征会改变结论（对有争议决策很重要）。

LLM 时代的可解释性新问题

- ▶ 无法用系数解释生成结果；
- ▶ 只能给出**证据链**：检索来源、推理步骤、工具调用记录；
- ▶ 因此更需要“可追溯 + 可复现 + 可审计”的系统设计；
- ▶ 高风险场景（信贷、医疗、司法）优先选择可解释模型。

来源：解释方法（PDP/ICE、SHAP、代理模型）据可解释机器学习通用实践整理。

部署形态

- ▶ 批处理打分 (每日/每小时);
- ▶ 在线 API (低延迟、需限流与降级);
- ▶ 边缘/端侧 (隐私与延迟优先);
- ▶ 人机协同 (模型建议 + 人工决策)。

监控指标

- ▶ 输入分布漂移 (PSI/KL 散度) 与特征缺失率;
- ▶ 预测分布与业务指标 (转化、坏账、成本);
- ▶ 性能衰减与错误案例分析队列;
- ▶ 成本、延迟与超时率;
- ▶ 模型/提示词版本与回滚记录。

上线前必答三问

(1) 失败时谁会受影响? (2) 如何在 1 小时内回滚? (3) 谁负责定期复查?

方法串讲：从房价预测到邮件分类

阶段	回归任务（房价）	分类任务（邮件）
问题定义	预测连续价格，误差成本线性	判断是否垃圾，漏判与误判成本不同
数据与体检	面积/房龄/地段，缺失与异常	文本 + 发件人特征，类别不平衡
特征	数值分箱、地理编码、交互项	TF-IDF、嵌入、行为特征
基线	均值预测	多数类预测
模型	线性回归 → 梯度提升	逻辑回归 → 梯度提升
评估	RMSE / MAE / R^2 （按时间切分）	PR-AUC / 精确率-召回率（按阈值）
部署	批量估值 + 在线查询	实时过滤 + 人工复核队列
监控	价格漂移、误差分布	垃圾邮件策略变化、误判率

同一套流程、不同损失与指标——这正是“机器学习 1-2-3”的具体化。

评测与护栏 Evaluation & Guardrails (LLMOps)

离线评测

- ▶ 自建评测集：真实样本 + 边界案例 + 对抗样本；
- ▶ 指标：准确率、事实性、格式合规率、拒答率、成本、延迟；
- ▶ 回归测试：提示词或模型升级后必须重跑。

在线护栏

- ▶ 输入过滤（注入攻击、敏感信息）；
- ▶ 输出校验（JSON schema、数值范围、引用存在性）；
- ▶ 权限与工具白名单、调用限额；
- ▶ 日志与审计、人工升级通道。

没有评测与护栏的 LLM 应用，本质上是“未测试的软件”。

常见错误清单 Checklist of Failure Modes

- ▶ 用测试集反复选模型（隐性过拟合）；
- ▶ 预处理在划分前完成（泄漏）；
- ▶ 时间序列随机切分（未来信息泄漏）；
- ▶ 只报告均值，不报告分布与失败案例；
- ▶ 忽略基线（“复杂模型比均值好”并不稀奇）。
- ▶ 无成本预算地调用大模型（账单失控）；
- ▶ 把 LLM 输出直接写入数据库或对外发布；
- ▶ 依赖单一供应商与单一模型版本；
- ▶ 没有监控与回滚机制就上线；
- ▶ 数据与模型缺少文档（无法交接与复现）。

三条实践建议

(1) 先建基线与评测集；(2) 每次改动都留痕并可回滚；(3) 高风险决策保留人工环节。

Part 5 小结 Summary

- ▶ 流程的**顺序与边界**比单个算法更重要（划分在前、选择在后）；
- ▶ EDA 的产物是假设与质量结论，而非漂亮图表；
- ▶ 特征工程与数据质量往往决定表格数据项目的成败；
- ▶ 评估要报告分布、成本与失败案例；LLM 应用必须有评测与护栏；
- ▶ 部署即开始衰减：监控、漂移检测、回滚是常规工作。

可信的分析 = 明确目标 + 可复现流程 + 诚实的评估。

案例版图（预告）：商业大数据分析 B1–B15

主题组	案例（后续讲次逐一展开）
市场情报	B1 金融知识图谱·B2 ESG 表现·B3 事件关联与影响预测·B4 另类数据 Alpha
进阶 KYC	B5 客户画像（性格/需求/价值）·B6 客户行为预测
投资策略	B7 AI Trader（外汇）·B8 AI Trader（股票）·B9 自动动态资产配置
客户交互	B10 客户沟通策略·B11 保险产品销售与营销策略
营销自动化	B12 自动故事生成·B13 市场竞争分析·B14 销售线索挖掘
人力资本	B15 人力资本增长建议

本讲只做”版图与入口”：每个案例都会用到今天讲的三件事——数据准备、模型选择、评估与合规。

课程地图 Course Map



本讲是“地图”：后续每一讲都会回到今天的框架——问题定义、数据、模型、评估、部署。

Prerequisites for the final project: data exploration (L1–L3), a predictive model (L6–L8), and an honest evaluation (all lectures).

讨论题 Discussion

1. **AI 会取代数据分析师吗？** 请从“任务”而非“岗位”的角度分析：哪些任务最容易被替代？哪些反而更值钱？
2. **数据、算力、监管**三重约束下，一家中型企业应优先做哪三件事？请给出优先级与理由。
3. 如果模型在测试集上表现很好，但上线后效果迅速下降，最可能的三个原因是什么？你会如何排查？
4. 用 LLM 辅助分析时，你会设计怎样的**验证环节**来避免“自信的错误”？
5. 选一个你熟悉的行业，指出一个“数据已经存在但尚未产生价值”的场景，并说明阻碍在哪里。

来源：讨论不设标准答案，重点考察论证结构与证据意识。

要点回顾 Ten Takeaways

1. 大数据的价值在**决策链路**而非体量;
2. 数据质量与偏差是第一性问题;
3. 机器学习 1-2-3: 数据 → 模型 → 优化;
4. 损失与指标必须匹配业务成本;
5. 划分、验证、防泄漏是纪律问题;
6. 基础模型 = 预训练 + 后训练对齐;
7. 推理模型用**测试时算力**换准确率;
8. 代理 = 模型 + 工具 + 记忆 + 循环控制;
9. 评测与护栏决定 LLM 应用能否上线;
10. 合规、成本与可复现性是长期竞争力。

从“会用工具”到“能对结果负责”。

课后阅读 Reading List

行业与趋势

- ▶ Stanford HAI, *AI Index Report 2026*;
- ▶ McKinsey, *The State of AI* (年度调查);
- ▶ KPMG, *AI Pulse* (企业代理化与 ROI);
- ▶ 2026 年开源前沿与许可模式报道 (见 40 页脚注)。

技术与合规

- ▶ OpenAI GPT-5 发布说明 (能力与限制);
- ▶ Gemini 3 / Deep Think 模型资料;
- ▶ Claude Opus 4.5 行业分析 (代理与编码);
- ▶ EU AI Act 义务概览; 中国 AIGC 标识办法解读与中欧对比。

来源: 完整链接见课程平台“L1 阅读与数据”文件夹; 请优先阅读官方文件与原始研究。

作业 1 提交要求与 AI 使用声明

提交内容

- ▶ 代码与数据说明 (可复现);
- ▶ 分析报告 (PDF, ≤ 8 页): 问题、数据、方法、结果、局限;
- ▶ 图表 (≥ 3 张, 注明数据来源);
- ▶ 附录: AI 使用声明。

AI 使用声明模板

- ▶ 工具: 名称 / 版本 / 使用日期;
- ▶ 用途: 代码 / 文本 / 分析 / 绘图 (分别说明);
- ▶ 关键提示词 (至少 3 条);
- ▶ 核验方式: 如“用 pandas 复算关键统计量”“抽取 30 条结果人工核对”;
- ▶ 未使用处声明: 哪些部分完全自主完成。

未声明使用 AI 视为学术不端; 声明规范使用不会扣分, 反而加分。

下一讲预告 Next Lecture

Lecture 2-3: 数据获取、清洗与特征工程

- ▶ 数据源与采集 (API、数据库、抓取、公开数据集);
- ▶ 缺失值、异常值与不一致性的处理策略;
- ▶ 特征构造与编码、泄漏防范实战;
- ▶ 从原始数据到可建模数据集的完整练习。

课前准备

- ▶ 完成作业 1 的环境安装;
- ▶ 选定一个公开数据集 (建议含类别型与数值型特征);
- ▶ 复习线性代数与概率的基本概念 (为 L6 做准备)。

来源: 课程进度与作业时间以课程平台公告为准。



谢谢! Thanks!

Q&A · 大数据分析 [2026 国际商务] · Lecture 1

戴谢尔 (Xieer Dai, David) · Xieer.dai@szu.edu.cn · 南 209