

课程 COURSE

Big Data Analytics

大数据分析 [2026 国际商务]

Lecture 2 — Data Sourcing 第二讲·数据获取
从数据类型到 API、抓取与一手数据采集

任课教师：戴谢尔 (Xieer Dai, David)

深圳大学 Shenzhen University 第 8-14 周 星期四 11-12 节

上课地点：四方楼南 406

学分 2 选修课 (讲座式) | 答疑：预约制 | E-mail: Xieer.dai@szu.edu.cn


学习目标 Learning Objectives

完成本讲后，你应能够：

1. 辨别数据的类型、结构（截面/时序/面板）与测量层级，并据此选择方法；
2. 依据覆盖、质量、成本、合规、可复现五维评估一个数据来源；
3. 说清内部专有、开放数据、第三方购买（3P）与替代数据、合成数据的差别与适用场景；
4. 用 API（REST/认证/分页/限流/缓存）与网页抓取规范地获取数据，并守住法律与伦理边界；
5. 设计问卷、抽样与 A/B 实验等一手数据采集方案，处理无响应偏差与标注一致性；
6. 输出一份可复现的数据源清单 + 获取脚本，并按规范声明 AI 工具的使用。

来源：课程组自编；数据源与合规要点截至 2026 年，来源见各页脚注。

本讲路线图 Roadmap (85 帧)



主线：数据从哪来 → 怎么拿到 → 是否可用 → 是否合规

代码页 9 帧：API 调用、抓取、PDF 抽取、LLM 抽取、数据体检、最小管道


与上一讲的衔接 From L1 to L2

L1 留下的问题

- ▶ 数据管道的第一步“采集”到底怎么做？
- ▶ 开放数据、第三方数据、API、抓取分别适合什么场景？
- ▶ 数据质量与合规风险从哪里来、如何前置控制？

L2 的回答

- ▶ 把“数据来源”拆成 3P + API + 替代数据 + 合成数据；
- ▶ 给出可执行的获取代码与合规红线；
- ▶ 输出数据源清单与可复现获取脚本。



本讲输出物 Deliverables

1) 数据源清单

来源、字段、时间覆盖、更新频率、成本、许可、质量评分、负责人（模板见 79 页）

2) 获取脚本

可重跑的 API/抓取代码：认证、分页、重试、缓存、落盘与日志（35–38、42–44 页）

3) 合规检查表

授权、个人信息、频率、署名、二次分发、数据出境（40、76–77 页）

作业 1（第 3 周布置 / 第 4 周提交）

自选一个数据集 → 完成数据源清单 + 获取脚本 + 数据体检报告 → 附AI 使用声明（详见 80 页）

来源：清单与脚本模板随讲义提供；示例数据源均为公开或可申请访问的渠道。

全讲导览 Map of the Lecture

部分	帧	关键问题
数据类型与测量	7-20	我拿到的是什么数据？结构如何？测量可靠吗？
已有数据来源	21-40	内部/开放/第三方/平台 API 各自的门槛与代价？
非结构化与实时	41-48	PDF、网页表、文本如何变成结构化数据？何时需要实时？
一手数据采集	49-62	问卷、抽样、实验、访谈、卡片分类怎么做才有效？
质量控制与 LLM	63-68	标注一致性怎么保证？LLM 辅助采集能不能信？
管道·治理·合规	69-77	如何把来源接成可复现、可审计的数据管道？
工作流与作业	78-85	清单模板、代码速查、作业要求与评分要点。

从世界到变量 From the World to a Variable



数据不是“自然存在”的：每一步操作化都注入了假设。写论文时要说清“这个概念用什么变量代理、为什么合理、局限在哪里”。

Measurement is a design decision: the same concept can be operationalised in several ways, each with different validity and bias.

三条提醒

(1) 指标 $\neq$ 概念 (GDP 不是“发展”，点击率不是“兴趣”); (2) 口径变化会让时间序列断裂; (3) 记录操作化过程本身，就是数据可复现的一部分。

测量层级 Levels of Measurement

层级	含义	允许的运算 / 例子
名义 Nominal	仅分类, 无顺序	计数、列联表 / 行业代码、性别、股票代码
有序 Ordinal	有顺序, 间隔不等	比较大小、秩相关 / 信用评级 AAA...C、李克特量表
区间 Interval	间隔等距, 零点任意	加减、均值 / 摄氏温度、年份、部分评分
比率 Ratio	有绝对零点	乘除、比率 / 收入、市值、成交量、人口

把有序数据当区间数据求均值, 是最常见的隐性错误 (如把评级 1-5 直接当数值做回归而不说明)。

The level of measurement determines which statistics are meaningful —and which conclusions are defensible.

数值型数据 Numerical Data

连续 vs 离散

- ▶ 连续：价格、收益率、温度（记录精度决定“看起来”的离散度）；
- ▶ 离散：订单数、点击数、事故数（计数型，常需 Poisson 类模型）；
- ▶ 混合：金额是连续概念、按分记账即为离散。

工程要点

- ▶ **量纲与单位**：元/万元/亿元；美元/人民币；必须写清算术口径；
- ▶ **精度与舍入**：浮点误差、四舍五入策略、货币用 Decimal；
- ▶ **零点**：比率型可直接算增长率；区间型不宜算倍数。

来源：测量理论的标准表述；工程要点据数据分析实践整理。

类别型数据 Categorical Data

- ▶ **名义** (行业、地区、品牌) 与**有序** (评级、满意度);
- ▶ **高基数**问题: 股票代码、邮编、SKU——独热编码会爆炸;
- ▶ 编码方式: 独热、序数、目标编码 (需交叉拟合避免泄漏)、嵌入向量;
- ▶ 未知/新增类别: 生产环境中必须设计“其他/未知”分支。

常见陷阱

- ▶ 把类别编号当数值: 行业代码 13 vs 26 没有大小关系;
- ▶ 时间上不稳定的类别口径 (行政区划调整、行业分类改版);
- ▶ 缺失本身是信息: 把“未填写”与“否”混为一谈。

中文语料还有额外问题: 简称、别名、繁体、错别字——实体对齐往往是数据获取环节的工作。

复合与高维数据类型 Complex & High-dimensional Types

类型	典型来源	处理入口（后续讲次）
文本	新闻、公告、财报、社交媒体、客服记录	分词/嵌入/RAG (L10–L11)
图像	卫星、门店监控、产品图、票据	卷积/预训练骨干 (L9)
音频	电话录音、客服质检、语音助手	语音识别 + 文本分析 (L9–L10)
视频	短视频、直播、监控	抽帧/多模态模型 (L9)
图 / 网络	转账、供应链、社交、引用	图算法与 GNN (L9)
时空轨迹	GPS、AIS、刷卡、外卖	面板与空间计量 (L14)

数据类型决定可用方法：先判断” 能不能变成数值/向量”，再决定建模路线，而不是反过来。


数据结构 A：截面数据与时序数据

截面数据 Cross-section

- ▶ 同一个时点上多个个体：2025 年各省 GDP、各公司市值；
- ▶ 适合横截面比较、分布与不公平度分析；局限是无法区分“个体差异”与“时间效应”。

时序数据 Time-series

- ▶ 同一个个体的多个时点：沪深 300 日收盘、月度 CPI；
- ▶ 适合趋势、季节、波动率与预测；局限是需处理自相关、非平稳与结构突变。



数据结构 B：面板数据 Panel Data

- ▶ 定义：个体 $i \times$ 时间 t 的二维表（平衡/非平衡面板）；
- ▶ 优势：同时利用组间差异与组内变化，可控制不可观测的个体异质性；
- ▶ 典型来源：上市公司年报（企业面板）、海关与工业企业匹配（L14）、家庭追踪调查（CFPS）；
- ▶ 关键处理：实体编码统一、进入/退出样本、口径变更、缺失模式。

	t_1	t_2	t_3	t_4	t_5
i_1	•	•	•	•	•
i_2	•	•	•	•	•
i_3	•	•	•	•	•
i_4	•	•	•		

空白 = 个体退出或数据缺失

来源：面板数据结构与优势的标准表述；中国家庭追踪调查（CFPS）等为常用微观面板来源。

数据结构 C：截面关联、空间与社会网络

截面关联

同一时点的个体相互影响：同行业价格战、同地区政策外溢。忽略关联会低估标准误。

空间数据


地理邻接或距离权重矩阵 W ；空间自相关 (Moran's I)；空间面板模型。

独立面板

个体之间近似独立，可按标准面板方法处理。

网络数据

节点-边结构：交易网络、供应链、社交、引用网络；度/中心性/社群。



一个“高中心性”节点

来源：空间计量与网络分析的标准概念；社会网络数据来源见 33、46 页。

结构化、半结构化与非结构化

类别	特征与例子	获取与处理方式
结构化	行列固定：行情数据、财报字段、交易流水、政府统计	数据库/API 直取，schema 明确
半结构化	自描述但模式可变：JSON/XML、日志、HTML、邮件头	解析器 + 字段抽取 + 规范化
非结构化	无固定形式：新闻、公告 PDF、语音、图像、视频	OCR/ASR/嵌入/LLM 抽取（需核验）

现实里约 80% 的新增数据是非结构化或半结构化的；把它们”结构化”是数据获取环节最大的工作量。

来源：结构化/非结构化划分沿用原课件框架（含市场数据与社交媒体示例）。

Market data is structured; behaviour, language and images are not —the sourcing pipeline is where the mess is cleaned up.

数据汇总与组织 Organising Data for Analysis

宽表 Wide

一行 = 一个个体，每个指标一列：适合建模与建模前的特征矩阵。

聚合层级

明细 → 日汇总 → 月汇总 → 个体汇总；每一次聚合都在丢弃信息，需记录口径。

长表 Long (tidy)

一行 = 一个“个体-变量-取值”：适合多期、多指标的统一存储与绘图。

可加性

金额/数量可加；比率、价格、指数不可直接相加，需加权（如加权平均收益率）。



聚合与粒度陷阱 Aggregation Traps

- ▶ **生态谬误**：群体相关 $\neq$ 个体相关（省级教育与收入的关系不等于个人层面）；
- ▶ **辛普森悖论**：整体趋势与分组趋势方向相反（L12 因果推断会正式处理）；
- ▶ **均值陷阱**：长尾数据用均值描述会误导，需中位数/分位数；
- ▶ **分母漂移**：比率型指标的分子分母口径变化（如“人均”用哪个人口口径）。

实操建议

- ▶ 保留原始粒度，聚合只作为派生视图；
- ▶ 每次聚合都写明：分组键、时间窗、权重、缺失处理；
- ▶ 用分布图检查聚合前后是否“变了故事”。

来源：生态谬误与辛普森悖论为统计学经典概念；建议结合 L4 可视化与 L12 因果推断一起理解。

抽样与总体 Sampling & Population

- ▶ **目标总体**（想推断谁）vs **可及总体**（实际能碰到谁）；
- ▶ **抽样框**：名单从哪来？漏掉了谁？（无手机号老人、未注册企业、未上网人群）
- ▶ **代表性**：样本特征分布 vs 总体分布（对比年龄/地区/规模结构）；
- ▶ **样本量**：由效应大小、方差、显著性水平与功效共同决定，不是“越大越好”。

抽样 vs 普查

- ▶ **普查**：覆盖全，成本高、周期长、问题项少；
- ▶ **抽样**：快、便宜、可问更多细节，但需处理抽样与无响应误差。

来源：抽样理论标准表述；中国人口普查（国家统计局）为普查类数据典型来源，见 56 页。

测量误差地图 The Error Chain



每一环都可能引入系统性偏差；报告结果时应说明最主要的误差来源与量级，而不是只给一个点估计。

Total survey error framework: coverage, sampling, nonresponse, measurement and processing error all matter —and they interact.

与后续讲次的连接


误差 → 区间估计与假设检验 (L4)；无响应与选择性 → 因果识别的外部效度 (L12)。

小结：拿到数据先问的 10 个问题

1. 谁采集的？出于什么目的？（利益相关方）
2. 覆盖谁、漏掉谁？（覆盖误差）
3. 时间覆盖与频率如何？口径是否变过？
4. 单位、币种、名义/实际、税率口径？
5. 缺失怎么产生？缺失率与模式？
6. 变量如何测量？信度与效度证据？
7. 能否合法使用、二次分发、跨境传输？
8. 更新频率与延迟？是否可自动化获取？
9. 是否可复现（版本、快照、脚本）？
10. 使用它会伤害谁？（伦理与合规）

把这张清单贴在项目开头：它比任何模型都更能决定研究质量。

数据来源全景 The Data Sourcing Landscape



原课件的 3P: Proprietary (专有)、Public (开放)、Purchased (购买); 2026 版再补三类: 平台 API、替代数据、合成数据。

Whatever the channel, three questions decide: coverage, quality, and the right to use the data.

来源评估框架：五维打分

维度	要问的问题	评分 (1-5)
覆盖 Coverage	覆盖哪些个体/时间/地区？漏掉谁？样本框缺口？	
质量 Quality	口径稳定？缺失率？校验机制？历史修订？	
成本 Cost	采购价 + 清洗人力 + 存储计算 + 维护成本	
合规 Compliance	授权范围、个人信息、数据出境、二次分发	
可复现 Reproducibility	能否脚本化获取？版本/快照？接口稳定性？	

用法：先给候选来源打分，再按权重加权（合规与覆盖通常设为一票否决项），最后写进数据来源清单。

Cheap but non-compliant is not cheap: it is a liability. Score before you code.

内部数据 In-house Data (Proprietary)

- ▶ **业务系统**：ERP (订单、库存、成本)、CRM (客户、跟进)、财务系统；
- ▶ **日志与埋点**：页面浏览、点击流、App 事件、接口调用日志；
- ▶ **交易与交互**：支付流水、发票、客服工单、邮件与通话记录；
- ▶ **运营数据**：排班、物流、仓储、设备传感器 (IoT)。

优势


细节最全、时效最好、可回溯、可与业务结果直接关联（做因果实验的天然场所）。

陷阱

口径割裂（同名不同义）、留存期短、权限混乱、字段含义靠口口相传、导出即“死数据”。

来源：内部数据分类据企业数据管理实践整理；沿用原课件“数据科学需要数据”的 3P 框架。

把内部数据变成“可用数据”



四个必做动作

- ▶ 建**数据字典**：字段、单位、取值范围、责任人；
- ▶ 统一**实体主键**：客户/商品/供应商/门店编码映射表；
- ▶ 明确**口径版本**：指标定义变更要记录生效日期；
- ▶ 建立**只读分析视图**：与分析代码解耦，避免误写生产库。

与合规相关

- ▶ 个人信息字段单独标注与脱敏；
- ▶ 导出行为留痕（谁、何时、导了什么）；
- ▶ 保留期到期自动清理或归档。

开放数据（国际） International Open Data

来源	内容	访问方式
World Bank	全球发展指标（GDP、贸易、教育、健康，200+ 国家、数十年）	开放 API（v2，JSON/XML）+ 批量 CSV
IMF	国际金融统计（IFS）、世界经济展望（WEO）、汇率与收支	数据门户 + API/SDMX
OECD	成员国社会经济统计、结构性指标	数据门户 + SDMX API
UN Comtrade	双边贸易流量（按 HS 编码、国别、年份）	网页 + API（免费额度有限）
Eurostat	欧盟统计（劳动力、价格、贸易、区域）	开放 API（JSON-stat）
FRED	美国及全球宏观时间序列（80 万 + 序列）	需 API Key 的 REST 接口

来源：各机构开放数据门户（2026）：data.worldbank.org、data.imf.org、data.oecd.org、comtrade.un.org、ec.europa.eu/eurostat、fred.stlouisfed.org。

开放数据（国际）：科研数据与网络数据

科研与研究数据

- ▶ Zenodo / Figshare: 论文配套数据与代码 (可引用 DOI);
- ▶ ICPSR / UK Data Service: 社会科学微观调查数据;
- ▶ 世界银行微观数据目录、AEA 数据仓库 (论文复现数据);
- ▶ 数据引用规范: 作者、年份、数据集名、版本、DOI。

网络与语料数据

- ▶ Common Crawl: 月度网页抓取快照 (PB 级, 需自建解析管道);
- ▶ Wikipedia / Wikidata: 结构化知识与多语言文本;
- ▶ arXiv / OpenAlex / Crossref: 文献元数据与引用网络;
- ▶ 使用前必读: robots、许可 (CC 版本)、再分发限制。

科研数据的优点是“可引用、可复现”; 网络语料的优点是“规模”, 代价是清洗成本与合规风险。

开放数据（中国）：政府统计与监管披露

来源	内容	访问方式
国家统计局	月度/季度/年度宏观数据（GDP、CPI、PPI、投资、社零、人口普查）	官网查询 + 数据接口（data.stats.gov.cn，非官方文档）
地方政府开放平台	各市/省数据开放平台（交通、环保、财政、公共服务）	门户网站 + 部分提供 API/CSV
中国人民银行	社会融资规模、信贷收支、利率与汇率、支付体系报告	官网统计表（Excel/PDF）
海关总署	进出口商品与国别统计（月度、HS 编码）	海关统计在线查询平台（网页查询导出）
交易所	行情、公告、融资融券、大宗交易、指数成分	上交所/深交所/北交所官网 + 官方数据接口（多为授权）

来源：各机构官网（2026）：stats.gov.cn、pbc.gov.cn、customs.gov.cn、sse.com.cn、szse.cn；部分接口未公开文档，需自行评估稳定性与合规性。

开放数据（中国）：市场数据与研究数据库

公开可得的市场信息

- ▶ **巨潮资讯 (cninfo)**: 上市公司公告、年报、招股书 (PDF 全文);
- ▶ **上交所/深交所**: 交易公开信息、融资融券、龙虎榜;
- ▶ **国家企业信用信息公示系统**: 工商登记、行政处罚、经营异常;
- ▶ **中国裁判文书网 / 执行信息公开网**: 司法与风险信息 (注意使用规范)。

研究型数据库 (多需机构订阅)

- ▶ **CSMAR**: 中国经济金融研究数据库 (面向学术, 字段规范、有引用要求);
- ▶ **CNRDS**: 中国研究数据服务平台 (文本、ESG、专利等特色库);
- ▶ **Wind / 同花顺 iFinD / CEIC**: 机构级行情与宏观库;
- ▶ **中经网统计数据库**: 宏观与行业统计。

高校一般已订阅部分库: 先查校内图书馆资源, 再考虑付费或自采——很多“贵数据”其实校园网内免费。

第三方数据服务（国际） Data-as-a-Service

金融与商业

- ▶ Bloomberg Terminal / Refinitiv (LSEG): 行情、财报、新闻、ESG;
- ▶ FactSet、S&P Capital IQ: 基本面与估值数据;
- ▶ MSCI / FTSE Russell: 指数与因子数据;
- ▶ 特点: 字段标准、历史可追溯、有 SLA; 成本高、许可限制严 (多为内部使用)。

消费、市场与网络数据

- ▶ Statista、Euromonitor: 市场与行业统计;
- ▶ Similarweb、Sensor Tower: 流量与 App 数据;
- ▶ Nielsen / Kantar: 零售与消费者面板;
- ▶ 采购要点: 样本定义、覆盖率、更新延迟、是否允许二次分析。

来源: 供应商信息据各公司公开产品说明 (2026); 具体授权范围以合同为准。

第三方数据服务（中国）

数据库	主要用户	特点与适用场景
CSMAR 国泰安	高校/研究者	从学术研究需求出发，表结构清晰、有字段说明，适合论文与教学
Wind 万得	机构投资者	覆盖最广、更新最快，终端与 API 结合，适合投研与实盘分析
同花顺 iFinD	机构/研究者	行情与财务数据，价格相对低，接口较友好
CNRDS	高校/研究者	文本、ESG、专利、招聘等特色库，适合文本与创新研究
CEIC 中国经济库	机构/研究者	宏观与行业高频指标，历史序列长、口径注释完整
中经网 / 国研网	高校	宏观与行业统计、研究报告，适合教学与综述

学术使用要点：**注明数据库来源与版本**、遵守单用户许可（不得共享账号）、导出数据不得二次分发。

来源：各数据库官方说明与高校图书馆采购信息（沿用原课件 CSMAR 相关页并扩展）。

CSMAR vs. Wind：怎么选？

维度	CSMAR（国泰安）	Wind（万得）
定位	学术研究数据库	机构投研终端
核心客户	高校、研究者	券商、基金、银行、企业
数据组织	按研究主题建表，附字段说明与说明文档	覆盖资产类别极广，实时性与一致性优先
更新频率	日/月/年为主，公告类随后更新	秒级/分钟级行情，实时新闻与公告
接口与工具	数据导出 + 部分 API（Python/R/Stata 支持）	Excel 插件 + API（需授权）+ 终端查询
成本	相对低（多为校园采购）	高（终端授权，按席位计费）
典型用途	论文实证、教学案例、面板数据	投研分析、因子回测、实盘监控
注意	引用规范、版本差异	许可严格、数据不得外传

来源：沿用原课件"CSMAR vs Wind" 页并补充接口与许可要点；以各库官方说明与校内采购范围为准。

公开数据集与竞赛平台 Dataset Platforms

国际平台

- ▶ **Kaggle**: 数据集 + Notebook + 竞赛 (含真实业务数据);
- ▶ **Hugging Face Datasets**: NLP/多模态数据集, 带加载脚本与卡片;
- ▶ **UCI / 云厂商开放数据**: 经典教学基准与大型开放数据集 (卫星、基因组、交通)。

中国平台

- ▶ **天池 (阿里)**: 竞赛与行业数据集 (电商、金融、物流);
- ▶ **和鲸社区**: 中文数据集与 Notebook 分享;
- ▶ **DataFountain / 中国开放数据平台**: 政务与企业赛题数据、地方开放数据聚合。

使用平台数据前检查: 许可 (CC/自定义)、是否可商用、是否含个人信息、是否允许再分发。

来源: 沿用原课件 Kaggle 页并补充中文平台; 各平台条款见其官方页面。

平台 API 生态 Platform APIs

类别	代表接口	门槛 / 注意
社交舆情	X/Twitter API、微博开放平台、Reddit	多为付费分级、历史数据受限
地图位置	高德/百度地图开放平台、Google Maps、OpenStreetMap	免费额度 + 商用限制; OSM 为 ODbL
电商交易	Amazon SP-API、淘宝开放平台、京东宙斯	需商家授权; 价格与销量常不可得
金融行情	yfinance、Alpha Vantage、Tushare、AKShare、交易所接口	免费额度、限流、延迟与商用限制
学术文献	OpenAlex、Crossref、Semantic Scholar、arXiv	多为开放, 礼貌池需附邮箱
企业与工商	国家企业信用信息公示、天眼查/企查查 (商业)	反爬严格, 务必走官方或商业授权

选择顺序: **官方 API** → 商业授权 → 抓取 (最后手段); API 的“免费”通常意味着额度、延迟或字段的限制。

API 基础 REST Fundamentals

- ▶ **请求**: 方法 (GET/POST)、端点、参数、请求头;
- ▶ **认证**: API Key (URL/Header)、Bearer Token、OAuth 2.0 (需刷新令牌);
- ▶ **响应**: JSON/XML/CSV; HTTP 状态码 (200/401/403/404/429/5xx);
- ▶ **分页**: offset/limit、page/per_page、cursor (游标) 三种模式;
- ▶ **限流**: QPS/日额度、并发上限; 429 需退避重试;
- ▶ **缓存与幂等**: 相同请求落盘缓存; 写操作设计幂等键。



来源: REST 与 API 工程实践通用要点; 分页与限流模式据主流数据服务文档整理。

【代码】API 调用通用骨架：会话、重试、分页、缓存

```
1 import json, hashlib, pathlib, requests
2 from requests.adapters import HTTPAdapter
3 from urllib3.util.retry import Retry
4
5 CACHE = pathlib.Path("cache"); CACHE.mkdir(exist_ok=True)
6
7 def make_session(token=None):
8     s = requests.Session()
9     s.mount("https://", HTTPAdapter(max_retries=Retry(
10         total=5, backoff_factor=0.8,          # 429/5xx 指数退避
11         status_forcelist=[429, 500, 502, 503, 504], allowed_methods=["GET"])))
12     s.headers.update({"User-Agent": "szu-course/1.0 (you@szu.edu.cn)",
13                     "Accept": "application/json"})
14     if token: s.headers["Authorization"] = f"Bearer {token}" # token 不硬编码
15     return s
16
17 def get_json(session, url, params=None, use_cache=True):
18     key = hashlib.md5((url + json.dumps(params or {}, sort_keys=True)).encode()).hexdigest()
19     fp = CACHE / f"{key}.json"
20     if use_cache and fp.exists(): return json.loads(fp.read_text(encoding="utf-8"))
21     r = session.get(url, params=params, timeout=30); r.raise_for_status()
22     data = r.json()
23     fp.write_text(json.dumps(data, ensure_ascii=False), encoding="utf-8")
24     return data
```

要点：把“认证 / 重试 / 缓存 / 超时”封装成一层，业务代码只关心端点与字段。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 2 Data Sourcing 第二讲-数据获取 | 已有数据来源

Data Sources (国际 + 中国)

【代码】国际数据源示例：World Bank API 批量拉取

```
1 import pandas as pd
2 from api_utils import make_session, get_json # 上一页的封装
3
4 BASE, IND = "https://api.worldbank.org/v2", "NY.GDP.MKTP.CD" # GDP (US$)
5 s = make_session()
6 rows, page = [], 1
7 while True:
8     js = get_json(s, f"{BASE}/country/CHN;USA/indicator/{IND}",
9                   {"format": "json", "per_page": 100, "page": page})
10    meta, data = js[0], js[1]
11    rows += [{"country": d["country"]["value"], "year": int(d["date"]),
12             "gdp_usd": d["value"]} for d in data if d["value"] is not None]
13    if page >= meta["pages"]:
14        break
15    page += 1
16
17 df = pd.DataFrame(rows).sort_values(["country", "year"])
18 print(df.groupby("country")["gdp_usd"].last()) # 最新一年 GDP
19 df.to_parquet("wb_gdp.parquet") # 落盘 + 版本可比
```

同一模式可换指标代码（如贸易额、人口、教育）与国家列表，批量构建面板数据。

来源：World Bank Indicators API v2 (api.worldbank.org/v2) 公开文档。

【代码】 金融行情与宏观时间序列（国际）

```
1 import yfinance as yf, pandas as pd
2
3 tickers = ["AAPL", "MSFT", "0700.HK", "600519.SS"] # 含港股与 A 股
4 px = yf.download(tickers, start="2020-01-01", end="2025-12-31",
5                 auto_adjust=True, progress=False, group_by="column")
6 close = px["Close"] # 行=日期, 列=代码
7 rets = close.pct_change().dropna()
8 print(rets.describe().T[["mean", "std", "min", "max"]])
9
10 # 宏观: FRED (需免费 API Key) ——用 pandas_datareader 或 requests 均可
11 from pandas_datareader import data as web
12 cpi = web.DataReader("CPIAUCSL", "fred", "2015-01-01", "2025-12-01")
13
14 # 注意: 批量下载易触发限流 → 分批 + 间隔 + 本地缓存 (见 35 页封装)
```

教学提示: 行情数据要在报告中说明**复权方式**、**时区**、**交易日历**, 否则回测结果无法比较。

来源: yfinance 与 FRED/pandas-datareader 官方文档; ticker 后缀规则 (.SS/.SZ/.HK) 见交易所说明。

【代码】中国数据源：Tushare Pro 与 AKShare

```
1 # ----- Tushare Pro: 需注册获取 token, 部分接口有积分门槛 -----
2 import tushare as ts
3 ts.set_token("YOUR_TOKEN")      # 环境变量更好: os.getenv("TS_TOKEN")
4 pro = ts.pro_api()
5 daily = pro.daily(ts_code="000001.SZ", start_date="20240101", end_date="20241231")
6 gdp = pro.cn_gdp(start_q="2015Q1", end_q="2024Q4") # 季度宏观
7 codes = pro.stock_basic(exchange="", list_status="L") # 全部在上市股票
8
9 # ----- AKShare: 免费、无需 token, 封装公开网页/接口 -----
10 import akshare as ak
11 hist = ak.stock_zh_a_hist(symbol="000001", period="daily",
12                           start_date="20240101", end_date="20241231", adjust="qfq")
13 cpi = ak.macro_china_cpi_monthly()      # 月度 CPI
14 trade = ak.macro_china_trade_balance()  # 贸易差额
```

两个库都依赖上游网页结构，接口可能变动：务必**锁定版本**（requirements）并做落盘快照。

来源：Tushare Pro 与 AKShare 官方文档（2026）；数据仅供教学研究，商用须遵守各平台条款。

网页抓取 (一): 原理与工具

- ▶ 静态页: HTML 可直接解析 (requests + BeautifulSoup/lxml);
- ▶ 动态页: 内容由 JS 渲染 → 需 Playwright/Selenium (或找隐藏的 JSON 接口);
- ▶ 常见目标: 列表页分页、详情页字段、HTML 表格、附件 PDF;
- ▶ 工程要点: 请求间隔、失败重试、UA 声明、断点续抓、落盘快照。

```
1 import requests, pandas as pd
2 from bs4 import BeautifulSoup
3
4 url = "https://example.org/stats?page=1"
5 html = requests.get(url, timeout=20,
6     headers={"User-Agent": "szu-course/1.0"}).text
7 soup = BeautifulSoup(html, "lxml")
8
9 # 方式 1: CSS 选择器逐字段抽取
10 rows = [{"name": tr.select_one("td.name").get_text(strip=True),
11     "value": tr.select_one("td.val").get_text(strip=True)}
12     for tr in soup.select("table#data tbody tr")]
13
14 # 方式 2: 直接读 HTML 表格 (更省事, 结构规整时首选)
15 tables = pd.read_html(html) # 返回 DataFrame 列表
16 df = tables[0]
```

原课件提到的可视化抓取工具 (如 Import.io 类产品) 适合一次性任务; 可复现研究请优先写代码。

网页抓取（二）：法律与伦理边界


- ▶ 先读 robots.txt 与网站服务条款：禁止抓取就换来源；
- ▶ 控制频率（建议 ≥ 1 秒/请求、并发 ≤ 2 ），避免影响对方服务；
- ▶ 明确声明身份与联系方式（User-Agent），提供退出机制；
- ▶ 不抓取个人隐私数据、付费墙内容、需登录的受限数据；
- ▶ 尊重版权与数据库权利：文本/图片再分发需许可；
- ▶ 记录抓取时间与快照，保证研究可复现与可核查。

```
1 import urllib.robotparser as rp
2
3 UA = "szu-course/1.0"
4 r = rp.RobotFileParser()
5 r.set_url("https://example.org/robots.txt")
6 r.read()
7 print(r.can_fetch(UA, "https://example.org/stats")) # 先问"
8                                     能不能"
9
10 # 礼貌抓取：间隔 + 重试 + 只取必要字段
11 import time, requests
12 for page in range(1, 6):
13     resp = requests.get(f"https://example.org/stats?page={
14                           page}",
15                           headers={"User-Agent": UA}, timeout
16                                   =20)
17     if resp.status_code == 429: # 被限流 → 等待后重试
18         time.sleep(30); continue
19     save(resp.text, page); time.sleep(1.2)
```

合规红线：隐私数据、受限内容、绕过技术保护措施——一律不做。

两类 PDF，处理方式完全不同

- ▶ **原生 PDF** (文本可选中): 直接抽取文本/表格, 精度高;
- ▶ **扫描 PDF** (图片): 需 **OCR** (Tesseract、云 OCR), 再抽取字段;
- ▶ **判断方法**: 尝试选中文字 / 查看是否含字体信息。



来源: 文档抽取工具 (pdfplumber、Camelot、Tesseract) 为通用开源方案; 扫描件质量决定 OCR 上限。

【代码】PDF 文本与表格抽取

```
1 import pdfplumber, pandas as pd
2
3 # 1) 逐页抽文本（适合键值对、段落）
4 with pdfplumber.open("annual_report_2024.pdf") as pdf:
5     text = "\n".join((p.extract_text() or "") for p in pdf.pages[:5])
6
7 # 2) 抽表格（适合财务三表、统计附表）
8 with pdfplumber.open("annual_report_2024.pdf") as pdf:
9     tables = [pd.DataFrame(t[1:], columns=t[0])
10               for p in pdf.pages for t in p.extract_tables() if t]
11 fin = tables[0].replace({"": None}).dropna(how="all")
12
13 # 3) 扫描件：先 OCR 再抽取（需 tesseract + chi_sim 语言包）
14 # from pdf2image import convert_from_path; import pytesseract
15 # pages = convert_from_path("scanned.pdf", dpi=300)
16 # text = "\n".join(pytesseract.image_to_string(p, lang="chi_sim+eng") for p in pages)
```

实务提醒：财报表格常跨页/有合并单元格，抽取后必须做**合计校验**（分项之和 vs 总计）。

来源：pdfplumber、pytesseract/pdf2image 官方文档；OCR 中文需 chi_sim 语言包。

【代码】表格规范化与多源合并

```
1 import pandas as pd, re
2
3 # 1) 读取：显式指定编码与 dtype，避免前导零丢失、"1,234" 变字符串
4 df = pd.read_csv("sales_2024.csv", encoding="utf-8-sig", thousands=",",
5                 dtype={"store_id": "string", "sku": "string"})
6
7 # 2) 金额与百分比解析（原始字段常混入货币符号与空格）
8 df["amount"] = (df["amount_raw"].astype(str)
9                 .str.replace(r"^\d.\-|", "", regex=True).astype(float))
10 df["growth"] = df["growth_raw"].str.rstrip("%").astype(float) / 100
11
12 # 3) 类别对齐：不同来源的写法统一到标准编码
13 region_map = {"深圳": "SZ", "深圳市": "SZ", "Shenzhen": "SZ", "广东": "GD"}
14 df["region"] = df["region_raw"].map(region_map).fillna("UNK")
15
16 # 4) 多源合并：保留来源标记，按业务主键去重
17 a = pd.read_csv("src_a.csv").assign(source="A")
18 b = pd.read_csv("src_b.csv").assign(source="B")
19 allx = (pd.concat([a, b], ignore_index=True)
20         .drop_duplicates(["date", "store_id", "sku"], keep="last"))
```

原则：先规范化再合并；每个转换步骤都要能解释“为什么这样做”。

【代码】用 LLM 做结构化抽取（含校验与抽样复核）

```
1 import os, json, jsonschema
2 from openai import OpenAI          # 兼容 OpenAI 协议的供应商均可
3
4 client = OpenAI(api_key=os.environ["LLM_API_KEY"])
5 MODEL = os.getenv("LLM_MODEL", "gpt-5-mini") # 也可换成国产模型端点
6
7 SCHEMA = {"type": "object", "required": ["company", "amount_million", "sign"],
8           "properties": {"company": {"type": "string"},
9                           "amount_million": {"type": ["number", "null"]},
10                          "sign": {"enum": ["positive", "negative", "neutral"]}}}
11 SYS = "你是财务文本信息抽取器：只输出 JSON，不确定填 null，禁止编造。"
12
13 def extract(text: str) -> dict:
14     r = client.chat.completions.create(
15         model=MODEL, temperature=0,
16         response_format={"type": "json_object"}, # 强制 JSON 输出
17         messages=[{"role": "system", "content": SYS},
18                  {"role": "user", "content":
19                     f"按 schema 抽取: {json.dumps(SCHEMA, ensure_ascii=False)}\n\n{text[:4000]}"}])
20     obj = json.loads(r.choices[0].message.content)
21     jsonschema.validate(obj, SCHEMA)          # 结构校验，不合规则重试/丢弃
22     return obj
23 # 抽样复核：随机抽 50 条与人工标注比对一致率，并在报告中写明
```

LLM 抽取的三个必要条件：结构校验 + 抽样人工复核 + 提示词留档。

流式与实时数据 Streaming & Real-time

- ▶ **事件流**：点击、支付、位置、设备心跳；消息队列（Kafka、Pulsar）；
- ▶ **流处理**：Flink/Spark Structured Streaming 做窗口聚合与告警；
- ▶ **CDC**：数据库变更捕获（binlog/WAL）→ 实时同步到数仓；
- ▶ **实时特征**：风控与推荐需要在毫秒-秒级拿到最新特征。

批 vs 流的三角

- ▶ 延迟：批（小时-天）→ 微批（分钟）→ 流（秒）；
- ▶ 成本：实时管道运维复杂度显著更高；
- ▶ 一致性：批处理更易重跑与审计，流处理需设计幂等与 exactly-once。



来源：流式架构（Kafka/Flink/CDC）为业界通用实践；教学项目通常用批处理即可满足需求。

替代数据 Alternative Data

类型	典型信号	常见来源 / 供应商
卫星与地理	停车场车流、夜间灯光、农作物长势、矿区活动	卫星影像供应商 + 自建识别模型
航运与物流	船舶位置与航速、港口拥堵、集装箱流量	AIS 数据、港口与船公司公开数据
消费与支付	信用卡消费、门店客流、外卖订单	卡组组织/聚合数据商（多为授权）
招聘与人力	招聘岗位数与技能需求、人员流动	招聘网站抓取或商业数据商
应用与网络	App 下载与活跃、网站流量、搜索指数	第三方监测平台、公开指数（如百度指数）
舆情与文本	新闻情绪、社交讨论、研报观点	新闻 API、社交平台 API、自建爬虫

替代数据的价值在于**领先性与非共识**；风险在于**覆盖偏差、样本变化、合规与可持续性**。

来源：另类数据的分类据行业综述与公开产品说明整理；具体可获得性取决于授权与地区。

替代数据评估与合规清单

技术与统计评估


- ▶ **覆盖率**: 样本覆盖多少真实活动? (抽样偏差)
- ▶ **信号强度**: 与目标变量的相关性与领先期;
- ▶ **稳定性**: 供应商改口径、改样本会破坏历史可比性;
- ▶ **可解释性**: 能否说清“为什么这个信号有效”;
- ▶ **成本效益**: 数据费 + 清洗 + 建模是否值得。

合规与伦理

- ▶ 是否含个人信息? 是否获授权? 能否用于本用途?
- ▶ 是否触碰隐私 (位置轨迹、消费明细)?
- ▶ 是否涉及国家安全/数据出境?
- ▶ 供应商的数据来源是否合法可追溯?
- ▶ 结论是否会给被观测群体带来伤害?

替代数据先问“能不能用”，再问“有没有用”。

来源选择决策树与小结



顺序原则：官方 API → 商业授权 → 抓取 → 自采；越靠后成本与风险越高。

Never start with scraping: it is the fallback with the highest maintenance and legal cost.

何时必须自己采数据？

三类情形

- ▶ **没有二手数据**：新产品、新市场、内部流程改进；
- ▶ **需要因果证据**：只能靠随机实验（A/B 测试）识别效应；
- ▶ **需要新变量**：现有数据不含关键构念（信任、意愿、体验）。

先算三笔账

- ▶ **时间**：设计 + 预测试 + 采集 + 清洗，通常 2–6 周；
- ▶ **钱**：样本激励、平台费用、人力；
- ▶ **质量**：响应率、样本代表性、测量效度。

原课件强调的新数据来源（访谈、问卷、实验室实验、A/B 测试）正对应这三类情形。

问卷设计（一）：问题与量表

- ▶ **开放题**：信息丰富但编码成本高；**封闭题**：易统计但限制回答；
- ▶ **李克特量表**：5 点 vs 7 点；标注端点含义；避免“中庸选项”缺失；
- ▶ **构念操作化**：一个构念用 3-5 个题目测量（多题项提高信度）；
- ▶ **反向题**：识别敷衍作答，但不宜过多（易混淆）。

好问题的四条标准

- ▶ 单一焦点（避免双重问题：“产品便宜且好用吗？”）；
- ▶ 语言平实（不用行业黑话与缩写）；
- ▶ 不预设答案（避免诱导性措辞）；
- ▶ 选项互斥且穷尽（含“其他/不知道”）。

来源：问卷方法学通用规范（如 Tourangeau 等关于问卷设计与认知过程的经典研究）。

问卷设计（二）：偏差与顺序效应

偏差	表现	缓解手段
社会赞许	倾向于给出“体面”的答案	匿名、中性措辞、间接提问
回忆偏差	记不清过去行为（频率/时点）	缩短回忆窗、用锚点事件、日记法
锚定效应	被前一个问题或数字影响	打乱敏感题顺序、随机化选项
默认/顺序	选第一项或默认项	选项随机化，避免预设默认值
中心倾向	一律选中间	强制选择、增加题目数量
无响应	特定人群不回答（系统性缺失）	追踪提醒、加权、替换样本

这些偏差多数无法“事后修正”：必须在问卷设计阶段就处理。

来源：调查方法学中常见的响应偏差分类与缓解策略（2020s 综述与实践指南）。

问卷设计 (三): 预测试、长度与流失

三步预测试

1. **专家评审**: 构念覆盖、措辞、逻辑跳转;
2. **认知访谈**: 让 5-10 人边答边说出理解过程, 找歧义;
3. **小样本试测**: 30-50 份, 检查信度 (Cronbach's α)、区分度与完成时间。

长度与流失

- ▶ 在线问卷中位完成时间超过 10 分钟, 流失率显著上升;
- ▶ 把关键题放在前 1/3, 人口统计题放最后;
- ▶ 显示进度条; 允许多次续答 (保存草稿);
- ▶ 记录放弃点, 分析流失是否与题目有关 (系统性)。

预测试的投入, 通常在数据清洗阶段以几倍时间省回来。

抽样方法 Sampling Methods

方法	做法	适用与代价
简单随机	从抽样框等概率抽取	需完整抽样框；方差最小、成本高
分层抽样	按关键特征分层后各层随机抽取	提升代表性（按行业/地区/规模）
整群抽样	抽群（学校/门店/社区）再调查群内全部	成本低，群内相关性会降低有效样本量
系统抽样	每 k 个抽 1 个	操作简单，需警惕周期性
便利/配额	就近或按配额招募	快且便宜，但不能推断总体
滚雪球	由受访者推荐受访者	适合难触达群体（如专家、极少数人群）

课堂研究常用便利/配额抽样：必须明确声明“样本不可推断总体”，并把局限写进报告。

问卷实施方式与成本-覆盖权衡

方式	覆盖特点	成本	适用场景
面访	覆盖广，可展示材料、可追问	最高，速度慢	复杂问卷、敏感话题、老年人
电话	覆盖固定电话与手机，响应率下降	中高，依赖话务	短问卷、快速筛查
邮寄	覆盖稳定地址人群，回邮率低	中，周期长	不愿意被电话打扰的人群
在线	覆盖上网人群（年轻人偏高）	最低，速度最快	通用问卷、实验、面板追踪
混合模式	兼顾覆盖与成本	中，需处理模式效应	大型调查（如官方统计）

原课件的结论依然成立：方式选择同时受成本与目标总体覆盖约束；并用”混合模式”弥补单方式缺口。

来源：调查实施方式的成本-覆盖权衡据调查方法学通用结论；中国场景下还需考虑手机实名与短信触达。

无响应偏差与加权 Nonresponse & Weighting

- ▶ **无响应**：抽到但没答；**项目无回答**：答了但某题空着；
- ▶ 危险在于**不随机**：高收入、年轻男性等群体系统性缺失；
- ▶ 检查方法：比较样本与总体的年龄/地区/规模结构；比较早答者与晚答者；
- ▶ 缓解：提醒与激励、缩短问卷、电话补访、事后加权。

加权与校正

- ▶ **事后分层加权**：按总体分布给样本单元赋权；
- ▶ **倾向得分加权**：建模“应答概率”的倒数作为权重；
- ▶ 注意：加权会放大方差，需报告有效样本量；
- ▶ 无法补救的情形：完全缺失的群体（no overlap）。

来源：无响应偏差与加权方法据调查统计标准做法；与 L12 因果推断中的选择性问题直接相关。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 2 Data Sourcing 第二讲-数据获取 | 一手数据采集

Primary Data Collection


普查与行政数据 Census & Administrative Data

普查 (Census)

- ▶ 全国人口普查 (每 10 年)、经济普查、农业普查;
- ▶ 优点: 覆盖全、最小地理单元可细分;
- ▶ 缺点: 周期长、题项少、微观数据获取需申请。

行政记录

- ▶ 工商登记、税务、社保、海关、医保等业务系统沉淀数据;
- ▶ 优点: 连续、成本低、覆盖真实行为;
- ▶ 缺点: 口径随政策变动、仅覆盖登记主体 (非正规部门缺失)。



“隐身人群”: 未登记、非正规就业、流动人口

来源: 中国人口普查由国家统计局组织; 行政数据使用需遵守相应管理规定与审批流程。

- ▶ **随机化**：把混杂因素（可观测与不可观测）平均化；
- ▶ **对照组**：无处理/安慰剂/现行方案；
- ▶ **盲法**：避免期望效应（受试者与执行者）；
- ▶ **功效分析**：给定效应大小与方差，估算所需样本量；
- ▶ **预注册**：先写假设与主要指标，避免事后挖数据。

最小样本量的直觉

$$n \approx \frac{16\sigma^2}{\Delta^2} \quad (\text{两组比较的粗略近似})$$

其中 Δ 为期望可检测的效应， σ 为结果的标准差。效应越小、噪声越大，所需样本越多（按平方增长）。

来源：实验设计与功效分析的标准表述；精确样本量应使用功效分析工具（如 G*Power、statsmodels）。

A/B 测试 (一): 从假设到判读



判读三件事

- ▶ 效应大小与**置信区间** (不只 p 值);
- ▶ 是否达到**实践意义** (成本、体验、长期影响);
- ▶ 分群结果是否一致 (异质性处理效应, 见 L12)。

原课件的例子 (仍适用)

- ▶ 邮件营销: 主题行 A/B → 打开率与转化率;
- ▶ 产品定价: 不同价格点的转化与收入;
- ▶ 页面/推荐位: 点击率与停留时长。

A/B 测试（二）：陷阱与防护

陷阱	后果	防护
SRM（分流失衡）	组间样本比例异常，结论不可信	每日校验分流比例，异常即停
多重比较	看很多指标/分组必“显著”	预先指定主指标；FDR/Bonferroni 校正
早停与偷看	反复查看提前结束，假阳性升高	固定样本量或序贯检验设计
网络效应/溢出	对照组被处理影响（社交、共享库存）	按群随机（cluster randomization）
代理指标漂移	优化点击率损害长期价值	加入护栏指标（留存、退款、投诉）
季节与外部冲击	与大促、节日、政策撞车	同期对照 + 记录外部事件

原课件” 邮箱营销/定价 A/B 测试” 示例，配上本页陷阱清单才是一套完整方法论。

来源：A/B 测试工程实践（SRM 检测、序贯检验、群随机）据业界平台经验与统计文献整理。

实验室与行为实验 Lab & Behavioural Experiments

- ▶ **实验室实验**：可控环境中呈现刺激、记录反应（原课件：分享信息或体验的在场项目）；
- ▶ **测量手段**：反应时、选择与出价、眼动、皮肤电/心率、面部表情；
- ▶ **实验经济学范式**：公共品博弈、最后通牒、信任博弈、拍卖；
- ▶ **优势**：内部效度高、可隔离机制；**劣势**：样本小、外部效度存疑（WEIRD 样本问题）。

线上行为实验

- ▶ 众包平台招募 + 在线任务（鼠标轨迹、选项随机化）；
- ▶ 与问卷调查结合：先行为后自陈，减少“言行不一”；
- ▶ 预注册与知情同意（伦理审查 IRB）。

来源：实验经济学与行为实验方法（含 WEIRD 样本批评）为通用学术共识。

访谈与定性方法 Interviews & Qualitative Methods

- ▶ **半结构化访谈**：提纲固定、追问灵活；适合**新情境**（原课件观点）；
- ▶ **焦点小组**：群体互动激发观点，但需控制从众效应；
- ▶ **抽样**：目的性抽样、最大差异抽样、理论饱和（不再出现新主题即停）；
- ▶ **成本**：单次 45–90 分钟 + 转录 + 编码，样本 10–30 人常见。


分析流程（主题分析）

1. 转录与熟悉材料；
2. 开放编码 → 归类 → 主题；
3. 双人编码与分歧讨论（报告一致性）；
4. 三角互验：与问卷、日志、文档证据交叉印证。

定性材料的价值是“解释机制”，不是“估计比例”。

卡片分类与结构发现 Card Sorting

- ▶ **开放式卡片分类**：被试自行分组并命名 → 发现用户心智模型；
- ▶ **封闭式卡片分类**：给定类别，判断归入哪一类；
- ▶ **产出**：相似度矩阵（两两同组次数）→ 层次聚类树状图；
- ▶ **用途**：信息架构、问卷题项归类、概念结构验证；
- ▶ 原文与实务都强调：样本 15–30 人即可得到稳定的分组结构。



来源：卡片分类与树状图（dendrogram）方法沿用原课件；聚类距离可用 Jaccard/欧氏距离。

众包标注与一致性 Crowdsourcing & Agreement

- ▶ **标注指南**: 写清判定规则与边界案例 (含反例截图/文本);
- ▶ **金标题目**: 混入已知答案的题项, 筛掉不认真的标注者;
- ▶ **多人标注**: 关键样本 2-3 人标注, 分歧进入仲裁;
- ▶ **一致性指标**: Cohen's κ / Fleiss' κ / Krippendorff's α ;
- ▶ **成本控制**: 先小批量试标, 校准指南后再放大。

一致性怎么看

- ▶ $\kappa < 0.4$: 一致性差, 指南需要重写;
- ▶ $0.4 \leq \kappa < 0.6$: 一般, 可用于探索;
- ▶ $0.6 \leq \kappa < 0.8$: 较好, 可用于建模;
- ▶ $\kappa \geq 0.8$: 很好 (医学标注常要求)。

注意: 类别极不平衡时 κ 会被压低, 需同时报告原始一致率。

来源: 标注一致性的标准指标与经验阈值 (Cohen 1960; Landis & Koch 1977; Krippendorff)。

LLM 辅助数据采集 (2026) LLM-assisted Collection

可用场景


- ▶ **文本结构化**: 从公告/新闻中抽取公司、金额、事件、情感;
- ▶ **零样本/少样本标注**: 分类、主题、信息提取;
- ▶ **问卷与访谈辅助**: 生成初稿题项、转录整理、主题汇总;
- ▶ **合成数据**: 扩充稀少类别、生成测试用例、模拟受访者。

不可依赖的场景

- ▶ 需要事实精确的数值 (会编造);
- ▶ 需要可追溯来源的结论 (无引用即不可信);
- ▶ 高风险决策的直接判定 (信贷、医疗、司法);
- ▶ 涉及个人隐私数据的直接上传 (合规风险)。

定位: LLM 是**高效的初标器与提取器**, 不是“事实来源”。人负责规则、核验与责任。

LLM 辅助的风险与核验流程



三类风险

- ▶ **自洽偏误**：模型倾向与自己的先验一致，误差不随机；
- ▶ **漂移**：供应商升级模型后，同一提示词结果会变；
- ▶ **许可与隐私**：输入数据可能被用于训练/留存（看条款）。

必做的四件事

- ▶ 记录模型名、版本、日期、温度与完整提示词；
- ▶ 抽样人工复核并报告一致率与误差类型；
- ▶ 保留原始文本与模型输出，报告中写明“哪些字段由模型生成、如何核验”。

合成数据与隐私增强技术

合成数据 Synthetic Data

- ▶ 用途：扩增稀少类别、构造测试集、共享数据时保护隐私；
- ▶ 方法：规则生成、SMOTE 类过采样、生成模型 (VAE/GAN/扩散)、LLM 生成；
- ▶ 风险：分布失真、放大原有偏差、“污染”后续训练；
- ▶ 纪律：合成数据必须与真实数据交叉验证，并单独标注来源。

隐私增强技术 PETs

- ▶ 去标识化/匿名化：删除或泛化标识符（注意可重识别风险）；
- ▶ 差分隐私：加噪保证个体不可区分，代价是精度；
- ▶ 联邦学习：数据不出域，只交换模型更新；
- ▶ 安全多方计算/同态加密：多机构联合统计而不共享原始数据。

来源：合成数据与隐私增强技术综述（2020s）；差分隐私的隐私预算与精度权衡需在设计中明确。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 2 Data Sourcing 第二讲-数据获取 | 质量控制与

LLM 辅助 Quality Control & LLM Assistance

【代码】数据体检：缺失、重复、异常与时间覆盖

```
1 import pandas as pd, numpy as np
2
3 df = pd.read_parquet("data/raw/snapshot_2026-09-01.parquet")
4 print(f"shape={df.shape} memory={df.memory_usage(deep=True).sum()/1e6:.1f} MB")
5
6 # 1) 缺失：按列排序，关注“成块缺失”（同一批字段一起缺）
7 miss = (df.isna().mean() * 100).round(2).sort_values(ascending=False)
8 print(miss[miss > 0].head(10))
9
10 # 2) 重复：整行重复 + 业务主键重复
11 print("dup rows:", int(df.duplicated().sum()))
12 print("dup keys:", int(df.duplicated(["date", "store_id", "sku"]).sum()))
13
14 # 3) 异常：IQR 规则给出各数值列的异常比例（先看比例，再决定处理方式）
15 num = df.select_dtypes("number")
16 q1, q3 = num.quantile(.25), num.quantile(.75); iqr = q3 - q1
17 outlier = ((num < q1 - 1.5*iqr) | (num > q3 + 1.5*iqr)).mean().round(4)
18 print(outlier.sort_values(ascending=False).head())
19
20 # 4) 时间覆盖：起止、频率与缺口
21 d = pd.to_datetime(df["date"])
22 print("range:", d.min().date(), "->", d.max().date())
23 print(d.dt.to_period("M").value_counts().sort_index().tail(6))
```

体检报告是作业 1 的核心交付物之一：结论要写成“发现 + 影响 + 处理计划”。

小结：一手数据质量控制清单

1. 构念操作化是否有多题项支撑？（信度）
2. 抽样框覆盖了目标总体的哪些人？漏掉谁？
3. 样本量与功效是否事先计算？
4. 问卷是否经过预测试与认知访谈？
5. 是否存在社会赞许/顺序/默认值偏差？
6. 无响应是否系统性？是否加权？
7. 实验是否随机化、是否有护栏指标？
8. 标注是否有多人与一致性报告？
9. LLM 辅助是否抽样复核并留档？
10. 数据与材料是否可复现、可审计、可删除？

一手数据的花费主要在”设计与核验”，不在”收集”。

从来源到分析表：ETL vs. ELT



传统 ETL：先转换后入库：先入库，用 SQL 在仓内转换

ETL 适合

强合规要求、需在入库前脱敏、目标库昂贵（只存处理后的数据）。

ELT 适合

云数仓弹性计算、需要保留原始明细、转换逻辑频繁变化。

共同要求

幂等可重跑、失败可续、变更留痕、来源可追溯（血缘）。

【代码】最小可用数据管道：快照 → 校验 → 分析表

```
1 import pathlib, logging, datetime as dt
2 import pandas as pd
3
4 logging.basicConfig(level="INFO", format="%asctime)s %(levelname)s %(message)s")
5 RAW, CUR = pathlib.Path("data/raw"), pathlib.Path("data/curated")
6 RAW.mkdir(parents=True, exist_ok=True); CUR.mkdir(parents=True, exist_ok=True)
7
8 def extract() -> pd.DataFrame:          # 抽取：先落不可变原始快照
9     df = pd.read_csv("https://example.org/api/export.csv")
10    df.to_parquet(RAW / f"snapshot_{dt.date.today().isoformat()}.parquet")
11    logging.info("snapshot rows=%d", len(df)); return df
12
13 def validate(df: pd.DataFrame) -> pd.DataFrame: # 校验：失败即中止
14     assert df["id"].is_unique, "id 必须唯一"
15     assert df["amount"].notna().mean() > 0.99, "amount 缺失率过高"
16     assert (df["amount"] >= 0).mean() > 0.99, "amount 异常负值"
17     return df.assign(date=pd.to_datetime(df["date"]).dt.date)
18
19 def load(df: pd.DataFrame) -> None:          # 装载：幂等落盘 + 日志
20     df.drop_duplicates(["date", "store_id", "sku"]).to_parquet(CUR / "sales.parquet")
21     logging.info("curated rows=%d cols=%d", *df.shape)
22
23 if __name__ == "__main__":
24     load(validate(extract()))
```

这一页可作为作业 1 的脚本骨架：快照 + 断言 + 幂等落盘 + 日志。

数据契约与数据产品 Data Contracts & Data Products

数据契约 (Contract)

- ▶ **结构**：字段名、类型、单位、允许空值；
- ▶ **语义**：口径定义、计算规则、生效日期；
- ▶ **质量**：完整性/唯一性/范围约束与阈值；
- ▶ **服务**：更新频率、延迟承诺 (SLA)、变更通知流程。

数据产品 (Product)

- ▶ 把数据集当“产品”管理：有负责人、有版本、有文档、有用户；
- ▶ 变更需走评审：破坏性变更提前公告（弃用期）；
- ▶ 用户反馈闭环：字段需求、质量问题登记与修复。

契约的价值：让上游变更**可预期**，而不是在某天早上发现报表全空了。

来源：数据契约与数据产品化实践（2020s 数据工程业界共识）。

现代数据栈与开放表格式

- ▶ **Lakehouse**: 对象存储 + 表格式 + SQL 引擎, 兼顾成本与事务;
- ▶ **开放表格式**: Iceberg / Delta Lake / Hudi ——支持 ACID、时间旅行、schema 演进;
- ▶ **查询引擎**: Spark、Trino、DuckDB (本地/单机大表分析)、Polars (内存/列式);
- ▶ **转换层**: dbt (SQL 建模 + 测试 + 文档)、Airflow/Dagster (调度与依赖)。

对课程项目的意义

- ▶ 小数据也能用工程化方法: DuckDB + Parquet + dbt 即可搭出可复现管道;
- ▶ 保留原始快照 + 派生表分离, 便于重跑与审计;
- ▶ 与 L1 的“现代数据栈”呼应, 本讲落到“具体怎么落地”。

来源: Apache Iceberg、Delta Lake、Hudi、DuckDB、dbt 官方文档 (2026)。

元数据、目录与血缘 Metadata & Lineage

- ▶ **技术元数据**：表/字段/类型/分区/文件大小；
- ▶ **业务元数据**：指标定义、口径、责任人、更新频率；
- ▶ **血缘 (Lineage)**：从原始来源到最终指标的全链路依赖；
- ▶ **数据目录**：可搜索的资产清单（谁有什么数据、谁能用）。

”这个数字从哪来？”

- ▶ 好的元数据能让任何指标**逐层回溯**到来源；
- ▶ 报表异常时，血缘图直接定位上游变更；
- ▶ 论文与报告中的数字应能指到具体表与版本。



版本、快照与可复现 Reproducibility

- ▶ **代码**：Git 管理脚本；提示词、配置也纳入版本控制；
- ▶ **数据**：原始快照不可变（按日期/版本命名），派生表可重建；
- ▶ **环境**：锁定依赖版本（requirements/lock）、容器镜像；
- ▶ **随机性**：固定随机种子；记录库与硬件版本；
- ▶ **工具**：DVC / Git-LFS 管理大数据；MLflow 类工具记录实验。

作业与论文层面的”可复现”

- ▶ 别人拿到你的仓库，能一条命令重跑出同样结果；
- ▶ 报告中的关键数字能对应到具体脚本与数据版本；
- ▶ 数据来源、获取日期、处理步骤完整可查。

可复现不是”额外工作”，而是数据获取环节的验收标准之一。

数据质量规则与监控 Data Quality Rules

维度	规则示例	触发后的动作
完整性	关键字段非空率 $\geq 99\%$	阻断入库 + 通知负责人
唯一性	主键唯一、无重复快照	去重或中止管道
取值范围	金额 ≥ 0 、比例 $\in [0, 1]$	标记异常记录并隔离
一致性	分项之和 = 总计；跨表对账	生成差异报告，人工确认
及时性	数据在约定时间前到达	告警 + 回退到上一版
分布稳定性	均值/分位数漂移超阈值	复核上游变更或模型重训

落地方式：把规则写成代码（Great Expectations / dbt tests / 自写断言），纳入每次运行与 CI。

来源：数据质量维度与规则化实践（Great Expectations、dbt tests 文档）。

隐私与合规：GDPR/CCPA 与 PIPL

维度	GDPR (欧盟) / CCPA (加州)	中国 PIPL / 数据安全法
合法性基础	同意、合同、正当利益等六项	同意、合同必需、法定义务等
告知与同意	明确告知、可撤回	单独同意 (敏感信息)、告知义务
个人权利	访问、更正、删除、可携带、反对	查阅、复制、更正、删除 (符合条件)
数据出境	充分性认定/SCC 等机制	安全评估、标准合同、认证
高风险活动	DPIA (数据保护影响评估)	个人信息保护影响评估
处罚	最高全球营业额 4%	罚款、暂停业务、责任人处罚

课程项目层面：不采集不必要的个人信息、能匿名化就匿名化、公开数据也要看条款与出境要求。

来源：GDPR (EU 2016/679)、CCPA/CPRA、中国《个人信息保护法》《数据安全法》及相关出境规定。

版权与许可

- ▶ 数据“公开可访问” ≠ “可自由使用”；
- ▶ 常见许可：CC BY / CC BY-NC / ODbL（开放数据库许可） / 自定义商业条款；
- ▶ 数据库权利：欧盟有 sui generis 数据库权；
- ▶ 论文与报告：注明来源、版本、获取日期与许可。

安全与伦理实践

- ▶ 最小权限、按需授权、离岗回收；
- ▶ 传输与存储加密，敏感字段脱敏/加密；
- ▶ 访问审计日志（谁在什么时候看了什么）；
- ▶ 弱势群体保护：儿童、患者、员工数据的额外限制；
- ▶ 透明度：让被采集者知道用途与权利。

合规不是最后一步的检查，而是数据获取设计的起点。

把研究问题翻译成数据需求

研究问题	关键构念	需要的变量 / 口径	候选数据源
数字贸易如何影响中小企业出口？	数字贸易强度、出口绩效	企业出口额（海关口径）、电商平台使用、地区数字化指数	海关统计、企业调研、地方开放数据
ESG 表现是否降低融资成本？	ESG 评分、融资成本	债券利差、评级、ESG 评分（口径与年份）	CSMAR/CNRDS、Wind、债券信息披露
情绪能否预测股价短期波动？	情绪、波动率	新闻/研报文本、日内收益率、成交量	新闻 API、巨潮公告、行情接口
消费者对定价策略的反应	价格敏感度、购买意愿	实验分组、转化率、客单价	自建 A/B 实验、平台后台数据

写法建议：先写” 构念”，再写” 可观测变量的代理”，最后才写” 数据源”——顺序反了会被数据牵着走。

数据源清单模板与获取失败排查

数据源清单（每个来源一行）

- ▶ **来源名称**：机构 / 网址 / 联系人（谁维护、谁答疑）；
- ▶ **内容与字段**：关键字段、单位、口径；
- ▶ **时间覆盖**：起止、频率、发布延迟；
- ▶ **获取方式**：API / 下载 / 抓取（是否需认证）；
- ▶ **成本、许可与质量**：价格、许可类型、可否再分发；覆盖/质量/成本/合规/可复现评分（1-5）。

获取失败排查清单

- ▶ 401/403：密钥过期、权限不足、需加 User-Agent；
- ▶ 429：限流 → 指数退避 + 缓存；
- ▶ 结构变更：字段改名/嵌套变化 → 加 schema 断言；
- ▶ 编码乱码：UTF-8/GBK → 显式指定 encoding；
- ▶ 漏数据：分页未走完、时区与交易日历不一致；
- ▶ 静默失败：空结果被当成“没有数据” → 记录响应码与条数。

作业 1：数据获取与整备

提交内容（个人完成）

1. **数据集**：自选公开或可授权数据（建议 1–10 万行，至少含 2 类字段类型）；
2. **数据源清单**：按 79 页模板填写，含许可与获取方式；
3. **获取脚本**：可重跑（含缓存、重试、日志），附依赖清单；
4. **数据体检报告**：缺失/重复/异常/时间覆盖 + 处理计划；
5. **AI 使用声明**：工具、版本、关键提示词、核验方式。

评分要点（100 分）

- ▶ 数据来源合法与可复现（25）；
- ▶ 获取代码质量与健壮性（25）；
- ▶ 体检深度与问题发现（25）；
- ▶ 报告表达与规范、AI 声明合规（25）。

提交：代码仓库链接 + PDF 报告（≤8 页）；第 4 周课前提交。

来源：作业与课程大纲第 4 周“作业 1 提交”对应；项目（4 选 1）要求另行公布。

常见错误清单 Common Pitfalls

1. 只因为“能抓到”就抓，不看 robots/ToS;
2. 把类别代码当数值参与计算;
3. 混用不同口径的同一指标（如不同来源的“出口额”）;
4. 忽略单位与币种，直接合并两个来源;
5. 抽样不可推断总体，却在报告里下总体结论;
6. 问卷未预测试就上量，导致中途改题;
7. A/B 测试反复偷看结果、提前停止;
8. 标注无一致性检验，误差被当成信号;
9. 让 LLM 直接写结论而不做抽样复核;
10. 数据无快照、无版本，三个月后无法复现。

数据获取阶段犯的错误，后期建模几乎无法弥补。

教材与专著

- ▶ McKinney, W. (2018). *Python for Data Analysis* (Ch.6 数据加载与存储) ;
- ▶ Provost & Fawcett (2013). *Data Science for Business* (数据获取与准备) ;
- ▶ Groves et al. (2009). *Survey Methodology* (问卷与无响应) ;
- ▶ Kohavi, Tang & Xu (2020). *Trustworthy Online Controlled Experiments*;
- ▶ Tourangeau et al. (2000). *The Psychology of Survey Response*.

文档与规范

- ▶ World Bank API、FRED、OpenAlex、Crossref 官方文档;
- ▶ Tushare / AKShare 文档与字段说明;
- ▶ Great Expectations、dbt、Apache Iceberg 文档;
- ▶ GDPR、CCPA/CPRA、中国《个人信息保护法》《数据安全法》;
- ▶ Kaggle / Hugging Face 数据集卡 (Dataset Card) 规范。

数据源速查表（国际）

名称	内容	获取方式
World Bank	发展指标（200+ 国家，数十年）	api.worldbank.org/v2（JSON，免费）
IMF / OECD	金融统计、WEO、结构指标	数据门户 + SDMX API
UN Comtrade	双边贸易（HS 编码）	网页 + API（额度受限）
Eurostat	欧盟统计	JSON-stat API
FRED	美国及全球宏观序列	REST API（需 Key）
OpenAlex / Crossref	文献与引用元数据	开放 REST API（附邮箱更礼貌）
SEC EDGAR	美股公司披露文件与财务数据	data.sec.gov（需 User-Agent 声明）
Kaggle / HF Datasets	数据集与基准	网页下载 / API / datasets 库
Common Crawl	月度网页快照	S3/HTTP 批量下载（需自建解析）

来源：各平台官方文档（2026）；商业数据源（Bloomberg/Refinitiv/FactSet/Statista）见 29 页。

数据源速查表（中国）与常用术语

名称	内容 / 方式
国家统计局	宏观与普查数据（网页查询 + 部分接口）
中国人民银行	社融、信贷、利率（Excel/PDF 统计表）
海关总署	进出口商品与国别统计（在线查询）
上交所 / 深交所	行情、公告、融资融券（官网 + 授权接口）
巨潮资讯	上市公司公告与年报 PDF
企业信用公示系统	工商登记与处罚信息（国家企业信用信息公示系统）
CSMAR / CNRDS	学术研究数据库（校内订阅）
Wind / iFinD / CEIC	机构级数据终端与 API
Tushare / AKShare	Python 数据接口（免费/积分制）
天池 / 和鲸 / DataFountain	中文竞赛与开放数据集

常用术语中英对照

- ▶ 数据源 data source; 数据契约 data contract
- ▶ 血缘 data lineage; 快照 snapshot
- ▶ 去标识化 de-identification; 差分隐私 differential privacy
- ▶ 联邦学习 federated learning; 替代数据 alternative data
- ▶ 合成数据 synthetic data; 无响应偏差 nonresponse bias
- ▶ 标注一致性 inter-rater agreement; 限流 rate limiting



谢谢! Thanks!

Q&A · Lecture 2 Data Sourcing 数据获取

下一讲 Lecture 3: Data Preparation 数据准备 (合并、清洗、缺失与异常)

戴谢尔 (Xieer Dai, David) · Xieer.dai@szu.edu.cn · 四方楼南 106