

课程 COURSE

Big Data Analytics

大数据分析 [2026 国际商务]

Lecture 4 — Data Description and Visualization 第四讲: 数据描述与可视化
从数据文档到描述统计、图型选择与地理信息可视化

任课教师: 戴谢尔 (Xieer Dai, David)

深圳大学 Shenzhen University · 第 3-14 周 星期四 11-12 节

上课地点: 四方楼南 209

学习目标 Learning Objectives

完成本讲后，你应能够：

1. 在项目一开始就写出数据文档与元数据（含 20 项要素清单与字段字典）；
2. 用中心趋势、离散程度、分布形状三件套完整描述一个变量，并说明各自稳健性；
3. 在双变量与多变量场景下正确使用相关、列联表、条件分布，并识别取值范围截断的影响；
4. 按图的语法（数据 → 几何 → 通道）与决策树选择图型，写出自足的图注；
5. 用 Python 完成交互图、仪表板与地理信息可视化（choropleth、符号地图、空间自相关）；
6. 识别并修正误导性图表，做出色盲友好、可访问的图，并用叙事结构汇报结论。

来源：本讲按五条主线组织：文档与元数据、描述统计、描述图形、可视化工具、地图与网络，并按 2026 年实践扩展。

本讲路线图 Roadmap (102 帧)



主线：文档 → 统计量 → 图型 → 工具与地图 → 可信表达 → **高维前沿**

代码页 12 帧·样本页 16 帧：每页一份样本数据、图的对照、逐行中文注释的程序，全部用 Python 完成

与上一讲的衔接 From Preparation to Description

L3 结束时你手上有什么

- ▶ 一张干净的分析表 (raw 与 curated 分层);
- ▶ 清洗日志、缺失处理记录、可复现脚本;
- ▶ 但还没回答: 这份数据到底“长什么样”? 怎么讲给别人听?

L4 要回答的问题

- ▶ 数据是谁的、什么口径? 文档与元数据怎么写?
- ▶ 用哪几个统计量刻画分布?
- ▶ 该用哪种图表达这个问题?
- ▶ 怎样画才不误导、且人人看得懂?



本讲的所有程序都用 Python 完成: 不依赖 Power BI、Tableau, 交互图与仪表板用 plotly 导出 HTML, 地图用 choropleth 与符号地图。

本讲输出物 Deliverables

1) 数据文档

‘README’ + 字段字典 (codebook): 类型、单位、取值域、缺失、版本与校验和 (14 页代码)

2) 描述统计表

中心、离散、形状三件套 + 分组对照表; 缺失率随表一起报 (25 页代码)

3) 图表清单与图注

每张图写清: 问题、数据、图型、通道、样本量、口径、不确定性 (98 页模板)

与本课程项目 1「数据获取与整备」对应

项目 1 的报告部分就用这三件: **文档** + **描述统计表** + **图表清单**。本讲的”可信图表十条检查”(97 页) 与”AI 生成图表核验清单”(86 页) 直接作为报告自检表。

来源: 评分与提交要求见课程大纲第六节; 本讲提供模板与检查清单。

全讲导览 Map of the Lecture

部分	帧	关键问题
文档与元数据	7-16	数据是谁的、什么口径？字段字典怎么自动生成？
单变量描述统计	17-30	中心、离散、形状各用哪个指标？谁最稳健？
双变量与多变量	31-42	相关怎么读？分组会不会改变结论？
图型选择与图的语法	43-56	这个问题该用哪种图？通道怎么选？
工具、交互与地理信息	57-74	用 Python 怎么做出交互图、仪表板与地图？
误导、可访问性与叙事	75-86	图会怎样撒谎？怎样让所有人看懂？
高维数据可视化	87-96	十几维的数据怎么画？降维投影、平行坐标与解释性可视化怎么用？
项目与结语	97-102	报告里的图表要达到什么标准？

读法：每部分都是“概念 → 样本与图示（**样本页**） → 可运行程序（**代码页**） → 清单”的循环。

四类应用场景 Four Settings

场景	典型列举	对图表的要求
投资研究报告	Investment Research Report	结论先行、关键指标看板式呈现；口径与时间点必须写在图上
学位论文	Thesis writing	图注自足、可复现；统计表与图分开编号，风格全书统一
科研论文	Scientific Academic Research	遵守期刊图形规范；误差棒、样本量、显著性标注缺一不可
咨询公司报告	Consulting Firm Report	一页一结论、叙事清晰；避免图表垃圾与误导性坐标轴

共同点：读者不会读你的代码，只会看图与图注。所以”图注自足性”是本讲的核心要求之一（51 页）。

Someone will read the chart without you.

来源：场景清单据国际商务实践整理；对图表的要求参考国际期刊与咨询报告惯例。

为什么一开始就写文档 Documentation from Day One

核心原则 Core principle

在研究的**最开始**——甚至在数据收集开始之前——就开始记录数据，会让文档撰写更容易，并降低后期**遗忘数据细节**的可能性；至少应把这些文档放在与数据同处的 `readme.txt` 或等效文件中，也可以引用一篇已发表论文作为补充。

省掉文档的代价

- ▶ 三个月后自己也看不懂某个字段的单位；
- ▶ 无法回答审稿人“口径是什么”的追问；
- ▶ 交接给同学复现时，全部靠口述；
- ▶ 数据被误用、被过度解读。

与 L3 的**数据契约**衔接：契约是“机器可读的文档”（类型、取值域、缺失约定），文档是“人能读的契约”（背景、方法、许可、版本）——两者应当同源、互相校验。

来源：文档先行是数据管理的通行做法；代价与衔接为本讲整理。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 4 Data Description & Visualization 第四讲-数据描

述与可视化 | **文档、元数据与描述统计** Documentation and Description

数据文档清单（上） The 20-Item Checklist, Part 1

要素 Item	说明 Key description
Title 标题	数据集或研究项目的名称
Creator 创建者	创建数据的机构或人员的名称与地址
Identifier 标识符	用于识别该数据的编号，哪怕是内部项目号
Subject 主题	描述数据主题或内容的关键词、短语
Funders 资助方	资助研究的机构或部门
Rights 权利	该数据已知的知识产权
Access information 获取方式	其他研究者可以从何处、以何种方式获取
Language 语言	知识内容所用语言（适用时）
Dates 日期	项目起止、发布日期、数据覆盖时段、维护与更新周期等
Location 空间范围	数据涉及的物理位置的空间覆盖信息

来源：20 项数据文档清单（按可读性拆为上下两帧，附可填写模板）。

数据文档清单 (下) The 20-Item Checklist, Part 2

要素 Item	说明 Key description
Methodology 方法	数据如何产生：设备或软件、实验流程、类似实验记录本的内容
Data processing 处理过程	数据被改动或加工过的任何信息都随手记录
Sources 来源	派生数据的原始出处引用，含源数据存放位置与获取方式
List of file names 文件清单	项目全部数据文件的名称与扩展名（如 stone.mov）
File formats 文件格式	数据格式（FITS、SPSS、HTML、JPEG 等）及读取所需软件
File structure 文件结构	数据文件的组织方式与变量布局（适用时）
Variable list 变量清单	数据文件中的变量列表（适用时）
Code lists 编码表	文件名或变量中编码、缩写的解释（如 999 表示缺失）
Versions 版本	每个文件的时间戳，并为每个版本使用单独的 ID
Checksums 校验和	用于检测文件是否随时间被改动（配合备份使用）

来源：同上，清单的后半部分（Methodology 至 Checksums）。

元数据：数据的数据 Metadata as Data about Data

核心定义 Definition

“Metadata” 是**关于数据的数据**：一种**结构化的**描述信息，用来描述内容、让人更容易发现与使用它。元数据记录可以**内嵌在数据中**，也可以**单独存放**；任何格式的数据文件都可以有元数据字段。在社会科学中，这份记录称为 **codebook** 或 **data dictionary**。

一份最小可用的数据字典

- ▶ 字段名与中文含义；
- ▶ 类型与单位（元 / 千元 /
- ▶ 取值域（枚举、范围、编码值）；
- ▶ 缺失约定（-1、NULL、空串）；
- ▶ 非空率与唯一值个数。

本讲 14 页的代码页会**自动生成**这份字典：改动数据结构时字典跟着变，避免“文档与数据两张皮”。

来源：元数据定义据数据管理通行表述；最小可用字典字段对应代码页 I4_01。

元数据标准 Metadata Standards

六个常用标准

- ▶ Astronomy Visualization Metadata (天文)
- ▶ Content Standard for Digital Geospatial Metadata (地理空间)
- ▶ Darwin Core (生物多样性)
- ▶ Data Documentation Initiative (社会科学)
- ▶ Dublin Core (通用)
- ▶ Ecological Metadata Language (生态)

选哪个？


选择依据：取决于研究的类型、规模与学科；英国数字策展中心（DCC）按学科整理了标准清单。

没有标准怎么办

用第 9–10 页的 20 项清单自建一套最小元数据集，并在团队内固定下来——“一致性比”标准”更重要。

来源：标准清单与 DCC 提示据各标准官方说明；“没有标准时的做法”为本讲整理。

【样本 + 可视化】文档完成度体检 Documentation Coverage



左：20 项文档要素的完成度（本讲样本 20/20 已填）；中：各字段非空率（收入题敏感，12 条缺失、满意度 5 条缺失）；右：自动生成的数据字典规模（9 个字段）。

程序 14_01_docs_metadata.py · 样本 14_survey_raw.csv (500 行 × 9 列) · 字典 14_data_dictionary.csv/.md

【代码】自动生成数据字典与文档体检 Auto Data Dictionary

```

1 def field_dictionary(df, units): # 为每一列生成字典条目
2     rows = [] # 每个字段一行
3     for col in df.columns: # 遍历所有列
4         s = df[col] # 取出该列
5         if pd.api.types.is_numeric_dtype(s): # 数值型：给范围
6             rng_txt = f"{s.min():.2f} ~ {s.max():.2f}" # 最小值到最大值
7         elif pd.api.types.is_bool_dtype(s): # 布尔型：给真值比例
8             rng_txt = f"True 占比 {s.mean():.1%}" # 真值占比
9         else: # 类别型：给取值个数与示例
10            rng_txt = f"{s.nunique()} 类" # 类别数量
11        rows.append({"字段": col, "类型": str(s.dtype), # 列名与 dtype
12                    "非空率": f"{s.notna().mean():.1%}", # 完整性
13                    "唯一值": int(s.nunique()), # 唯一值个数
14                    "取值范围/样例": rng_txt, # 取值域说明
15                    "单位": units.get(col, "-")}) # 单位（若已知）
16    return pd.DataFrame(rows) # 汇总成表
17 dictionary = field_dictionary(survey, UNITS) # 生成字段字典
18 dump(dictionary, "l4_data_dictionary.csv") # 落盘为 CSV

```

同一份字典同时导出 CSV 与 Markdown, 可直接贴进报告; 完整程序见

website/code/lecture04/l4_01_docs_metadata.py.

文档与数据契约 Documentation and Data Contracts

两者分工

- ▶ **文档**：给人读——背景、方法、口径、许可、版本历史；
- ▶ **契约**：给机器读——类型、取值域、缺失约定、主键唯一性（L3 已讲）；
- ▶ 二者应当**同源**：契约变化时文档必须同步，反之亦然。

版本与校验和

应记录**版本**（**时间戳** + **独立 ID**）与**校验和**：前者让“哪一版”可追溯，后者让“文件是否被改过”可检测。配合 L3 的**不可变快照**，就得到一条完整的证据链。

实操建议：把校验和写进发布脚本的日志（sha256sum），并把“数据版本号”写进每张图的图注。

来源：版本与校验和要求据数据管理通行做法；与 L3 契约体系的衔接为本讲整理。

小结：文档的验收标准 Documentation Acceptance Criteria

四条标准

1. **可理解**：外人读文档能说清“这数据是什么、什么口径”；
2. **可追溯**：每个字段都有来源与处理记录；
3. **可校验**：版本号与校验和能证明文件未被改动；
4. **可同步**：数据变了，字典与契约同时更新。

进入 Part 2 之前自查

- ▶ 我的 README 有 20 项要素中的哪几项？
- ▶ 有没有**自动生成**的字段字典？
- ▶ 单位与缺失约定写清楚了吗？

下一部分 (17-30 页)：**单变量描述统计**——中心、离散、形状三件套。

描述统计 vs 推断统计 Descriptive vs Inferential

核心定义 Definition

描述统计量（可数名词）是定量地描述或概括一批信息特征的**汇总统计量**；而**描述统计学**（不可数名词）是使用与分析这些统计量的**过程**。它与**推断统计**的区别在于目标：**概括样本**，而不是用样本去认识它所代表的总体。

常用度量

- ▶ **集中趋势**：均值、中位数、众数；
- ▶ **离散程度**：标准差（方差）、最小值与最大值、峰度、偏度。

报告里的三种用途：(1) **体检**——先看数据是否合理（有无异常、偏态、双峰）；(2) **汇报**——用少数几个数字概括现状；(3) **建模前**——决定要不要取对数、要不要标准化。 Describe first, infer later.

来源：描述统计与推断统计的区分据统计学通行定义；三种用途为本讲整理。

集中趋势 Measures of Central Tendency

核心说明 Key points

集中趋势关注数据的**平均或中间取值**，而离散程度关注数据的**分散情况**；这两类度量借助图形、表格与讨论，帮助人们理解所分析数据的含义。集中趋势描述一个数据分布**中心位置**：分析者考察分布中每个数据点出现的频次，用**均值、中位数或众数**来概括最常见的模式。

该选哪一个

- ▶ **均值**：对称、无极端值时最有效，且便于代数运算；
- ▶ **中位数**：右偏或有离群点时更代表“典型值”；
- ▶ **众数**：类别型数据、或想找“最常见取值”时用；
- ▶ 报告建议：**均值与中位数一起给**，差异本身说明偏态。

直观例子：均值 65 分（满分 100）听起来“中等”，但数据里可能同时存在 1 分与 100 分——这正是需要离散度量的原因（下一帧）。

离散程度 Measures of Variability

核心说明 Key points

离散程度 (或“散布度量”) 帮助分析一组数据的分布有多分散: 集中趋势给出平均值, 却没有说明数据在集合内如何分布。极差、四分位数、绝对偏差与方差都是离散度量的例子。

经典数字例子

数据: 5, 19, 24, 62, 91, 100; 极差 = $100 - 5 = 95$ (最大值减最小值)。

四个常用指标的脾气

- ▶ 极差: 只看两端, 对离群点最敏感;
- ▶ IQR ($Q3 - Q1$): 稳健, 配合箱线图使用;
- ▶ MAD (中位数绝对偏差): 稳健的“平均偏离”;
- ▶ 方差/标准差: 代数性质好、可分解, 但被离群点放大。

来源: 离散程度的定义与经典数字例子 (极差 95); 四个指标的比较见样本页 (23–24 页)。

分布与频数分布 Distribution

核心说明 Key points

分布 (或**频数分布**) 指的是某个数据点出现的**次数**, 或者等价地, 是某个数据点**未出现**的度量。例子: 性别序列 male, male, female, female, female, other 的分布为——男性 2 人、女性 3 人、其他 1 人、非男性 4 人。

三个容易混的概念

- ▶ **频数**: 出现了多少次 (男 = 2);
- ▶ **占比**: 频数除以总数 (男性 33.3)
- ▶ **密度**: 连续变量的单位区间频数 (直方图的纵轴)。

画图时最容易犯的错: 纵轴混用频数与密度, 或者用饼图表达“非男性”这类**补集**——补集不是同一层级的类别。

来源: 频数分布说明与性别计数例子; 三概念区分与画图提醒为本讲整理。

偏度 Skewness

计算口径 Formula

偏度（有时称相对偏度）计算为对均值的偏差三次方的平均，再除以标准差的三次方以消除量纲。按此度量：对称分布偏度为 0，正偏（右偏）为正，负偏（左偏）为负。

怎么读

- ▶ **右偏**（收入、房价、成交量）：均值 $>$ 中位数，长尾在右；
- ▶ **左偏**（考试成绩天花板效应）：均值 $<$ 中位数；
- ▶ 经验门槛： $|skew| > 1$ 视为明显偏态，考虑取对数或分位数描述。

本讲样本：城市 GDP 与月收入都是典型右偏——所以后面两个样本页都同时给出均值与中位数。

来源：偏度的标准差标准化口径；经验门槛与样本对应为本讲整理。

峰度 Kurtosis

核心说明 Key points




峰度度量分布尾部相对于其余部分的权重——也就是落在均值 2.5 个标准差之外的总概率比例。比正态分布尾部更厚的称 leptokurtic (厚尾), 更薄的称 platykurtic (薄尾), 与正态相近的称 mesokurtic。厚尾 (薄尾) 分布比正态分布更频繁 (更少) 地产生极端偏离。

为什么关心

- ▶ 厚尾意味着极端事件比正态假设下更常见;
- ▶ 金融收益、灾害损失、网络流量都是厚尾;
- ▶ 用正态分布假设做风险管理会系统性低估极端风险 (衔接 L13)。

来源: 峰度定义与 leptokurtic / platykurtic / mesokurtic 三类命名; 风险管理含义为本讲整理。


【样本 + 可视化】中心趋势的稳健性 Robustness of the Mean



1000 个收入观测 + 3 个高收入离群点：逐个加入离群点后，**均值移动 +12.5%**，**中位数只移动 +0.7%**；右图对比五个指标被带偏的幅度。

程序 14_02_descriptive_stats.py · 样本 14_income_skewed.csv · 统计表 14_descriptive_table.csv

【样本 + 可视化】离散程度与分布形状 Dispersion and Shape



左一：同一均值、不同离散；左二：标准差 / IQR / MAD 三个离散指标；右二：偏度（左偏 / 对称 / 右偏）；右一：峰度（厚尾 $t(3)$ / 正态 / 薄尾均匀）。

程序 14_02_descriptive_stats.py · 四联图一次讲清“离散”与“形状”两组概念

【代码】描述统计一条龙 A Full Descriptive Pass

```
1 def describe_series(s):                # 计算描述统计量
2     return {                            # 逐项计算
3         "n": int(s.notna().sum()),      # 有效样本量
4         "mean": float(s.mean()),       # 均值
5         "median": float(s.median()),   # 中位数
6         "mode": float(s.round(1).mode().iloc[0]), # 众数 (按 0.1 分箱)
7         "std": float(s.std(ddof=1)),    # 标准差
8         "range": float(s.max() - s.min()), # 极差
9         "iqr": float(s.quantile(.75) - s.quantile(.25)), # 四分位距
10        "mad": float((s - s.median()).abs().median()), # 中位数绝对偏差
11        "skew": float(s.skew()),        # 偏度
12        "kurt": float(s.kurt()),        # 超额峰度
13    }                                     # describe_series 的返回字典结束
14 rows.append({"样本": "含离群点", **describe_series(df["income_k"])} ) # 汇总一行
15 table = pd.DataFrame(rows).round(3)    # 三组对照 (纯净 / 含离群 / 经典例子)
16 dump(table, "l4_descriptive_table.csv") # 落盘描述统计表
```

要点：把统计量打包成函数，换一份数据即可复用；输出直接落盘成表，与图一起进报告。完整程序

l4_02_descriptive_stats.py。

单变量图型五件套 Five Univariate Charts

五类基础图型

变量分布的特征可以用图形或表格表示，包括直方图与茎叶图。

怎么选

报分布形状 → 直方图或小提琴；报“典型值与离散” → 箱线图；报阈值比例 → ECDF；样本很小 ($n < 100$) → 茎叶图或点图 (dot plot)。

五种图各管什么

- ▶ 直方图：看形状（偏态、双峰、长尾）——分箱数会改变观感；
- ▶ 箱线图：看四分位与离群点，适合分组比较；
- ▶ 小提琴图：箱线 + 核密度，能看出多峰；
- ▶ ECDF：看分位数与阈值比例（“多少人低于 X”）；
- ▶ 茎叶图：保留原始数值，适合小样本精读。

分布形状怎么读 Reading the Shape

四个信号

- ▶ **双峰**：很可能混了两个总体（两个城市、两种产品），应先分层再看；
- ▶ **长尾**：极端值或幂律过程，考虑取对数或改用分位数指标；
- ▶ **断点 / 尖峰**：编码问题（上限截尾、四舍五入到整数）；
- ▶ **零堆积**：大量 0 值（未购买、未点击），需要两阶段模型。


对应动作

信号	处理
双峰	分层/分面后重画
长尾	取对数、报中位数
尖峰	查数据字典与采集规则
零堆积	分开建模或改为二值

记住：图形异常往往是数据问题的线索，先查数据、再改模型——这与 L3 的清洗流程直接衔接。

来源：信号与处理对应为描述统计实践整理；与 L3 清洗流程衔接。

【样本 + 可视化】同一变量、五种画法 One Variable, Five Charts



同一列城市 GDP：直方图（分箱决定观感）、箱线图（离群点）、小提琴图（密度形状）、ECDF（阈值比例）、茎叶图（保留原值）。**换图型就换视角。**

程序 14_05_chart_zoo.py · 样本 14_city_gdp.csv (40 个城市)

单变量陷阱 Univariate Pitfalls

- ▶ **均值掩盖双峰**：两个城市混在一起，均值落在“无人区”；
- ▶ **均值 vs 百分位**：平均工资上涨可能只因高收入者变多；
- ▶ **分箱数操纵观感**：同一数据 10 箱与 50 箱讲出两个故事；
- ▶ **缺失被默认丢弃**：均值只对“有价值的人”成立，结论外推有偏；
- ▶ **量纲混淆**：元 / 万元 / 千元混用，均值差 1000 倍。


三条习惯

1. 任何均值旁边都配一个中位数；
2. 报分布时同时给样本量与缺失率；
3. 分箱参数写进图注 (bins=30、区间上下界)。

本讲后续的所有图都遵守这三条：**样本量**、**缺失处理**、**参数**写在图注里，别人才能复核。

来源：陷阱据描述统计实践与本讲样本 (I4_01、I4_02) 整理。

小结：中心、离散、形状 The Descriptive Trio



报告模板（一句话）

“该变量共 n 个有效观测（缺失 x 条），中位数 m （均值 $\bar{x}$ ），四分位距 IQR ，偏度 sk ，呈右偏分布。”

下一步

单变量只是起点：真实结论往往在两个变量的关系里——进入 Part 3（双变量与多变量）。

双变量与多变量总览 Bivariate and Multivariate

核心要点 Key points

当样本包含多个变量时，描述统计可以用来刻画变量之间的关系。此时描述统计包括：

- ▶ 交叉表与列联表；
- ▶ 用散点图做图形表示；
- ▶ 依赖性的定量度量；
- ▶ 条件分布的描述。

来源：多变量描述的四项内容；用途对应为本讲整理。

四件事各自的用途

工具	回答什么
列联表	两个类别变量是否相关
散点图	两个数值变量的关系形态
相关系数	关系强度（且仅限线性/单调）
条件分布	在另一变量取定值时的分布

列联表与交叉表 Contingency Tables

读法（三张表顺序）

1. 频数表：每格多少人；
2. 行百分比：看“同一行内”的构成差异；
3. 列百分比：看“同一列内”的来源差异。

只报频数几乎看不出关系——**占比才可比**。

关联强度

- ▶ **卡方检验**：判断“是否独立”（只给“有/无”，不给强度）；
- ▶ **Cramér's V**：0—1 的强度指标（本讲样本给出具体数值）；
- ▶ **门槛**：0.1 弱、0.3 中、0.5 强（经验值，需结合语境）。

本讲样本：**收入档** × **触达渠道**的交叉表——行百分比显示高收入者更常走线上渠道，但关联强度偏弱，结论只能写成“有差异”而非“渠道决定收入”。

来源：列联表读法为通用实践；Cramér's V 与门槛经验值为本讲补充（对应代码页 I4_03）。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 4 Data Description & Visualization 第四讲-数据描

述与可视化 | **双变量与多变量** Bivariate and Multivariate

相关: Pearson 与 Spearman Which Correlation?

度量说明 Measures

依赖性的定量度量包括**相关**——两个变量都连续时用 **Pearson's r** , 其中一个或两个不是连续变量时用 **Spearman's ρ** ——以及**协方差** (它反映变量的测量尺度)。

使用边界

- ▶ Pearson: **线性**关系、无极端离群点; 对离群点极敏感;
- ▶ Spearman: **单调**关系即可, 对离群点稳健、可用于有序变量;
- ▶ 两者差距很大时, 通常说明**关系非线性或有离群点**。

最常被误读的一句话: "**零相关不等于没有关系**"——抛物线关系、分段关系都可能给出 $r \approx 0$ 。先画散点图, 再谈相关系数。

来源: 相关度量的定义; 使用边界与“零相关”提醒为本讲整理。

协方差与回归斜率 Covariance and Slope

两种斜率的区别

回归分析中的斜率同样反映变量间关系：未标准化斜率表示预测变量变动一个单位时，被解释变量变动的单位数；标准化斜率则表示以标准化(z 分数)单位衡量的这种变化。

两点提醒

- ▶ 协方差受量纲影响：把“元”换成“万元”，协方差缩小 10000 倍，相关系数不变；
- ▶ 未标准化斜率不能跨变量比较：要比“哪个变量更重要”，用标准化斜率或弹性。

国际贸易场景示例：引力模型里 $\ln(\text{贸易额})$ 对 $\ln(\text{距离})$ 的斜率可直接读作弹性，这就是本讲样本采用的设定（距离每增加 1%，贸易额下降约 1.15%）。

来源：斜率与标准化斜率的定义；量纲提醒与弹性示例为本讲整理。

对数变换：让图更对称 Log Transform

核心建议 Recommendation

高度偏态的数据常常通过**取对数**来变换：使用对数会让图形**更对称**、**更接近正态分布**，从而更容易直观解释。

三个好处 + 一个代价

- ▶ 压缩右尾，极端值不再主导坐标轴；
- ▶ 斜率读作**弹性**（百分比对百分比）；
- ▶ 乘法关系变成加法关系，便于线性模型；
- ▶ 代价：**不能再直接读“元”**，且 0 与负数需要 $\log(1 + x)$ 等处理。

本讲样本：城市 GDP 与月收入取对数后偏度显著下降——这也解释了为什么宏观与金融数据几乎总是“取对数后再画”。

来源：对数变换的动机；好处与代价为本讲整理（与 L3 的变换一节衔接）。

受限取值范围如何削弱相关 Restricted Range

现象：截断即削弱

一个经典演示： X 与 Y 的 Pearson/Spearman 相关系数，分别对应“两个变量取值范围**不受限**”与“ X 的范围被**限制在区间 $(0, 1)$** ”两种情形。结论：**截断取值范围会削弱相关系数**。




为什么会这样

相关系数衡量的是**共同变化**；当一端的取值被切掉，共同变化的“幅度”随之减少，剩下的只是局部斜率——于是 r 变小，甚至方向都可能改变。

实务含义：“**只研究某个区间**”必须先声明；把样本限制在“最近 25% 的贸易伙伴”里，再报一个很高的相关系数，是典型的选择性报告。

来源：受限取值范围削弱相关的经典结论；机制解释与实务含义为本讲整理。


【样本 + 可视化】受限范围实验 Restricted Range in Action



220 对国家对的引力模型数据：全样本 $\text{Pearson} = -0.589$ 、 $\text{Spearman} = -0.606$ ；只保留“最近 25%”的伙伴后降到 -0.200 与 -0.213 ——相关强度只剩三分之一。

程序 14_03_correlation_crosstab.py · 样本 14_trade_pairs.csv · 相关矩阵 14_correlation_{pearson,spearman}.csv

【样本 + 可视化】多变量三视图 Multivariate Views



60 家企业 $\times$ 8 年面板: 相关矩阵 (发散色板)、按行业着色的散点 (分组是否改变关系)、行业营收小多图、各行业 ROA 的条件分布 (箱线)。

程序 14_04_multivariate.py · 样本 14_firm_panel.csv · 条件均值 14_conditional_roa.csv

【代码】相关、列联表与条件均值 Correlation & Crosstabs

```
1 log_trade = np.log(pairs["trade_usd"])      # 取对数: 右偏变量对称化
2 log_dist = np.log(pairs["distance_km"])     # 距离同样取对数
3 r_full = np.corrcoef(log_dist, log_trade)[0, 1] # Pearson 相关 (全样本)
4 rho_full = pd.Series(log_dist).corr(pd.Series(log_trade), method="spearman") # Spearman
5 cut = np.quantile(log_dist, 0.25)           # 25% 分位作为截断点
6 mask = log_dist <= cut                      # 截断掩码: 只留最近的伙伴
7 r_restricted = np.corrcoef(log_dist[mask], log_trade[mask])[0, 1] # 受限后的 Pearson
8 corr_pearson = analyze.corr(method="pearson").round(3) # 相关矩阵
9 ct = pd.crosstab(survey["income_band"], survey["channel"], # 交叉表
10                 margins=True, margins_name="合计") # 带边缘合计
11 ct_pct = pd.crosstab(survey["income_band"], survey["channel"], normalize="index") # 行百分比: 看同一行内的构成差异
12 chi2, p, dof, expected = chi2_contingency(core) # 卡方检验: 是否独立
13 cramers_v = float(np.sqrt(chi2 / (n_obs * (min(core.shape) - 1)))) # Cramér's V
```

一段代码同时给出**全样本与受限范围**的两种相关, 以及**列联表 + 卡方 + 强度指标**: 结论是否有条件依赖, 一眼可见。完整程序 14_03_correlation_crosstab.py。

分组比较与小多图 Small Multiples

常用图型清单

常用图型包括：柱状图、分布图、**权重趋势图**、散点图、**相关性矩阵图**、热力图、趋势图、流程图。

分组的正确做法

- ▶ **小多图**：每个类别一格，形状可比、互不遮挡；
- ▶ **颜色上限**：一张图最多 4—5 种颜色，超过就分面；
- ▶ **统一坐标轴**：分面之间轴范围要一致，否则比较无效；
- ▶ 分组后**样本量写进图注**（小组的线更抖）。

反例：把 15 个行业画在一条图里、用 15 种颜色——读者只能看到”毛线球”。**该分面就分面。**

来源：常用描述统计图型清单；分组做法见样本页（38 页的小多图）。

大数据分析 [2026 国际商务] Big Data Analytics | Lecture 4 Data Description & Visualization 第四讲·数据描

述与可视化 | **双变量与多变量** Bivariate and Multivariate

条件分布与辛普森悖论 Conditional Distributions

什么是条件分布

在另一个变量取定值时，目标变量的分布。例如“线上渠道的满意度分布”与“门店渠道的满意度分布”——**比较的是分布，而不只是均值**（均值可能相同、分布完全不同）。

辛普森悖论

总体上的关系与**每个子组内**的关系方向相反：分组变量的分布不均衡时就会发生。对策：**先分层看图，再决定是否控制分组变量**（衔接 L12 因果推断）。

操作建议：任何“总体相关”都要配一张**分组散点或条件箱线**；如果分组后关系反转，报告必须同时给出两层结论。

来源：条件分布是多变量描述的内容之一；辛普森悖论与对策为本讲整理。

小结：相关三问 Three Questions about Correlation

三问


1. 方向：正还是负？（看散点与系数符号）
2. 强度： $|r|$ 多大？（结合语境，不看“0.5 就强”）
3. 形式：线性还是单调？有没有分组/截断？

两条纪律

- ▶ 报相关系数**必配散点图**（Anscombe 四组数据的教训）；
- ▶ 报相关系数**必写样本范围**（受限范围会削弱相关）。

下一部分（43–56 页）：**图型选择与图的语法**——把“关系”翻译成“图形”。

图的语法 The Grammar of Graphics



Same data, different mapping, different truth.

核心原则 Core principle

从学术角度看，可视化可视为**原始数据**（通常是数值）到**图形元素**（图中的线或点）的映射；映射决定了这些元素的属性如何随数据变化。例如**柱状图**就是把柱子的长度映射到变量的数量。由于映射的图形设计会影响图表的可读性，映射是数据可视化的核心能力。

来源：三层结构与通道概念为图形语法的通用框架（Wilke、Munzner）。

通道有效性排序 Which Channel Is Most Accurately Read

从最准到最不准

1. **位置** (共同刻度上的点): 最准;
2. **长度** (条形): 很准;
3. **角度 / 斜率**: 中等 (饼图与折线斜率都靠它);
4. **面积**: 较不准 (人眼按半径估面积, 会高估);
5. **体积 / 3D**: 最不准;
6. **颜色明度、色相**: 适合分类与顺序, 不适合精确比较。

实践含义

- ▶ 要“比大小”→ 用位置或长度 (条形图、点图);
- ▶ 别用饼图比较相近的占比 (第 79 页有对照实验);
- ▶ 气泡图要**按面积**编码, 不能按半径;
- ▶ 颜色只做“辅助通道”, 并配冗余编码。

来源: 通道有效性排序据可视化感知实验的通用结论 (Cleveland & McGill 系列研究); 实践含义为本讲补充。

按问题选图 Choose the Chart by the Question

问题类型	首选图型	次选 / 慎用
比较多少	条形图 / 点图 (排序后)	雷达图 (难比); 饼图 (只适合 2—3 类)
看分布	直方图 / 箱线图 / 小提琴图 / ECDF	均值 $\pm$ 误差棒 (会隐藏多峰)
看变化	折线图 (注意基线与平滑)	面积堆叠 (只看总体趋势)
看关系	散点图 / 相关矩阵 (防过绘)	双轴折线 (会制造伪相关)
看构成	堆叠条形图 / 桑基图	饼图与环形图 (角度不精确)
看空间	choropleth (比率) / 符号地图 (总量)	3D 地图 (面积与视角双重误导)
看结构	网络图 (少节点、少颜色)	力导向大图 (除非做交互探索)

用法：先写出你的**问题句**（“哪几个渠道的满意度更高？”），再查这张表——问题决定图型，而不是反过来。

来源：决策表据图表选择通用实践整理；覆盖常用描述统计图型。

比较与分布 Comparison and Distribution

比较类：柱状图与条形图

- ▶ **排序**是最便宜的改进：读者一眼看出高低；
- ▶ 纵向柱 (column) 适合时间；横向条 (bar) 适合长标签；
- ▶ **纵轴从 0 开始** (柱状图的基本纪律，第 75 页)；
- ▶ 类别超过 10 个 → 取前 N 名 + “其他”。

分布类：箱线与小提琴

- ▶ 箱线图适合**分组比较** (同轴、同尺度)；
- ▶ 小提琴图能看出**多峰**，但需要足够的样本量；
- ▶ 小样本 ($n < 20$) 直接画**点图**，不要画箱线；
- ▶ 报分布时写出 n 、中位数与四分位。

“柱状图 / 分布图”对应的就是这两类问题，已放入上面的选图决策表。

来源：要点据常用图型与上面的选图决策表整理。

时间类：趋势图与权重趋势图 Trends over Time

两类时间图

权重趋势图 (weight trend) 与**趋势图** (trend)。前者常用于组合权重随时间的变化（金融场景），后者用于指标本身随时间的变化。

平滑与噪声

移动平均、季节性调整能让趋势更清楚，但**必须写在图注**：平滑会掩盖转折点，也可能制造“趋势”（端点效应）。

基线怎么选

- ▶ 指数化（首期 = 100）便于不同量级对比；
- ▶ **断轴是禁忌**（第 75 页），但“从 0 起”对折线不是硬性要求——折线比较的是**变化率**，不是长度；

脉冲图是事件型的极端情形：把政策/事件在时间轴上**标注**出来，让读者看到“变化发生在什么时候”。

来源：时间类图型（趋势图、权重趋势图、脉冲图）；基线与平滑提醒为本讲整理。

关系类：散点、相关矩阵与热力图 Scatter, Matrix, Heatmap

散点图的头号问题：过绘

点太多会糊成一片。对策：调透明度、抖动、抽样、改用二维密度或六边形分箱 (hexbin)，或者直接画分位数曲线。

矩阵与热力图的用法

- ▶ 相关矩阵：发散色板 + 数值标注（本讲样本采用）；
- ▶ 上三角重复，可只画一半；
- ▶ 聚类重排 (clustered heatmap) 能发现“成块的变量”；
- ▶ 热力图不要用彩虹色板（顺序感错乱）。

“散点图、相关性矩阵图、热力图”正对应这三件事；本讲用企业面板数据把它们一次画全（样本页 38 页）。

结构与流程：流程图与网络图 Structure and Flow

两类结构图

流程图（描述分析流程、供应链路径）与**网络图**（Gephi 的图与网络可视化、CiteSpace 的引文结构、SNAP 的专利引文图）。

画好网络图的四条

1. **节点数**控制在几十个以内，否则先聚合或筛选；
2. **布局**要说清（力导向 / 环形 / 地理），并固定随机种子；
3. **用大小与颜色编码不同含义**（度数、社群），并给图例；
4. 大图交给**交互工具**（Gephi/CiteSpace）探索，报告里放简化版。

供应链、贸易网络、引文网络都能用同一套读图法：**先看枢纽，再看社群，最后看方向。**

来源：结构与网络图型及常用外链；四条做法为本讲整理（对应第 74 页的贸易网络案例）。

事件叙事：脉冲图与时间轴标注 Impulse Charts

脉冲图 Impulse chart

脉冲图把**事件**与**指标变化**放在同一时间轴上：指标随时间变化，事件以竖线或标记出现，用来回答“变化发生在什么时候、可能因为什么”。

三个要点

- ▶ 事件**必须真实可考**（政策发布日、财报日），并写明来源；
- ▶ 标注不要遮挡数据（放在图外或用引线）；
- ▶ **不要暗示因果**：时间相邻不等于因果（衔接 L12）。

本讲样本的能量与实验数据都可以加事件标注：例如“某月起更换计费方式”——这类图在国际贸易与金融复盘很常用。

来源：脉冲图（事件型时间图）；要点与因果提醒为本讲整理。

图表规范 Figure and Table Conventions

编号与排版规范

正文中出现的图表力求简明；图次与表次一律写成图 1、图 2.....或表 1、表 2.....，并尽可能随文排（放在首次提到的正文附近）。

图注自足性（本讲强调）


一条合格的图注要能回答：

- ▶ 数据是什么（来源与文件）；
- ▶ n 是多少、缺失怎么处理；
- ▶ 口径与单位；坐标轴是否截断；
- ▶ 不确定性（误差棒/区间）与统计方法。

图注示例（本讲 88 页模板给出完整版）：“图 1 各渠道满意度均值（数据 l4_survey_raw.csv, $n = 500$ ；满意度 1—5 分，缺失 5 条未插补；纵轴自 2.5 起，仅用于观察渠道间差异）。”

来源：图表编号与随文排的通行规范；图注自足性四要素为本讲整理。

【样本 + 可视化】七类图型总览 The Chart Zoo



(1) 柱状图（比较）(2) 分布图(3) 趋势图(4) 散点图（关系）(5) 相关矩阵(6) 条形图（构成）(7) 网络图（结构），第八格给出按问题选图的口诀——覆盖常用图型清单。

程序 14_05_chart_zoo.py ·样本 14_city_gdp.csv、14_category_counts.csv

【代码】图表工厂：统一风格、批量出图 A Chart Factory

```
1 def style_axes(ax, title=None, xlabel=None, ylabel=None): # 统一设置标题与轴标签
2     if title: # 有标题才设置
3         ax.set_title(title) # 设置子图标题
4     if xlabel: # 有横轴标签才设置
5         ax.set_xlabel(xlabel) # 设置横轴标签
6     return ax # 返回同一对象便于链式调用
7 def annotated(ax, text, loc="upper left"): # 在图内加注释
8     xy = {"upper left": (0.02, 0.96), "lower right": (0.98, 0.06)}.get(loc, (0.02, 0.96)) # 位置字典: 未知位置退回左上
9     ax.text(xy[0], xy[1], text, transform=ax.transAxes, va="top", ha="left", # 用轴坐标放置文字
10            fontsize=8.6, bbox=dict(boxstyle="round", pad=0.25, fc="#F7F3F2"))
11     return ax # 返回同一对象
12 fig, axes = plt.subplots(2, 4, figsize=(13.8, 6.1)) # 两行四列共八格
13 axes[0, 0].bar(top["city"], top["gdp_yi"], color="#8A0C3C") # 柱状图: 比较大小
14 axes[0, 1].hist(cities["gdp_per_cap"], bins=18) # 分布图
15 axes[0, 2].plot(range(len(trend)), trend, "-") # 趋势图
16 axes[0, 3].scatter(cities["pop_wan"], cities["gdp_yi"], s=22) # 散点图
```

把标题、轴标签、图内注释封装成函数后，每张图只剩一两行代码——风格自然统一，也方便统一改字号与色板。完整程序 14_05_chart_zoo.py。

坐标轴、刻度与基准线 Axes and Scales

四条规则

1. 柱状图纵轴必须从 0 开始 (长度编码);
2. 折线图可以不从 0 起, 但必须在图注声明并给出提示 (如断轴符号);
3. 对数轴用于跨数量级数据, 刻度要标出真实数值 (1、10、100);
4. 避免双轴: 两个量纲放在一张图里, 视觉相关是画出来的, 不是数据里的。

刻度与网格

- ▶ 刻度数 4—8 个为宜, 间隔取整齐的数 (1、2、5 的倍数);
- ▶ 网格线要浅, 主要给“读数”服务;
- ▶ 基准线 (0 线、目标线、均值线) 要显式标注含义。

来源: 规则据图表设计通用实践整理; 双轴风险与第 77 页的误导对照直接呼应。


颜色：连续、分类与发散 Three Kinds of Palettes

色板类型	适用数据	例子与注意
连续 / 顺序	有大小顺序的连续变量 (GDP、密度、相关性强度)	viridis、RdPu; 浅 → 深要有单调亮度变化
分类	无序类别 (行业、国家、渠道)	Okabe-Ito、ColorBrewer; 最多 5—8 种
发散	有中心基准的差异 (增长率、相对均值偏离)	RdBu; 中心必须是“零/基线”

三条纪律：(1) 颜色**不承担精确比较** (用位置/长度); (2) **分类色板要色盲友好** (第 84 页); (3) 同一份报告里**同一含义用同一颜色**, 不要让红色一会儿是“亏损”一会儿是“中国”。

来源：色板分类与实例据 ColorBrewer 与 matplotlib 官方文档；纪律为本讲补充。

小结：图表选择五步 Choosing a Chart in Five Steps



自检

把图给同学看 10 秒，他能说出你的结论吗？
说不出，问题多半在第 1 步或第 3 步。

下一步

下一部分 (57-74 页)：用Python 把这些图做出来——交互图、仪表板与地理信息可视化。

可视化的定义 What Data Visualisation Is

核心定义 Definition

数据与信息可视化是一个跨学科领域，处理**数据与信息**的**图形表示**。当数据或信息量很大时（例如时间序列），它是一种特别高效的沟通方式。它也是研究**抽象数据的视觉表示**以增强人类认知的学问；抽象数据既包括数值也包括非数值（如文本与地理信息）。

来源：可视化定义据可视化研究通行表述。

为什么有效

人眼对**位置与长度**的分辨远快于对数字的分辨：一张好的图把“比较”从“读数字”变成“看形状”，把注意力留给**结论**而不是**检索**。

信息可视化 vs 科学可视化 Info-viz vs Sci-viz

两者区别 The distinction

当空间表示是“选定的”（例如平面设计的页面布局）时，称为**信息可视化**；当空间表示是“给定的”（例如真实的物理空间）时，称为**科学可视化**。它与信息图（infographics）和科学可视化都相关。

在本课程中的对应

- ▶ **信息可视化**：柱状图、热力图、网络图——布局由我们决定；
- ▶ **科学可视化**：地图、气象场、医学影像——坐标由现实决定；
- ▶ 本讲第 67–73 页的地图部分属于后者：**位置的正确性不可协商**。

来源：信息可视化与科学可视化的区分据可视化研究通行表述；与地图部分的对应为本讲整理。

工具全景：本讲统一到 Python Tools Overview

工具	擅长	本讲的用法
Stata	计量分析强；图形标准化、地图与网络	保留命令对照，操作全部用 Python 完成
Tableau	拖拽式看板、交互筛选	用 plotly 子图 + HTML 实现（第 65–66 页）
R	ggplot2 图形语法、统计图生态	作为对照：图形语法的思想与 Python 相通
Python	生态最全、可编程、可复现	本讲全部示例 ：matplotlib / seaborn / plotly

统一到 Python 的三个理由：(1) 与 L3 的整备脚本同一套环境，**一条流水线跑到底**；(2) 图表**可复现**（脚本化、固定种子）；(3) 免授权、免安装商业软件，同学在自己电脑上就能做。

来源：工具定位据各工具官方文档；“统一到 Python”为按本学期教学口径确定（不使用 Power BI / Tableau）。

Stata: 能力与边界 Stata Revisited

能力与边界

- ▶ **优势**: 专注计量经济分析;
- ▶ **短板**: 图形较为标准, 没有地图与网络图形工具;
- ▶ **常用命令**: `twoway`、`matrix`、`bar`、`box`、`dot`、`pie`。

启示

工具的能力边界决定了你的图能表达什么: 需要**地图**、**网络**、**交互**时, Stata 的短板就出现了——这不是“哪个软件更好”, 而是**任务与工具的匹配**。本讲的地图与交互示例正是为补上这两块。

如果你后续做计量分析, Stata 依然很好用; 但**把结果导出到 Python 里画图**是常见做法: 两者各司其职, 数据口径仍要统一。

来源: Stata 的能力与常用命令; 启示与分工建议为本讲整理。

Python 生态：四件套 The Python Stack

库	定位	本讲对应
matplotlib	底层可控：一切都能调，适合定稿出图	13 张样本图的主力（第 53 页）
seaborn	统计图形快捷接口：分布、分组、回归	分布与分组对照
plotly	交互图与地图：悬浮、缩放、导出 HTML	交互图、仪表板、choropleth（第 63–70 页）
altair	声明式语法（Vega-Lite），适合规范化出图	作为“图形语法”的延伸了解

推荐学习资源：python-graph-gallery.com（按图型找代码）、Kaggle Learn 的 Data Visualization 课程；R 侧对应 data-to-viz.com 与 r-graph-gallery.com。

来源：库定位与本讲映射为本讲整理；资源链接见各站官网。

R 生态与“按图选型”资源 Learning by Chart Type

ggplot2 的图形语法

用 `ggplot(data, aes(...)) + geom_*()` 组合图层：把“数据—通道—几何对象”的语法写成代码——这与第 43 页的图的语法完全一致，看懂一种，另一种自然通。

两个站点的用法

- ▶ data-to-viz.com: 按数据类型与问题推荐图型;
- ▶ r-graph-gallery.com / python-graph-gallery.com: 按图型找可复制的代码;
- ▶ Kaggle Learn: 交互式练习。

学习建议：不要从“库的 API”学起，而要从“我要表达什么”出发去检索图型——本讲的选图决策表（45 页）就是检索关键词表。



来源：资源与用法据各站官方说明；学习建议为本讲整理。

【代码】交互图表与导出 Interactive Charts with plotly

```
1 line_fig = px.line(energy, x="month", y="generation_twh", color="source", # 折线: 按能源着色
2                     title="月度发电量 (可悬浮查看数值、可框选缩放)", # 标题写明交互能力
3                     labels={"month": "月份", "generation_twh": "发电量 (TWh)"} # 中文轴名
4 line_fig.write_html(INT / "energy_trend.html", include_plotlyjs="cdn") # 导出单文件 HTML
5 plot_df = survey.dropna(subset=["satisfaction", "income_k", "spend_k"]) # plotly 不接受缺失值
6 scatter_fig = px.scatter(plot_df, x="income_k", y="spend_k", color="channel", # 散点: 按渠道着色
7                          size="satisfaction", hover_data=["city", "education"]) # 悬浮显示明细
8 scatter_fig.write_html(INT / "income_spend.html", include_plotlyjs="cdn") # 导出交互散点
9 sankey_fig = go.Figure(data=[go.Sankey(
10     node=dict(label=labels, pad=14, thickness=16), # 节点样式
11     link=dict(source=list(range(len(flow))), # 连线起点
12               target=[len(flow) + i for i in range(len(flow))], # 连线终点
13               value=flow["generation_twh"].round(1).tolist())]) # 连线粗细=数值
14 sankey_fig.write_html(INT / "energy_sankey.html", include_plotlyjs="cdn") # 导出桑基图
```

交互图的两个注意点: (1) 缺失值要先处理 (plotly 会直接报错); (2) include_plotlyjs="cdn" 让 HTML 只有几十 KB, 便于随仓库发布。完整程序 14_06_plotly_interactive.py。

【样本 + 可视化】交互图与静态图的分工 Interactive vs Static



左：静态图——信息固定、可打印、进报告；右：交互图——可缩放、筛选、悬浮看数值，适合探索与课堂演示。仓库里附 6 个可打开的交互 HTML（能耗趋势、收入散点、桑基图、世界地图、流向图、仪表板）。


程序 14_06_plotly_interactive.py ·交互文件 figures/lecture04/interactive/ ·样本 14_energy.csv

【代码】Python 仪表盘（替代 BI 工具） A Dashboard in Python

```
1 kpi = {"样本量": f"{len(survey):,}",          # 顶部 KPI 卡: 样本量
2       "平均满意度": f"{survey['satisfaction'].mean():.2f} / 5", # 满意度均值
3       "复购率": f"{survey['revisit'].mean():.1%}", # 复购比例
4       "人均 GDP 中位数": f"{cities['gdp_per_cap'].median()/1e4:.1f} 万元"} # 城市人均
5 fig = make_subplots(rows=2, cols=2,          # 2x2 面板布局
6                     subplot_titles=("各渠道满意度分布", "收入与消费",          # 四个子图标题
7                                     "月度发电量（按能源）", "城市 GDP 与人口")) # 标题续行
8 fig.add_trace(go.Box(y=sub, name=ch, boxmean=True), row=1, col=1) # 左上: 分组箱线
9 fig.add_trace(go.Scatter(x=survey["income_k"], y=survey["spend_k"], # 右上: 散点
10                        mode="markers", name="受访者"), row=1, col=2) # 放到右上格
11 fig.add_trace(go.Scatter(x=sub["month"], y=sub["generation_twh"], # 左下: 时间序列
12                        mode="lines", name="src", row=2, col=1) # 放到左下格
13 fig.add_trace(go.Scatter(x=cities["pop_wan"], y=cities["gdp_yi"], # 右下: 城市指标
14                  text=cities["city"], mode="markers"), row=2, col=2) # 放到右下格
15 fig.write_html(INT / "dashboard.html", include_plotlyjs="cdn") # 导出单文件 HTML 仪表盘
```

同一份数据、同一套口径，同时产出交互 HTML 仪表盘与静态图（第 66 页）；无需服务器与授权，拷给别人双击即可打开。
完整程序 14_07_dashboard.py。

仪表盘设计原则 Dashboard Design



顶部四个 KPI 卡（一眼看结论）+ 2×2 面板（分布、关系、趋势、地理指标）：**一屏之内回答四个问题，而不是把二十张图堆在一起。**

布局层次：结论 (KPI) → 关键对比 → 细节；延伸路径：用 Streamlit 或 Dash 加交互筛选（本讲不依赖服务器，用单文件 HTML）。

地理数据的结构 Structure of Geospatial Data

三种常见形态

- ▶ **点数据**: 经纬度坐标 (门店、港口、事件);
- ▶ **面数据**: 行政区边界 (GeoJSON / Shapefile), 用于 choropleth;
- ▶ **栅格数据**: 卫星影像、气象场, 像元矩阵。

必须知道的两件事

- ▶ **坐标系 (CRS)**: EPSG:4326 是经纬度 (度), EPSG:3857 是 Web 墨卡托 (米); 投影会改变面积与形状;
- ▶ **地理编码**: 地址 → 经纬度, 质量取决于地址库与匹配策略。

本讲做法: 省级边界用公开 GeoJSON (构建时下载并缓存到 data/lecture04/), 点数据直接由经纬度列提供; 若边界文件不可用, 自动退化为**中心点气泡图**, 流程不中断。

来源: 地理数据结构与 CRS 为 GIS 通用知识; 本讲的数据与退化策略见代码页 69 页。

choropleth 与分级方法 Classifying a Choropleth

三种分级

- ▶ **等间距**：按数值区间等分——极值会“吃掉”所有颜色；
- ▶ **分位数**：每类数量相同——视觉对比强，但同类内部差异被隐藏；
- ▶ **自然断点 (Jenks)**：让类内方差最小、类间最大——最贴近数据分布。

画 choropleth 的三条纪律

1. 只能表达**比率或强度**（人均、占比、密度），不要用总量（大区域天然占优）；
2. **写清分级方法与色标**——换一种分级，图就变样；
3. 无数据的区域用**灰色**并说明，不要当成 0。


来源：分级方法与纪律据制图学与数据新闻通用实践；本讲示例见样本页 70 页与代码页 69 页。

【代码】地图三件套：choropleth、符号地图与流向图

```
1 value = prov.set_index("province")["gdp_pc"] # 用省级简称索引的人均 GDP
2 if geojson: # 有边界文件：画真正的 choropleth
3     for feat in geojson["features"]: # 遍历每个省级要素
4         short = feat["properties"]["name"].replace("省", "").replace("市", "") # 名称标准化
5         ring = np.array(feat["geometry"]["coordinates"][0]) # 取外环坐标
6         patches.append(Polygon(ring, closed=True)) # 构造多边形
7         val = float(value[short]) # 该省的人均 GDP
8         colors.append(cmap((val - vmin) / (vmax - vmin + 1e-9))) # 归一化后取色
9         axes[0].add_collection(PatchCollection(patches, facecolor=colors)) # 批量绘制
10 axes[1].scatter(prov["lon"], prov["lat"], s=prov["gdp_yi"] * 3.2, # 符号地图：大小=总量
11                c=prov["gdp_pc"], cmap=SEQ) # 颜色=人均
12 fig_flow.add_trace(go.Scattergeo(lat=links["lat"], lon=links["lon"], # 流向图：终点气泡
13                                marker=dict(size=links["trade_share"] * 2.2, color=links["trade_share"]))) # 终点气泡：大小与颜色编码贸易占比
14 world = px.choropleth(cty, locations="iso3", color="gdp_pc", # 世界分级统计图
15                       locationmode="ISO-3", color_continuous_scale="RdPu") # 用 ISO-3 定位 + 连续色板
```

同一份省级数据画两张图：choropleth 看**比率**、符号地图看**总量**；世界地图用 ISO-3 代码定位（无需几何文件）。完整程序 14_08_geo_maps.py。

【样本 + 可视化】choropleth 与符号地图 Choropleth vs Symbol Map



左: **choropleth**——按省级人均 GDP 填色 (边界来自公开 GeoJSON, 35 个要素); 中: **符号地图**——气泡大小 = GDP 总量、颜色 = 人均; 右: 两种地图的选择依据与分级提醒。

程序 14_08_geo_maps.py · 样本 14_province_gdp.csv · 交互地图 [interactive/map_world_choropleth.html](#)、
[map_trade_flows.html](#)

空间自相关: Moran's I Spatial Autocorrelation

三个概念



- ▶ **空间权重矩阵 W** : 定义“谁是谁的邻居” (邻接或 K 近邻), 行标准化;
- ▶ **空间滞后**: Wz , 即每个地区的邻居均值;
- ▶ **Moran's I**: $I = \frac{\sum_i z_i (Wz)_i}{\sum_i z_i^2}$, 取值约在 -1 到 1 之间。

怎么读

- ▶ $I > 0$: **聚集** (高值扎堆、低值扎堆);
- ▶ $I \approx 0$: 随机分布;
- ▶ $I < 0$: **离散** (高低相间, 像棋盘);
- ▶ 四个象限: HH (高一高)、LL (低—低)、HL、LH; 后两者是**异常点**。

来源: Moran's I 与 LISA 的经典表述 (Anselin); 权重矩阵与滞后的实现见代码页 69 页的程序。

【样本 + 可视化】Moran 散点图 Moran Scatter



31 个省级单位、4 近邻权重：Moran's I = 0.659，象限计数 HH 16、LL 13、LH 2 ——东部高值成片、西部低值成片，说明人均 GDP 存在明显的正向空间聚集。

程序 14_08_geo_maps.py · 样本 14_province_gdp.csv · 结果表 14_moran.csv

地图的四个陷阱 Four Map Pitfalls

陷阱	问题	对策
面积扭曲	大而人少的区域在视觉上占主导	用比率而非总量；必要时用变形地图或网格地图
分级操纵	换一种分级，结论就变	写明分级方法；同时给出连续色标或图例区间
投影选择	不同投影改变面积与形状	标注投影；小范围用等面积投影
MAUP	可塑面积单元问题：聚合层级不同相关也不同	报告时说明空间单元，必要时做多尺度稳健性

一句提醒：地图是**最强的说服工具，也是最容易被操纵的工具**——任何地图都要写清“什么指标、什么分级、什么投影、缺少哪些地区”。

来源：四类陷阱据空间统计与数据新闻实践整理；MAUP 为地理学经典问题（Openshaw）。

网络、引文与贸易流 Networks and Trade Flows

常用资源

- ▶ **WITS** (世界银行) 国际贸易可视化: 出口国—买家网络图, 按 HS 编码、年份、阈值筛选 (wits.worldbank.org);
- ▶ **Gephi**: 开源图与网络可视化探索平台;
- ▶ **CiteSpace**: 文献结构与时序模式的交互可视化;
- ▶ **SNAP** (Stanford): 专利与引文网络数据集。

读图三问

1. **枢纽是谁?** (度数/中心性最大)
2. **社群怎么分?** (聚类着色)
3. **方向与权重?** (箭头与线宽代表什么)

本讲的可复现替代: 用合成贸易数据在 Python 里画流向图与桑基图 (interactive/map_trade_flows.html), 课堂演示 WITS 的真实网络图作为对照。

来源: 资源清单 (WITS、Gephi、CiteSpace、SNAP); 读图三问与 Python 替代方案为本讲整理。

误导 (一): 截断坐标轴 Truncated Axes

手法

把柱状图的纵轴起点从 0 改为“最小值 -1”: 同一份数据, A 组 11.1% 与 B 组 13.1% 的差异在视觉上被放大数倍。

为什么是误导

柱状图用长度编码数值; 截断后长度不再成比例, 读者的“两倍高”直觉与数据无关——这是通道被破坏。

修正

- ▶ 柱状图纵轴一律从 0 开始;
- ▶ 折线图可以聚焦区间, 但要在图注声明并加断轴符号;
- ▶ 想强调差异 → 用差异图 (B-A 的置信区间), 而不是压缩坐标轴。

本讲样本的对照实验: 同一组 A/B 数据, 截断纵轴的版本看起来“B 组遥遥领先”, 从 0 开始的版本显示差异只有 2 个百分点。

误导 (二): 面积、体积与 3D 错觉 Area and Volume Illusions

三个经典错误

- ▶ **气泡按半径编码**: 数值 2 倍 $\rightarrow$ 面积 4 倍, 视觉夸大;
- ▶ **3D 饼图**: 透视让前排扇区显得更大, 角度失真;
- ▶ **双重编码**: 同时用大小与颜色表达同一数值, 视觉上“放大两次”。

修正

- ▶ 气泡**按面积** (代码里 $s \propto$ 数值, 而不是 $\sqrt{\quad}$ 之后的半径);
- ▶ 饼图只在“各部分与整体、且类别 ≤ 3 ”时考虑, 比较相近占比改用条形图;
- ▶ 一个数值只用**一个通道**编码, 其余通道留给别的变量。

来源: 面积/体积错觉与改进做法据可视化感知研究; 对照实验见样本页 79 页第 (2) 列。

误导 (三): 双轴与选择性区间 Dual Axes and Cherry-picking

双轴伪相关

把“转化率”与“样本量”画在左右两个纵轴上，两条曲线的相似完全取决于两个刻度的选择——换个刻度就“不相关”了。正确做法：画散点图看真实关系，并给出相关系数。

选择性区间

只画“实验组领先”的前 5 天，或者只报有利的月份/子样本。对策：画满全部区间，把被截掉的部分标出来，并在图注写明区间选择规则（是否符合预注册 / 事前分析计划）。

这类误导的共同点：不伪造数据，只筛选呈现。因此本讲强调“图的诚实性”也是研究诚信的一部分。

来源：双轴与选择性报告为图表批评与开放科学讨论中的常见问题；对策为本讲补充。

误导 (四): 统计与图形联合 Statistics Meets Graphics

- ▶ **辛普森悖论**: 总体上升, 分组后每组下降 (第 41 页);
- ▶ **幸存者偏差**: 只统计“活下来的个体”, 均值被抬高;
- ▶ **对数轴掩盖绝对差**: 增长率相同, 绝对差距却在扩大;
- ▶ **不报不确定性**: 把“可能”说成“确实” (第 81 页)。


三道防线

1. **分层复核**: 任何总体结论都做一次分组检查;
2. **同时给相对与绝对** (% 与百分点);
3. **区间 + 样本量**: 让读者自己判断证据强度。

记住一条: **图表不会自己撒谎, 选择图表的人会**——本讲的检查清单 (80、87 页) 就是把“选择”摊开给读者看。

来源: 四类联合误导数据统计与可视化实践整理; 与本课程 L12 因果推断主题衔接。

【样本 + 可视化】六种误导手法与修正版 Six Tricks, Six Fixes



上排”误导版”、下排”修正版”：(1) 截断纵轴 (2) 气泡按半径 (3) 双轴伪相关 (4) 只画有利区间 (5) 饼图讲相近占比 (6) 丢掉不确定性——同一份 A/B 数据，六种讲法。

程序 14_09_misleading.py · 样本 14_ab_test.csv ($n = 2400$, A 组 11.14% / B 组 13.11%)

【代码】把图形规范写成断言 Chart Honesty as Assertions

```
1 checks = [                                     # 每条检查给出布尔结论
2     ("纵轴从零开始", True),                     # 修正版都满足
3     ("气泡按面积而非半径编码", True),          # 面积成比例
4     ("不使用双轴表达两个量纲", True),          # 改用散点看关系
5     ("不使用选择性区间", True),                 # 画满全部天数
6     ("不用饼图比较相近占比", True),            # 改用条形图
7     ("给出不确定性(置信区间)", True),           # 带误差棒
8     ("报告样本量与绝对差", True),               # 报告 n 与百分点差
9 ]                                                 # 检查项列表结束
10 assert all(ok for _, ok in checks), "图形规范检查未通过" # 全部通过才继续
11 se_a = np.sqrt(rate_a * (1 - rate_a) / n_a)      # 比例的标准误
12 se_b = np.sqrt(rate_b * (1 - rate_b) / n_b)      # 另一组的标准误
13 CI_A = (rate_a - 1.96 * se_a, rate_a + 1.96 * se_a) # A 组 95% 置信区间
14 CI_B = (rate_b - 1.96 * se_b, rate_b + 1.96 * se_b) # B 组 95% 置信区间
15 overlap = not (CI_A[1] < CI_B[0] or CI_B[1] < CI_A[0]) # 两个区间是否重叠
16 print("两区间是否重叠:", overlap)               # 重叠时结论必须写成"有提示但不确定"
```

本讲样本的实测结论：A 组 95% CI = [9.39%, 12.89%], B 组 = [11.16%, 15.06%], 两区间重叠、差值区间跨 0——所以正确表述是“有提升迹象，尚不能确认”。完整程序 14_09_misleading.py。

不确定性的表达 Showing Uncertainty

四种常用方式

- ▶ **误差棒**：点估计 $\pm$ 标准误/置信区间（柱状图与散点图都能加）；
- ▶ **置信带**：随时间变化的区间（时间序列）；
- ▶ **扇形预测带**：越远越宽（预测场景）；
- ▶ **分布对比**：直接画分布（箱线/小提琴/密度），信息最全。

三条纪律

1. 写清区间**是什么**（95% CI? 标准误? 分位区间? 自助法?）；
2. 写清**重采样次数** B 与方法；
3. 组间比较看**差值区间**，不要只看两个区间是否重叠。

“不画不确定性”往往比“画错不确定性”更危险：读者会把点估计当成事实。


来源：不确定性可视化的分类据统计图形实践；纪律为本讲补充（对应样本页 83 页）。

【代码】自助法与置信带 Bootstrap Confidence Bands

```
1 def bootstrap_ci(values, stat=np.mean, level=0.95, boot=B): # 通用自助法区间函数
2     values = np.asarray(values, dtype=float) # 转成浮点数组
3     idx = RNG.integers(0, len(values), size=(boot, len(values))) # 每次重采样同样大小
4     stats_ = stat(values[idx], axis=1) # 计算每次重采样的统计量
5     lo, hi = np.percentile(stats_, [(1 - level) / 2 * 100, # 百分位区间下界
6                                     (1 + level) / 2 * 100]) # 上界
7     return float(stat(values)), float(lo), float(hi), stats_ # 点估计、区间与分布
8 m, lo, hi, dist = bootstrap_ci(sub["converted"]) # 转化率的自助区间
9 diff_dist = boot_store["实验组 B"][3] - boot_store["对照组 A"][3] # 两组差值的自助分布
10 d_lo, d_hi = np.percentile(diff_dist, [2.5, 97.5]) # 差值的 95% 区间
11 axes[2].fill_between(daily.index, band_lo, band_hi, # 时间序列置信带
12                     color="#8A0C3C", alpha=0.18)
13 axes[3].fill_between(months, center - 2 * width, # 扇形预测带（越远越宽）
14                     center + 2 * width, alpha=0.15) # 95% 预测带（更宽）
```

自助法的好处：不需要分布假设，直接给出区间与分布形状；两组差值区间 $[-0.0056, +0.0456]$ 跨 0，这正是“要写不确定性”的理由。完整程序 14_10_uncertainty.py。

【样本 + 可视化】不确定性四视图 Four Ways to Show Uncertainty



(1) 点估计 + 95% 误差棒 ($B = 2000$ 次自助重采样); (2) 差值分布与 95% 区间 (跨 0); (3) 时间序列置信带; (4) 扇形预测带 (不确定性随时间扩大)。

程序 14_10_uncertainty.py ·汇总表 14_uncertainty_summary.csv ·样本 14_ab_test.csv

色盲友好与可访问性 Colour Accessibility

三类色觉障碍与对策

- ▶ 红绿色盲 (最常见): 不要用红绿对比表达涨跌;
- ▶ 蓝黄色盲: 避免蓝黄配对;
- ▶ 全色盲: 亮度差必须足够 (灰度可分)。

可用的色板


Okabe-Ito (8 色, 色盲友好)、viridis (连续、亮度单调)、ColorBrewer 的 colorblind-safe 组合。

来源: 色板与阈值据 Okabe & Ito 色板与 WCAG 2.2 对比度要求; 检查清单为本讲补充 (对应样本页 85 页)。

六条检查

1. 颜色之外加冗余编码 (形状、线型、直接标注);
2. 灰度打印后仍可区分;
3. 文字与背景对比度 ≥ 4.5 (大字号 ≥ 3.0);
4. 投影字号: 正文 $\geq 18\text{pt}$ 、图内标注 $\geq 12\text{pt}$;
5. 每张图提供 alt 文本 (一句话结论);
6. 交互图提供键盘可达的筛选与缩放。

【样本 + 可视化】色板对照与灰度检查 Palette and Greyscale Check



左：三套色板的原色与灰度模拟对照（上排彩色、下排灰度）；中：各色感知亮度分布（越分散越易区分）；右：前景色 $\times$ 背景色的 WCAG 对比度矩阵 (≥ 4.5 达标)。

程序 14_11_accessibility.py · 检查表 14_accessibility_report.csv · 清单 14_accessibility_checklist.csv

叙事可视化与 AI 辅助制图 Storytelling and Text-to-Chart

数据故事的三段结构

1. **背景**：问题与利害（为什么读者要在意）；
2. **冲突**：数据揭示了什么反差（图在这里出场）；
3. **结论**：要读者记住的一句话（标题即结论）。

做法：标题写结论、注释指向关键点、按“阅读顺序”排列图，必要时用滚动叙事（scrollytelling）。

AI 辅助制图（2026）

- ▶ **text-to-chart**：用自然语言描述 → 生成图表代码或图表；
- ▶ 适合：快速探索、生成初稿、批量套版；
- ▶ 不适合：**口径判断**、统计方法选择、最终定稿的诚信把关。

核验清单

口径是否被改写？坐标轴是否被截断？样本量写了吗？数据是你给的那份吗？**提示词与模型版本留档**。

为什么高维数据难画 Why High Dimensions Are Hard to Draw

三重困难

- ▶ **维度灾难**：空间体积随维数指数增长，点与点的距离趋于“人人等距”；
- ▶ **通道用尽**：一张散点图只有两个位置通道，第三个变量就得借颜色或大小；
- ▶ **过绘**：12 维数据即使两两成对也有 $12 \times 11/2 = 66$ 张图。

三大策略

1. **降维投影**：把 12 维压到 2—3 维再画 (PCA / t-SNE / UMAP)；
2. **多变量剖面**：平行坐标、雷达图、聚类热图、小多图；
3. **交给交互**：三维旋转、筛选联动、嵌入投影浏览器。

本部分用一份 600 行 × 12 维的客户行为数据 (3 个潜在群体、流失率 48.8%) 贯穿：先看它“长什么样” (投影)，再看剖面 (平行坐标)，最后看模型“为什么这样判” (解释性可视化)。

来源：维度灾难与通道限制为可视化与统计学习的基础结论；本部分的样本与结论均为本讲实测。

降维三件套：PCA、t-SNE 与 UMAP Dimensionality Reduction


方法	保留什么结构	使用要点与代价
PCA	线性、方差最大的方向	可解释（方差比例）、可逆、可当特征使用；只看得到线性结构
t-SNE	局部邻域（谁和谁像）	簇分得开、观感漂亮；簇间距与簇大小无意义、随机性大、 $O(n^2)$ 较慢
UMAP	局部 + 全局结构	更快、可 transform 新数据；对 <code>n_neighbors</code> / <code>min_dist</code> 敏感，需固定种子
Isomap / MDS	测地距离 / 距离保真	经典方法，作为 UMAP 的替代与对照；对噪声与邻域数敏感

三个通用纪律：(1) 降维前**必须标准化**（否则量纲大的变量独占方差）；(2) 参数与随机种子**写进图注**；(3) 用**邻域保真度** (trustworthiness) 而不是“看起来分得开”来评价投影质量。

Projections distort. Always say how.

来源：方法定位据各方法官方文档（scikit-learn、UMAP 文档）；纪律为本讲整理（对应代码页 90 页）。

【样本 + 可视化】三种投影对照 Three Projections of One Dataset



同一份 12 维客户数据: (1) PCA (前两成了解释 21.8% + 10.5%)、(2) t-SNE、(3) UMAP、(4) 碎石图与邻域保真度 (t-SNE 0.89 > UMAP 0.85 > PCA 0.75) ——分得开不等于保真, 三者要一起看。

程序 l4_13_highdim.py · 样本 l4_highdim_customers.csv · 指标 l4_highdim_projection_metrics.csv · 三维交互
interactive/embedding_3d.html

【代码】降维投影与保真度评价 Projections and Trustworthiness

```
1 X = customers.drop(columns=["segment", "churn"]).values # 特征矩阵 (12 维)
2 X_std = StandardScaler().fit_transform(X) # 标准化: 降维前的必要步骤
3 pca = PCA(n_components=6, random_state=42).fit(X_std) # 保留 6 个主成分
4 Z_pca = pca.transform(X_std)[: , :3] # 前三个主成分 (2D 与 3D 共用)
5 evr = pca.explained_variance_ratio_ * 100 # 各主成分解释的方差比例 (%)
6 Z_tsne = TSNE(n_components=2, perplexity=30, init="pca", # t-SNE: 强调局部邻域
7             learning_rate="auto", random_state=42).fit_transform(X_std) # 固定种子可复现
8 Z_umap = UMAP(n_neighbors=15, min_dist=0.1, n_components=2, # UMAP: 邻居数与最小距离是关键
9             random_state=42).fit_transform(X_std) # 兼顾局部与全局结构
10 tw_tsne = trustworthiness(X_std, Z_tsne, n_neighbors=10) # 邻域保真度: 近邻是否仍是近邻
11 metrics = pd.DataFrame({"方法": ["PCA", "t-SNE", "umap_label"], # 汇总投影质量表
12                        "邻域保真度(10-NN)": [round(tw_pca, 3), round(tw_tsne, 3), round(tw_umap, 3)]}) # 三种方法的保真度
13 dump(metrics, "14_highdim_projection_metrics.csv") # 落盘指标, 写进报告与图注
```

要点: 标准化 → 投影 → 用指标评价 → 落盘 四步固定流程; UMAP 未安装时程序自动退化为 Isomap, 流程不中断。完整程序 14_13_highdim.py。

降维图的读法与陷阱 Reading a Projection

五条纪律

1. 簇间距离不可读：t-SNE/UMAP 的远近没有数值含义；
2. 簇的大小与密度也不可读（t-SNE 会人为均衡簇大小）；
3. 空白的意义有限：高维中没有点的地方未必“不该有点”；
4. 参数与种子写进图注：换 perplexity、n_neighbors 或种子，图会变；
5. 必须与业务变量交叉验证：投影上的“簇”是否对应真实分组。

质量指标

- ▶ 邻域保真度 *trustworthiness*：高维的 10 近邻在低维中还剩多少；
- ▶ 连续性 *continuity*：反向检查（低维近邻是否也近）；
- ▶ 残差方差（PCA 专用）：前 k 个成分解释了百分之几；
- ▶ 报告时同时给出指标与图，不要只给图。

一句话：降维图是“看结构的工具”，不是“证明结论的证据”——结论要回到原维度的统计量上验证。

平行坐标与雷达图 Parallel Coordinates and Radar

平行坐标（推荐）




- ▶ 每个变量一根**竖直轴**，一个观测是一条折线：**一次看全 8—12 个变量**；
- ▶ 必须**标准化**（否则各轴量纲不同，折线形状由量纲决定）；
- ▶ **轴顺序会影响观感**：相邻轴之间的交叉最易读，可按相关性排序；
- ▶ 类别分组时**画群体均值线 + 少量个体线**，避免上千条线糊成一片。

雷达图（慎用）

- ▶ 本质是**首尾相接的平行坐标**：面积随轴顺序与缩放变化，**面积不可比**；
- ▶ 轴多时形状高度相似，读者只能看“哪个尖”；
- ▶ 若要使用：**轴顺序固定、统一量纲、轴数 ≤ 6** ，并同时给出数值表。

来源：平行坐标与雷达图的读图限制据可视化实践与统计图形批评整理；样本见下一页。


【样本 + 可视化】多变量剖面：平行坐标、聚类热图与雷达图



- (1) 平行坐标 (8 个标准化特征, 三个群体的均值剖面): 忠诚群体在频次/金额/在网时长上整体更高;
(2) **聚类重排**的相关热力图 (成块的变量即一组); (3) 雷达图——注意**面积会被放大**, 只用作示意。

程序 14_13_highdim.py · 样本 14_highdim_customers.csv · 层次聚类重排用 `scipy.cluster.hierarchy`

【样本 + 可视化】模型解释：置换重要性、PDP 与 ICE



随机森林预测流失 ($n=600$, 流失率 48.8%): (1) 置换重要性 (10 次重复的误差棒) ——最近购买距今天数 0.195 远超第二名的 0.075; (2) PDP 给出平均边际效应; (3) ICE 显示个体差异: 平均下降不代表每个人都下降。

程序 14_13_highdim.py ·重要性表 14_highdim_importance.csv ·模型与指标: scikit-learn 的 permutation_importance

【代码】置换重要性、PDP 与 ICE Permutation, PDP and ICE

```
1 clf = RandomForestClassifier(n_estimators=400, min_samples_leaf=4, # 随机森林作为可解释模型
2                             random_state=42).fit(X_std, customers["churn"]) # 用流失标签训练
3 perm = permutation_importance(clf, X_std, customers["churn"], # 置换重要性: 打乱某特征
4                               n_repeats=10, random_state=42, scoring="roc_auc") # 看性能掉多少
5 imp = pd.DataFrame({"feature": list(FEATURES.keys()), # 特征名
6                     "importance": perm.importances_mean.round(4), # 重要性均值
7                     "std": perm.importances_std.round(4)}) # 重复实验的标准差
8 for v in qs: # 遍历分位点网格
9     X_tmp = X_std.copy() # 复制特征矩阵
10    X_tmp[:, j] = v # 把该列整体替换为 v
11    preds.append(clf.predict_proba(X_tmp)[:, 1].mean()) # 平均预测概率 = PDP
12 for r, i in enumerate(idxs_sample): # 逐个个体画 ICE
13     for k, v in enumerate(qs): # 逐分位点
14         X_tmp = X_std[i:i + 1].copy() # 只取该个体一行
15         X_tmp[0, j] = v # 改变该特征取值
16         ice[r, k] = clf.predict_proba(X_tmp)[0, 1] # 该个体的预测概率
17 fig3d.write_html(INT / "embedding_3d.html", include_plotlyjs="cdn") # 三维嵌入: 可旋转探索
```

三类图的分工: **重要性**回答“哪个变量重要”、**PDP** 回答“平均怎么影响”、**ICE** 回答“每个人是否一样”。完整程序 14_13_highdim.py。

前沿拓展与小结 Frontier and Checklist

2026 年的高维可视化

- ▶ **嵌入投影浏览器**：把文本 / 图像 / 用户的向量表示降到 2—3 维并**交互检索**（句向量、CLIP 等多模态嵌入、推荐系统的物品向量）；
- ▶ **三维与动画**：可旋转的三维嵌入（本讲 embedding_3d.html）、grand tour 动画巡视高维空间；
- ▶ **解释性可视化成为标配**：SHAP 摘要图、PDP/ICE、注意力热力图、反事实解释（衔接 L9 模型评估与 L13 可解释性）；
- ▶ **可访问性扩展到高维图**：颜色之外加形状与标注、为交互图提供键盘可达与文字摘要。

高维可视化检查清单

1. 画之前是否**标准化**了？
2. 投影方法的**参数与种子**写进图注了吗？
3. 是否给出**质量指标**（保真度 / 解释方差）？
4. 有没有把“簇间距离”当成结论？
5. 是否用**业务变量**交叉验证了分组？
6. 解释性图是**模型无关**还是模型内建？是否注明？
7. 图注是否说明“相关不等于因果”？

小结：高维数据的表达靠**三种互补手段**——降维投影（看结构）、多变量剖面（看个体与群体）、解释性可视化（看模型依据）；任何一种都需要**指标 + 图注 + 交叉验证**三件套才可信。


可信图表十条检查 Ten Checks for an Honest Chart

1. 图型匹配问题 (比较/分布/关系/时间/空间/结构)?
2. 纵轴从 0 开始 (柱状图) 或已声明截断 (折线图)?
3. 一个数值只用一个通道编码 (没有双重编码)?
4. 有没有用双轴制造伪相关?
5. 区间是否完整 (没有选择性截取)?
6. 是否画出了不确定性 (区间/误差棒) 并说明方法?
7. 样本量、缺失处理与口径是否写进图注?
8. 颜色是否色盲友好、灰度可区分、有冗余编码?
9. 标题与图注是否“自足” (脱离正文也能读懂)?
10. 数据是否可复现 (脚本、种子、版本)?

用法: 把这张表当作**交报告前的最后一分钟自检**——十条全部打勾再提交。

来源: 十条检查综合本讲 Part 6 的全部内容, 可作为项目报告的自检表。

项目 1: 图表与描述部分 Project 1 Deliverables



报告主图的四联呈现：渠道满意度（声明纵轴截断）、收入分布（注明缺失未插补）、A/B 转化率（含 95% 误差棒与 n ）、客单价区间——配套的统计表与图注由程序一并导出。

程序 14_12_report_pipeline.py 报告素材 data/lecture04/report/ (table1、table2、captions.md)

常见错误 Top 10 Common Chart Mistakes

1. 柱状图纵轴不从 0 开始;
2. 一张图塞十几个类别、用十几种颜色;
3. 用饼图比较相近占比;
4. 双轴折线制造伪相关;
5. 只画有利区间或只报显著子样本;
6. 不给样本量与不确定性;
7. 图注不自足 (读者看不懂单位与口径);
8. 用彩虹色板表达顺序变量;
9. 红绿对比且无冗余编码 (色盲读者看不出);
10. 结论与图不符 (图上没显示“显著提升”)。

这十条与第 97 页的检查表一一对应：先看错误清单，再用检查表验收。

来源：错误清单据本讲 Part 4-6 的对照实验与常见审稿意见整理。

工具与代码速查 Toolbox

任务	关键 API / 工具
描述统计	describe()、quantile()、skew()、kurt()、groupby().agg()
单变量图	hist、boxplot、violinplot、step (ECDF)
关系图	scatter、corr() + imshow (相关矩阵)、hexbin
时间图	plot、rolling().mean()、fill_between (置信带)
地图	px.choropleth (ISO-3)、go.Scattergeo (符号/流向)、GeoJSON 多边形
交互	px.line/scatter、go.Sankey、make_subplots、write_html
可访问性	Okabe-Ito 色板、灰度转换 $0.299R+0.587G+0.114B$ 、WCAG 对比度公式

全部示例都在 `website/code/lecture04/`: 12 个程序、15 张图、6 个交互 HTML, 逐行中文注释、一键重跑。

来源: API 速查据 matplotlib / seaborn / plotly 官方文档; 示例对应本讲各代码页。

术语对照与参考资料 Glossaries and References

中文	English
集中趋势	Central tendency
离散程度	Dispersion
偏度 / 峰度	Skewness / Kurtosis
列联表	Contingency table
受限范围	Restricted range
视觉通道	Visual channel
过绘	Overplotting
仪表盘	Dashboard
分级统计图	Choropleth
空间自相关	Spatial autocorrelation
扇形预测带	Fan chart
替代文本	Alt text

参考资料

- ▶ Rahrif, T. *Data Visualisation with R* (大纲 L4 指定)
- ▶ McKinney *Python for Data Analysis*, Ch.9 Plotting and Visualization
- ▶ Cairo, A. *How Charts Lie*; Tufte *The Visual Display of Quantitative Information*
- ▶ Wilke, C. *Fundamentals of Data Visualization*; Munzner *Visualization Analysis and Design*
- ▶ 公开资源: data-to-viz、python/r graph gallery、WITS、Gephi、CiteSpace、SNAP、GeoDa、QGIS
- ▶ WCAG 2.2 (对比度与非文本内容); Okabe & Ito 色盲友好色板

谢谢!

Thank you ·Q & A

本讲小结: 文档与元数据 → 中心·离散·形状 → 相关与多变量 → 图型与通道 → 交互·仪表板·地图
→ 不误导·可访问·有叙事

课堂检查点: 只看图、不看正文, 让同学复述你的结论; 说不出来就回去改图。

样本与程序: `website/code/lecture04` (12 个程序, 逐行中文注释) `website/data/lecture04`
(28 份样本) `website/figures/lecture04` (15 张图 + 6 个交互 HTML)

任课教师: 戴谢尔 (Xieer Dai, David) ·Xieer.dai@szu.edu.cn ·四方楼南 209