深圳大学 SHENZHEN UNIVERSITY

课程 COURSE

Big Data Analytics
大数据分析 [2026 国际商务]

Lecture 5 — Introduction to Machine Learning 第五讲·机器学习入门
从学习范式到评估协议、算法族与可信交付

任课教师：戴谢尔 (Xieer Dai, David)

深圳大学 Shenzhen University

上课时间：第 3–14 周 星期四 11-12 节

上课地点：四方楼南 209

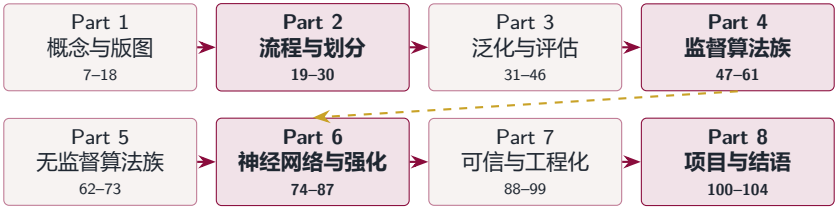
学习目标 Learning Objectives

完成本讲后，你应能够：

1. 区分监督、无监督、自监督与强化学习四类范式，并说明各自需要什么数据；
2. 用偏差-方差与三类误差解释过拟合与欠拟合，并读懂学习曲线；
3. 正确执行训练 / 验证 / 测试划分与交叉验证，识别六类数据泄漏；
4. 选择并评估基线模型：回归与分类指标、阈值与业务代价、概率校准；
5. 说清神经网络与强化学习的基本机制（前向传播、激活函数、反向传播、奖励）；
6. 交付一份可信的模型：可解释性、模型卡、数据泄漏清单，并写出项目选题说明（问题 / 数据 / 方法）。

来源：对应课程大纲第 5 讲目标：区分学习范式；理解偏差-方差与评估协议；能建立并评估基线模型。

本讲路线图 Roadmap（104 帧）



主线：概念 → 流程 → 评估 → 算法族 → 可信交付

代码页 10 帧•样本页 14 帧：全部示例用 Python，每一行代码都带英文注释，随机种子固定 20260506

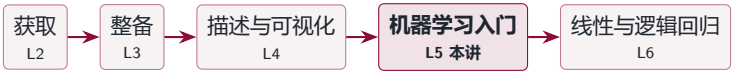
与上一讲的衔接 From Description to Prediction

L4 结束时你手上有什么

- 干净的数据表 + 数据字典；
- 描述统计表与图表清单；
- 但还没有回答：能不能预测？预测得准不准？凭什么相信它？

L5 要回答的问题

- 这个问题属于哪类学习范式？
- 怎么划数据、怎么衡量好坏？
- 该选哪个算法族，代价是什么？
- 结论怎么解释、记录与交付？



本讲是总览课：把四大范式、评估协议与主要算法族串成一张地图；L6–L9 再逐个深入。

本讲输出物 Deliverables

1) 基线模型与评估协议

划分方式、交叉验证、指标与阈值选择，全部落盘成表（样本页 28–30、44 页）

2) 数据泄漏清单

目标泄漏、选择泄漏、时间泄漏、重复行、分组泄漏逐条自检（93 页）

3) 模型卡与运行记录

用途、数据、指标、限制、伦理；一键重跑的 JSON 记录（92 页代码）

与第 6 周任务对应：项目选题说明（一页）

问题（预测还是因果）/ 数据（来源与许可）/ 方法（基线 + 评估协议 + 指标）/ 预期产出。帧 101 给出填写模板，本讲的评估协议直接照抄。

来源：评分与提交要求见课程大纲第六节；本讲提供模板与检查清单。

全讲导览 Map of the Lecture

部分	帧	关键问题
概念与版图	7–18	什么是机器学习？四类范式各要什么数据？
流程、划分与评估协议	19–30	怎么划数据？预测与因果怎么分工？
泛化、偏差-方差与评估	31–46	为什么样本外会变差？该报哪个指标？
监督学习算法族	47–61	回归、KNN、SVM、树与集成怎么选？
无监督学习算法族	62–73	没有标签时怎么降维、怎么聚类、怎么评估？
神经网络与强化学习	74–87	前向、反向、激活函数与奖励到底在算什么？
可信、可解释与工程化	88–99	怎么解释、怎么记录、怎么避免泄漏与偏差？
项目与结语	100–104	第 6 周的选题说明怎么写？

读法：每部分都是" 概念 → 样本与图示（样本页）→ 可运行程序（代码页）→ 检查清单" 的循环。

从三个问题切入 Three Questions

预测一个数

" 下个月这家门店的销售额是多少？"
任务：回归；指标：RMSE / MAE

判断一个类

" 这笔交易是不是欺诈？"
任务：分类；指标：AUC / 召回率

找出一些组

" 哪些客户行为相似？"
任务：聚类；指标：轮廓系数 / 业务解释

三个问题对应三种" 能不能被检验"

- 回归与分类有标签，可以用样本外误差检验；
- 聚类没有标签，" 好" 取决于用途与解释——评估最容易被忽略；
- 三类任务共同的纪律：先划数据，再谈模型。

来源：三类任务的划分据统计学习通用框架；与课程项目选题（问题/数据/方法）直接对应。

机器学习的定义 Mitchell (1997)

定义

"A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E."

— Tom Mitchell, *Machine Learning*, 1997

要素	含义	信用卡欺诈场景
T 任务	要完成的事情	判断一笔交易是否为欺诈
E 经验	用于学习的数据	历史交易与人工标注结果
P 性能度量	判断好坏的标准	ROC-AUC、召回率、误报成本

定义的威力在于把" 学习" 拆成可检查的三件事：任务说清了没有？经验够不够、有没有偏？度量选对了吗？——本讲后面每一部分都在回答其中一个。

来源：定义与出处：Mitchell, T. (1997). *Machine Learning*, McGraw-Hill。

AI、机器学习、深度学习与生成式 AI The Landscape





Not magic: a function fitted on data, with assumptions you can inspect.

边界在哪

- ML 是" 从数据中学一个函数"：给定输入预测输出；
- 深度学习是 ML 的一支：用多层网络表示复杂函数；
- 生成式 AI 学习的是数据分布，输出可以不是标签而是内容（衔接 L11）。

来源：版图据统计学习与基础模型研究的通行划分；与 L1 的 AI 版图、L11 的 NLP 内容衔接。

金融业的应用 Applications in Finance

投资管理价值链

技术已经渗透到每一步：更好地理解客户 → 发现新的 alpha 来源 → 更高效地执行交易。机器学习技术最早于 1990 年代进入金融，随着数据爆炸与廉价算力而繁荣。

从业者的角色

投资从业者不必精通数学细节，但作为领域专家，重要的是能够：选择合适的模型输入、解读模型输出、把输出转化为投资动作。

七类典型应用

1. 流程自动化
2. 文档分析
3. 组合管理
4. 算法交易
5. 数字助理
6. 风险管理
7. 欺诈与反洗钱

来源：应用清单与价值链表述据金融机器学习教材中的行业综述；本讲按课程语境整理。

案例：用年报文本预测收益 Filings as Data

一个真实的研究范式

研究者用文本分析发现：年报（10-K）与季报（10-Q）的同比变化，尤其是管理层讨论与风险章节中的负面变化，对股票收益有较强的预测力。

拆成 ML 语言

- 任务 T：预测未来收益（回归）或超额收益方向（分类）；
- 经验 E：历年文本 + 对应收益；
- 度量 P：样本外 R^2、IC、多空组合夏普；
- 陷阱：文本发布日期与交易时点的时间泄漏（93 页）。

这个例子说明：特征工程常常比模型选择更重要——把" 文本变化" 变成可计算特征，是金融 ML 的主要工作量。

来源：案例据统计文本分析与资产定价文献的通行做法；数据与结论为文献综述表述，本讲不含真实数据。

商业应用 Applications in Business

七类场景

- 社交媒体特征提取
- 商品推荐
- 图像识别
- 情感分析
- 购买行为预测
- 客户满意度提升
- 营销优化与垃圾信息识别

每一类都要问的三个问题

1. 标签从哪来？（购买记录、人工标注、还是代理指标）
2. 评估口径是什么？（点击率、转化率、还是长期价值）
3. 上线代价多大？（延迟、算力、误判成本）

推荐系统的典型陷阱：用曝光数据训练、用全量数据评估，忽略" 没被推荐过的商品永远没机会"。

来源：场景清单据商业数据分析教材的通行分类；三个问题与陷阱为本讲补充。

预测任务的三种形态 Three Data Shapes

形态	典型数据	关键注意点
表格回归	房价、销量、违约损失	先做线性基线；检查非线性与交互；注意目标泄漏
表格分类	欺诈、流失、违约	类别不平衡、阈值与代价、概率校准
非结构化	文本、图像、音频、序列	先做特征表示（嵌入）；时间切分；标注成本高

经验法则：表格数据先试树与集成（梯度提升仍是强基线）；非结构化数据先试预训练表示 + 简单分类头，再考虑端到端微调（帧 86）。

Right tool for the data shape.

来源：形态划分与经验法则据表格数据与深度学习的实证对比研究整理。

核心动作：找模式，用模式 Find the Pattern, Apply the Pattern

核心原则

机器学习的目标是从大量数据中提取知识：通过从已知样例中学习，确定数据中的内在结构，从而在没有人工干预的情况下生成结构或预测。一种初级的理解方式是："找模式，用模式。"

"无人工干预"的边界

- 人仍然决定：任务、度量、特征、阈值、部署方式；
- 模型只负责在给定的假设空间内搜索参数；
- 因此"自动化"不等于"无需判断"——判断被前移到了设计与评估阶段。

来源："找模式、用模式"的表述据机器学习基础教材；边界讨论为本讲补充（与帧 20 的自省呼应）。

监督学习 Supervised Learning

关键概念

- 输入 X（特征）与输出 Y（标签）成对出现；
- 学习的目标是推断从输入到输出的映射；
- 用训练数据训练，再对新输入预测输出。

两个必须区分的词

- 样本内（in-sample）：训练集上的表现，只是"记住"的程度；
- 样本外（out-of-sample）：新数据上的表现，才决定模型有没有用。

第一个基线：多元回归

回归模型用成对的 (X, y) 估计参数，刻画 y 与 X 的关系；估计出的参数可用于对新的 X 预测；预测值与真实值的差异用来评估样本外表现。

来源：监督学习的定义与多元回归示例据金融机器学习教材的基础章节。

无监督学习 Unsupervised Learning

核心说明

无监督学习不使用带标签的数据：我们只有输入，没有目标。算法要在数据内部发现结构。正因为如此，无监督学习特别适合探索新数据——为专家提供对"太大或太复杂、无法目视"的数据集的洞察。

两类主要问题

- 降维：在保留观测间变异的前提下减少特征数量；目的包括可视化、去噪、压缩，以及为下游模型提供更少但更稳的输入；
- 聚类：把观测分成若干组，使同组内更相似；分组标准可以预设（如组数）也可以由数据决定。

资产管理中的用法：按财报特征把公司分成经验分组，而不是沿用行业或国别这类传统分组。

来源：说明与两类问题的表述据金融机器学习教材；应用示例为该教材中的资产管理案例。

深度学习与强化学习 Deep Learning and Reinforcement Learning

深度学习

用更复杂的算法处理高度复杂的任务：图像分类、人脸识别、语音识别、自然语言处理。

强化学习

计算机通过与自身或环境交互来学习（数据也由算法自己产生），没有逐步的标签与即时反馈。

共同基础：神经网络

深度学习与强化学习都建立在神经网络之上：NN 是非常灵活的 ML 算法，已被成功用于非线性与特征交互突出的任务。除分类与回归之外，NN 也是深度学习与强化学习的基础，而这两者既可以是监督的，也可以是无监督的。

来源：表述据金融机器学习教材对神经网络、深度学习与强化学习的综述。

监督与无监督的对照 Supervised versus Unsupervised

维度	监督学习	无监督学习
前提假设	独立观测、环境稳定	独立观测、结构可由相似性定义
典型任务	回归 $E[Y \mid X = x]$、分类 $\Pr(Y = y \mid X = x)$	发现相似的组、压缩表示
数据类型	特征 + 标签	只有特征（图像、文档、个人上网行为等）
度量	样本外误差、AUC、召回率	轮廓系数、稳定性、业务可解释性
跨学科差异	使用方法差异较小	使用方法差异较小

注意最上面一行："环境稳定" 是监督学习的隐含前提。分布一旦漂移，样本外表现就会崩塌——这正是 MLOps 要监控漂移的原因（帧 96）。

来源：对照表据金融机器学习教材中的监督/无监督对比页整理。

预测问题与因果问题 Prediction versus Causation

预测问题

目标：在只看得到 X 的新数据上，估计并最小化均方误差。不需要知道"为什么"，只需要预测得准：可以做样本外检验，可以比较不同模型。

因果问题

目标：估计干预的效果（"如果价格提高 5%，销量会怎样"）。需要识别策略（实验、工具变量、断点等），而且无法用留出集检验——因为反事实观测不到（衔接 L12）。

很多问题可以分解为两部分

- 用现成的 ML 处理预测部分（例如先估出需求函数中的 nuisance 部分）；
- 用计量方法处理因果部分（把估计量对准感兴趣的参数）；
- 两部分共享同一条纪律：数据划分、验证、记录。

来源：预测与因果的分工据经济学与机器学习交叉领域的综述（Athey、Mullainathan 等）。

两种自省：我们说的与我们做的 Two Kinds of Self-Awareness

机器学习侧

- 说：只用预测说话，把人从选择中解放出来；
- 做：用预测模型并忽略其他考虑——因果、均衡与反馈效应；
- 心里担心可解释性、可靠性、稳健性、适应性，却缺乏让算法直接优化这些目标的渠道。

计量经济学侧

- 说：报告因果效应与标准误，再加几个稳健性设定；
- 做：跑很多函数形式、把研究助理跑的几百个回归里" 挑几个有代表性的"；
- 按" 只跑了一个模型" 的方式报告标准误，隐含多重比较问题。

两侧的毛病其实同源：选择过程没有被记录。共同的解药是预注册 + 留出验证 + 完整报告——这也正是本讲反复强调" 评估协议要落盘" 的原因。

来源：两侧的" 说的与做的" 对照据计量经济学与机器学习的方法论评述整理。

机器学习与传统计量经济学的差别 ML versus Econometrics

维度	传统计量经济学	机器学习
数据规模	关注 $N \gg P$（样本远多于变量）	关注 P 很大、甚至 $P > N$
样本内误差	可近似样本外误差；OLS 是 BLUE，不必引入偏差	样本内误差会严重低估样本外误差，必须留出验证
共线性	方差膨胀、系数不稳	正则化与集成可以当作" 降方差" 的手段
核心目标	估计因果效应与识别	提高样本外预测表现
检验方式	标准误、识别假设的可信度	留出集与交叉验证（无法检验识别假设）

一句话总结：目标不同，评价方式就不同。预测任务用样本外误差当裁判；因果任务必须靠设计，而不是靠" 预测得准"。

来源：对照据计量经济学与机器学习比较的方法论文献；结论为通用共识。

当变量比样本还多 When P Exceeds N

会发生什么

- 样本内误差可以做到接近零（甚至完全为零）；
- OLS 在 $P > N$ 时根本没有唯一解；
- 只要允许模型足够复杂，它就能" 记住" 训练数据，包括其中的噪声；
- 于是样本外表现可能比简单模型更糟。

本讲的实测例子

房价样本 1,200 行、7 个原始特征，做三次多项式展开后变成 164 个特征，而训练集只有 900 行——此时不加惩罚的线性模型已经不稳，Ridge/Lasso 立刻变得重要（帧 39、51）。

三条应对：正则化（惩罚复杂度）、降维（用更少的方向概括变异，帧 64）、留出验证（用样本外误差做裁判）。

来源：高维下的过拟合与 OLS 失效为统计学习的基本结论；数值例子来自本讲程序 l5_05。

给计量经济学的几点启示 Lessons for Empirical Work

方法论启示

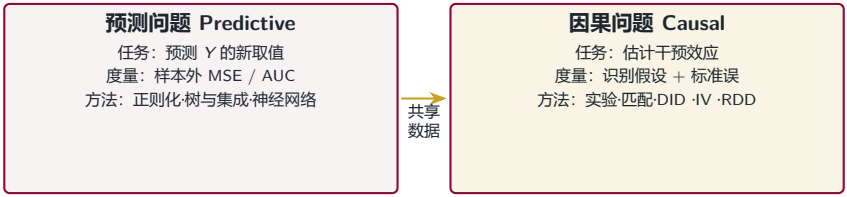
1. 很多问题可以分解为预测部分与因果部分；
2. 预测部分可以直接用现成 ML；
3. 用数据驱动的方式做模型选择，但准则要服从研究目标；
4. 把注意力放在感兴趣的参数上；
5. 在能评估表现的地方使用数据驱动选择，同时保留推断能力。

验证的启示

- ML 永远有测试集；计量研究也可以设计" 更难的测试"：例如在价格异常的日子评估预测，或比较价格变动前后的购买变化；
- 技术公司天然拥有大量 A/B 测试与算法变更，它们是研究反馈与均衡效应的天然实验场；
- 结构模型的替代计算工具：随机梯度下降、变分推断。

来源：启示据统计学与经济学交叉的方法论文章整理；引用示例为该领域的代表性研究。

一张图看清分工 Who Does What

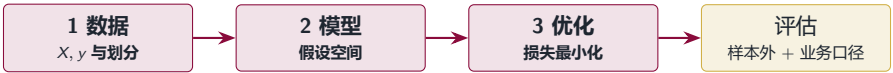


两者共享同一份数据、同一套验证纪律、同一份文档；区别在于" 能不能用留出集检验"：预测可以，因果不行。

Two goals, one dataset, different referees.

来源：分工图为据预测与因果文献整理的示意；具体识别策略在 L12 展开。

机器学习 1-2-3 Machine Learning in Three Steps



每一步的常见错误

- 数据：泄漏、划分不可比、样本量不足；
- 模型：假设空间与问题不匹配（线性模型做非线性任务）；
- 优化：不收敛、学习率不当、把调参当建模；
- 评估：用测试集调参、只看准确率、忽略代价。

顺序不能颠倒

先定度量，再定划分，最后才选模型。反过来做（先挑模型再想怎么评）几乎必然得到乐观结论——这也是本讲把评估放在算法族之前的原因。

来源：1-2-3 框架沿用课程 L1 的表述；常见错误据本项目实践与教科书整理。

训练、验证与测试 Three Splits

三个不重叠的样本

- 训练集：用来训练模型（样本内）；
- 验证集：用来比较方案与调超参数；
- 测试集：只用一次，用来确认模型在新数据上的表现。

常用比例 60/20/20；样本很小时可用交叉验证替代验证集。

本讲的划分（信用卡样本）

3,000 行、正类比例 26.7%，按 60/20/20 分层切分：训练 1,800 行、验证 600 行、测试 600 行；分层保证三份数据的正类比例一致。

两种必须改变划分方式的场景：(1) 时间序列（按时间切分，不能随机打乱）；(2) 分组数据（同一客户/同一门店的记录不能跨集合，否则是分组泄漏）。

来源：三划分与比例据统计学习通行做法；样本信息来自本讲程序 l5_01 的实测输出。

交叉验证 Cross-Validation

基本做法

- 把训练数据分成 k 折（常用 5 或 10）；
- 每次用 $k-1$ 折训练、留 1 折评估，轮换 k 次；
- 报告 k 个得分的均值与标准差；
- 调参时用嵌套交叉验证，避免"调参泄漏"。

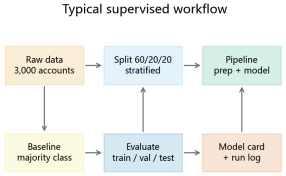
五种划分器

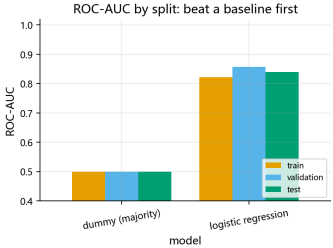
划分器	何时使用
KFold	回归等无类别不平衡问题
StratifiedKFold	分类，保持各折正类比例
GroupKFold	分组数据(同一实体不跨折)
TimeSeriesSplit	时间序列，只用过去预测未来
LeaveOneOut	小样本，计算代价高

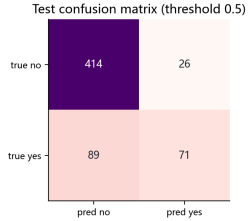
纪律：测试集绝不参与调参。任何"在测试集上试了几次"的模型，其报告分数都已经是乐观估计——这与帧 30 的泄漏实验是同一类错误。

来源：交叉验证做法与划分器选择据 scikit-learn 用户指南与统计学习实践整理。

【样本 + 可视化】端到端流水线与基线 Pipeline and Baseline







3,000 笔账户、正类 26.7%：多数类基线准确率 73.3%，但 ROC-AUC 只有 0.500——只看准确率会被基线骗过；逻辑回归样本外 AUC 0.840、准确率 80.8%，才算"有信息"。

程序 `15_01_pipeline_baseline.py`（每行英文注释）·样本 `15_credit_default.csv` ·结果 `15_baseline_scores.csv`

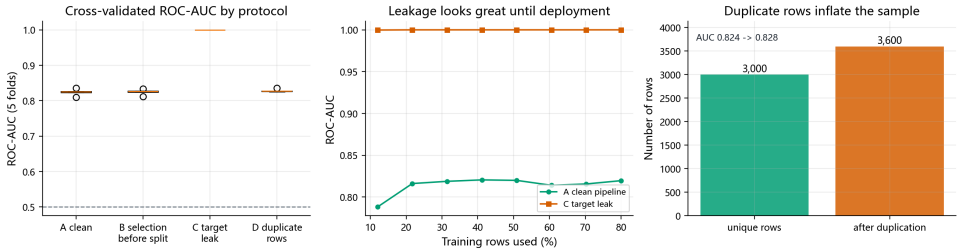
【代码】划分、流水线与交叉验证 Splitting and Cross-Validation

```python
X_train, X_tmp, y_train, y_tmp = train_test_split(    # first split: training versus the rest
    X, y, test_size=0.4, random_state=42, stratify=y) # stratify keeps the default rate identical
X_val, X_test, y_val, y_test = train_test_split(      # second split: validation versus test
    X_tmp, y_tmp, test_size=0.5, random_state=42, stratify=y_tmp) # both halves keep the same rate
prep = ColumnTransformer(                             # route each column type to its transformer
    transformers=[("num", StandardScaler(), num_cols), # numeric columns are standardised
                  ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols)]) # categories become dummies
def make_pipe(model):                                 # build a fresh pipeline for an estimator
    return Pipeline(steps=[("prep", prep), ("model", model)]) # preprocessing then estimator
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42) # five stratified folds, fixed seed
scores_clean = cross_val_score(clean, X, y, cv=cv, scoring="roc_auc") # honest cross-validated AUC
scores_target = cross_val_score(model_only, X_target, y, cv=cv, scoring="roc_auc") # leaked column included
```

要点：预处理必须放进流水线，否则每一折的信息会互相污染；交叉验证只报告均值与标准差，不要只报一个最好看的折。

完整程序 `15_02_cv_and_leakage.py`。

【样本 + 可视化】四种协议，四个分数 Four Protocols of One Model



同一模型：诚实流水线 0.824、先选特征再切分 0.825、目标泄漏 1.000（把结果当特征）、重复行 0.828；诚实留出集给出 0.865——分数只反映协议，不反映模型。

程序 `15_02_cv_and_leakage.py` ·结果 `15_cv_results.csv` ·泄漏清单见帧 93

过拟合 Overfitting

核心定义

一个 ML 算法如果把训练数据拟合得太好，通常无法在新数据上预测得好：也就是说，它泛化得不好。泛化好的模型是在样本外仍保持解释力的模型。

过拟合是怎么发生的

过拟合模型把训练数据中的噪声与随机波动也学进了关系里；这些波动不存在于任何新数据中，因此会损害泛化能力。所以评估的重点是新数据上的预测误差，而不是训练数据上的拟合优度。

识别信号：训练误差很低、验证误差明显更高，且两者差距随复杂度单调扩大。

来源：过拟合与泛化的表述据金融机器学习教材的评估章节。

欠拟合 Underfitting

核心定义

欠拟合指的是模型无法准确捕捉输入与输出之间的关系，从而在训练集与未见数据上都产生较高的误差。

常见原因与对策

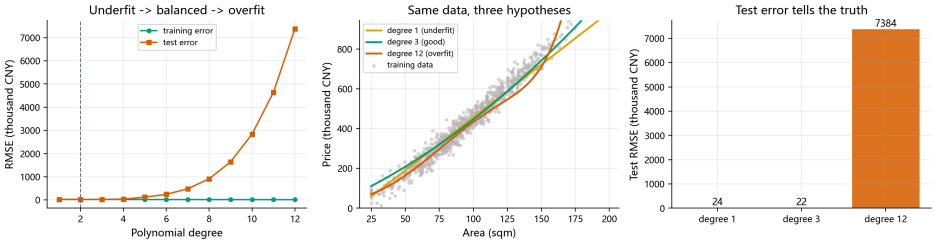
- 模型过于简单（线性模型拟合弯曲关系）；
- 特征不足或特征表达不好（缺少交互项）；
- 正则化过强（惩罚把信号也压掉了）；
- 训练不充分（迭代次数太少、学习率太小）。

对策：增加特征或提高模型容量，并重新检查学习曲线（帧 36）。

与过拟合一样，欠拟合的模型也无法用于分类或预测；泛化能力最终才是让机器学习算法每天可用的原因。

来源：欠拟合定义与原因据金融机器学习教材；对策为据学习曲线诊断的实践整理。

【样本 + 可视化】同一数据、三种假设 Three Hypotheses



房价样本（1,200 行，均价 42.3 万）：多项式次数 1（欠拟合）、2（本样本最佳）、12（过拟合）；左图显示训练误差单调下降而测试误差先降后升——这就是"复杂度旋钮"的代价。

程序 `l5_03_overfitting_curves.py` · 样本 `l5_housing.csv` · 扫描表 `l5_complexity_table.csv`

【代码】复杂度扫描与学习曲线 "Complexity" Sweep and Learning Curves

```python
for degree in range(1, 13):                          # degrees one to twelve
    pipe = Pipeline(steps=[("poly", PolynomialFeatures(degree=degree, include_bias=False)), # expansion
                           ("scale", StandardScaler()),   # standardise the expanded features
                           ("model", Ridge(alpha=1.0))])  # ridge keeps high degrees stable
    pipe.fit(X_train, y_train)                       # fit on the training split
    train_rmse = np.sqrt(mean_squared_error(y_train, pipe.predict(X_train))) # in-sample error
    test_rmse = np.sqrt(mean_squared_error(y_test, pipe.predict(X_test))) # out-of-sample error
def curve_for(degree, ridge_alpha):                  # helper returning train/test curves
    sizes, train_err, test_err = learning_curve(     # compute the learning curve
        pipe, X_train, y_train, cv=5, shuffle=True, random_state=42, # five folds, shuffled
        train_sizes=np.linspace(0.1, 1.0, 8), scoring="neg_root_mean_squared_error") # RMSE per size
    return sizes, -train_err.mean(axis=1), -test_err.mean(axis=1) # flip the sign back to positive RMSE
```

要点：一次扫描得到" 复杂度—误差" 曲线，再用 `learning_curve` 看样本量的作用；两条曲线一起看，才能区分" 缺样本" 与" 缺约束"。完整程序 `15_03_overfitting_curves.py`。

三类误差：偏差、方差与基误差 Three Sources of Error

三类误差

1. 偏差误差：模型拟合训练数据的程度。假设错误会产生高偏差、近似能力差，导致欠拟合与高样本内误差；
2. 方差误差：模型结果对新数据的敏感程度。不稳定的模型会捡起噪声、产生高方差，导致过拟合与高样本外误差；
3. 基误差：数据本身的随机性带来的误差（不可消除）。

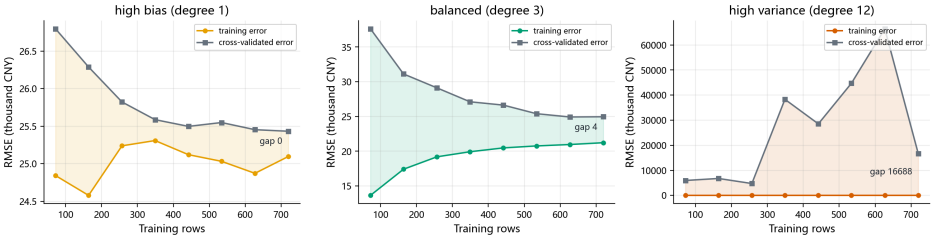
来源：三类误差的表述据金融机器学习教材；方差-偏差分解为统计学习标准结论。

分解式

$$\mathbb{E}\left[(y-\hat{f}(x))^2\right] = \underbrace{\mathrm{Bias}^2}_{\text{模型误差}} + \underbrace{\mathrm{Var}}_{\text{估计误差}} + \underbrace{\sigma^2}_{\text{噪声}}$$

含义：最小化均方误差必然要接受一些偏差；" 更复杂的模型一定更好" 是错的。

【样本 + 可视化】学习曲线诊断 Diagnosing with Learning Curves



三种模型的训练误差（实线）与交叉验证误差（虚线）随样本量变化：高偏差时两线都高且靠得近；高方差时训练误差极低而验证误差迟迟不降、两条线之间留着大缺口——加数据比换模型更有效。

程序 `15_03_overfitting_curves.py` ·曲线用 `learning_curve` 5 折计算，误差为 RMSE（千元）

学习曲线的两种含义 Two Meanings of a Learning Curve

机器学习的学习曲线

横轴是训练样本量，纵轴是准确率或误差；稳健的模型表现为：随着训练数据增加，样本外准确率上升，训练误差与验证误差相互靠拢，并趋向一个理想误差（或基误差）。

人类的学习曲线

同样叫" 学习曲线"，但横轴是经验或练习量、纵轴是熟练度：做得越多、组织与行业做得越久，任务完成得越好。

同名异义提醒：读文献时先看横轴是什么。本课程里的" 学习曲线" 若无特别说明，都指样本量—误差曲线。

来源：两种含义的对照据金融机器学习教材与组织学习文献中的同名概念。

防止过拟合的两条原则 Two Principles against Overfitting

原则一：限制复杂度（奥卡姆剃刀）

最简单的解往往是正确的解。在监督学习中，这意味着限制特征数量，并惩罚过于复杂或过于灵活的算法——约束它们只保留能降低样本外误差的参数。

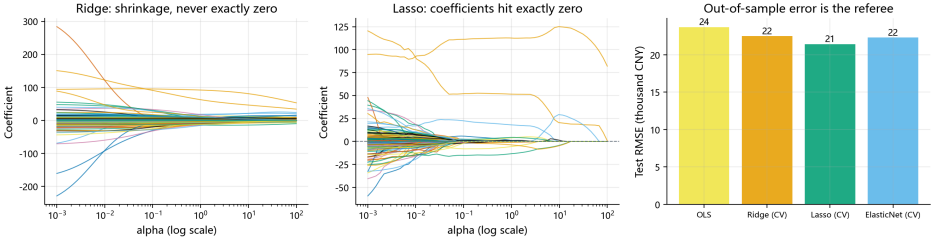
原则二：避免抽样偏差

好的实验设计有代表性样本与控制组，且二者应来自同一理论分布。监督学习中的做法是谨慎地把数据分成三份：训练样本（标签已知）、验证样本（比较与调参）、测试样本（确认预测能力）。目标是让模型部署到同一领域的全新数据上。

两条原则对应两类技术：惩罚（Ridge/Lasso、剪枝、早停）与采样（交叉验证、分层、时间切分、分组切分）。

来源：两条原则与奥卡姆剃刀的表述据金融机器学习教材的评估章节。

【样本 + 可视化】正则化路径：收缩与稀疏 Shrinkage versus Sparsity



三次展开后有 164 个特征（训练行只有 900）：Ridge 让系数整体收缩但不归零，Lasso 让系数逐个归零；右图的样本外误差显示惩罚比不惩罚更准，但三种惩罚之间差异不大——选型要看稀疏性是否对你有用。

程序 `15_05_regularized_regression.py` ·样本 `15_housing.csv` ·结果 `15_regression_scores.csv`

泛化误差与归纳偏置 Generalisation Error and Inductive Bias

监督学习的目标

用输入对象（预测变量向量）与期望输出（人工标注的监督信号）训练模型；训练过程构建一个把新数据映射到期望输出的函数。理想情况下，算法能对未见实例给出正确输出。

归纳偏置

这要求学习算法能以" 合理" 的方式从训练数据泛化到未见情形——这个" 合理" 来自算法的归纳偏置（它偏好什么样的解）。算法的这一统计性质通过泛化误差来度量。

例子：线性模型的偏好是" 平滑的线性关系"；KNN 的偏好是" 局部相似"；树模型的偏好是" 轴平行的矩形划分"。偏好与数据形态不匹配，就会欠拟合。

来源：监督学习定义与泛化误差的表述据机器学习基础教材；归纳偏置示例为本讲补充。

回归任务的评估指标 Regression Metrics

指标	定义与特点	何时使用
MSE	均方误差，对大误差惩罚重	作为优化目标（可导、便于分解）
RMSE	与目标同量纲（本讲房价单位：千元）	向业务方汇报误差大小
MAE	绝对误差均值，对离群点更稳健	误差分布厚尾时
R^2	解释的方差比例，与基线比较	需要"相对提升"的说法时
MAPE	百分比误差，跨量纲可比	目标值远离零且量纲差异大时

纪律：报误差时必须给出基线（例如"用均值预测"的 RMSE）；并且同一份报告里不要混用不同指标做模型对比。

来源：指标定义据统计学习与 scikit-learn 文档；汇报纪律为本讲补充。

分类任务的评估指标 Classification Metrics

从混淆矩阵出发

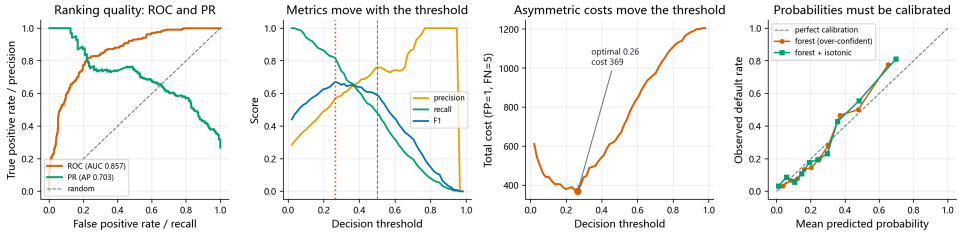
- 准确率：正确比例——类别不平衡时会被基线骗过；
- 精确率：预测为正的里面有多少真的正；
- 召回率：真的正里面有多少被抓到；
- F1：精确率与召回率的调和平均；
- ROC-AUC：跨阈值的排序能力；
- PR-AUC：正类稀少时更敏感。

本讲样本的实测

信用卡样本正类 26.7%：多数类基线准确率 73.3%、AUC 0.500；逻辑回归测试集 AUC 0.840。在 0.5 阈值下正类召回率只有 0.444——阈值没调好，模型再好也没用（帧 43）。

来源：指标定义据机器学习评估通行做法；数值来自本讲程序 l5_01 与 l5_04 的实测输出。

【样本 + 可视化】指标、阈值与校准 Metrics, Thresholds and Calibration



测试集 ROC-AUC 0.857、平均精度 0.704；在" 漏判代价是误报 5 倍" 的假设下，最优阈值是 0.26 而不是 0.5（总代价 369）；随机森林概率偏自信（Brier 0.146），等渗校准后降到 0.143，逻辑回归本身已达 0.130。

程序 `l5_04_metrics_thresholds.py` ·阈值表 `l5_threshold_table.csv` ·样本 `l5_credit_default.csv`

代价敏感与阈值选择 Cost-Sensitive Decisions

把业务代价写进去

- 误报（FP）代价：人工复核成本、客户打扰；
- 漏判（FN）代价：坏账损失、欺诈金额；
- 期望总代价 $= \text{cost}_{FP} \cdot FP + \text{cost}_{FN} \cdot FN$；
- 在阈值网格上最小化期望代价，得到业务最优阈值。

三条实务建议

1. 阈值不进模型、进决策层：模型输出概率，阈值由业务定；
2. 阈值变化要说清召回率/精确率的交换；
3. 代价不对称时，用代价曲线而不是 AUC 做最终选择。

本讲样本：把漏判代价设为误报的 5 倍后，最优阈值从 0.5 降到 0.26——同样的模型，决策规则一变，业务结果就变。

来源：代价敏感决策据信用风险与欺诈检测的业务实践；数值来自本讲程序 l5_04。

【代码】指标、阈值与概率校准 Metrics, Thresholds, Calibration

```python
fpr, tpr, _ = roc_curve(y_test, proba)                # ROC curve points
roc_auc = auc(fpr, tpr)                               # area under the ROC curve
prec, rec, thr_pr = precision_recall_curve(y_test, proba) # precision-recall curve points
ap = average_precision_score(y_test, proba)           # average precision, the PR summary
for t in thresholds:                                  # loop over the threshold grid
    pred = (proba >= t).astype(int)                   # hard labels at this threshold
    rows.append({"threshold": round(float(t), 3),     # threshold value
                 "precision": round(precision_score(y_test, pred, zero_division=0), 4), # precision
                 "recall": round(recall_score(y_test, pred, zero_division=0), 4), # recall
                 "f1": round(f1_score(y_test, pred, zero_division=0), 4)}) # harmonic mean
costs = cost_curve(y_test, proba, thresholds, cost_fp=1.0, cost_fn=5.0) # FN costs five times an FP
best_cost_idx = int(np.argmin(costs))                 # threshold with the lowest total cost
calibrated = CalibratedClassifierCV(                  # wrap the forest with isotonic calibration
    Pipeline([("prep", prep), ("model", RandomForestClassifier(random_state=42))]), # base pipeline to calibrate
    method="isotonic", cv=5)                          # isotonic regression fitted with cross-validation
```

要点：曲线描出全部阈值，再用业务代价挑一个点；概率要校准后才可用于" 期望损失" 计算。完整程序 `15_04_metrics_thresholds.py`。

概率校准与不确定性 Calibration and Uncertainty

校准是什么意思

模型说"70% 会违约" 的时候，如果现实中确实约 70% 违约，概率就是校准的（reliability diagram 落在对角线上）。树与集成模型常常过度自信，需要等渗（isotonic）或 Platt 校准。

除了校准还要报什么

- 样本量与置信区间（L4 已讲过的自助法可直接复用）；
- 校准指标：Brier 分数、可靠性曲线；
- 决策的不确定性：阈值附近的样本占比；
- 分布漂移下的重校准计划（帧 96）。

一句话：概率用于决策，就必须可信；只报 AUC 不报校准，等于把" 排序能力" 当成了" 概率质量"。

来源：校准方法（isotonic、Platt）与 Brier 分数据 scikit-learn 文档与概率预测文献。

算法族地图 A Map of Supervised Algorithms

家族	代表方法	特点、代价与坑
线性模型	线性回归、逻辑回归、Ridge/Lasso	快、可解释、可给系数置信；非线性关系下欠拟合
距离模型	KNN	无需训练、天然非线性；预测慢、对量纲与维度敏感
间隔模型	SVM（线性/核）	小样本高维表现好；调参敏感、概率需校准、大数据慢
树模型	CART	可解释、能处理混合类型；方差大、易过拟合
集成模型	随机森林、梯度提升	表格数据的强基线；调参多、解释性下降
神经网络	MLP、深度网络	处理非结构化与高交互；需要数据与算力、调参难

选择顺序建议：先线性基线 → 再树与集成 → 最后神经网络；每一步都要与前一步比样本外表现，而不是比" 谁更先进"。

来源：家族划分与特点据统计学习教材与 scikit-learn 用户指南整理。

线性与多元回归 Linear and Multiple Regression

作为第一个基线

- 形式简单：$\hat{y} = \beta_0 + \sum_j \beta_j x_j$；
- 系数可读作边际效应（在控制其他变量的条件下）；
- 计算极快，几分钟内就能得到" 可达水平" 的参照；
- 在样本量远大于变量数、关系近似线性时已经够用。

什么时候必须放弃

- 明显非线性或强交互（如面积与地段的交互）；
- 特征数接近或超过样本量（帧 22）；
- 存在大量离群点且未处理（改用稳健回归）。

本讲房价样本的线性基线已经能解释相当一部分变异，但把面积的三次项与面积 $\times$ 地段交互加进去后，样本外 RMSE 明显下降——这就是" 基线 $\rightarrow$ 增强" 的标准流程。

来源：回归基线的实践据统计学习教材；本讲数值来自程序 l5_03 与 l5_05。

惩罚回归：Ridge、Lasso 与 Elastic Net Regularised Regression

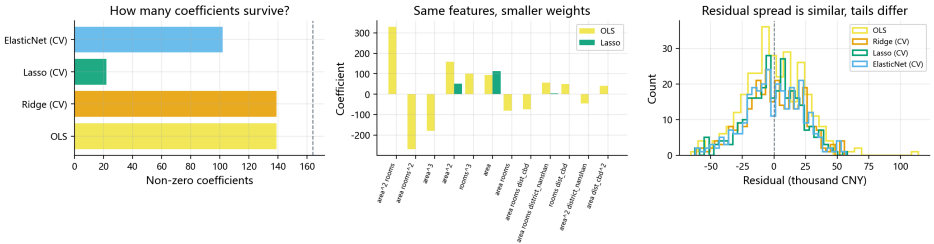
方法	惩罚项	结果与使用场合
OLS	无	无偏但方差大；P 接近 N 时不可靠
Ridge	$\lambda \sum \beta_j^2$	系数收缩但不为零；共线性强、特征都有用时首选
Lasso	$\lambda \sum \lvert\beta_j\rvert$	产生稀疏解（部分系数恰好为零）；需要变量选择时用
Elastic Net	两者混合	兼顾稀疏与稳定；特征成组相关时优于纯 Lasso

三个前提：(1) 惩罚前必须标准化（否则惩罚强度依赖量纲）；(2) λ 用交叉验证选（`RidgeCV`/`LassoCV`）；(3) 惩罚会引入偏差，换来更低的方差——这正是帧 35 的偏差-方差权衡。

Penalties trade bias for variance.

来源：三种惩罚的形式与适用场合据统计学习教材；前提与选择方式为本讲补充。

【样本 + 可视化】回归族对照 Comparing the Regression Family



同一份 164 维展开特征：Lasso 把绝大多数系数压到零（稀疏），Ridge 保留全部但整体变小；右图显示三种惩罚的残差分布几乎一致——说明在这个样本上，"稀疏性"的价值在于可解释与部署成本，而不是精度。

程序 `l5_05_regularized_regression.py` · 系数表 `l5_coefficients.csv` · 结果 `l5_regression_scores.csv`

【代码】正则化回归与系数路径 Regularised Regression Paths

```python
poly = PolynomialFeatures(degree=3, include_bias=False) # cubic expansion creates many columns
Xtr_poly = poly.fit_transform(X_train)                  # expand the training features
scaler = StandardScaler().fit(Xtr_poly)                 # scaling is fitted on the training split only
Xtr = scaler.transform(Xtr_poly)                        # scaled training matrix
alphas = np.logspace(-3, 2, 60)                         # grid of penalty strengths, log spaced
models = {                                              # one entry per family
    "OLS": LinearRegression(),                          # no penalty at all
    "Ridge (CV)": RidgeCV(alphas=alphas, cv=5),         # L2 penalty, strength chosen by CV
    "Lasso (CV)": LassoCV(alphas=alphas, cv=5, max_iter=20000, random_state=42), # sparse solutions
    "ElasticNet (CV)": ElasticNetCV(alphas=alphas, l1_ratio=[0.2, 0.5, 0.8], cv=5)} # mixed penalty
for a in alphas:                                        # walk the penalty grid from weak to strong
    r = Ridge(alpha=a).fit(Xtr, y_train)                # ridge at this strength
    l = Lasso(alpha=a, max_iter=20000).fit(Xtr, y_train) # lasso at this strength
    paths_ridge.append(r.coef_)                         # store the ridge coefficients
    paths_lasso.append(l.coef_)                         # store the lasso coefficients
```

要点：缩放 → 展开 → 逐 λ 拟合 → 画路径；路径图能直观看出" 哪些变量先被淘汰"。完整程序 `l5_05_regularized_regression.py`。

K 近邻 K-Nearest Neighbours

做法

对新样本，找训练集中距离最近的 k 个邻居，按多数类（分类）或均值（回归）给出预测。属于惰性学习：训练只是存数据，预测时才计算。

四个关键点

- 距离度量（欧氏、曼哈顿）与标准化必须一起定；
- k 小 $\to$ 边界复杂、方差大；k 大 $\to$ 边界平滑、偏差大；
- 维度灾难：维度高时" 最近邻" 也不再近；
- 类别不平衡时用距离加权或分层抽样。

本讲双月牙样本的实测（测试集 180 行）：$k = 1$ 准确率 0.839、$k = 15$ 0.911、$k = 99$ 0.861——中间最好，两头都差。

来源：KNN 的性质据统计学习教材；数值来自本讲程序 l5_06 的实测输出。

支持向量机 Support Vector Machines

核心思想

找一个能把两类分开、并且间隔最大的超平面；允许少量违例（软间隔，由 C 控制）；用核函数把非线性问题映射到高维空间后线性可分。

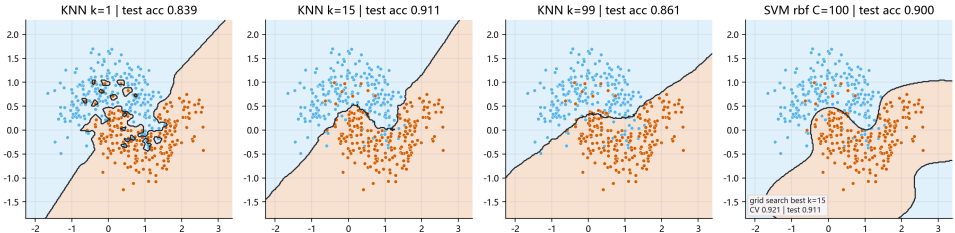
调参与注意事项

- C 大：尽量不违例（易过拟合）；C 小：容忍更多违例（更平滑）；
- RBF 核还有 γ：控制" 单个样本的影响半径"；
- 概率输出需要Platt 校准（`probability=True` 会变慢）；
- 标准化几乎总是必须的；样本量很大时训练代价高。

本讲双月牙样本上，RBF 核明显优于线性核；交叉验证给出的最优配置与测试集表现一致（帧 54 的搜索表）。

来源：SVM 与核方法据统计学习教材与 scikit-learn 文档；数值来自程序 l5_06。

【样本 + 可视化】KNN 与 SVM 的决策边界 Decision Boundaries



同一份双月牙数据（600 行）：$k = 1$ 边界破碎（测试 0.839）、$k = 15$ 平滑且准确（0.911）、$k = 99$ 过于平滑（0.861）；网格搜索选出 $k = 15$（交叉验证 0.921，测试 0.911）。

程序 `15_06_knn_svm_tuning.py` ·样本 `15_two_moons.csv` ·搜索表 `15_tuning_results.csv`、`15_svm_tuning.csv`

决策树与集成学习 Trees and Ensembles

决策树（CART）

- 递归地选择"最能降低不纯度的划分"（基尼或熵）；
- 深度与叶节点最小样本数是主要复杂度旋钮；
- 优点：可解释、能处理混合类型与缺失；
- 缺点：方差大——数据稍有变化，树结构就变（帧 57 左图）。

集成学习

- Bagging：并行训练多棵深树再平均 → 主要降方差（随机森林）；
- Boosting：串行训练浅树、每棵修正前面的错误 → 主要降偏差（GBDT）；
- 随机森林再加特征子采样，进一步降低树之间的相关性。

本讲房价与信用样本上：单棵树 AUC 0.790 明显落后，随机森林 0.822、梯度提升系 0.809–0.831——集成的收益主要来自降方差。

来源：树与集成的原理据统计学习教材；数值来自本讲程序 l5_07 的实测输出。

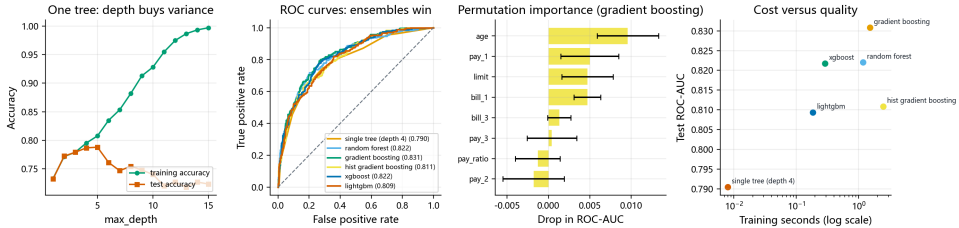
梯度提升族：XGBoost、LightGBM、CatBoost Gradient Boosting

实现	特点	本讲实测（信用卡样本，测试集 900 行）
经典 GBDT	逐棵拟合残差，慢但稳定	AUC 0.831，训练 1.53 s
scikit-learn HistGB	直方图分箱，免独热	AUC 0.811，训练 2.49 s
XGBoost	正则化 + 行列采样，工业标配	AUC 0.822，训练 0.29 s
LightGBM	叶子优先生长，大数据最快	AUC 0.809，训练 0.19 s
CatBoost	类别特征内建处理	（本讲未含类别特征，未启用）

三个共同的关键超参数：学习率、树的棵数、树深/叶子数；调参顺序建议：先固定学习率 0.05–0.1，用早停确定棵数，再调结构。

来源：实现特点据各库官方文档；实测数字来自本讲程序 l5_07（同一台机器、同一划分）。

【样本 + 可视化】树与集成：代价与收益 Trees versus Ensembles



左一：单棵树加深会训练准确率飙升但测试准确率回落；左二：六种模型的 ROC 曲线；右二：置换重要性显示还款状态三列最重要；右一：训练成本 vs 质量——本样本上 LightGBM 用 0.19 s 拿到 0.809，性价比最高。

程序 `15_07_trees_ensembles.py` ·结果 `15_ensemble_scores.csv` ·重要性 `15_feature_importance.csv`

【代码】树与集成：拟合、计时与重要性 Ensembles with Timing

```python
def fit_model(name, model):                          # helper that fits one model and scores it
    pipe = Pipeline([("prep", trees_prep), ("model", model)]) # wrap the estimator with preprocessing
    t0 = time.time()                                 # start the clock
    pipe.fit(X_train, y_train)                       # fit on the training split
    seconds = time.time() - t0                       # record the cost
    proba = pipe.predict_proba(X_test)[:, 1]         # predicted probabilities on the test split
    fpr, tpr, _ = roc_curve(y_test, proba)           # ROC points for the panel
    row = {"model": name,                            # model identifier
          "test_auc": round(float(auc(fpr, tpr)), 4), # area under the ROC curve
          "train_seconds": round(seconds, 3)}        # training cost
    return row, pipe, (fpr, tpr)                     # return everything the figure needs
row, pipe, curve = fit_model("lightgbm", LGBMClassifier(n_estimators=400, # histogram based boosting
    learning_rate=0.06, num_leaves=31, random_state=42, verbose=-1)) # leaf-wise growth, quiet console
perm = permutation_importance(fitted[best_name], X_test, y_test, # model-agnostic importance
                        n_repeats=8, random_state=42, scoring="roc_auc") # eight repeats for a spread
```

要点：计时与打分放在同一个函数里，才能画出"代价—质量"面板；重要性用置换法（模型无关），比内建重要性更可比。

完整程序 `15_07_trees_ensembles.py`。

朴素贝叶斯、LDA 与相似度学习 Naive Bayes, LDA, Similarity

朴素贝叶斯

假设特征在给定类别下条件独立，用贝叶斯公式分类。训练极快、小样本可用，是文本分类的经典基线；缺点是独立性假设常常不成立（特征高度相关时概率被推得过于极端）。

线性判别分析（LDA）

假设各类服从同协方差的高斯分布，寻找使类间/类内方差比最大的方向；自带降维能力，样本量相对特征数偏小时需要正则化版本。

相似度学习与其他

- 度量学习：学习一个距离，使同类更近、异类更远（人脸、检索）；
- 最近邻检索：把样本表示为向量，用近似最近邻索引找相似项（衔接 L11 的嵌入与 RAG）；
- 选择原则：先跑一遍简单模型，看它离要求有多远，再决定是否升级。

来源：朴素贝叶斯与 LDA 的假设据统计学习教材；相似度学习与向量检索据信息检索实践。

选型决策表 Choosing an Estimator

问题	数据情况	建议起点
数值预测	特征相关性强	PCA 降维后再回归
数值预测	线性、$N \gg P$	线性回归 → Ridge/Lasso
数值预测	非线性、有交互	树与集成（GBDT）→ 神经网络
分类	有标签、线性可分	逻辑回归；KNN 或线性 SVM
分类	有标签、非线性	树与集成；RBF 核 SVM；神经网络
分类	无标签（分组）	已知组数：k-means；未知组数：层次聚类/DBSCAN

使用方式：从问题与数据两列出发查找，再回到第 47 页的算法族地图确认代价；任何选择都要用同一套评估协议验证（帧 26–30）。

来源：决策表据估计器选择流程与统计学习教材整理，覆盖原流程中的 PCA、惩罚回归、KNN、SVM、树、集成与聚类分支。

scikit-learn 估计器地图 Using the Estimator Map

怎么用这张图

官方用户指南提供一张交互式估计器地图：从"我有多少样本、要不要预测类别"出发，沿着问题分支一直走到具体估计器，点击即可跳到文档。

本课程的用法

- 用地图找候选，用第 60 页的决策表做取舍；
- 候选至少包含一个基线（多数类/均值）与一个简单模型；
- 最终选择由交叉验证的均值与标准差决定，而不是由名气决定。

与课程其他讲次的衔接

- L6：线性回归与逻辑回归的闭式解与梯度下降；
- L7：SVM 与核、CART、随机森林、梯度提升、不平衡处理与调参；
- L8：PCA、因子分析、聚类与异常检测；
- L9：深度学习与训练技巧。

来源：估计器地图，scikit-learn 官方用户指南（scikit-learn.org/stable/tutorial/machine_learning_map）。

无监督学习的用途 What Unsupervised Learning Is For

四类用途

1. 探索：在没有任何假设的情况下看数据结构；
2. 压缩：用更少的维度概括变异（降维）；
3. 分组：把相似对象放到一起（聚类）；
4. 发现异常：找出与大多数不同的个体。

最大的困难：没有标准答案

- 没有标签 → 不能用" 准确率" 评价；
- 只能用内部指标（轮廓系数等）与稳定性（重采样后分组是否一致）；
- 最终裁判是业务可解释性与后续用途；
- 因此无监督结果必须与外部变量交叉验证（例如分组是否对应不同的留存率）。

来源：四类用途与评估困难据无监督学习综述与教材整理。

主成分分析 Principal Component Analysis

在做什么

找到一组互相正交的方向，使数据投影到这些方向后方差最大；第一个方向（PC1）解释最多变异，第二个在与第一个正交的约束下解释次多，依此类推。数学上是对相关系数矩阵做特征值分解。

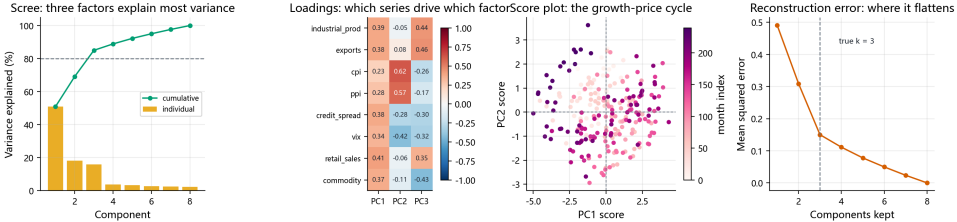
使用要点

- 必须先标准化，否则量纲大的变量独占总方差；
- 用碎石图与累计解释率决定保留几个成分；
- 载荷（loadings）说明" 每个成分由哪些变量驱动"；
- 成分的符号不唯一（整体取反等价），解释时要注意。

本讲宏观面板（240 个月 $\times$ 8 个序列，由 3 个潜在因子生成）：前三个成分解释 50.9% + 18.2% + 15.9%，五个成分累计 92.2%。

来源：PCA 的性质据统计学习教材；数值来自本讲程序 l5_08 的实测输出。

【样本 + 可视化】PCA 与潜在因子 Principal Components and Factors



240 个月、8 个宏观序列（真实结构是 3 个潜在因子）：碎石图在第 3–4 个成分处出现拐点；载荷热力图显示 PC1 由生产与出口驱动、PC2 由物价驱动、PC3 由风险驱动；重构误差曲线也提示 $k \approx 3$。

程序 `15_08_pca_factors.py` ·样本 `15_macro_panel.csv` ·载荷 `15_pca_loadings.csv` ·重构 `15_pca_reconstruction.csv`

【代码】PCA 与重构误差 PCA and Reconstruction Error

```
X = panel[cols].values                                  # numeric matrix of observables
X_std = StandardScaler().fit_transform(X)               # standardising is mandatory before PCA
pca = PCA().fit(X_std)                                  # keep all components for the scree plot
evr = pca.explained_variance_ratio_ * 100               # share of variance explained per component
cum = np.cumsum(evr)                                    # cumulative share of variance
scores = pca.transform(X_std)[:, :3]                    # keep the first three component scores
loadings = pd.DataFrame(pca.components_[:3].T, index=cols, # rows are series, columns are components
                        columns=["PC1", "PC2", "PC3"]).round(3) # round for readability
for k in range(1, len(cols) + 1):                       # from one component to all of them
    pca_k = PCA(n_components=k).fit(X_std)              # fit a truncated decomposition
    approx = pca_k.inverse_transform(pca_k.transform(X_std)) # project down and back up
    recon_error.append(float(np.mean((X_std - approx) ** 2))) # mean squared reconstruction error
```

要点：碎石图定个数、载荷定含义、重构误差定损失；三个视角一致时，成分个数才可信。完整程序 `l5_08_pca_factors.py`。

因子分析与金融应用 Factor Analysis in Finance

与 PCA 的差别

PCA 找的是方差最大的方向（纯数据驱动）；因子分析假设观测由少数潜在因子 + 个体噪声生成，估计的是" 共同变动的来源"，因此对变量的共同部分更敏感。

金融中的经典用途

- 收益的共同因子：市场、规模、价值（Fama–French 三因子的直觉）；
- 用少量因子解释大量资产的共同变动；
- 因子暴露用于风险归因与组合约束；
- 注意：因子是统计构造，命名与解释需要经济学理由。

方法上的教训：降维后的成分/因子本身没有含义，必须结合载荷与业务知识给它命名，否则"PC1"什么也说明不了。

来源：因子分析与 Fama–French 因子模型据资产定价文献；与 L13 金融专题衔接。

非线性降维与嵌入 Non-linear Embeddings

t-SNE 与 UMAP

- t-SNE：保持局部邻域，簇分得开；簇间距与簇大小不可读；
- UMAP：兼顾局部与全局结构、更快、可对新样本 transform；
- 两者都对参数与随机种子敏感，必须写进图注；
- 用邻域保真度（trustworthiness）而不是" 看起来分得开" 评价。

何时用不监督降维

- 可视化：把高维样本画成二维查看结构 (L4 Part 7 已有完整示例)；
- 特征压缩：为下游模型提供更少、更稳的输入；
- 检索：把样本变成嵌入向量，用近似最近邻找相似项（衔接 L11)；
- 陷阱：把降维结果当" 证据"——结论要回到原维度验证。

来源：方法与陷阱据流形学习研究与 L4 第 7 部分的实测经验整理。

聚类总览 Four Families of Clustering

思路	代表方法	假设与适用
基于中心	k-means	球形、大小相近的簇；需要预设 k；快
基于层次	层次聚类（Ward 等）	不需要预设 k；给树状图；$O(n^2)$ 内存
基于密度	DBSCAN、HDBSCAN	任意形状、能识别噪声；对 eps 极敏感
基于模型	高斯混合 + EM	软分配与概率密度；可给出后验概率

本讲行为客户样本（830 行含 30 个离群点）：k-means 与 Ward 都恢复出 4 个生成簇（ARI 1.00 与 0.99），而DBSCAN 在单一 eps 下只分出 2 组、并把 25 个点判为噪声——" 密度聚类能不能用" 取决于簇的密度形状，不是方法高低。

来源：四类聚类思路据聚类分析综述；数值来自本讲程序 l5_09。

k-means：最常用也最容易被误用 k-means

算法与目标

最小化簇内平方和 (inertia)：$\sum_c \sum_{x \in c} \|x - \mu_c\|^2$。交替执行" 分配样本 $\rightarrow$ 更新中心"，直到收敛；用 k-means++ 初始化以降低陷入局部最优的概率。

四个常见误用

1. 不做标准化：量纲大的特征独占距离；
2. 用 inertia 选 k：inertia 随 k 单调下降，必须看拐点或轮廓系数；
3. 强行解释球形簇：对长条形或密度不均的簇会切错；
4. 忽略初始化：不同随机种子给出不同结果，应设 `n_init` 并报告稳定性。

本讲样本的实测提醒：轮廓系数偏好 $k = 2$（0.568），但真实结构与业务判断都是 4（ARI 1.00）——内部指标只是参考，必须结合外部信息。

来源：k-means 的目标函数与初始化据统计学习教材；数值来自本讲程序 l5_09。

层次聚类、DBSCAN 与高斯混合 Hierarchy, Density, Mixtures

层次聚类

自底向上合并最近的簇，得到树状图；在合适的距离高度切一刀即得分组。距离定义（单链、全链、平均、Ward）决定结果，Ward 偏好紧凑的球形簇。

DBSCAN

以邻域半径 eps 与最小点数定义"稠密"；能发现任意形状的簇并识别噪声点，但单一全局 eps 无法同时适配不同密度的簇。

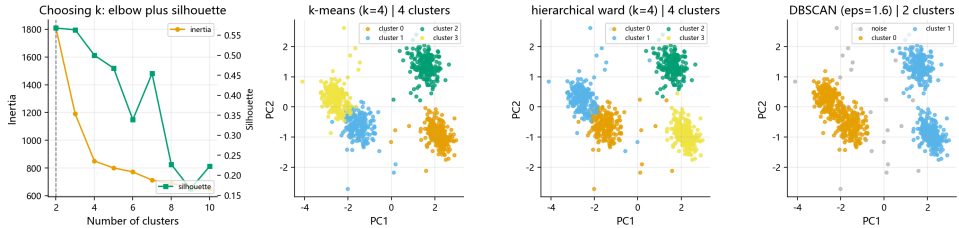
高斯混合 + EM

假设数据由若干个高斯分布混合生成：

- E 步：计算每个样本属于各成分的后验概率（软分配）；
- M 步：用后验加权重估均值与协方差；
- 与 k-means 的关系：k-means 是"硬分配 + 等方差球"的特例。

来源：三类方法的表述据聚类分析教材；与 L8 的聚类专题衔接。

【样本 + 可视化】三种聚类方法对照 Three Clustering Families



830 个客户（含 30 个离群点）：k-means 与 Ward 恢复出 4 组（ARI 1.00 与 0.99）；DBSCAN 在 eps=1.6 下只找到 2 组、25 个噪声点（ARI 0.50）。左图提醒：轮廓系数偏好 2 组，与生成结构不一致。

程序 `l5_09_clustering.py` ·样本 `l5_customers_behavior.csv` ·对照表 `l5_cluster_scores.csv`

【代码】聚类的 k 选择与三种方法 Choosing k and Comparing

```python
for k in k_grid:                                    # loop over the candidates
    km = KMeans(n_clusters=k, n_init=10, random_state=42).fit(X_std) # fit k-means for this k
    sil = silhouette_score(X_std, km.labels_, sample_size=600, random_state=42) # sampled silhouette
    ch = calinski_harabasz_score(X_std, km.labels_)   # variance ratio criterion
    rows.append({"k": k, "inertia": round(float(km.inertia_), 1), # within cluster sum of squares
                 "silhouette": round(float(sil), 4)})   # separation measure
kmeans = KMeans(n_clusters=4, n_init=10, random_state=42).fit(X_std) # centroid based clustering
agglo = AgglomerativeClustering(n_clusters=4, linkage="ward").fit(X_std) # hierarchical, ward linkage
dbscan = DBSCAN(eps=1.6, min_samples=12).fit(X_std)   # density based clustering
mask = lab >= 0                                     # DBSCAN noise points have label minus one
enough = mask.sum() > 10 and len(set(lab[mask])) > 1  # silhouette needs two non-empty clusters
sil = silhouette_score(X_std[mask], lab[mask], sample_size=600, random_state=42) if enough else np.nan # guarded score
ari = adjusted_rand_score(labels_true[labels_true >= 0], lab[labels_true >= 0]) # agreement with truth
```

要点：同时看三个内部指标 + 与已知结构的一致性（ARI）；DBSCAN 的噪声标签（-1）在计算指标前必须处理。完整程序 `15_09_clustering.py`。

评估、异常检测与关联规则 Evaluation, Anomalies, Rules

聚类评估

- 内部指标：轮廓系数、Calinski–Harabasz、Davies–Bouldin；
- 外部指标（有标签时）：ARI、NMI、纯度；
- 稳定性：重采样后分组是否一致（本讲用 ARI 与生成结构对照）。

异常检测

孤立森林、LOF、单类 SVM：在没有异常标签时仍可用于筛查，但阈值需要业务确认。

关联规则

从交易数据中发现" 一起出现" 的组合 (Apriori、FP-Growth)；关注支持度、置信度、提升度三个量，提升度接近 1 说明只是" 因为都常见"，不是真的关联。

来源：评估指标与三类方法据无监督学习教材与数据挖掘教材；与 L8 的无监督专题衔接。

为什么需要神经网络 Why Neural Networks

神经网络擅长什么

神经网络（ANN）是一类高度灵活的 ML 算法，在非线性与特征交互突出的任务上表现很好；既用于分类与回归，也是深度学习与强化学习的基础（后两者可以是监督的，也可以是无监督的）。

但在表格数据上要先克制

- 表格数据的强基线仍然是树与集成（帧 56–57）；
- 神经网络需要更多数据、更多调参与更多算力；
- 只有在非结构化数据（图像、文本、序列）或强交互场景，神经网络的收益才明显；
- 结论：先跑集成，再决定要不要上网络。

来源：神经网络定位据金融机器学习教材；表格数据与深度模型的取舍据近年实证对比研究。

从多元回归到神经网络 From Regression to Networks

多元回归（对照）

用 4 个输入特征预测 1 个输出：$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_4 x_4$。预测值是输入的线性组合。

单隐层神经网络

- 由节点（圆圈）与链接（箭头）构成；
- 三类层：输入层（每个特征一个节点）、隐层（学习发生的地方）、输出层（把结果传出网络）；
- 关键差别：隐层节点把输入非线性地变换成新值，再组合成输出——没有非线性，多层就退化成一层。

本讲的实测对照（双月牙样本）：手写两层网络测试准确率 0.929，scikit-learn 的同宽度网络 0.933——机制一致时，实现细节决定最后几个千分点。

来源：结构与表述据金融机器学习教材的神经网络章节；数值来自本讲程序 l5_10。

一个节点的内部：求和与激活 Inside One Neuron

两个功能部件

1. 求和算子：把收到的输入各乘一个权重再相加，得到总净输入；
2. 激活函数：把总净输入变换成该节点的最终输出。

打个比方，激活函数像调光开关，把输入的强度调高或调低。

激活函数必须是非线性的

函数	特点
sigmoid	输出 0–1，两端梯度小（易梯度消失）
tanh	输出 -1–1，零中心
ReLU	$\max(0, z)$，计算快、缓解梯度消失；负半轴梯度为零
softmax	输出层用于多分类，输出和为 1

非线性意味着输出的变化率随输入水平而不同——这正是神经网络能拟合弯曲关系、而线性模型不能的原因。

来源：节点机制与激活函数的表述据金融机器学习教材；函数对照为通用整理。

结构就是超参数 Architecture as Hyper-Parameters

从 4-5-1 说起

一个输入层 4 个节点、1 个隐层 5 个节点、输出层 1 个节点的网络，"4、5、1" 这三个数字就是超参数——它们决定网络的结构。更复杂的网络可以有多个隐层、每层不同宽度。

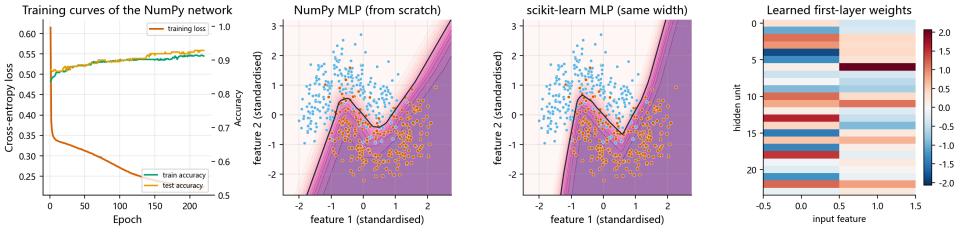
主要超参数清单

超参数	作用
层数与宽度	模型容量
学习率	每步更新幅度
批大小	梯度估计的噪声与速度
正则化	dropout、权重衰减、早停
轮数 epoch	训练多久（配合早停）

纪律：网络结构也要进交叉验证。本讲的手写网络固定一个隐层 24 个单元，就是为了让" 机制" 而不是" 调参" 成为重点。

来源：超参数清单据深度学习实践与金融机器学习教材整理。

【样本 + 可视化】两层网络的训练过程 Training a Two-Layer Network



左一：手写网络的损失下降、训练与测试准确率上升（双月牙样本）；中两格：手写网络与 scikit-learn 同宽度网络的决策边界几乎一致（测试准确率 0.929 vs 0.933）；右一：第一层权重热力图——网络学到了" 特征组合"。

程序 `15_10_mlp_numpy.py` ·训练历史 `15_mlp_history.csv` ·样本 `15_two_moons.csv`

前向传播 Forward Propagation

从输入到输出

输入层的值经链接传给隐层节点：每条链接带一个权重，节点把加权值求和，再经激活函数"决定是否发放"。负的净输入经 S 形函数后接近 0（不发放），正的净输入接近 1（发放）；激活后的值继续向前传给下一层，直到输出层。

矩阵写法

$$z_1 = XW_1 + b_1, \quad a_1 = \mathrm{ReLU}(z_1)$$

$$\hat{y} = \mathrm{softmax}(a_1 W_2 + b_2)$$

这就是本讲手写实现中的两行代码；一层的输出是下一层的输入，如此而已。

来源：前向传播的表述据金融机器学习教材的神经网络章节；矩阵形式为本讲补充。

【代码】纯 NumPy 的前向与反向传播 Forward and Backward in NumPy

```python
def forward(Xb, params):                          # forward propagation through the network
    W1, b1, W2, b2 = params                       # unpack the parameters
    z1 = Xb @ W1 + b1                             # linear combination of the inputs
    a1 = np.maximum(z1, 0.0)                      # ReLU activation of the hidden layer
    logits = a1 @ W2 + b2                         # linear output layer
    exp = np.exp(logits - logits.max(axis=1, keepdims=True)) # stabilised exponentials for softmax
    proba = exp / exp.sum(axis=1, keepdims=True)  # class probabilities
    return logits, a1, proba                      # return intermediate values for back propagation
def loss_and_grads(Xb, yb, params, l2=1e-4):      # cross-entropy loss plus its gradients
    logits, a1, proba = forward(Xb, params)       # run the forward pass
    loss = -np.log(np.clip(proba[np.arange(n), yb], 1e-12, 1.0)).mean() # mean cross-entropy
    dlogits = proba.copy()                        # gradient of the loss with respect to the logits
    dlogits[np.arange(n), yb] -= 1.0              # subtract one at the true class
    dW2 = a1.T @ dlogits + 2 * l2 * W2            # gradient for the second weight matrix
    dz1 = da1 * (a1 > 0)                          # ReLU derivative: one where the unit fired
    dW1 = Xb.T @ dz1 + 2 * l2 * W1                # gradient for the first weight matrix
```

要点：前向算出中间值，反向按链式法则逐层回传；交叉熵对 logits 的梯度恰好是" 预测减真实"，这让实现异常简洁。完整程序 `15_10_mlp_numpy.py`。

训练循环与优化器 Training Loop and Optimisers

一次迭代发生了什么

1. 取一个小批量（mini-batch）样本；
2. 前向计算预测与损失；
3. 反向计算各参数的梯度；
4. 沿梯度更新权重（学习率决定步长）；
5. 重复直到遍历完数据（一个 epoch），多轮直到收敛。

优化器家族

- SGD：最简单的梯度下降，需仔细调学习率；
- Momentum：积累方向，减少震荡；
- Adam：自适应步长，通常收敛更快（本讲 sklearn 对照用 Adam）；
- 早停：验证误差不再下降就停，是最有效的正则化之一。

调试顺序：先让模型在小批量上过拟合（确认能学），再正规化；损失不下降先查学习率与数据缩放，而不是先换结构。

来源：训练循环与优化器据深度学习实践教材；调试顺序为本讲补充。

深度学习网 Deep Learning Nets

定义与规模

带有很多隐层的神经网络被称为深度学习网 (DLN) ——至少 3 层，常见超过 20 层，是这一轮人工智能革命的骨干。DLN 推动了图像、模式与语音识别等复杂任务的进展。

它是怎么工作的

输入特征逐层经过带权重的非线性函数，每层输出通常落在 $(0,1)$ 或 $(-1,1)$ 区间；最后一层给出" 样本属于各个类别的概率"，取概率最高的类别作为预测。训练时用大数据集确定权重，以最小化指定损失函数。

2026 视角：规模与成本的取舍变了——小模型微调或提示 + 检索常常比从头训练更划算（帧 86–87、95）。

来源：深度学习网的表述据金融机器学习教材；2026 取舍为课程补充。

强化学习 Reinforcement Learning

核心设定

智能体（agent）应当采取一系列动作，以最大化长期回报，同时受环境约束。以 AlphaGo 为例：虚拟棋手（智能体）用控制台指令（动作），依据屏幕信息（环境），最大化自己的得分（回报）。

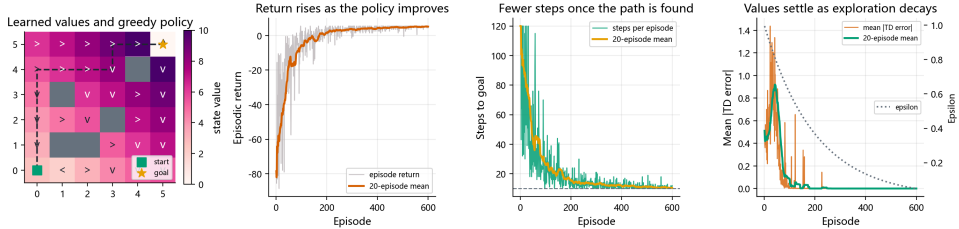
与监督学习的三点不同

1. 没有每个观测的直接标签；
2. 没有即时反馈——好动作的收益可能在很多步之后；
3. 算法必须观察环境、试验新动作、复用历史经验，其中一些动作在短期内看起来并不优。

关键权衡是探索与利用：本讲的 ε-贪心策略一开始几乎随机探索，随后逐渐转向利用学到的价值（帧 84 的曲线）。

来源：强化学习设定与 AlphaGo 案例据金融机器学习教材；探索-利用的表述为通用整理。

【样本 + 可视化】Q-learning 在网格世界里学会走路



6×6 网格、五个障碍：左上角是学到的状态价值热力图与贪心策略箭头（虚线为最优路径，长度 11 步）；右三格显示回合回报上升、步数下降、TD 误差随探索率衰减而收敛（最后 20 回合平均回报 5.20，平均 10 步到达目标）。

程序 `l5_11_rl_gridworld.py` ·训练历史 `l5_rl_returns.csv` ·无标签、无即时反馈

【代码】Q-learning：一个能跑通的强化学习例子

```python
def step(state, action):                                # one environment transition
    r, c = state[0] + action[0], state[1] + action[1] # candidate next cell
    if not (0 <= r < SIZE and 0 <= c < SIZE):          # moving off the grid is not allowed
        return state, -1.0                              # stay in place and pay the step cost
    if (r, c) in WALLS:                                 # moving into a wall is not allowed
        return state, -1.0                              # stay in place and pay the step cost
    if (r, c) == GOAL:                                  # reaching the goal ends the episode
        return (r, c), 10.0                             # terminal reward
    return (r, c), -0.5                                 # small negative reward encourages speed
for episode in range(1, episodes + 1):                  # loop over the episodes
    if rng.random() < eps:                              # explore with probability epsilon
        a = int(rng.integers(len(ACTIONS)))             # pick a random action
    else:                                               # otherwise exploit the current knowledge
        a = int(np.argmax(Q[state[0], state[1]]))       # greedy action from the Q table
    best_next = 0.0 if next_state == GOAL else float(np.max(Q[next_state[0], next_state[1]])) # bootstrap value
    td_target = reward + gamma * best_next              # the Q-learning target
    Q[state[0], state[1], a] += alpha * (td_target - Q[state[0], state[1], a]) # value update
```

要点：**奖励设计决定行为**（本讲用 -0.5 的步进代价鼓励走短路），ε 衰减控制探索；这就是 RLHF 之外最小可用的强化学习骨架。完整程序 `l5_11_rl_gridworld.py`。

自监督、迁移学习与微调 Self-Supervision and Transfer

三个概念

- 自监督：用数据自身构造监督信号（预测被遮住的词、判断两张图是否同源）；
- 迁移学习：先在大规模数据上预训练，再迁移到小数据任务；
- 微调：在目标任务上继续更新（部分或全部）权重。

三种用法怎么选

方式	适用
特征提取	数据很少、算力有限：冻结主体，只训分类头
部分微调	中等数据：只微调最后几层 (PEFT/LoRA)
全量微调	数据充足、任务与预训练差异大
提示 + 检索	无法微调或需要最新知识 (衔接 L11)

决策依据不是" 哪个更先进"，而是数据量、算力预算、更新频率与延迟要求——下一帧的 2026 取舍表给出判据。

来源：自监督与迁移学习的分类据深度学习与基础模型文献；用法选择为本讲整理。

2026 取舍：AutoML、基础模型与自建模型 Build or Reuse

路线	优势	代价与风险
自建监督模型	完全可控、可解释、推理便宜	需要标注数据与工程投入；泛化范围窄
AutoML（自动搜索）	快速得到强基线、省调参人力	搜索算力成本；可解释性与可复现性要额外管理
基础模型微调	少样本即可迁移、效果好	算力与数据治理成本；版本与漂移管理复杂
提示 + 检索	无需训练、更新最快	依赖外部服务；延迟与成本波动；需要评测防幻觉

本课程的立场：先用简单模型把评估协议立起来，再按" 数据量 × 更新频率 × 延迟预算" 三问决定是否升级到微调或基础模型（衔接 L10、L11）。

来源：取舍表据 AutoML 与基础模型工程实践整理；与课程 L1、L11 的 AI 版图和 NLP 内容衔接。

可解释性的三类方法 Three Families of Explainability

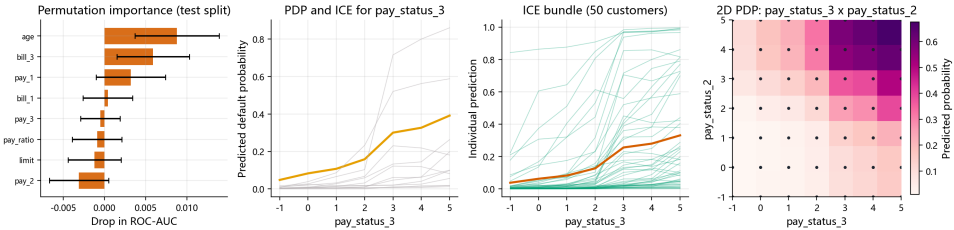
类型	代表方法	说明与注意
内在可解释	线性/逻辑回归、浅树、规则集	结构与系数本身可读；精度通常低于集成
模型无关	置换重要性、PDP、ICE	对任意模型可用；置换会破坏特征相关性
归因方法	SHAP、LIME、梯度类方法	给出单样本贡献；近似方法的稳定性需检验

三条纪律：(1) 解释不等于因果；(2) 相关特征会分摊重要性，别把" 重要性低" 当成" 没用"；(3) 解释也要记录与版本化 (帧 93 的模型卡)。

Explain the model, not the world.

来源：三类方法据统计机器学习可解释性文献；纪律为本讲补充。

【样本 + 可视化】解释一个梯度提升模型 Explaining a Boosting Model



信用卡样本（测试 ROC-AUC 0.809、Brier 0.158）：置换重要性显示近三个月的还款状态最重要（0.094 / 0.092 / 0.090）；PDP 给出平均边际效应，ICE 显示个体曲线并不重合；右下角二维 PDP 揭示逾期次数与金额之间的交互。

程序 `l5_12_interpretability_modelcard.py` ·重要性 `l5_model_importance.csv` ·模型卡 `artifacts/model_card_l5_credit.md`

【代码】解释性可视化与模型卡 Explanation and Model Card

```
perm = permutation_importance(model, X_test, y_test, n_repeats=10, # shuffle one feature at a time
                              random_state=42, scoring="roc_auc") # measure the drop in ROC-AUC
importance = pd.DataFrame({"feature": X.columns,          # feature names
                           "importance": perm.importances_mean.round(4), # mean drop in ROC-AUC
                           "std": perm.importances_std.round(4)}) # spread across the ten repeats
pd_one = partial_dependence(model, X_test, [top2[0]], grid_resolution=40, kind="average") # one dimensional PDP
for _, row in sample_rows.iterrows():                 # loop over the sampled customers
    tmp = pd.DataFrame([row] * len(grid_values), columns=X.columns) # repeat the row along the grid
    tmp[top2[0]] = grid_values                        # vary the feature of interest
    ice_curves.append(model.predict_proba(tmp)[:, 1]) # store the individual curve
card = f"""# Model card -- Lecture 5 credit default demo         # one page markdown model card
## Intended use ... ## Model ... ## Data ... ## Metrics ... ## Limitations
"""                                                   # end of the model card text
dump_artifact(card, "model_card_l5_credit.md")        # write the model card
write_json({"lecture": "L5", "seed": 20260506,        # run log metadata for reproducibility
            "metrics": {"roc_auc": ..., "brier": ...}}, "l5_run_log_12.json") # write the run log
```

要点：重要性 + PDP + ICE + 二维交互四张图一起看，再把用途、数据、指标、限制写进模型卡；运行记录落盘才能复现。完整程序 `l5_12_interpretability_modelcard.py`。

数据泄漏清单 The Leakage Checklist

五类泄漏与自检问题

1. 目标泄漏：特征是否只在结果已知后才能获得？（本讲把它做出 AUC 1.000）
2. 选择泄漏：特征选择/降维是否在划分之前做了？
3. 预处理泄漏：标准化、插补是否在划分之前拟合？
4. 重复行泄漏：同一实体是否同时出现在训练与测试？
5. 时间泄漏：是否用未来信息预测过去？

三条工程措施

- 一切预处理放进流水线（帧 29）；
- 先划分、后处理，且切分逻辑写进脚本；
- 用时间切分与分组切分替代随机切分；
- 交付前做一次" 如果我只知道当时的信息，这个特征还会有吗"的灵魂拷问。

来源：五类泄漏据机器学习工程实践整理；本讲的量化演示见程序 l5_02 与样本页 30 页。

公平性与偏差 Fairness and Bias

偏差从哪来

- 历史偏差：训练数据反映了过去的歧视性决策；
- 代理变量：邮编、学历等与受保护属性高度相关；
- 测量偏差：标签本身由有偏的流程产生（如只对某群体严格审查）；
- 样本偏差：某些群体在数据中代表性不足。

常用公平性指标与权衡

指标	含义
人口均等	各组正类预测率相同
机会均等	各组在真实正类上的召回相同
预测均等	各组精确率相同

这些指标通常不能同时满足，必须结合业务与合规目标选择并写进模型卡。

来源：公平性指标据机器学习公平性文献；权衡说明为通用结论（与 L15 营销与国际商务伦理衔接）。

模型卡：一页说清你的模型 The Model Card

模型卡的六个部分

1. 用途：做什么、不做什么（明确禁止的用法）；
2. 模型：算法、超参数、版本；
3. 数据：来源、规模、正类比例、已知偏差；
4. 指标：样本外指标与不确定性；
5. 限制：失效场景、已知风险；
6. 伦理考量：受保护属性、潜在的差别影响。

为什么必须写

- 让接手的人知道这份模型能用在哪；
- 让审计与合规有据可查（帧 98）；
- 迫使自己回答"失败时会怎样"；
- 本讲程序会自动生成一份模型卡草稿（`artifacts/`）。

来源：模型卡的组成据模型文档（Model Cards）研究；本讲给出可直接使用的模板。

从脚本到系统：MLOps 基础 From Script to System

四件事

1. 版本：数据、代码、模型三者版本必须能对应（本讲用种子 + JSON 运行记录）；
2. 实验跟踪：记录参数、指标、产物（MLflow、Weights & Biases 的职责）；
3. 监控：输入分布漂移、预测分布漂移、业务指标；
4. 回滚：发现退化能一键切回上一个版本。

本讲的轻量做法

- 每个程序输出`l5_run_log_*.json`：脚本名、种子、数据摘要、指标、产物清单；
- 模型卡为 Markdown，随代码一起进仓库；
- 生产环境的 MLflow/W&B 只是把同一套信息集中管理，不是另一个世界。

来源：MLOps 四要素据机器学习工程实践；轻量做法为本讲为教学环境设计的替代方案。

AutoML：省调参，但不省判断 AutoML and Its Costs

AutoML 能做什么

自动搜索特征处理、模型族与超参数的组合，按给定指标选出最优配置（Optuna 等工具做贝叶斯搜索）。它把" 调参人力" 换成" 搜索算力"。

三个必须自己负责的事

1. 评估协议：搜索用的交叉验证必须与最终报告一致，否则搜索本身就是泄漏；
2. 选择偏差：试了很多配置后，最优分数天然乐观，需要在独立测试集上复核；
3. 可复现与可解释：搜索过程与最终配置要记录，否则无法交付（帧 93–94）。

一句话：AutoML 让" 找到好模型" 变便宜，但" 证明它真的好" 仍然要靠人。

来源：AutoML 的能力与风险据自动机器学习与超参数优化文献；纪律为本讲补充。

成本与延迟：模型的隐藏约束 Cost and Latency

三类成本

- 训练成本：一次要多久、多久重训一次（本讲六种模型 0.008–2.49 秒）；
- 推理成本：单次预测的算力与费用；
- 错误成本：误报与漏判的业务损失（帧 44）。

延迟预算怎么定

- 实时风控：几十毫秒级 → 线性模型或小树模型；
- 批量营销：小时级 → 梯度提升或集成；
- 离线研究：天级 → 神经网络与大模型；
- 兜底策略：降级到简单模型，保证可用性。

来源：成本结构据机器学习系统实践；本讲数值来自程序 l5_07 的实测计时（同机同划分）。

指标被优化之后 After the Metric Is Optimised

指标失真的三种机制

- 过拟合测试集：反复看测试分数做选择；
- 代理指标偏离目标：优化点击率却损害长期价值；
- 分布漂移：训练时的分布与线上不再一致。

四条对策

1. 保留一个从未看过的测试集，只在最后用一次；
2. 监控输入与预测分布的漂移（帧 94）；
3. 报告校准与区间，而不只是点估计；
4. 定期用新的时间段数据做外部复核，并记录退化速度。

来源：指标失真与漂移监控据机器学习评测与生产实践文献；对策为本讲整理。

合规与高风险场景 Compliance in High-Risk Settings

高风险应用的共同要求

- 可追溯：数据、代码、模型版本可对应（帧 94）；
- 可解释：给出影响决策的主要因素（帧 89）；
- 人工复核：对高影响决策保留人工介入；
- 记录与报告：模型卡、评测结果、已知限制；
- 持续监控：上线后评估偏差与漂移。

教育场景的红线

- 不用模型自动判定学生的最终成绩或资格；
- 不把敏感个人信息作为特征或标签；
- AI 生成的分析结果必须标注并复核（与课程 AI 使用规范一致）；
- 涉及个人数据的研究，遵守知情同意与最小必要原则。

来源：高风险场景要求据 EU AI Act 等合规框架的通行要点；教育场景红线据本课程与学校规范。

交付前自查清单 Pre-Delivery Checklist

1. 有基线吗？（多数类/均值）
2. 划分方式写清了吗（随机/分层/时间/分组）？
3. 预处理是否在流水线内？
4. 有没有泄漏（五类逐条检查）？
5. 指标是否匹配问题与代价？
6. 概率校准了吗？阈值怎么定的？
7. 结果能解释吗（重要性/PDP/ICE）？
8. 模型卡与运行记录齐了吗？
9. 成本与延迟在预算内吗？
10. 失败时会怎样，兜底方案是什么？

用法：把这十条当作提交前最后一分钟的自检；任何一条答不上来，就先补上再交。

来源：清单综合本讲 Part 2–7 的全部内容，可直接用于课程项目与工作实践。

工具栈 The Tool Stack

环节	工具（本课程使用）
数据处理	pandas、NumPy（L3、L4 已熟悉）
建模与评估	scikit-learn（流水线、模型、指标、校准、可解释性）
梯度提升	XGBoost、LightGBM（CatBoost 处理类别特征）
调参与搜索	`GridSearchCV`、`RandomizedSearchCV`、Optuna
实验跟踪	本讲用 JSON 运行记录 + 模型卡 演示；生产可用 MLflow、Weights & Biases
可视化与解释	matplotlib、plotly（L4）；置换重要性、PDP/ICE（可选 SHAP）

课程仓库 `website/code/lecture05/` 提供 12 个程序：每一行都有英文注释，一条命令 `python run_all.py` 即可重建全部样本、图表与实验记录。

来源：工具选择对应课程大纲第 5 讲工具条目：scikit-learn、XGBoost/LightGBM、MLflow、Weights & Biases。

第 6 周任务：项目选题说明（一页）Project One-Pager

模板（四段）

1. 问题：是预测还是因果？预测什么、给谁用、错了代价多大？
2. 数据：来源与许可、规模、标签如何得到、已知偏差；
3. 方法：基线 + 候选模型；划分方式；指标与阈值规则；解释方式；
4. 预期产出：图表清单、模型卡、可复现脚本、结论的适用边界。

评分关注点

- 问题是否可检验（指标能算出来）；
- 数据是否合法可得（来源写明）；
- 评估协议是否防泄漏；
- 是否给出基线与失败时的兜底。

写法建议：用第 99 页的十条自查清单反向检查这份说明——每条都能在说明里找到对应句子，就算合格。

来源：任务与提交要求见课程大纲第 6 周安排；模板为本讲提供。

常见错误 Top 10 Common Mistakes

1. 不做基线，直接上复杂模型；
2. 用测试集调参或反复看测试分数；
3. 预处理写在划分之前（泄漏）；
4. 随机切分时间序列或分组数据；
5. 只看准确率，忽略不平衡与代价；
6. 报了概率却不校准、不定阈值；
7. 把特征重要性当成因果效应；
8. 用聚类结果直接下业务结论而不做外部验证；
9. 没有模型卡与运行记录，无法复现；
10. 忽略成本与延迟，模型上不了线。

这十条与第 99 页的自查清单一一对应：先看错误清单，再用清单验收。

来源：错误清单综合本讲各部分的实测演示与常见评审意见。

术语对照与参考资料 Glossaries and References

中文	English
特征 / 标签	feature / label
超参数	hyper-parameter
训练·验证·测试	train/validation/test
交叉验证	cross-validation
偏差 / 方差	bias / variance
过拟合 / 欠拟合	overfitting / underfitting
正则化	regularisation
数据泄漏	data leakage
集成学习	ensemble learning
梯度提升	gradient boosting
降维 / 聚类	dimension reduction / clustering
轮廓系数	silhouette score
校准	calibration
强化学习	reinforcement learning
模型卡	model card

参考书与资料

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.), Ch.1–3（大纲指定）
- Mitchell, T. (1997). *Machine Learning*（E/T/P 定义）
- Hastie, Tibshirani & Friedman. *The Elements of Statistical Learning*, Ch.7
- James et al. *An Introduction to Statistical Learning*
- Athey, S. (2017, *Science*)；Mullainathan & Spiess (2017, *JEP*)：预测与因果的分工
- scikit-learn 用户指南与估计器地图；XGBoost / LightGBM 文档；Optuna；MLflow
- 模型卡（Mitchell et al., 2019）；EU AI Act 高风险清单；Kaggle Learn

来源：参考书对应课程大纲第 5 讲阅读要求；原课件链接与工具备忘已并入工具栈一页。

谢谢！

Thank you · Q & A

本讲小结：四类范式 → 划分与评估协议 → 偏差-方差与指标 → 监督与无监督算法族 → 神经网络与强化学习 → 可信交付

课堂检查点：用三句话讲清你的模型——预测什么、怎么评、错在哪。

样本与程序：`website/code/lecture05`（12 个程序，逐行英文注释） `website/data/lecture05`（样本 + 模型卡 + 运行记录） `website/figures/lecture05`（14 张图）

下一讲预告：Lecture 6 Logistic Regression and Linear Classifier （从线性回归到交叉熵与梯度下降）

任课教师：戴谢尔 (Xieer Dai, David) · Xieer.dai@szu.edu.cn · 四方楼南 209