深圳大学 SHENZHEN UNIVERSITY

课程 COURSE

Big Data Analytics
大数据分析 [2026 国际商务]

Lecture 6 — Logistic Regression and Linear Classifier 第六讲·逻辑回归与线性分类器
从最小二乘到极大似然，再到梯度下降与正则化

任课教师：戴谢尔 (Xieer Dai, David)
深圳大学 Shenzhen University

·第 3–14 周·星期四 11-12 节
上课地点：四方楼南 209



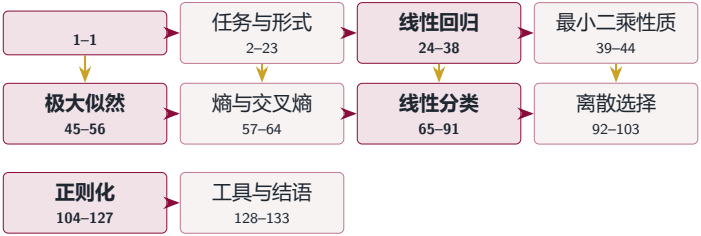
学习目标 Learning Objectives

完成本讲后，你应能够：

1. 写出线性回归的正规方程 normal equation 并推导它；
2. 用极大似然估计 MLE 导出 l_2 损失与交叉熵 cross-entropy；
3. 解释 sigmoid 的三条性质（有界、对称、$\sigma' = \sigma(1-\sigma)$）；
4. 手写梯度下降 gradient descent 并与 PyTorch 自动微分 对照；
5. 解释对数几率 log-odds 与几率比 odds ratio 的业务含义；
6. 用正则化 regularisation（LASSO/Ridge/Elastic Net）与概率校准 calibration 控制复杂度与可信度。

来源：对应课程大纲第 6 讲目标：掌握线性回归的闭式解与极大似然推导；掌握逻辑回归、交叉熵与梯度下降。

本讲路线图 Roadmap（133 帧）



主线：任务 → 形式 → 线性回归 → 最小二乘性质 → 极大似然 → 熵与交叉熵 → 分类 → 离散选择 → 正则化

代码页 10 帧•样本页 14 帧：全部示例用 Python，每一行代码都带英文注释

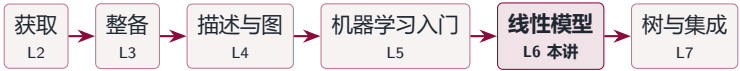
与上一讲的衔接 From Evaluation to Estimation

L5 结束时你手上有什么

- 学习范式、偏差-方差、评估协议与算法族地图；
- 但还有一个问题没答：损失函数为什么是平方、是交叉熵？

L6 要回答的问题

- 函数类怎么选（假设类 hypothesis class）？
- 损失从哪来（似然 likelihood）？
- 参数怎么解（正规方程或梯度下降）？
- 怎么控制复杂度（正则化）？



本讲是推导课：四条推导（正规方程、l_2 = 高斯 + MLE、逻辑回归 = sigmoid + MLE、交叉熵梯度）都会给完整步骤。

本讲输出物 Deliverables

1) 四条推导

正规方程；l_2 = 高斯 + MLE；逻辑回归 = sigmoid + MLE；$\nabla L = \frac{1}{n} X^\top (\sigma(Xw) - y)$

2) 手写实现

NumPy 正规方程与梯度下降，逐行英文注释；与 scikit-learn、statsmodels、PyTorch 对账

3) 术语表

79 条中英对照（CSV + Word/Excel）；每条含符号、公式与一句话解释

本讲的数字都来自可复现的程序：`website/code/lecture06/`，种子固定 20260603，一条命令重建全部图与表。

来源：程序与样本随课程仓库发布；术语表另附可打印版本。

全讲导览 Map of the Lecture

部分	帧	关键问题
任务与形式化	7–22	什么是学习任务？假设类、损失与经验风险（empirical risk）怎么定义？
线性回归与正规方程	23–36	最小二乘怎么解？为什么是投影（projection）？数值稳不稳？
极大似然与损失函数	37–50	平方损失与交叉熵分别对应什么概率假设？
线性分类与逻辑回归	51–74	为什么用 sigmoid？怎么解？怎么解释系数？
正则化与监督学习结构	75–92	LASSO 与 Ridge 差在哪？偏差-方差怎么分解？
工具、术语与结语	93–100	推断视角怎么用？术语怎么背？

读法：每部分是" 定义 → 推导 → 样本图 → 可运行代码 → 术语" 的循环；术语首次出现都附英文。

三类任务与核心术语 Three Tasks and Their Terms

二分类

二分类 binary classification
输出两个类别，例如欺诈/正常、室内/室外。
训练数据 training data、测试数据 test data

多分类

多分类 multi-class classification
输出三个及以上类别，例如 ImageNet 的上千类。

聚类

聚类 clustering
无标签数据分组；无监督学习 unsupervised learning

一个例子把三个术语串起来（图像分类）

任务：判断图片是室内 indoor 还是室外 outdoor；性能度量：误分类概率 probability of misclassification；经验/数据：带标签的图片（有标签数据 labeled data）。

术语复习：监督学习 supervised learning 用带标签数据；无监督学习 unsupervised learning 只用特征。

来源：术语与例子沿用课程讲义的任务设定；英文对照据机器学习通行译法。

图像分类：任务与性能度量 Image Classification

任务

给定一张图片，判断它是室内还是室外。这是一个二分类 binary classification 问题。

性能度量

最自然的选择是误分类概率 probability of misclassification：$\Pr[f(x) \neq y]$。它正是0-1 损失的期望。

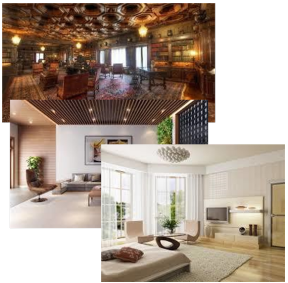
为什么不用准确率

准确率 $= 1-$ 误分类率；两者等价。但误判的代价未必对称：把" 室外" 误判为" 室内" 与反过来，业务后果可能差很多 (衔接 Part 4 的第一类错误 Type I error 与第二类错误 Type II error)。

本节要建立一个习惯：先写清任务与度量，再选模型。度量一旦写错，后面所有推导都会跑偏。

来源：例子据课程讲义；代价不对称的说明衔接 L5 的评估协议。

【样本】室内还是室外：两张图看懂特征 The Two Classes





室内 indoor：暖色温、低对比、（多为）近距离纹理　室外 outdoor：高动态范围、强边缘、天空与地平线

这两张图把" 特征" 这个词落了地：颜色直方图、边缘密度、纹理能量、亮度的空间分布——它们都是人设计出来的特征（hand-crafted features）。这正是本讲 1-2-3 流程里" 选特征" 那一步要花力气的地方：同一批像素，换一组特征，线性模型的效果会差很多。

课堂素材图（室内 / 室外各一张）；特征解读为本讲补充。

多分类与真实规模 Multi-class at Scale

从二分类到多分类

多分类 multi-class classification：输出 $K > 2$ 个类别。做法有两种常见路线：

- 训练 K 个" 一对多" 二分类器（one-vs-rest）；
- 直接输出 K 个概率（softmax），即多分类逻辑回归。

真实规模

ImageNet 有上千个类别、上千万张图片。此时：

- 类别越多，混淆矩阵越大，单指标越不够用；
- 需要top-k 准确率与每类召回率；
- 训练与推理的成本成为设计约束。

预告：softmax 与多类交叉熵在帧 68–70 展开，本帧只建立" 多分类是分类的自然延伸" 这一直觉。

来源：ImageNet 规模为公开事实；多分类评估的提醒为本讲补充。

聚类：无标签数据的分组 Clustering

任务与度量

任务：把图片分成两组；性能：组内相似度similarity高、组间差异大。数据：一组无标签unlabeled 图片。

两组术语

- 无标签数据 unlabeled data vs 有标签数据 labeled data；
- 无监督学习 unsupervised learning vs 监督学习 supervised learning。

与 L5 的呼应：无监督没有" 正确答案"，所以评估只能靠内部指标与业务解释；本讲不展开聚类算法，只强调术语与评估的差别（详见 L8）。

来源：例子据课程讲义；评估提醒衔接 L5 的无监督部分。

从像素到特征向量 From Pixels to a Feature Vector

手工特征

用颜色直方图 colour histogram 概括一张图片：把红/绿/蓝三个通道各分若干区间，统计落在每个区间的像素比例，得到一串数字——这就是特征 feature。

数学记号

- 特征向量 feature vector $x_i \in \mathbb{R}^d$；
- 标签 label y_i（分类里 $y_i \in \{0, 1\}$）；
- 训练集写作 $\{(x_i, y_i) : 1 \le i \le n\}$。

" 提取特征" 这一步决定了模型的上限。本讲先假设特征已给定，到帧 21 再讨论" 能不能让机器自己学特征"（表征学习 representation learning）。

来源：颜色直方图的例子据课程讲义；记号为本讲统一约定。

形式化（1）：找一个函数 Find a Function

问题

给定训练数据 training data $\{(x_i, y_i) : 1 \le i \le n\}$，找一个函数 f，使得 $y = f(x)$ 对新数据也成立。

为什么说"新数据"

在训练集上拟合得好没有意义——把每个样本都记住即可。真正要的是泛化 generalisation：在未见样本上正确。

这一步还缺什么

- 候选函数从哪里来？（下一步：假设类 hypothesis class）
- "正确"怎么衡量？（后面的损失函数 loss function）

提示：形式化一共六步（帧 12–18），每一步只加一个要素，最后拼成完整的学习问题。

来源：六步形式化据课程讲义的组织顺序；说明为本讲补充。

形式化（2）：假设类 Hypothesis Class

加入假设类

在给定的函数族 $\mathcal{H}$ 中找 $f \in \mathcal{H}$。$\mathcal{H}$ 称为假设类 hypothesis class，它决定了模型的表达能力。

三个例子

- 线性函数：$\mathcal{H} = \{x \mapsto w^\top x\}$——最常用、可解释；
- 多项式：$\mathcal{H} = \{x \mapsto \sum_{j \le d} w_j x^j\}$——更灵活但更易过拟合；
- 神经网络：$\mathcal{H}$ 由层数与激活函数决定。

术语要点

选 $\mathcal{H}$ 就是选模型族 model family；本讲后面所有推导都限定在线性 $\mathcal{H}$ 上，便于得到闭式解。

来源：假设类的定义统计学习通行表述；三个例子为本讲补充。

形式化（3）：训练与测试同分布 Same Distribution

加入分布假设

训练数据与测试数据都来自同一个分布 D。没有这个假设，" 在训练集上学到的规律" 就不保证对新数据有效。

这个假设意味着什么

- 训练集与测试集是同一个世界的两个样本；
- 数据的生成机制在两者之间没有变化；
- 一旦环境变化（政策、疫情、平台规则），假设就破了。

破了会怎样

分布漂移 distribution shift：样本外误差突然变大。这正是 L5 的 MLOps 监控要盯的东西（衔接帧 96—97）。

来源：同分布假设为统计学习的基本前提；漂移的后果衔接 L5 的监控与评测部分。

形式化（4）：独立同分布 i.i.d.

加入独立性

训练样本 $\{(x_i, y_i)\}$ 与测试样本都独立同分布（i.i.d. independently identically distributed）：同分布给出" 同一个世界"，独立给出" 样本之间不互相决定"。

独立性为什么重要

有了独立性，经验平均才是期望的无偏近似，大数定律与集中不等式才能用来给出泛化界。

什么时候不成立

时间序列（今天的价格依赖昨天）、面板数据（同一公司多年）、社交网络（用户互相影响）——本讲末的股市例子（帧 22）就是反例。

来源：i.i.d. 的作用据统计学习教材；不成立的场景为本讲补充（衔接帧 22）。

形式化（5）：期望损失 Expected Loss

加入性能度量

要求期望损失（期望风险 expected risk）小：

$$L(f) = \mathbb{E}_{x,y\sim D}\big[l(f,x,y)\big],$$

其中 l 是损失函数 loss function。它衡量" 平均而言错得多离谱"。

两种常用损失

- 0-1 损失 0-1 loss：$l = \mathbb{I}[f(x) \neq y]$，取期望即误分类概率；
- 平方损失 l_2 loss：$l = (f(x) - y)^2$，取期望即均方误差。

注意

期望损失是对分布求的，我们并不知道 D，所以只能估计——这就引出下一步的经验损失 empirical loss。

来源：期望风险的定义给出学习通行表述。

损失函数示例：0-1 与 l_2 Two Loss Functions

损失	单样本形式	期望形式与用途
0-1 损失 0-1 loss	$\mathbb{I}[f(x) \neq y]$	$L(f) = \Pr[f(x) \neq y]$；分类、可直接解释
平方损失 l_2 loss	$(f(x) - y)^2$	$L(f) = \mathbb{E}[(f(x) - y)^2]$；回归、易求导
l_1 损失 l_1 loss	$\lvert f(x) - y \rvert$	对离群点更稳健；不可导点需处理
合页损失 hinge loss	$\max(0, 1 - yf(x))$	支持向量机的损失（L7）
指数损失 exponential loss	$e^{-yf(x)}$	AdaBoost 的损失（L7）

一个问题先记下：为什么线性回归偏偏用 l_2？帧 31 给经验理由，帧 43 给概率理由（MLE）。

来源：损失家族据统计学习教材；本讲聚焦 0-1 与 l_2。

形式化（6）：经验损失 Empirical Loss

用样本平均代替期望

既然不知道 D，就用训练集上的平均——经验损失 empirical loss（经验风险 empirical risk）：

$$\hat{L}(f) = \frac{1}{n} \sum_{i=1}^{n} l(f, x_i, y_i).$$

整个学习问题

给定 $\{(x_i, y_i)\}$ i.i.d. $\sim D$，在假设类 $\mathcal{H}$ 中找 f 使 $\hat{L}(f)$ 最小。这就是经验风险最小化 empirical risk minimisation (ERM)。

一句话记住

学习 = 在 $\mathcal{H}$ 里找 f，让 $\hat{L}(f)$ 最小。

来源：ERM 的表述统计学习通行定义。

期望风险与经验风险 The Generalisation Gap

两个风险

- $L(f)$：期望风险 expected risk，我们真正关心的；
- $\hat{L}(f)$：经验风险 empirical risk，我们能算的；
- 二者之差 $L - \hat{L}$ 叫泛化差距 generalisation gap。

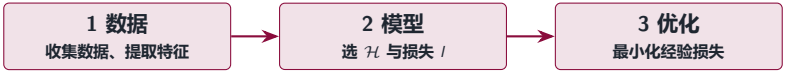
两种失败

- 差距大 $\rightarrow$ 过拟合 overfitting：模型记住了训练噪声；
- 两者都大 $\rightarrow$ 欠拟合 underfitting：假设类太简单。

这就是 L5 的偏差-方差故事在这里的" 风险版本"：训练好 $\neq$ 泛化好，所以必须留出验证集（衔接 L5 帧 26–30）。

来源：泛化差距与两种失败据统计学习教材；与 L5 的衔接为本讲补充。

机器学习 1-2-3 Machine Learning in Three Steps



三个要素与术语

- 数据：特征提取 feature extraction、经验 experience；
- 模型：假设类 hypothesis class + 损失函数 loss function；
- 优化：经验风险最小化 ERM，常见手段是梯度下降 gradient descent。

先验知识在哪

先验知识 prior knowledge 会进入前两步：选什么特征、选什么假设类，都是人做的判断——这也是为什么 L5 说"AI 不替代判断"。

来源：1-2-3 框架沿用课程 L1/L5 的表述。

能不能让机器自己学特征 Representation Learning

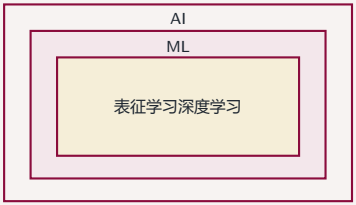
疑问

为什么还要手工设计特征向量 x？能不能直接在原始图片上学习特征？

答案

可以，这称为表征学习 representation learning：让模型自己学习从原始输入到有用表示的映射。

包含关系



DL $\subseteq$ Representation Learning $\subseteq$ ML $\subseteq$ AI

2026 的说法：预训练模型就是大规模表征学习（衔接 L9 深度学习与 L11 自然语言处理）。

来源：包含关系据课程讲义；2026 视角为本讲补充。

1-2-3 覆盖不了什么 What the Recipe Misses

并非所有方法都符合 1-2-3

- 强化学习 reinforcement learning：没有固定的训练集，数据由交互产生；
- 主动学习 active learning：自己决定标注哪些样本；
- 在线学习 online learning：数据流式到达，模型持续更新。

反例：股市预测

用滑动窗口 sliding window 构造样本：用过去 k 天预测下一天。但相邻样本高度相关、分布随时间漂移，i.i.d. 不成立，所以" 随机切分" 会给出虚高的样本外表现（衔接 L5 的泄漏清单）。

结论：1-2-3 是" 默认模板"，用之前先问三件事——数据独立吗？同分布吗？有标签吗？

来源：边界与反例据课程讲义与 L5 的数据泄漏讨论。

一个真实数据集：前列腺癌 Prostate Cancer Data

数据

Stamey et al. (1989) 的 97 位病人的临床数据：

- 目标 y：前列腺特异性抗原 prostate specific antigen (PSA) 的对数；
- 特征 $(x_1, \ldots, x_8)$：临床指标 clinical measures ——对数癌体积、对数前列腺重量、年龄、对数 BPH、精囊侵犯、对数包膜穿透、Gleason 评分、Gleason 4/5 百分比。

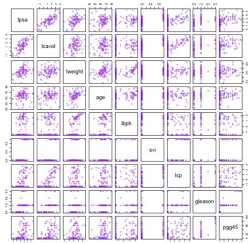
为什么用它

这是《The Elements of Statistical Learning》的经典例子：样本不大（$n = 97$）、特征不多（$p = 8$）、关系近似线性——正好用来演示最小二乘、推断与正则化的全部细节。

本讲的样本 `16_prostate.csv` 按同样的变量结构合成（数值非真实病人数据），以便复现且不涉及隐私；图注中会注明这一点。

来源：数据来源：Stamey, T. et al. (1989), *Journal of Urology*; 经 ESL 教材广泛使用。

【样本】前列腺癌数据：本讲的”标准作业” The Prostate Data



这份数据是什么

97 位病人的前列腺特异性抗原（PSA，prostate-specific antigen）与 8 个临床变量：年龄、体重指数、前列腺体积、游离 PSA 等。目标是解释PSA 水平（回归）。

它在统计学习里几乎是”Hello World”：变量之间高度相关（体积、重量、游离 PSA 互相纠缠），所以系数不稳——这正好是后面讲多重共线性与正则化的完美素材。本讲帧 22、28、32、80 都用它。

课堂素材图；数据结构据 Hastie, Tibshirani & Friedman (2009) 的 prostate 数据集。

线性回归：假设类与损失 Linear Regression

形式化

给定训练数据 $\{(x_i, y_i) : 1 \le i \le n\}$ i.i.d. $\sim D$，在线性假设类中找

$$f_w(x) = w^\top x, \qquad w \in \mathbb{R}^d,$$

并使平方损失 l_2 loss 的经验风险 $\hat{L}(f_w) = \frac{1}{n}\sum_i (w^\top x_i - y_i)^2$ 最小。

术语

- 线性模型 linear model：f_w 关于 w 线性；
- 均方误差 mean squared error (MSE)：即 $\hat{L}$ 本身；
- 残差 residual：$y_i - w^\top x_i$。

注意

"f 关于 x 线性" 是假设，不是定理；真实关系弯曲时，线性模型会欠拟合 (L5 帧 32)。

来源：形式化与记号据统计学习教材；术语为本讲统一。

矩阵形式：把求和写成向量运算 Matrix Form

构造

把 n 个样本堆成矩阵：第 i 行为 $x_i^\top$，即

$$X \in \mathbb{R}^{n\times d}, \qquad y \in \mathbb{R}^n.$$

于是

$$\hat{L}(f_w) = \frac{1}{n}\|Xw - y\|_2^2$$

$$= \frac{1}{n}\left(w^\top X^\top X w - 2w^\top X^\top y + y^\top y\right).$$

展开时用到的两个恒等式：$(Xw)^\top(Xw) = w^\top X^\top X w$，以及 $(Xw)^\top y = w^\top X^\top y$。

来源：矩阵形式据统计学习教材的标准推导。

为什么这样写

- 求和变成矩阵乘法，便于求导；
- 复杂度从 $O(nd)$ 的循环变成一次矩阵运算；
- 后续的梯度、正规方程都能直接用矩阵表达。

梯度为零：正规方程的推导 The Normal Equation

推导

对 w 求梯度并令其为零：

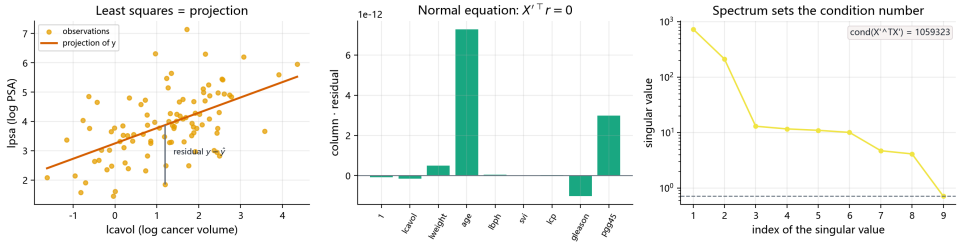
$$
\begin{aligned}
\nabla_w \hat{L} &= \nabla_w \frac{1}{n}\left(w^\top X^\top X w - 2w^\top X^\top y + y^\top y\right) \\
&= \frac{1}{n}\left(2X^\top X w - 2X^\top y\right) = 0 \\
\Longrightarrow \quad & X^\top X w = X^\top y \\
\Longrightarrow \quad & \boxed{w = (X^\top X)^{-1} X^\top y}
\end{aligned}
$$

这组方程叫 正规方程 normal equation；解 w 叫最小二乘解 least squares solution。条件是 $X^\top X$ 可逆（列满秩）。

Set the gradient to zero, solve the linear system.

来源：推导据统计学习教材；本讲把每一步都写出来便于跟算。

【样本 + 可视化】正规方程的几何：投影 Projection



左：最小二乘解是 y 在 X 的**列空间**上的投影 projection，残差与列空间正交；中：数值验证 $X^\top r \approx 0$（本样本最大点积 7×10^{-12}）；右：设计矩阵的**奇异值谱**，其比值决定条件数 condition number。

程序 `16_01_linreg_normal_equation.py` ·样本 `16_prostate.csv` ·系数表 `16_coef_compare.csv`

带偏置项：增广技巧 The Bias Term

模型

加上截距 intercept（也叫偏置 bias）：

$$f_{w,b}(x) = w^\top x + b.$$

化归为无偏置情形

令

$$w' = \begin{pmatrix} w \\ b \end{pmatrix}, \qquad x' = \begin{pmatrix} x \\ 1 \end{pmatrix},$$

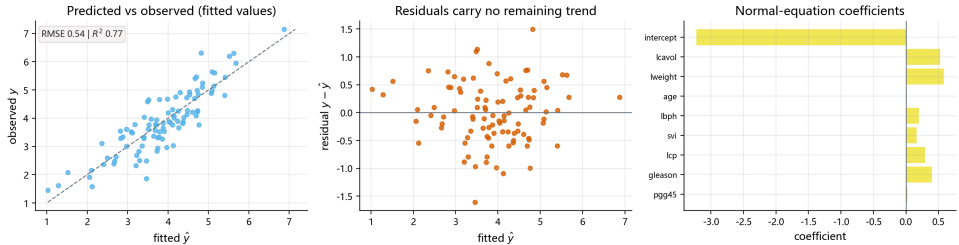
则 $f_{w,b}(x) = w'^\top x'$——形式完全一样，只是多了一列常数。

实现上的三点

- 增广矩阵记作 $X' = [\mathbf{1}, X]$；
- 这一列不要标准化（否则常数项被压成 0）；
- 正则化时通常不惩罚截距。

来源：增广技巧据统计学习教材；实现细节为工程实践补充。

【样本 + 可视化】前列腺数据：拟合、残差与系数



本讲合成样本（$n = 97$，$p = 8$）：RMSE 0.54、R^2 0.77；残差对拟合值没有明显趋势；右图给出正规方程解出的八个系数（对数尺度上，`lcavol` 与 `lweight` 的影响最大）。

程序 `16_01_linreg_normal_equation.py` ·三种实现（NumPy / sklearn / statsmodels）系数完全一致

【代码】正规方程的三种实现 Three Implementations

```python
Xa = add_intercept(X)                                # augmented design matrix X' = [1, X]
w_np = normal_equation(Xa, y)                        # w = (X'^T X')^{-1} X'^T y by our helper
w_sk = LinearRegression(fit_intercept=False).fit(Xa, y).coef_ # scikit-learn on the augmented matrix
w_sm = sm.OLS(y, Xa).fit().params                    # statsmodels ordinary least squares
max_gap = float(np.max(np.abs(w_np - w_sk)))         # largest gap between two implementations
assert max_gap < 1e-8, "implementations disagree"    # they must agree to numerical precision
y_hat = Xa @ w_np                                    # fitted values
resid = y - y_hat                                    # residuals
orthogonality = Xa.T @ resid                         # dot products of residuals with the columns
print("max |column . residual| = %.2e" % float(np.max(np.abs(orthogonality)))) # should be ~0
coef_table = pd.DataFrame({"term": ["intercept"] + cols, # term names in the augmented order
                           "numpy": np.round(w_np, 4),    # normal-equation solution
                           "sklearn": np.round(w_sk, 4),  # scikit-learn solution
                           "statsmodels": np.round(w_sm, 4)}) # statsmodels solution
dump(coef_table, "l6_coef_compare.csv")              # persist the comparison table
```

要点：三种实现必须给同一组系数（本样本差小于 10^{-8}）；残差与设计矩阵正交是正规方程的几何签名。完整程序 `l6_01_linreg_normal_equation.py`。

为什么偏偏是 l_2 损失 Why the Squared Loss

经验理由：好优化

平方损失对 w 是二次函数：梯度是线性的，令其为零得到闭式解 $w = (X^\top X)^{-1} X^\top y$。换 l_1 或合页损失就没有这个便利。

理论理由：编码先验

平方损失等价于假设噪声服从高斯分布（帧 43 会证明）。所以" 用 l_2" 其实是" 假设残差是高斯白噪声"——这是一个可检验的建模假设。

术语：先验知识 prior knowledge 在这里的具体含义是" 误差的分布形状"。选择损失就是选择你对数据的假设，而不是选一个" 更好看的函数"。

来源：两条理由据统计学习教材与课程讲义；MLE 的证明见帧 43。

多重共线性与条件数 Multicollinearity

问题

当两列近似线性相关时，$X^\top X$ 接近奇异：

- 条件数 condition number $\kappa = \lambda_{\max}/\lambda_{\min}$ 很大；
- 系数对数据的微小扰动极其敏感；
- 系数符号可能与本意相反（" 符号翻转"）。

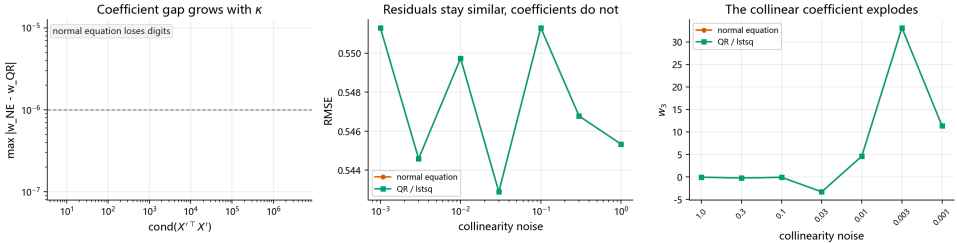
三条对策

1. 用QR 分解或 SVD 求解，而不是显式求逆（帧 34）；
2. 标准化特征，改善数值尺度；
3. 用正则化（Ridge）接受一点偏差换取稳定（帧 78）。

本讲实测：前列腺样本的 $\kappa(X'^\top X') \approx 1.06 \times 10^6$——已经很高，说明先标准化再解释系数是必要的。

来源：条件数与共线性据统计学习教材；实测数值来自程序 l6_01。

【样本 + 可视化】数值稳定性：正态方程 vs QR



让第三列越来越接近第一列：$\kappa(X'^{\top}X')$ 上升，正态方程与 QR 的系数差按数量级放大；但两者的残差几乎相同——说明" 拟合得好" 不能证明" 系数算得对"。

程序 `16_02_numerical_stability.py` ·样本 `16_illconditioned.csv` ·扫描表 `16_stability.csv`

【代码】数值稳定：lstsq、QR 与伪逆 Stable Least Squares

```
gram = design.T @ design                              # gram matrix X'ᵀ X'
cond = float(np.linalg.cond(gram))                    # condition number of the normal equations
w_ne = normal_equation(design, y)                     # normal-equation solution
w_qr = np.linalg.lstsq(design, y, rcond=None)[0]      # QR/SVD based solution
w_sv = np.linalg.pinv(design) @ y                     # explicit pseudo-inverse solution
resid_ne = rmse(y, design @ w_ne)                     # residual of the normal-equation fit
resid_qr = rmse(y, design @ w_qr)                     # residual of the stable fit
rows.append({"collinearity_noise": level, "cond_gram": cond, # record the condition number
             "coef_gap_ne_vs_qr": float(np.max(np.abs(w_ne - w_qr))), # largest coefficient gap
             "rmse_ne": resid_ne, "rmse_qr": resid_qr, # residuals of both solutions
             "w_x3_ne": float(w_ne[3]), "w_x3_qr": float(w_qr[3])}) # the unstable coefficient itself
stability = pd.DataFrame(rows).round(6)               # assemble the table
dump(stability, "l6_stability.csv")                   # persist it
```

工程结论：永远用 `lstsq/solve`，不要显式写 `inv(X'X)`；伪逆 pseudo-inverse 还能处理秩亏（X 不满列秩）的情形。完整程序 `l6_02_numerical_stability.py`。

线性回归的评估 Evaluation and Extrapolation Risk

三个诊断

- R^2 coefficient of determination：解释了多少方差；
- 残差图 residual plot：看是否还有结构（弯曲 = 缺项）；
- RMSE root mean squared error：与业务单位一致的误差。

外推的代价

线性模型在训练数据的取值范围内插值较可靠；超出范围（外推 extrapolation）时，$\hat{y}$ 会线性地越走越远，可能与现实完全不符。

实践建议：报告里写清训练数据的取值区间；对超出区间的预测要标注" 外推，仅作参考"。

来源：诊断与风险据统计学习实践；外推提醒为本讲补充。

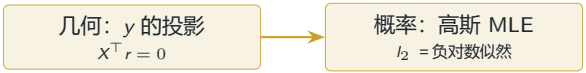
小结：最小二乘的两种解释 Two Readings of Least Squares

几何：投影

$\hat{y} = Xw$ 是 y 在 X 列空间上的正交投影；残差 $r = y - \hat{y}$ 与列空间正交，因此 $X^\top r = 0$——这正是正规方程。

概率：极大似然

若 $y \mid x \sim \mathcal{N}(w^\top x, \sigma^2)$，则最小化平方损失 $\Leftrightarrow$ 最大化似然（帧 43 证明）。



下一部分把"概率"这条线展开：损失的来源就是似然。

来源：两种解释据统计学习教材；与 Part 3 的衔接为本讲安排。

最小二乘的五个假设 Five Assumptions for OLS

编号	假设	数学写法	违背会怎样
A1	线性于参数（linear in parameters）	$y = X\beta + \varepsilon$	模型设定错误，怎么估都偏
A2	满秩（full rank）	$\mathrm{rank}(X) = p$	$X'X$ 不可逆，系数不唯一
A3	外生性（exogeneity）	$\mathbb{E}[\varepsilon \mid X] = 0$	有偏（遗漏变量、内生性）
A4	同方差（homoskedasticity）	$\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$	仍无偏，但标准误错
A5	正态性（normality，可选）	$\varepsilon \mid X \sim \mathcal{N}(0, \sigma^2 I)$	小样本下 t/F 检验不精确

注意 A1–A3 决定"准不准"（无偏），A4 决定"稳不稳"（方差最小），A5 只影响小样本的检验。三个层次不要混在一起谈——这是初学者最常见的表述错误。

来源：假设体系据经典计量教材（如 Wooldridge 与 Greene）；表述与"三层"划分是本讲整理。

估计量的两条性质：无偏与协方差 Unbiasedness and Variance

无偏性（unbiasedness）

关键洞察：$\hat{\beta}$ 的随机性只来自 ε（X 视为固定）。

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'y = (X'X)^{-1}X'(X\beta+\varepsilon)\\ &= \beta + (X'X)^{-1}X'\varepsilon,\end{aligned}$$

取条件期望，$\mathbb{E}[\varepsilon \mid X] = 0$ 让第二项消失：

$$\mathbb{E}[\hat{\beta} \mid X] = \beta.$$

协方差矩阵（covariance matrix）

$$\begin{aligned}\mathrm{Var}(\hat{\beta} \mid X) &= (X'X)^{-1}X'\,\mathrm{Var}(\varepsilon \mid X)\,X(X'X)^{-1}\\ &= \sigma^2(X'X)^{-1}.\end{aligned}$$

对角线开方就是标准误（standard error）：

$$\widehat{\mathrm{se}}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2(X'X)^{-1}_{jj}}.$$

这两条式子回答了两个不同的问题：" 平均来说对不对"（无偏）、" 换一份数据会晃多少"（方差）。后者才是 t 检验与置信区间的输入。

来源：推导据标准最小二乘理论（Greene, *Econometric Analysis*）。

Gauss-Markov 定理：为什么说 OLS 是 BLUE

定理（Gauss-Markov, 1821/1823）

在 A1–A4 成立时，普通最小二乘估计量 $\hat{\beta}_{OLS}$ 是所有线性无偏估计量（linear unbiased estimator）中方差最小的那一个。

BLUE 拆开读

Best：方差最小；
Linear：$\hat{\beta}$ 是 y 的线性函数 Ay；
Unbiased：$\mathbb{E}\hat{\beta} = \beta$；
Estimator：一个估计量，不是一个数。

证明思路（一页版）

任取另一个线性无偏估计量 $\tilde{\beta} = Ay$，记 $A = (X'X)^{-1}X' + C$。无偏性要求 $CX = 0$。展开方差：

$$\mathrm{Var}(\tilde{\beta}) = \sigma^2\left[(X'X)^{-1} + CC'\right] = \mathrm{Var}(\hat{\beta}_{OLS}) + \sigma^2 CC'.$$

由于 CC' 半正定，第二项永远 ≥ 0——所以 OLS 的方差不可能被超过。

定理的边界要记牢：只在" 线性 + 无偏" 这个擂台里比。允许有偏时（Ridge），可以做到更小方差——这就是正则化敢用的理论依据。

来源：Gauss-Markov 定理由 Gauss (1821) 与 Markov (1900) 提出；现代表述见 Greene 与 Plackett (1949)。

残差的正交性与方差分解 Orthogonality and Decomposition

三条正交关系

$$X'\hat{\varepsilon} = 0, \qquad \hat{y}'\hat{\varepsilon} = 0,$$

$$\|y\|^2 = \|\hat{y}\|^2 + \|\hat{\varepsilon}\|^2.$$

含义：残差与每个解释变量都不相关；拟合值与残差垂直；总平方和可以拆成两半。

R^2 的定义与性质

$$R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}} = \frac{\mathrm{ESS}}{\mathrm{TSS}},$$

$\mathrm{TSS} = \sum (y_i - \bar{y})^2$、$\mathrm{RSS} = \sum \hat{\varepsilon}_i^2$。$R^2 \in [0,1]$（含截距时），且随变量增加单调不减。

所以比较模型要用调整 R^2：$\bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-p-1}$。再加一个变量，$R^2$ 不变也可能让 $\bar{R}^2$ 下降——这就是" 加变量免费涨分" 的破解办法。

来源：正交性与方差分解据标准最小二乘理论；调整 R^2 的性质为本讲强调。

从估计到推断：标准误、t 与 F Inference after OLS

三个统计量

$$\hat{\sigma}^2 = \frac{\mathrm{RSS}}{n-p}, \qquad t_j = \frac{\hat{\beta}_j}{\widehat{\mathrm{se}}(\hat{\beta}_j)},$$

$$F = \frac{(\mathrm{RSS}_r - \mathrm{RSS}_u)/q}{\mathrm{RSS}_u/(n-p)} \sim F_{q,\,n-p}.$$

t_j 检验单个系数是否为 0；F 检验 q 个约束是否同时成立。

置信区间与读法

$$\hat{\beta}_j \pm t_{1-\alpha/2,\,n-p} \cdot \widehat{\mathrm{se}}(\hat{\beta}_j).$$

区间跨过 0 $\Leftrightarrow$ 在 α 水平上不显著。注意：显著 $\neq$ 重要——样本足够大时，极小的效应也会显著。

本讲帧 96 的 statsmodels 输出就是这张表：系数、标准误、t、p 值、置信区间。同一个模型，sklearn 只给你系数，statsmodels 才给你" 这个系数有多可信"——要写结论、要谈因果关系时，必须用后者。

来源：t 与 F 检验据标准回归推断；读法提醒为本讲补充。

假设不成立时怎么办 When the Assumptions Break

问题	症状	后果	对策
异方差	残差随 $\hat{y}$ 扩散	无偏但标准误错、t 虚高	稳健标准误 (robust standard error) (HC0–HC3)、加权最小二乘
自相关	残差按时间成串	标准误被低估	聚类标准误、Newey-West
多重共线	$X'X$ 条件数大	系数方差大、符号乱跳	岭回归、删变量、主成分回归
内生性	$\mathrm{Cov}(X, \varepsilon) \neq 0$	有偏且不一致	工具变量、面板固定效应、DID
设定错误	残差有结构	系统性偏差	加非线性项、样条、树模型

一句话分工：前三个是" 方差问题"，可以用统计手段补救；后两个是" 识别问题"，只能换设计——这也是第 12 讲因果推断的起点。

来源：诊断与对策据计量实践（Wooldridge, Greene）；" 方差问题 vs 识别问题" 的划分为本讲整理。

为什么需要极大似然 Why Maximum Likelihood

问题

损失函数不是随手挑的。它编码了你对数据如何产生的假设。如果损失与数据生成过程不匹配，模型就会系统性地错。

MLE 的思路

极大似然估计 maximum likelihood estimation (MLE)：在所有候选参数中，选那个让已观测数据出现概率最大的参数。

这一部分的目标：把" 损失函数" 从" 给定" 变成" 推导出来"。推导完你会看到——平方损失是高斯假设的产物，交叉熵是伯努利假设的产物。

来源：MLE 的动机据统计学习教材；框架为本讲组织。

分布族与参数 Distributions and Parameters

设定

给定训练数据 $\{(x_i, y_i)\}$，假设数据来自一族由参数 θ 索引的分布：

$$\{P_\theta(x, y) : \theta \in \Theta\}.$$

θ 是参数 parameter，Θ 是参数空间 parameter space。

例子

- 高斯族：$\theta = (\mu, \sigma^2)$；
- 伯努利族：$\theta = p$；
- 逻辑回归：$\theta = w$，$P_w(y = 1 \mid x) = \sigma(w^\top x)$。

关键区分

参数是要学的 (w)；超参数 (hyper-parameter) 是人定的（如 λ、学习率）。

来源：分布族的表述统计学习通行定义；超参数的区分衔接帧 76。

似然：从单个样本到整份数据 Likelihood

单个样本的"拟合度"

定义参数 θ 对一个样本 (x_i, y_i) 的似然likelihood：

$$\mathrm{lik}(\theta; x_i, y_i) := P_\theta(x_i, y_i).$$

它是"在参数为 θ 时，看到这个样本的概率"。

整份数据（利用 i.i.d.）

独立同分布意味着概率相乘：

$$\mathrm{lik}(\theta; \{(x_i, y_i)\}) = \prod_{i=1}^{n} P_\theta(x_i, y_i).$$

这就是联合似然joint likelihood。

注意术语差别：概率是"给定参数看数据"，似然是"给定数据看参数"——同一个式子，两种读法。

来源：似然的定义统计学习通行表述。

为什么取对数 Why Take the Log

两个理由

1. 数值：n 个小于 1 的数相乘会下溢 underflow 成 0（帧 48）；
2. 代数：对数把乘积变成求和，求导方便。

$$\log \mathrm{lik}(\theta) = \sum_{i=1}^{n} \log P_\theta(x_i, y_i).$$

单调性保证等价

$\log$ 是单调递增函数，所以

$$\arg\max_\theta \mathrm{lik}(\theta) = \arg\max_\theta \log \mathrm{lik}(\theta).$$

最大化似然与最大化对数似然 log-likelihood 是同一件事。

来源：取对数的理由据统计学习与数值计算实践；单调性为基本事实。

负对数似然作为损失 Negative Log-Likelihood

把” 最大化” 改成” 最小化”

优化器通常做最小化，于是定义负对数似然 negative log-likelihood (NLL)：

$$\hat{L}(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log P_\theta(x_i, y_i).$$

所以

极大似然估计 $\Leftrightarrow$ 最小化 NLL。而 NLL 正是我们要找的损失函数——它由分布假设唯一决定（差一个常数因子）。

两个具体的 NLL

- 高斯 $\rightarrow$ 平方损失（帧 43）；
- 伯努利 $\rightarrow$ 逻辑损失，即交叉熵 cross-entropy（帧 44、59）。

来源：ML 与 ERM 的关系统计学习通行表述。

条件似然：判别式与生成式 Conditional Likelihood

判别式 discriminative

只建模条件分布：

$$P_\theta(y \mid x).$$

目标是最小化 $-\frac{1}{n}\sum_i \log P_\theta(y_i \mid x_i)$。分类任务通常这么做（逻辑回归）。

生成式 generative

建模联合分布：

$$P_\theta(x, y) = P_\theta(x) P_\theta(y \mid x).$$

除了分类，还能生成样本、处理缺失；代价是假设更多、参数更多。

逻辑回归是判别式的：它只关心" 给定特征下标签的概率"，不假设特征本身怎么分布。这使它对特征分布的错误假设更稳健。

来源：判别式与生成式的区分据 Bishop 与统计学习教材；与本讲的关系为本讲补充。

【推导】平方损失 = 高斯噪声 + MLE l_2 Loss from a Gaussian

推导（三步）

设 $y_i \mid x_i \sim \mathcal{N}(w^\top x_i, \sigma^2)$，则

$$P_w(y_i \mid x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \frac{(y_i - w^\top x_i)^2}{2\sigma^2} \Big).$$

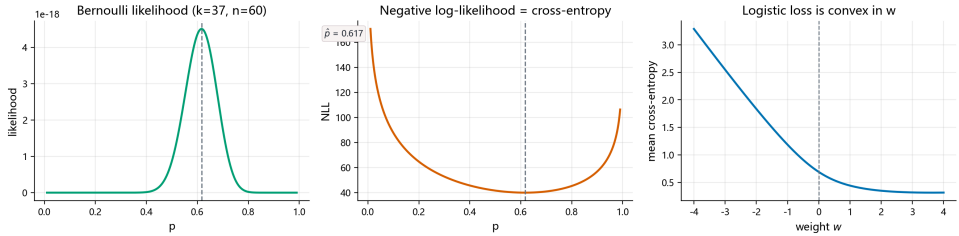
取负对数，与 w 无关的项是常数；对 i 求和、除以 n、乘 $2\sigma^2$ 后只剩平方项：

$$\arg\min_w \big[- \log \mathrm{lik} \big] = \arg\min_w \frac{1}{n} \sum_i (y_i - w^\top x_i)^2.$$

结论：在高斯噪声假设下，最小化平方损失就是极大似然。所以" 为什么用 l_2" 的答案不是审美，而是对误差分布的假设。

来源：推导统计数据学习教材；步骤为本讲展开。

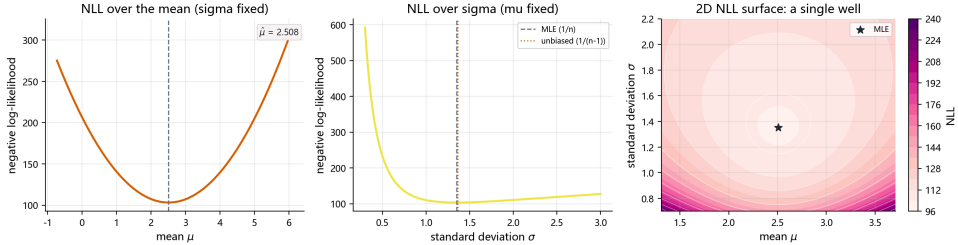
【样本 + 可视化】伯努利似然与逻辑损失 Bernoulli Likelihood



左：伯努利似然在观测频率处取最大（本样本 $k = 37$、$n = 60$，MLE $\hat{p} = 0.617$）；中：对应的负对数似然 NLL 是凸的；右：单个特征的逻辑损失 logistic loss 也是凸函数——凸性保证梯度下降收敛到全局最优。

程序 `16_03_mle_gaussian.py` ·结果 `16_spam.csv` ·与帧 59 的交叉熵推导衔接

【样本 + 可视化】负对数似然曲面 The NLL Surface



高斯样本（$n = 60$，真实 $\mu = 2.5, \sigma = 1.4$）：左：固定 σ 时 NLL 对 μ 是抛物线，最优解是样本均值 2.302；中：NLL 对 σ 的最优点在 1.367（除以 n），而无偏估计是 1.379（除以 $n-1$）；右：二维曲面是单个" 碗"，凸且唯一最优点。

程序 `16_03_mle_gaussian.py` ·曲面数据 `16_nll_surface.csv` ·与数值优化的结果一致

【代码】用 MLE 拟合高斯 Fitting a Gaussian by MLE

```python
def nll_gaussian(params, data):                    # negative log-likelihood of a Gaussian
    mu, log_sigma = params                         # unpack the parameter vector
    sigma = np.exp(log_sigma)                      # keep sigma positive by construction
    z = (data - mu) / sigma                        # standardised residuals
    return float(np.sum(0.5 * z ** 2 + log_sigma + 0.5 * np.log(2 * np.pi))) # sum of NLL terms
fit = minimize(nll_gaussian, x0=[0.0, 0.0], args=(sample,), method="Nelder-Mead") # numerical MLE
mu_grid = np.linspace(sample.min() - 0.5, sample.max() + 0.5, 300) # grid over the mean
nll_mu = [nll_gaussian([m, np.log(mle_sd)], sample) for m in mu_grid] # NLL as a function of the mean
sd_grid = np.linspace(0.3, 3.0, 300)               # grid over the standard deviation
nll_sd = [nll_gaussian([mle_mu, np.log(s)], sample) for s in sd_grid] # NLL as a function of sigma
mle_mu = float(sample.mean())                      # MLE of the mean equals the sample mean
mle_sd = float(sample.std(ddof=0))                 # MLE of the sd divides by n, not n-1
print("numerical MLE: mu %.4f | sigma %.4f" % (fit.x[0], np.exp(fit.x[1]))) # should match the closed form
```

要点：参数化要对——用 $\log\sigma$ 保证 $\sigma > 0$；闭式解与数值优化必须一致，这是检验推导的最快方式。完整程序 `l6_03_mle_gaussian.py`。

数值问题：下溢与 log-sum-exp Underflow

下溢

300 个 0.01 相乘是 10^{-600}，在浮点数里直接变成 0；似然变成 0 后，对数无定义、梯度全为 0。

溢出

反过来，$\exp(1000)$ 会变成 inf，softmax 里出现 inf/inf 就得到 NaN。

解法：先减最大值

$$\log \sum_k e^{z_k} = m + \log \sum_k e^{z_k - m}, \quad m = \max_k z_k.$$

同理 softmax 用 $e^{z_k - m}$ 计算。这个技巧叫 log-sum-exp log-sum-exp。

本讲实测：300 个 0.01 的连乘得到 0.0，而取对数再求和得到 -1381.55；logits 为 $\{1000, 1001, 1002\}$ 时，朴素 softmax 返回 nan，稳定版返回 $\{0.09, 0.24, 0.67\}$。

来源：下溢与溢出为浮点数基本事实；数值来自程序 l6_04。

【代码】稳定的 log-sum-exp Stable Log-Sum-Exp

```python
def stable_softmax(z):                          # shifted softmax used in practice
    z = np.asarray(z, dtype=float)              # work with a float array
    shifted = z - np.max(z)                     # the shift removes the overflow
    ez = np.exp(shifted)                        # safe exponentials
    return ez / np.sum(ez)                      # normalise
def logsumexp(a, axis=None, keepdims=False):    # stable log-sum-exp helper
    a = np.asarray(a, dtype=float)              # work with float arrays
    amax = np.max(a, axis=axis, keepdims=True)  # subtract the maximum first
    shifted = np.exp(a - amax)                  # safe exponentials
    out = amax + np.log(np.sum(shifted, axis=axis, keepdims=True)) # log-sum-exp of the shifted values
    return float(np.squeeze(out)) if axis is None and not keepdims else out # scalar when fully reduced
naive_product = float(np.prod(probs))           # naive product underflows to zero
log_product = float(np.sum(np.log(probs)))      # working in logs keeps the value
assert naive_product == 0.0, "expected underflow for 300 factors of 0.01" # document the failure mode
```

要点：任何概率连乘、任何 softmax，都应先减最大值；这条规则在深度学习的损失函数里无处不在（衔接 L9）。完整程序 `l6_04_logsumexp.py`。

信息量与熵：把不确定变成一个数 Self-Information and Entropy

自信息（self-information）

一个概率为 p 的事件发生时，带来的" 信息量"

$$I(x) = -\log p(x).$$

为什么取负对数：概率越小越意外（信息越大）；独立事件的信息量可加：$I(x, y) = I(x) + I(y)$，只有对数满足这一点。

熵（entropy）

对整条分布取期望信息量：

$$H(p) = \mathbb{E}_{x\sim p}\big[-\log p(x)\big] = -\sum_{k=1}^{K} p_k \log p_k.$$

读作" 平均要多少比特/奈特才能描述这个随机变量"。

单位：以 2 为底是比特（bit），以 e 为底是奈特（nat），两者差一个 $\ln 2$。机器学习里几乎都用奈特——因为求导时 $\log$ 的导数是 $1/x$，不用带常数。

本讲实测：$H(0.5, 0.5) = 0.693$ nats $= 1$ bit；$H(0.9, 0.1) = 0.325$ nats $= 0.469$ bit。

来源：自信息与熵据 Shannon (1948)；单位约定为本讲统一。

熵的四条性质 Four Properties of Entropy

四条

1. 非负：$H(p) \geq 0$，且当且仅当某个 $p_k = 1$ 时取 0（结果确定，没有不确定性）。
2. 最大值：$H(p) \leq \log K$，在均匀分布处取到。
3. 凹性：H 是 p 的凹函数，所以" 混合两个分布" 会增加不确定性。
4. 可加（链式法则）：$H(X, Y) = H(X) + H(Y \mid X)$。

本讲实测（奈特 / 比特）

分布	nats	bits
$(1, 0)$	0	0
$(0.9, 0.1)$	0.325	0.469
$(0.5, 0.5)$	0.693	1.000
均匀 $K = 4$	1.386	2.000

K 越大上界越高：$\log 4 = 1.386$ 正是 2 比特。

第 2 条是" 熵" 最常用的性质：越均匀越不确定。它也是决策树" 信息增益" 的起点——分裂之后子节点的熵加权和下降多少，就是这次分裂的价值。

来源：性质与链式法则据 Cover & Thomas (2006)；数值来自 `16_15_entropy.py`。

交叉熵：用”错的分布”编码”真的分布”Cross-Entropy

定义

真实分布 p、模型分布 q：

$$H(p,q) = -\sum_{k=1}^{K} p_k \log q_k.$$

注意期望按 p 取、对数按 q 取——这就是” 用 q 去编码来自 p 的数据” 的平均长度。

三条性质

(1) 下界：$H(p,q) \geq H(p)$；(2) 等号条件：当且仅当 $q = p$ 时取等；(3) 不对称：$H(p,q) \neq H(q,p)$。

本讲实测：固定真实分布 $p = (0.2, 0.8)$，$H(p) = 0.5004$ nats

模型 q	$H(p,q)$	$D_{KL}(p\|q)$	说明
$(0.2, 0.8)$	0.5004	0.0000	猜对：交叉熵 = 熵
$(0.5, 0.5)$	0.6931	0.1927	猜成均匀：多付 0.19
$(0.05, 0.95)$	0.6402	0.1398	猜过头：也多付

来源：交叉熵据 Shannon (1948)；表参 Cover & Thomas (2006)；数值为自本讲程序。

KL 散度与互信息：交叉熵减去熵 KL Divergence

KL 散度（相对熵）

$$D_{KL}(p\|q) = \sum_k p_k \log \frac{p_k}{q_k} = H(p,q) - H(p) \geq 0.$$

非负性由 Jensen 不等式得到：$-\log$ 是凸函数，所以 $\mathbb{E}_p[-\log(q/p)] \geq -\log \mathbb{E}_p[q/p] = 0$。

三个注意

不对称：$D_{KL}(p\|q) \neq D_{KL}(q\|p)$，所以它不是距离（不满足三角不等式）；不是有界的（$q_k \to 0$ 而 $p_k > 0$ 时爆炸）；$D_{KL} = 0$ 当且仅当 $p = q$。

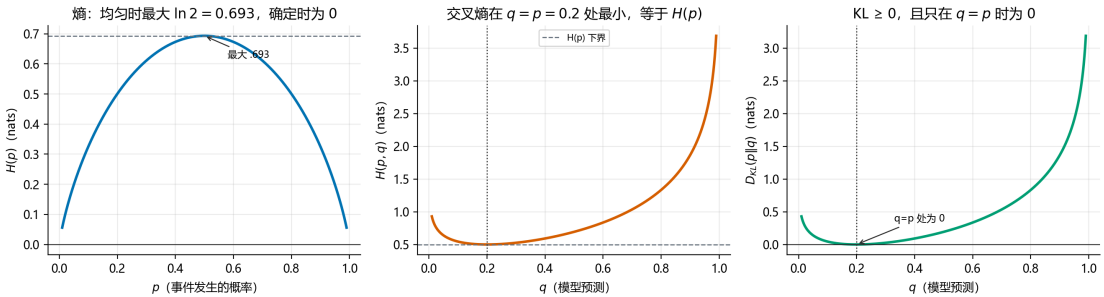
互信息（mutual information）是它的一个特例：

$$I(X;Y) = D_{KL}\big(p(x,y) \,\|\, p(x)p(y)\big),$$

衡量" 知道 Y 能减少多少关于 X 的不确定性"。特征选择、决策树分裂、文本里的 PMI 都是它——这就是本讲与 L10 的接口。

来源：KL 与互信息据 Cover & Thomas (2006)；与 L10 的衔接为课程设计。

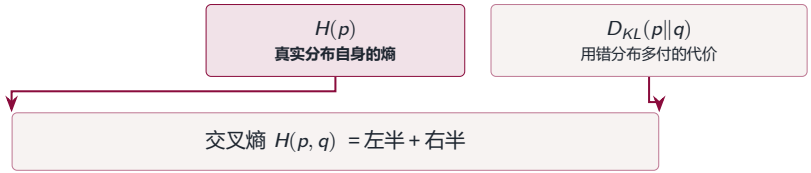
【样本】三条曲线看懂熵、交叉熵与 KL Three Curves



左：二分类的熵，$p = 0.5$ 时最大 $\ln 2 = 0.693$，两端趋近 0（结果确定）；中：固定真实分布 $p = 0.2$，交叉熵在$q = 0.2$ 处最小，且最小值正好等于 $H(p) = 0.5004$；右：KL 散度恒非负、只在 $q = p$ 处为 0——这就是" 最小化交叉熵 = 让预测分布贴近真实分布" 的几何证据。

程序 l6_15_entropy.py ·图 fig_entropy.png ·表 l6_entropy_table.csv / l6_cross_entropy_checks.csv

三个量的关系，以及它们为什么出现在机器学习里 Three Quantities



用处	用的是哪个量	为什么
分类损失	交叉熵 $H(p,q)$	p 是 one-hot 时 $H(p)=0$，等价于最小化 KL
极大似然	负对数似然	与交叉熵完全等价（本讲帧 43 的推导）
决策树分裂	熵 / 信息增益	分裂后子节点熵加权和下降多少
语言模型	困惑度	perplexity $= e^{H(p,q)}$（奈特下）
特征选择	互信息	知道特征后标签不确定性减少多少

一句话记住：交叉熵 = 熵 + KL。熵是你无法消除的部分（数据本身的随机性），KL 是你可以改进的部分（模型有多差）。所以训练时最小化交叉熵，本质上就是在把 KL 压到 0。

来源：关系式与困惑度定义据 Cover & Thomas (2006) 与 Goodfellow et al. (2016)。

交叉熵在分类中的用法 Using Cross-Entropy in Classification

定义

对两个分布 p, q：

$$H(p,q) = -\sum_k p_k \log q_k \quad (\text{交叉熵 cross-entropy}),$$

$$D_{KL}(p\|q) = \sum_k p_k \log \frac{p_k}{q_k}.$$

两式满足 $H(p,q) = H(p) + D_{KL}(p\|q)$。

为什么分类用它

当 p 是真实标签 (one-hot) 时，$H(p)$ 是常数，于是最小化交叉熵 $\Leftrightarrow$ 最小化 KL 散度 $\Leftrightarrow$ 让预测分布逼近真实分布。

二分类时交叉熵写成 $-\frac{1}{n}\sum_i \left[y_i \log p_i + (1-y_i)\log(1-p_i)\right]$，其中 $p_i = \sigma(w^\top x_i)$——这就是帧 59 要推导的逻辑回归损失。

来源：交叉熵与 KL 的关系据信息论与机器学习教材。

小结：损失函数从哪里来 Where Losses Come From

损失	对应的分布假设	推导出的解
平方损失 l_2	高斯噪声 $\mathcal{N}(w^\top x, \sigma^2)$	闭式解 $w = (X^\top X)^{-1} X^\top y$
交叉熵（二分类）	伯努利 $P(y \mid x) = \sigma(w^\top x)$	无闭式解，用梯度下降
交叉熵（多分类）	类别分布 + softmax	无闭式解，用梯度下降
l_1 **损失**	拉普拉斯噪声	中位数回归，无闭式解

一句话：损失 = 你对数据的概率假设。下一部分把" 伯努利 + sigmoid" 这条线走完，得到逻辑回归与它的梯度。

来源：损失与分布的对应关系统计学习与信息论教材。

线性分类的几何 Geometry of a Linear Classifier

决策规则

用超平面把空间分成两半：

$$\hat{y} = \begin{cases} 1, & w^\top x > 0 \\ 0, & w^\top x < 0 \end{cases}$$

w 是法向量 normal vector，$w^\top x = 0$ 是超平面 hyperplane（决策边界）。

两个几何量

- 间隔 margin：样本到边界的距离 $|w^\top x|/\|w\|$；
- 间隔越大，分类越"自信"——这也是 L7 支持向量机的出发点。

从回归到分类只换了两件事：输出从实数变成类别，损失从平方变成误分类计数。后者带来一个新困难（帧 53）。

来源：线性分类的几何据统计学习教材；间隔的铺垫衔接 L7。

自然尝试：阶跃函数 + 0-1 损失 The Natural Attempt

写法

用阶跃函数 step function 把线性得分变成类别：

$$\hat{y} = \mathrm{step}(w^\top x), \qquad \hat{L}(w) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}\big[\mathrm{step}(w^\top x_i) \neq y_i\big].$$

这就是 0-1 损失 0-1 loss 的经验风险。

垃圾邮件例子（输入形态）

每封邮件变成一个向量：叹号数、“Mr.” 数、“sale” 数、…
标签是 spam / not spam。

直觉上很合理

误分类计数最贴合任务目标：错一个算一个。问题在于——它没法优化。

来源：垃圾邮件特征表据课程讲义；0-1 损失的表述统计学习通行。

为什么 0-1 损失难优化 Why the 0-1 Loss Is Hard

三个原因

1. 梯度为零：阶跃函数几乎处处是常数，$\nabla_w \hat{L} = 0$，梯度下降无从下手；
2. 不可导：在 $w^\top x = 0$ 处跳变；
3. 组合爆炸：在最坏情形下，这个问题是 NP-hard 的。

教科书的原话

"Drawback: difficult to optimize. NP-hard in the worst case." ——这正是课程讲义对这一做法的结论。

所以需要找一个光滑的替代损失（surrogate loss），它把 0-1 损失"包"起来：最小化它就能间接降低误分类率。下一帧给出第一个替代方案。

来源：NP-hard 的结论据课程讲义原文；替代损失的思路统计学习通行。

退一步：把分类当回归 Regression as a Classifier

做法

忽略 $y \in \{0, 1\}$ 的事实，直接用平方损失：

$$\hat{L}(w) = \frac{1}{n} \sum_{i=1}^{n} \left(w^\top x_i - y_i \right)^2,$$

然后令 $\hat{y} = \mathbb{I}[w^\top x > 0.5]$。

好处

有闭式解、好优化，实现只需几行（帧 30 的代码可复用）。

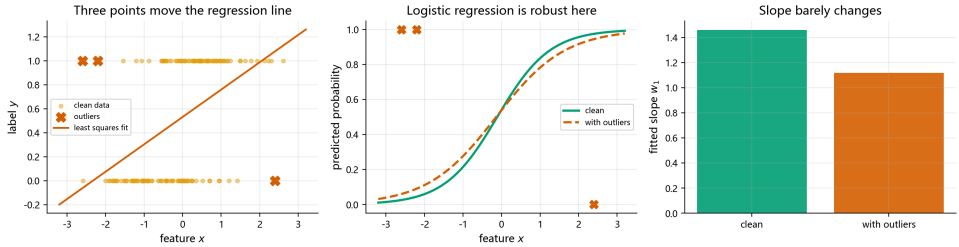
代价

平方损失惩罚"太自信"的预测，因此对离群点 outlier 极其敏感——一个标错且离边界很远的点，会把整条边界拉歪（帧 55 的样本）。

这是一个重要的教训：损失函数的选择会改变模型的鲁棒性，不只是改变"优化好不好做"。

来源：回归当分类的做法及其缺陷据课程讲义与 Bishop 教材。

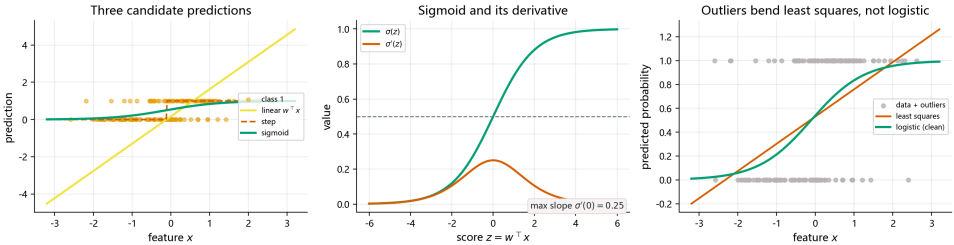
【样本 + 可视化】离群点如何破坏回归分类器 Outliers



左：三个标错的点把最小二乘的直线压弯（阈值 threshold 从 0 附近移到 -2.3）；中：逻辑回归的边界几乎不动；右：两种方法斜率的直接对比（clean 与 with outliers）。

程序 `16_05_linreg_vs_sigmoid.py` ·样本 `16_two_class.csv`（含三个离群点）

【样本 + 可视化】step、线性与 sigmoid 三条曲线



左：三种候选预测——线性得分无界、step 不连续、sigmoid 有界且光滑；中：sigmoid 与它的导数，拐点处斜率最大（0.25）；右：同一份带离群点的数据，最小二乘被拉弯而逻辑回归基本不动。

程序 `16_05_linreg_vs_sigmoid.py` ·样本 `16_two_class.csv`

sigmoid 的定义：它是从哪来的 What the Sigmoid Is

定义

$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{e^{z}}{1+e^{z}}.$$

也叫logistic 函数（logistic function）。把整条实轴 $(-\infty, +\infty)$ 单调压到 $(0,1)$——所以它能当概率用。

三种来历（等价）

(1) 对数几率的反函数：$\mathrm{logit}(p) = \ln \frac{p}{1-p}$，反解 $p = \sigma(z)$；(2) 两个选项的 softmax：$\frac{e^{z_1}}{e^{z_1}+e^{z_0}}$，取 $z_0 = 0$ 就是 $\sigma(z_1)$；(3) 伯努利分布的 GLM 链接：$p = \sigma(w^{\top}x)$。

本讲实测的数值（z 与 $\sigma(z)$、几率 e^{z}）

z	-3	-2	-1	0	1	2	3
$\sigma(z)$	0.047	0.119	0.269	0.500	0.731	0.881	0.953
e^{z}（几率）	0.050	0.135	0.368	1.000	2.718	7.389	20.09

两条要记住的读法：$z = 0$ 时概率正好一半（几率 1:1）；z 每加 1，几率乘 $e \approx 2.72$——这就是" 系数可解释为对数几率" 的由来。命名提醒：" logistic 回归" 的名字来自 logit 链接，不是来自 sigmoid 本身；σ 与求和号 Σ 无关。

来源：定义与三种来历据 McCullagh & Nelder (1989) 与 Hosmer & Lemeshow (2000)；数值为本讲计算。

sigmoid 的三条性质 Three Properties of the Sigmoid

上一帧给了定义 $\sigma(a) = \frac{1}{1+e^{-a}}$，这里推它的三条性质。

(1) 有界

$\sigma(a) \in (0,1)$：永不取到 0 或 1，适合当概率。

(2) 对称

$1 - \sigma(a) = \sigma(-a)$：“反面”与 “取负数” 等价。

(3) 导数

$\sigma'(a) = \sigma(a)\big(1 - \sigma(a)\big)$：梯度只用输出值就能算。

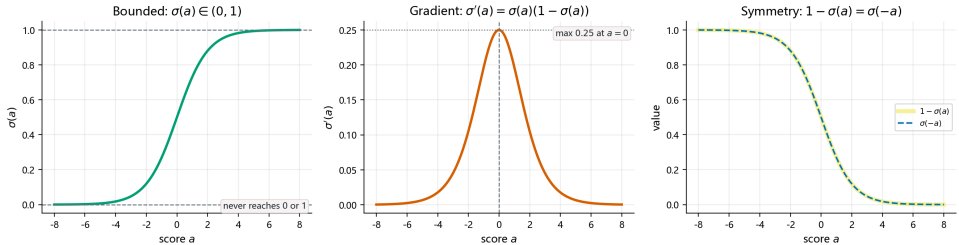
两条公式的推导

(2) $1 - \sigma(a) = \frac{e^{-a}}{1+e^{-a}} = \sigma(-a)$；　(3) $\sigma'(a) = \frac{e^{-a}}{(1+e^{-a})^2} = \sigma(a)\big(1 - \sigma(a)\big)$.

第 (3) 条是逻辑回归能高效训练的关键：梯度可以只用输出值算出来，不需要再算一遍指数函数 (帧 62 会用到)。

来源：三条性质据课程进义；推导为本讲展开。

【样本 + 可视化】sigmoid 的形状、导数与对称性



左：值域严格在 $(0, 1)$ 内；中：导数关于 0 对称，最大值 0.25（在 $a = 0$ 处）；右：$1 - \sigma(a)$ 与 $\sigma(-a)$ 完全重合——这就是" 对称性" 的图形表示。

程序 `16_05_linreg_vs_sigmoid.py` ·图由同一份代码生成，便于核对公式

从极大似然出发（一）：一个伯努利模型 Starting from MLE

模型设定

每个样本的标签是 0/1，所以最自然的假设是伯努利分布：

$$y_i \mid x_i \sim \mathrm{Bernoulli}(p_i), \qquad p_i = \sigma(x_i^\top w),$$

其中 $\sigma(z) = \frac{1}{1+e^{-z}}$（帧 55 的定义）。

似然

四个字：把每个样本的概率乘起来。

$$L(w) = \prod_{i=1}^{n} p_i^{y_i} (1-p_i)^{1-y_i},$$

$$\ell(w) = \log L(w) = \sum_{i=1}^{n} \Big[y_i \log p_i + (1-y_i) \log(1-p_i) \Big].$$

两个约定：取对数是因为乘积会下溢、而且对数把" 乘" 变成" 加"；MLE 就是让 $\ell(w)$ 最大，即 $\hat{w} = \arg\max_w \ell(w)$。注意此时还没有出现" 损失函数"——它是下一步才被定义的。

来源：设定与似然据标准广义线性模型（McCullagh & Nelder 1989）。

从极大似然出发（二）：一步化简 A Single Line

先用两个恒等式

记 $z_i = x_i^\top w$，则

$$\log \sigma(z) = -\log(1+e^{-z}), \qquad 1-\sigma(z) = \sigma(-z).$$

第二式就是对称性（帧 56 的第 (2) 条）。

代入即可

$$\log p_i = -\log(1+e^{-z_i}),$$
$$\log(1-p_i) = -z_i - \log(1+e^{-z_i}),$$

代回 ℓ，同类项直接消掉：

$$\ell(w) = \sum_{i=1}^{n} \Big[y_i z_i - \log\left(1+e^{z_i}\right) \Big].$$

这一步是整段推导的唯一技巧，也是" 简化" 的关键：原来有四项、两个 $\log\sigma$，化简后只剩两项。它还有个工程后果——$\log(1+e^z)$ 就是帧 48 讲的 log-sum-exp，所以实现时用 `logaddexp(0, z)` 而不是先算 $1+e^z$ 再取对数（会溢出）。

来源：化简为标准逻辑损失（logistic loss）形式；数值实现据帧 48。

从极大似然出发（三）：梯度长这样 The Gradient

求导只有一步

因为 $\dfrac{d}{dz}\log(1+e^{z}) = \sigma(z)$，

$$\frac{\partial \ell}{\partial w} = \sum_{i=1}^{n} \big(y_i - \sigma(z_i)\big)x_i = X^{\top}(y-p),$$

$p = \sigma(Xw)$ 是预测概率向量。

为什么一定有唯一解

二阶导（Hessian）：

$$\nabla^2(-\ell) = X^{\top}WX, \qquad W = \operatorname{diag}\big(p_i(1-p_i)\big).$$

W 对角元恒正，所以 Hessian 半正定——负对数似然是凸函数，驻点即全局最优。

三个可直接讲的结论：(1) 梯度里没有 σ'——它被化简吃掉了，这就是" 形式与线性回归一模一样" 的原因；(2) 因为 p 依赖 w，令梯度为 0 得不到闭式解（帧 61），只能迭代；(3) 但它是凸的，所以牛顿法 / IRLS 几步就收敛——「无闭式解」不等于「不可靠」。

来源：梯度与 Hessian 据标准 GLM 理论；与线性回归的形式对照为本讲强调。

四个名字，一个最优解 MLE = 最小交叉熵

等价性（一行代数）

平均值交叉熵：

$$\overline{H}(w) = -\frac{1}{n}\sum_{i=1}^{n}\Big[y_i \log p_i + (1-y_i)\log(1-p_i)\Big].$$

而 $\ell(w)$ 正是方括号里的和，于是

$$\boxed{\overline{H}(w) = -\frac{1}{n}\ell(w)}$$

两者只差一个正的常数因子和符号，所以最小化交叉熵 $\Leftrightarrow$ 最大化似然，最优解完全相同。

再用熵的分解看一遍

由帧 55–58 的 $H(p,q) = H(p) + D_{KL}(p\|q)$：标签是 one-hot 时 $H(p) = 0$，

$$\overline{H}(w) = D_{KL}\big(p \,\|\, q(w)\big).$$

于是四个说法是同一件事：最大似然 = 最小负对数似然 = 最小交叉熵 = 最小 KL。

什么时候”等价”要加条件

标签是概率（soft label、标签平滑）时，交叉熵仍需期望按 p 取，等价性依然成立；但若给损失加正则项，等价对象就变成MAP（最大后验）而不是 MLE——L2 惩罚对应高斯先验，这是帧 74–78 正则化的贝叶斯解释。

来源：《数学基础》标准统计学习教材（如 Hastie et al. 2009 与 Bishop 2006）；MAP 的解释为本讲补充。

对数几率与系数解释 Log-Odds and Coefficients

对数几率

设 $p = P(y = 1 \mid x)$，则

$$\log \frac{p}{1-p} = w^\top x.$$

左端叫对数几率 log-odds；它关于 x 线性——这就是" 逻辑回归是线性模型" 的准确含义。

系数怎么读

特征 j 增加 1 个单位：

- 对数几率增加 w_j；
- 几率乘以 $\exp(w_j)$，即几率比 odds ratio；
- 本讲样本：$w_1 = 1.17$，几率比 $e^{1.17} = 3.22$ ——几率变为 3.2 倍。

业务建议：汇报逻辑回归时，给几率比而不是给系数；系数是" 对数几率的变化"，非专业人士很难直读。

来源：对数几率与几率比据统计学习教材；数值来自程序 l6_10。

为什么没有闭式解 No Closed-Form Solution

原因

交叉熵损失对 w 是非线性的（sigmoid 是非线性的），令梯度为零会得到一个没有解析解的方程组。

好消息：凸性

逻辑回归的损失是凸函数 convex function：

- 任何局部最优都是全局最优；
- 梯度下降一定收敛（步长合适时）。

所以策略变了：不再"求公式"，而是迭代求解。这是从"线性回归"到"逻辑回归"最重要的一步跨越——也是所有深度学习优化的原型。

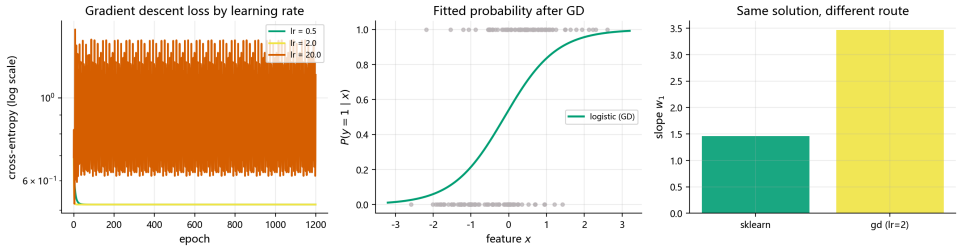
来源：凸性与无闭式解据统计学习教材。

【代码】手写梯度下降训练逻辑回归 Gradient Descent by Hand

```python
def logistic_loss(w_vec, Xm, yv, l2=0.0):            # mean cross-entropy plus optional L2
    p = sigmoid(Xm @ w_vec)                          # predicted probabilities
    eps = 1e-12                                      # avoid log(0)
    loss = -np.mean(yv * np.log(p + eps) + (1 - yv) * np.log(1 - p + eps)) # cross-entropy
    loss += 0.5 * l2 * float(w_vec @ w_vec)          # weight decay term
    return float(loss)                               # return the scalar loss
def logistic_grad(w_vec, Xm, yv, l2=0.0):            # analytic gradient
    p = sigmoid(Xm @ w_vec)                          # predicted probabilities
    grad = (Xm.T @ (p - yv)) / len(yv)               # X^T (p - y) / n
    grad += l2 * w_vec                               # gradient of the weight decay
    return grad                                      # return the gradient vector
def train_gd(learning_rate, epochs=1200, l2=0.0):    # full-batch gradient descent
    w_vec = np.zeros(X.shape[1])                     # start from zero weights
    hist = []                                        # loss history per epoch
    for _ in range(epochs):                          # fixed number of full-batch steps
        hist.append(logistic_loss(w_vec, X, two["y"].values, l2)) # record the loss before the update
        w_vec = w_vec - learning_rate * logistic_grad(w_vec, X, two["y"].values, l2) # gradient step
    return np.array(hist), w_vec                     # return history and final weights
```

要点：三行核心——算概率、算损失、算梯度；其余都是记账。完整程序 `16_05_linreg_vs_sigmoid.py`，与 sklearn 结果对比在帧 64。

【样本 + 可视化】收敛曲线与学习率的敏感性 Learning Rate



左：学习率 0.5 与 2.0 都收敛到同一损失（0.518），20.0 振荡发散（损失停在 1.15）；中：梯度下降拟合出的概率曲线；右：与 sklearn 的斜率几乎一致（截距的小差异来自 sklearn 默认的 L2 正则）。

程序 `16_05_linreg_vs_sigmoid.py` ·轨迹表 `16_gd_history.csv`

【代码】PyTorch 自动求导：与手写梯度对账 Autograd

```python
import torch                                          # automatic differentiation
import torch.nn as nn                                 # loss modules
Xt = torch.tensor(X_np, dtype=torch.float64)          # torch version of the design matrix
yt = torch.tensor(y_np, dtype=torch.float64)          # torch version of the labels
w_t = torch.zeros(X_np.shape[1], dtype=torch.float64, requires_grad=True) # parameter with gradients
opt = torch.optim.SGD([w_t], lr=2.0)                  # plain stochastic gradient descent
bce = nn.BCEWithLogitsLoss()                          # numerically stable logistic loss
for _ in range(800):                                  # same number of epochs
    opt.zero_grad()                                   # clear the previous gradients
    logits = Xt @ w_t                                 # linear score
    loss = bce(logits, yt)                            # loss computed in a stable way
    loss.backward()                                   # autograd fills w_t.grad
    opt.step()                                        # apply the update
w_check = torch.tensor([0.1, 0.4], dtype=torch.float64, requires_grad=True) # arbitrary point
loss_check = nn.functional.binary_cross_entropy_with_logits(Xb @ w_check, yb) # loss there
loss_check.backward()                                 # autograd gradient
assert np.allclose(grad_torch, grad_np_b, atol=1e-10), "autograd and analytic gradients disagree"
```

实测：两种路线得到完全相同的系数 $(0.1627, 1.1709)$，梯度差 2.8e-17；`BCEWithLogitsLoss` 内部已做 log-sum-exp，所以数值稳定。完整程序 `l6_06_logistic_torch.py`。

优化器家族与早停 Optimisers and Early Stopping

优化器	更新规则（直觉）	适用情形
SGD	沿当前梯度走一步	简单、稳，但慢
Momentum	累积"惯性"，抑制震荡	病态曲面、方向反复
Adam	按参数自适应步长	默认首选，对尺度不敏感

超参数

学习率 learning rate、批量大小 batch size、权重衰减 weight decay——都是超参数 hyper-parameter，需用验证集选。

早停

早停 early stopping：验证损失不再下降就停。它本身是一种隐式正则化（帧 75）。

来源：优化器家族与早停据深度学习实践；术语为本讲统一。

标准化与收敛速度 Standardisation

问题

特征量纲差异大时（年龄以年计、收入以万元计），交叉熵的等高线被拉成细长椭圆，梯度下降会在窄方向上来回震荡。

对策

先做标准化 standardisation：

$$x_j \leftarrow \frac{x_j - \bar{x}_j}{s_j}.$$

好处：(1) 收敛更快；(2) 正则化更公平；(3) 系数可比。

两个坑：(1) 统计量 $\bar{x}, s$ 只能来自训练集，否则泄漏；(2) 截距不标准化，正则化时也通常不惩罚截距。

来源：标准化的作用与两个坑据机器学习实践；与 L5 的泄漏清单一致。

多分类：softmax 回归 Softmax Regression

从 sigmoid 到 softmax

对 K 类，每类有自己的权重 w_k，输出

$$P(y=k \mid x)=\frac{e^{w_k^\top x}}{\sum_{j=1}^{K} e^{w_j^\top x}}.$$

分母保证 $\sum_k P=1$；$K=2$ 时退化为 sigmoid。

损失与梯度

多类交叉熵：

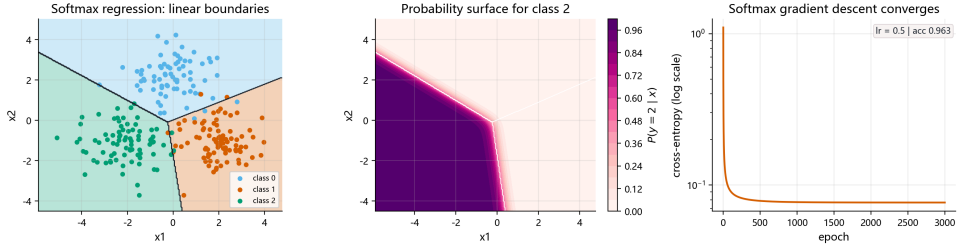
$$\hat{L}=-\frac{1}{n}\sum_i \log P(y_i \mid x_i),$$

梯度形式仍然是 $X^\top(P-Y)/n$（P 为概率矩阵，Y 为 one-hot）。

工程注意：实现时用 log-sum-exp（帧 48）算分母，否则大 logits 会溢出；参数化时可省掉一个冗余参数。

来源：softmax 回归据 Bishop 与统计学习教材；数值注意为本讲补充。

【样本 + 可视化】softmax 的决策区域与概率面



三类二维样本（$n = 240$）：左：线性决策边界把平面分成三块；中：类别 2 的概率面，边界处约 0.5；右：梯度下降的损失曲线。**sklearn 与手写实现准确率 0.963 vs 0.967**，差别只来自正则与收敛精度。

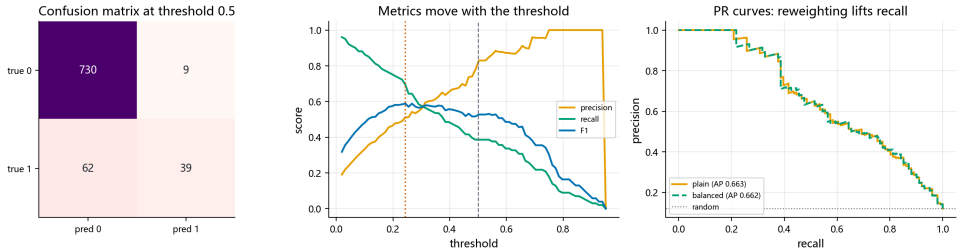
程序 `16_07_softmax_regression.py` ·样本 `16_three_class.csv` ·轨迹 `16_softmax_history.csv`

【代码】softmax 的手写实现与 sklearn 对照

```python
def softmax_matrix(Z):                          # row-wise stable softmax
    Z = np.asarray(Z, dtype=float)              # work with a float array
    Z = Z - Z.max(axis=1, keepdims=True)        # remove the overflow risk
    E = np.exp(Z)                               # safe exponentials
    return E / E.sum(axis=1, keepdims=True)     # normalise every row
def softmax_loss_grad(W, Xm, Y_oh):             # cross-entropy and gradient
    P = softmax_matrix(Xm @ W)                  # class probabilities for every row
    eps = 1e-12                                 # avoid log(0)
    loss = -np.mean(np.sum(Y_oh * np.log(P + eps), axis=1)) # mean cross-entropy over the rows
    grad = Xm.T @ (P - Y_oh) / len(Xm)          # gradient with respect to W
    return float(loss), grad                    # return both
W = np.zeros((Xa.shape[1], 3))                  # weight matrix (parameters per class)
for _ in range(epochs):                         # full-batch gradient descent
    loss, grad = softmax_loss_grad(W, Xa, Y_oh) # evaluate loss and gradient
    W = W - lr * grad                           # gradient step
sk = LogisticRegression(multi_class="multinomial", max_iter=2000) # multinomial = softmax regression
```

要点：梯度与二分类同构——$X^\top(P-Y)/n$，只是 P, Y 变成矩阵。`multi_class="multinomial"` 才是真正的 softmax；默认的 `ovr` 是"一对多"。完整程序 `16_07_softmax_regression.py`。

【样本 + 可视化】类别不平衡与重加权 Class Imbalance



一个 8% 正例的样本 ($n = 2400$)：左：阈值 0.5 时的混淆矩阵——大量漏判藏在右下角；中：阈值一动，精确率/召回率/F1 全变（最优 F1 在 0.27 附近）；右：`class_weight="balanced"` 明显抬高 PR 曲线。

程序 `l6_09_metrics_roc.py` ·样本 `l6_imbalanced.csv` ·阈值表 `l6_threshold_metrics.csv`

阈值选择与代价敏感 Thresholds and Costs

阈值不是 0.5

0.5 只是"概率到标签"的默认切点。业务上应根据两类错误的代价来选：

$$t^* = \arg\min_t \big[\text{成本}(t)\big],$$

成本 $= \text{FN} \times C_{FN} + \text{FP} \times C_{FP}$。

两类错误

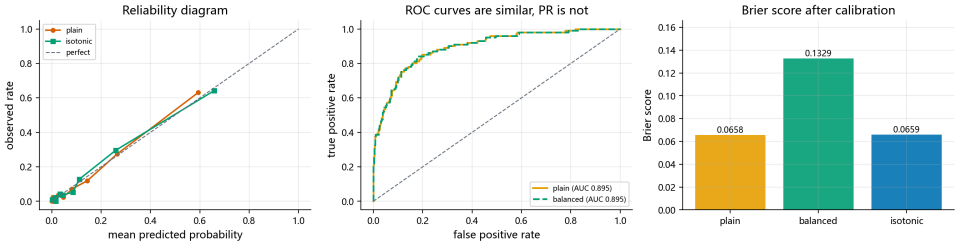
- 第一类错误 Type I error（误报 FP）：把好事判成坏事；
- 第二类错误 Type II error（漏判 FN）：把坏事放过。

降低一类通常抬高另一类——所以必须按业务定价。

项目里的写法：先给出 C_{FN} 与 C_{FP} 的依据（监管罚金、客诉成本、人工复核成本），再报告最优阈值与该阈值下的混淆矩阵。

来源：阈值与代价敏感据业务建模实践；衔接 L5 的评估协议。

【样本 + 可视化】概率校准与 ROC/PR Calibration



左：可靠性曲线——未校准的模型在低概率区系统性偏高，等渗回归 isotonic regression 后贴近对角线；中：ROC 曲线两条几乎重合（AUC 0.870 vs 0.871），但 PR 曲线差别明显；右：布里尔分数 Brier score 从 0.0659 降到 0.0649。

程序 `16_09_metrics_roc.py` ·汇总表 `16_metrics_summary.csv`

小结：线性回归与逻辑回归对照 Two Linear Models

维度	线性回归 Linear regression	逻辑回归 Logistic regression
任务	回归（连续 y）	二分类（$y \in \{0, 1\}$）
输出	$w^\top x$	$\sigma(w^\top x)$，概率
损失	平方损失（高斯 MLE）	交叉熵（伯努利 MLE）
解	闭式解 $w = (X^\top X)^{-1} X^\top y$	无闭式解，梯度下降
梯度	$\frac{2}{n} X^\top (Xw - y)$	$\frac{1}{n} X^\top (\sigma(Xw) - y)$
系数解释	一单位变化引起的 y 变化	一单位变化引起的对数几率变化

同一套框架（假设类 + 损失 + 优化），换一个" 输出变换 + 损失" 就得到新模型。下一部分给这个框架加上复杂度控制——正则化。

来源：对照表为本讲整理；术语与公式均在前文推导过。

从二分类到”多选一”：离散选择模型 Discrete Choice

逻辑回归是它的最小版本

逻辑回归处理两个选项（买 / 不买）。现实中消费者面对的是多个品牌 + 一个" 都不买"：这就是离散选择模型（discrete choice model）。

三个要素

(1) 选择集（choice set）$J+1$ 个选项；(2) 效用（utility）u_{ij}；(3) 选择规则：选效用最大的那个。

为什么营销与产业组织都爱用它：它把" 市场份额" 变成了" 概率"，于是" 价格变动 1% 份额会怎样" 变成一个可以算的式子——这正是需求分析、定价与并购评估的地基。

来源：框架据 McFadden (1974) 与 Train (2009)；表述为本讲组织。

随机效用模型：为什么 logit 有闭式解 Random Utility

设定

消费者 i 从选项 j 得到

$$u_{ij} = \underbrace{\delta_j}_{\text{平均效用}} + \varepsilon_{ij}, \qquad \delta_j = x_j'\beta + \alpha p_j + \xi_j,$$

α 是价格的边际效用（通常为负），ξ_j 是研究者看不到的质量。

关键一步

若 ε_{ij} 独立同分布、服从极值分布（Gumbel），则选择概率有闭式解：

$$s_j = \frac{e^{\delta_j}}{1 + \sum_{k=1}^{J} e^{\delta_k}}.$$

这就是" 为什么偏偏是 logit"：不是随便挑的，而是 Gumbel 误差下概率的解析解。换成正态误差就得到 probit——没有闭式解，只能数值积分。本讲 Part 3 讲的"l_2 = 高斯 + MLE" 是同一个套路：分布假设决定损失/公式。

来源：随机效用与 Gumbel 误差据 McFadden (1974)；与 probit 的对照为本讲补充。

市场份额 = 概率：一个可估的方程 Market Share as Probability

从概率到数据

把 s_j 解释成市场份额，再取对数：

$$\ln s_j - \ln s_0 = \delta_j = x_j'\beta + \alpha p_j + \xi_j,$$

s_0 是外部选项（outside good）的份额。右边是线性的——可以直接回归。

外部选项为什么必须有

没有 s_0，所有品牌同时涨价时" 总需求" 不变。加一个" 都不买" 的选项，才允许市场规模变化——这也是它与普通多分类 softmax 的实质区别。

于是估计变成一个三步动作：算 $\ln s_j - \ln s_0$ → 回归 → 得到 β, α。本讲的并购模拟样本页用 300 个市场、4 个品牌把这条链走通，并当场暴露下一个问题：价格是内生的。

来源：对数份额方程据 Berry (1994)；外部选项的讨论据 Train (2009)。

价格弹性：从系数直接算出来 Elasticities

自身弹性（own elasticity）

$$\varepsilon_{jj} = \frac{\partial \ln s_j}{\partial \ln p_j} = \alpha\, p_j (1 - s_j).$$

份额 s_j 越大，自身弹性越小（大品牌" 抗涨"）。

交叉弹性（cross elasticity）

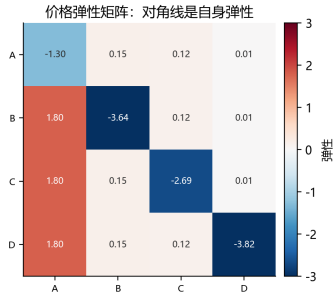
$$\varepsilon_{jk} = \frac{\partial \ln s_j}{\partial \ln p_k} = -\alpha\, p_k\, s_k \qquad (j \neq k).$$

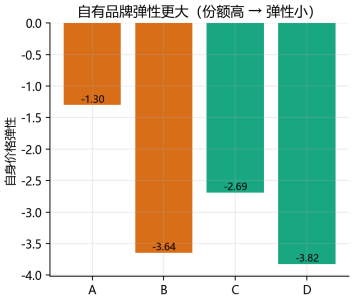
注意它只依赖 k 的份额，与 j 无关——这正是 IIA（无关选项独立性）的数学表现。

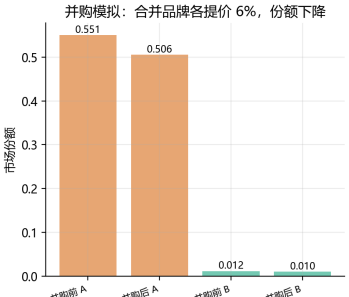
两个直接用途：定价（涨 1% 销量掉多少）与并购评估（合并后提价，份额会流向谁）。但注意 IIA 的副作用：" 红公交" 降价会等比例抢走" 蓝公交" 和" 地铁" 的份额——这与直觉不符，所以才有下一帧的批评。

来源：弹性公式据 logit 需求的标准推导（如 Berry, Levinsohn & Pakes 1995）；IIA 讨论据 Train (2009)。

【样本】弹性矩阵、IIA 与并购模拟 Elasticities in Numbers







左：4 个品牌的价格弹性矩阵（对角线是自身弹性，-1.30 到 -3.82）；中：份额越大自身弹性越小（A 占 55% 份额 → 只 -1.30）；右：A、B 合并后各提价 6%，A 份额 $0.550 \to 0.506$、B $0.012 \to 0.010$，外部选项 $0.368 \to 0.407$。主导品牌的涨价，流失的 82% 去了" 不买"——这就是现实里的份额流失。

程序 `l6_14_discrete_choice.py`（300 个市场 × 4 品牌，种子 20261113）·弹性矩阵 `l6_elasticity_matrix.csv`

价格是内生的：为什么必须用工具变量 Price Endogeneity

问题

厂商看到 ξ_j（我们看不到的质量）才定价：p_j 与 ξ_j 正相关。回归 $\ln s_j - \ln s_0$ 对 p_j，会把" 质量效应" 算成" 价格效应"——系数被拉向 0。

本讲实测

真值 $\alpha = -2.00$；
OLS：-1.319（明显低估）；
2SLS：-2.150（接近真值）；
第一阶段 $F = 959.9$（工具很强）。

工具变量从哪来：成本转移（cost shifter）——原材料价格、汇率、关税、物流成本。它们影响价格，但不直接进入消费者效用（排他性）。注意：这个 OLS 偏误方向和普通回归" 遗漏变量" 一样，只是这里偏得更狠——因为价格与质量在同一个 δ 里。

来源：识别策略与 BLP 的工具变量思想据 Berry, Levinsohn & Pakes (1995)；数字来自本讲程序。

IIA：logit 最著名的缺陷 The IIA Problem

红蓝公交悖论

原来只有开车与红公交，份额各 50%。现在加一条一模一样的蓝公交。logit 会说：红公交份额掉到 1/3、蓝公交 1/3——各抢一半。现实是：蓝公交几乎只抢红公交，开车基本不变。

数学根源

$$\frac{s_j}{s_k} = \frac{e^{\delta_j}}{e^{\delta_k}}$$

两个选项的相对几率与第三个选项无关。加入任何新选项，对所有既有选项的比例影响相同。

IIA 的后果很实在：用它做并购模拟会高估" 抢外部"、低估" 抢对手"；用它做品类规划会把" 相似产品" 当成" 独立产品"。三种修补：嵌套 logit（按相似度分组）、混合 logit（随机系数）、probit（相关误差）。

来源：红蓝公交例据 Debreu (1960) 与 Train (2009)；三种修补据 McFadden (1978)、Berry et al. (1995)。

嵌套 logit：先选组，再选品牌 Nested Logit

结构

把选项分成 G 个巢（nest，如" 可乐 vs 气泡水"）。先在组间选，再在组内选：

$$s_j = s_{j|g} \cdot s_g.$$

组内仍然是 logit，但组间带一个相关系数 λ_g。

λ 读法

$\lambda = 1 \to$ 退回普通 logit（组内组外一样）；$\lambda \to 0 \to$ 组内替代极强（" 同组才互相抢"）。所以 λ 就是" 相似度" 的参数。

代价：分组要人来定，而分组不同结论就不同。所以实务上常把嵌套 logit 与混合 logit 比较，再做一个" 分组稳健性" 检验——这和第 12 讲的敏感性分析是同一个思路。

来源：嵌套 logit 据 McFadden (1978)；λ 的解读与稳健性建议为本讲补充。

混合 logit 与 BLP：让系数因人而异 Random Coefficients

混合 logit（mixed logit）

让系数随消费者变化：

$$\alpha_i = \alpha + \sigma_\alpha \nu_i, \qquad \nu_i \sim N(0,1),$$

$$s_j = \int \frac{e^{\delta_j + \alpha_i p_j}}{\sum_k e^{\delta_k + \alpha_i p_k}} f(\nu)\, d\nu.$$

没有闭式解，要模拟积分。

BLP 的三步

(1) 给定参数，反解 δ 使预测份额 = 观测份额（收缩映射）；(2) 用工具变量做 GMM 让 ξ 与工具正交；(3) 外层搜索非线性参数 (σ)。

BLP（1995）之所以是里程碑：它让" 只有市场份额数据"也能估出 因人而异的价格敏感度，从而算出更真实的替代模式与并购效应。代价：计算量大、对工具与数值细节敏感——这就是" 实证产业组织" 这门手艺。

来源：混合 logit 据 McFadden & Train (2000)；BLP 算法据 Berry, Levinsohn & Pakes (1995)。

实证产业组织：从需求到政策 Empirical IO in Four Steps

步骤	做什么	关键假设	产出
1 需求	估计 α, β（logit / BLP）	随机效用 + 工具外生	弹性矩阵、替代模式
2 供给	假设伯特兰竞争（Bertrand）	厂商按利润最大化定价	边际成本 $c_j = p_j + \frac{s_j}{\partial s_j / \partial p_j}$
3 并购	合并后内部化两家利润	成本不变、无进入	新价格、新份额、涨价幅度
4 福利	消费者剩余变化	效用可货币化	ΔCS、转移支付

两个必会概念：转移率（diversion ratio）$D_{jk} = \frac{\partial s_k / \partial p_j}{\partial s_j / \partial p_j}$——"从 j 流失的顾客有多少去了 k"；向上定价压力（UPP）——并购审查里的第一道筛查。本讲的并购模拟样本页就是第 3 步的最小版本。

来源：四步框架与伯特兰加成定价据 Berry et al. (1995)、Nevo (2001)；UPP 据 Farrell & Shapiro (2010)。

需求分析的三种数据与识别来源 Three Data Sources

数据	典型来源	识别靠什么	局限
市场份额面板	零售扫描、平台后台	成本转移 + 跨市场价差	看不到个人，只能靠模型
消费者面板	会员卡、App 日志	个体选择 + 换购记录	覆盖偏差、样本小
实验 / A-B	平台实验、优惠券	随机化价格	只能测短期、单品类

选哪个

要定价 → 份额面板 + 工具变量（能算弹性）；要个性化 → 消费者面板（能算异质性）；要因果 → 实验（但外推要小心，见第 12 讲）。

常见错误

用销量代替份额（市场规模变了就废）；漏掉外部选项（弹性系统性偏小）；把促销价当常态价（估计的是短期弹性）。

来源：数据来源与识别策略据实证 IO 实践（Nevo 2001；Einav & Levin 2010）；错误清单为本讲整理。

小结：从 logistic 到实证 IO 的一条线 One Line of Thought

模型	选择集	误差结构	什么时候用
逻辑回归	2（买/不买）	独立	点击、违约、转化
多项 logit	$J+1$	独立 Gumbel	品牌选择、渠道选择
嵌套 logit	分组	组内相关	品类内替代更强
混合 logit / BLP	$J+1$	随机系数	并购、定价、政策
probit	$J+1$	正态、可相关	需要灵活替代时

一句话：离散选择模型 = 把" 份额" 写成" 概率"，再用工具变量救回因果。它把本讲前面学的 logit、MLE、工具变量、正则化 全部串了起来——到了第 12 讲，你会发现" 识别" 这个问题在需求估计里又出现了一次。

来源：对照表为本讲整理；与第 12 讲因果推断的衔接为课程设计。

为什么需要正则化 Why Regularise

三个症状

- 特征数 P 接近或超过样本数 N：$X^\top X$ 不可逆；
- 系数很大、符号反复：对数据极敏感；
- 训练误差很低，验证误差很高：过拟合 overfitting。

思路

给模型加一个复杂度预算 complexity budget：不允许系数自由变大。预算越紧，模型越"简单"，方差越小、偏差越大（帧 83）。

正则化不是"补救措施"，而是建模的一部分：它把你的先验（"系数不该太大"）写成数学。这也是它和特征选择、早停能互相替代的原因。

来源：正则化的动机据统计学习教材；复杂度预算的比喻为本讲补充。

惩罚回归：目标函数 Penalised Regression

形式

在损失后加一个惩罚项 penalty：

$$\min_{w} \underbrace{\frac{1}{n}\sum_{i}(y_i - w^\top x_i)^2}_{\text{残差平方和}} + \underbrace{\lambda\,\Omega(w)}_{\text{惩罚项}}.$$

$\lambda \geq 0$ 是超参数 hyper-parameter，控制" 拟合" 与" 简单" 的权衡。

三种常见的 Ω

- $\|w\|_1 = \sum_j |w_j|$：LASSO （帧 77）；
- $\|w\|_2^2 = \sum_j w_j^2$：Ridge （帧 78）；
- 两者混合：Elastic Net （帧 79）。

注意：惩罚项通常不含截距；$\lambda = 0$ 时退回普通最小二乘。

关键术语

惩罚回归 penalised regression、收缩 shrinkage、稀疏 sparsity。

来源：惩罚回归的表述(统计学习教材 ESL 第 3 章)。

LASSO：L1 惩罚与稀疏解 LASSO

形式

$$\min_{w} \frac{1}{n}\sum_{i}(y_i - w^\top x_i)^2 + \lambda \sum_{j}|w_j|.$$

三条性质

- λ 增大时，部分系数恰好变成 0；
- 因此自动完成特征选择 feature selection；
- 解是稀疏的 sparse solution——只留少数变量。

直觉（几何）

L1 的等高线是菱形，相切点常在顶点上——那里某些坐标恰为 0。

原书的比喻

"Capitalist"——in doubt, give all to one. （面对相关特征，L1 倾向于只留一个。）

业务价值：LASSO 给出的变量清单本身就是结论——" 这 3 个因素比那 20 个更重要" 是报告里常见的一句话。

来源：LASSO 由 Tibshirani (1996) 提出；几何与比喻据 ESL 与课程讲义。

Ridge：L2 惩罚与收缩 Ridge Regression

形式

$$\min_{w} \frac{1}{n}\sum_{i}(y_i - w^\top x_i)^2 + \lambda \sum_{j} w_j^2.$$

它有闭式解：$w = (X^\top X + \lambda I)^{-1} X^\top y$——$\lambda I$ 让矩阵可逆，绕开了共线性问题。

性质

- 系数向零收缩 shrinkage，但不会恰好为零；
- 对共线特征" 平均分配" 权重——"Socialist"（in doubt, distribute to multiple）；
- 可解释为高斯先验下的贝叶斯后验。

实测对照（本讲前列腺样本 + 6 个噪声列，14 个特征）：Ridge 保留 14 个、Lasso 保留 13 个；测试 RMSE：Ridge 0.724、Lasso 0.705、Elastic Net 0.712。

来源：Ridge 的闭式解与贝叶斯解释统计学习教材；实测数据来自程序 l6_08。

Elastic Net：两者的混合 Elastic Net

形式

$$\min_{w} \frac{1}{n}\sum_{i}(y_i - w^\top x_i)^2 + \lambda\Big(\alpha\sum_{j}|w_j| + (1-\alpha)\sum_{j} w_j^2\Big).$$

$\alpha \in [0,1]$ 控制 L1 与 L2 的比例。

什么时候用

- 特征成组高度相关：L1 会随机留一个，Elastic Net 会成组保留；
- 特征数远大于样本数（$P \gg N$）；
- 既想要稀疏、又想要稳定。

超参数变成两个（λ 与 α），所以需要的验证数据更多。实践建议：先固定 $\alpha = 0.5$ 调 λ，再网格搜两个。

来源：Elastic Net 由 Zou & Hastie (2005) 提出；实践建议为本讲补充。

商业案例（一）：13 个渠道，只有 4 个真有效 A Media-Mix Case

场景

500 个门店-月样本，13 个投放与运营变量（电视、社交、搜索、户外、优惠券、邮件、联盟、达人、电商平台……）。目标：预测月销售额，并回答" 哪个渠道真的有用"。

问题：共线

所有渠道都跟着门店流量走：$\mathrm{corr}(\text{流量}, \text{电视}) = 0.939$、$\mathrm{corr}(\text{电视}, \text{社交}) = 0.872$。结果：OLS 的系数在重采样下平均波动 1.32，符号甚至会翻——" 哪个渠道有效" 根本读不出来。

方法	测试 RMSE	选中变量数	系数波动（重采样）	该怎么用
OLS	9.770	13	1.319	只做基线，别解读系数
Ridge	9.736	13	0.956	预测优先、要稳的系数
Lasso	9.632	6	0.956	要" 选出渠道" 就用它

注意 Lasso 选出的 6 个 里，真有效的只有 4 个——它不保证" 选对"，但保证把 13 个问题收敛成 6 个可讨论的问题。

来源：程序 `ab_13_ridge_business.py`；数据为本讲合成（种子 20261106）。

商业案例（二）：四种场景与选型 Four Business Settings

场景	共线从哪来	该用哪种	为什么
门店销售额（广告组合）	各渠道都跟流量走	LASSO	要挑出少数有效渠道
房价/租金定价	面积、房间数、房龄	Ridge	变量都该留，只求稳
信贷额度定价	收入、负债、征信分	Ridge + 约束	系数要可解释、要平稳
用户生命周期价值	消费频次、客单价、活跃度	Elastic Net	相关变量成组出现

怎么选 λ

交叉验证选误差最小点；再遵循 1-SE 规则：在"一个标准误之内"选最简的模型（帧 81）。

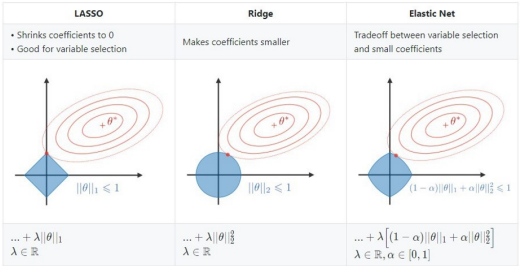
一句话判据

你要的是"预测准"还是"说清哪个变量有用"？前者偏 Ridge，后者偏 Lasso。

还有一条常被忽略：正则化不能救"变量选错"。如果真正的影响因素根本没进模型，压系数只会让你更自信地错。

来源：场景与选型为本讲整理；1-SE 规则据 Hastie et al. (2009)。

【样本】正则化的两张常见示意图 Two Pictures of Regularisation



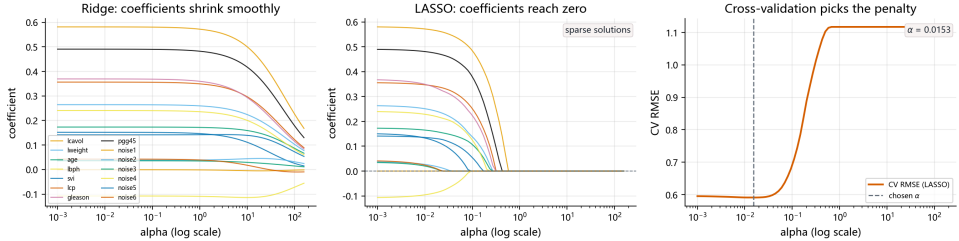
这两张图在说什么

左图：损失等高线与约束区域（菱形 = L1，圆形 = L2）相切的位置，就是带约束的最优解；右图：系数随 λ 收缩的路径。

关键在几何上：L1 的菱形有尖角，等高线最容易碰到角上——而角上意味着某些系数恰好为 0，这就是 LASSO 稀疏性的来源。L2 的圆没有角，所以只能整体压小、不归零。

课堂素材图；几何解释据 Tibshirani (1996) 与 Hastie et al. (2009)。

【样本 + 可视化】正则化路径与交叉验证选 λ



左：Ridge 的系数平滑收缩（8 个真实特征 + 6 个噪声列）；中：LASSO 的系数逐个归零，噪声列最先消失；右：交叉验证误差随 λ 变化，虚线是选中的 λ（本样本 0.0178）。

程序 `l6_08_regularization_cv.py` ·样本 `l6_prostate.csv` ·对照表 `l6_regularization_scores.csv`

【代码】LASSO / Ridge / Elastic Net 的交叉验证

```python
from sklearn.linear_model import (RidgeCV, LassoCV, ElasticNetCV, # CV-fitted penalties
                                  Ridge, Lasso)                   # single-strength penalties for the paths
alphas = np.logspace(-3, 2.2, 80)                                 # penalty grid
cv = KFold(n_splits=8, shuffle=True, random_state=42) # eight folds for a stable CV curve
models = {"Ridge": RidgeCV(alphas=alphas, cv=cv),     # L2 penalty
          "Lasso": LassoCV(alphas=alphas, cv=cv, max_iter=50000, random_state=42), # L1 penalty
          "ElasticNet": ElasticNetCV(alphas=alphas, l1_ratio=[0.2, 0.5, 0.8], cv=cv, # mixed penalty
                                     max_iter=50000, random_state=42)} # generous solver budget
for name, model in models.items():                                # loop over the three penalties
    pipe = Pipeline([("scale", StandardScaler()), ("model", model)]) # scaling inside the pipeline
    pipe.fit(X_train, y_train)                                    # fit on the training split
    pred = pipe.predict(X_test)                                   # predictions on the hold-out split
    mdl = pipe.named_steps["model"]                               # the fitted penalty object
    coefs = mdl.coef_ if mdl.coef_.ndim == 1 else mdl.coef_[0] # coefficients (flatten for ElasticNet)
    nonzero = int(np.sum(np.abs(coefs) > 1e-8))                   # count surviving features
```

要点：标准化必须在 Pipeline 里，否则测试集的统计量会泄漏到训练；交叉验证在训练集内部完成，测试集只在最后用一次。完整程序 `l6_08_regularization_cv.py`。

如何选 λ：交叉验证与 1-SE 规则 Choosing the Strength

交叉验证

在训练集内部切 K 折，轮流留一折验证，取平均误差最小的 λ。**测试集不能参与选 λ**——否则样本外误差会被乐观高估。

1-SE 规则

选误差在一个标准误之内的最简单（λ 最大）的模型：宁可简单一点，换取稳定性。

做法	后果
在测试集上选 λ	乐观偏差，上线后骤降（L5 帧 42 的清单）
用交叉验证 + 1-SE	稳健，报告里可解释
固定 λ 不解释	审稿人会问" 为什么是这个数"

来源：交叉验证与 1-SE 规则据 ESL；偏差说明衔接 L5。

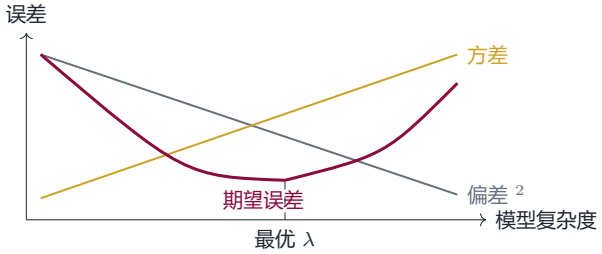
正则化与偏差-方差 Regularisation as Bias for Variance

一句话

正则化主动引入偏差，换取方差的下降。只要方差下降得多，总误差就下降。

什么时候不划算

当真实关系很强、样本很足时，惩罚会压掉真实信号，造成欠拟合——这就是 λ 不能太大的原因。



来源：偏差-方差权衡据 ESL；本图为本讲自绘。

偏差-方差分解 The Bias-Variance Decomposition

分解式

对平方损失，期望预测误差可写成三项：

$$\mathbb{E}\left[(y-\hat{f}(x))^2\right] = \underbrace{\left(\mathbb{E}\hat{f}(x)-f(x)\right)^2}_{\text{偏差}^2\ \mathrm{Bias}^2} + \underbrace{\mathbb{E}\left[\hat{f}(x)-\mathbb{E}\hat{f}(x)\right]^2}_{\text{方差 Var}} + \underbrace{\sigma^2}_{\text{噪声}}.$$

读法

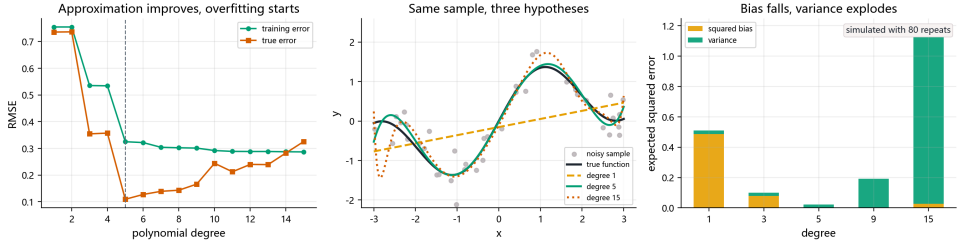
- 噪声 σ^2：不可约，任何模型都消不掉；
- 偏差：模型太简单造成的系统偏离；
- 方差：换一份样本就变很多。

与正则化的关系

正则化压方差、抬偏差；数据集变大主要压方差；更复杂的假设类压偏差、抬方差。

来源：分解式据 ESL 第 7 章，读法为本讲整理。

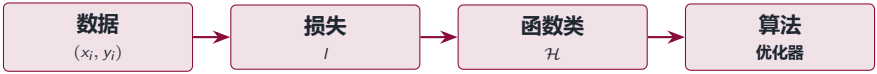
【样本 + 可视化】近似—过拟合权衡 Approximate or Overfit



左：多项式次数上升，训练误差单调下降，真实误差先降后升（最优在 5 次）；中：同一份样本的三种拟合（1 次欠拟合、5 次合适、15 次过拟合）；右：用 80 次重复模拟得到的偏差 ^{2} 与方差分解——9 次时方差从 0.019 跳到 0.822。

程序 `l6_11_overfit_curves.py` ·样本 `l6_poly_sample.csv` ·分解表 `l6_bias_variance.csv`

预测问题的统一框架 The Prediction Problem



四要素

四样都定了，模型就定了：**数据、损失、函数类、算法。**

术语

经验风险最小化 ERM；正则化 regularisation 是对函数类的额外约束。

为什么有用

任何"新模型"都可以用这四个格子定位——它改的是哪一格？

来源：四要素框架据 ESL 与课程讲义；"改哪一格"的提法为本讲补充。

【术语】计量经济学的说法 vs 机器学习的说法

计量经济学 Econometrics	机器学习 Machine Learning	说明
因变量 dependent variable	标签 label / 目标 target	要预测的量 y
自变量 independent variable	特征 feature / 协变量 covariate	输入 x
估计 estimate	训练 train / 拟合 fit	从数据求参数
预测 predict	推断 infer（预测时）	对新样本输出
标准误 standard error	验证误差 validation error	不确定性的度量
系数 coefficient	权重 weight	参数 w_j
拟合优度 goodness of fit	样本外 R^2 out-of-sample R^2	拟合 vs 泛化

同一件事两种语言。写项目报告时选定一套并全篇统一，并在附录里给出这张对照表——评审老师可能来自任一传统。

来源：对照表据 Mullainathan & Spiess (2017, JEP) 与 Athey (2017)；说明为本讲补充。

回归的平方误差损失 Squared-Error Loss in Practice

两个经典应用

- 房价预测：$y = \log(\text{房价})$，特征为面积、房龄、地段；
- 消费预测：$y = \log(\text{消费})$，特征为收入、家庭规模。

两者都用 l_2 损失，并报告RMSE 与 R^2。

为什么常取对数

- 右偏分布被拉回近似对称；
- 系数可解释为百分比变化（弹性）；
- 误差更接近同方差。

注意：取对数后，$\hat{y}$ 在对数尺度上无偏，但在原尺度上是有偏的（Jensen 不等式）——报告里要么说清尺度，要么做校正。

来源：案例据 Mullainathan & Spiess (2017, JEP)；对数尺度的偏差为本讲补充。

【代码】混淆矩阵、阈值扫描与 ROC/PR

```python
from sklearn.metrics import (confusion_matrix, roc_curve, auc, # evaluation metrics
                        precision_recall_curve, average_precision_score,
                        precision_score, recall_score, f1_score,
                        brier_score_loss, accuracy_score)
thresholds = np.linspace(0.02, 0.95, 80)              # threshold grid
for t in thresholds:                                  # sweep the grid
    pred = (proba >= t).astype(int)                   # hard labels
    rows.append({"threshold": round(float(t), 3),     # threshold value
                 "precision": round(float(precision_score(y_test, pred, zero_division=0)), 4), # precision
                 "recall": round(float(recall_score(y_test, pred, zero_division=0)), 4), # recall
                 "f1": round(float(f1_score(y_test, pred, zero_division=0)), 4)}) # F1
weighted = Pipeline([("scale", StandardScaler()),     # same preprocessing
                     ("model", LogisticRegression(max_iter=2000, class_weight="balanced"))]) # reweighted loss
prec_w, rec_w, _ = precision_recall_curve(y_test, proba_w) # PR curve for the reweighted model
fpr_u, tpr_u, _ = roc_curve(y_test, proba)            # ROC curve for the plain model
calibrated = CalibratedClassifierCV(                  # isotonic calibration with internal CV
    Pipeline([("scale", StandardScaler()), ("model", LogisticRegression(max_iter=2000))]), # base model
    method="isotonic", cv=5)                          # isotonic regression
```

实测：AUC 0.870、AP 0.601、Brier 0.0659；重加权后 AP 略降但召回显著提高，等渗校准把 Brier 降到 0.0649。完整程序 `16_09_metrics_roc.py`。

监督学习者的结构 Structure of a Supervised Learner



函数类	正则项	优化算法
线性、多项式、树、神经网络——决定能表达什么。	L1/L2、早停、dropout——决定有多保守。	闭式解、梯度下降、坐标下降——决定多快找到解。

这张图是本讲的收束：任何监督学习算法都可以填进这三格。L7 的树与集成、L9 的神经网络，都是在这三格上做文章。

来源：三要素结构据课程讲义（第 80 页）；解读为本讲补充。

线性模型家族全景 The Linear-Model Family

模型	输出变换	损失	正则化版本
线性回归 OLS	恒等	平方	Ridge / Lasso / Elastic Net
逻辑回归	sigmoid	交叉熵	带 L2 惩罚的 `LogisticRegression`
softmax 回归	softmax	多类交叉熵	同上（多类）
泊松回归	exp	泊松 NLL	带惩罚的 GLM

共同点：都是广义线性模型 generalised linear model——线性得分 + 一个" 连接函数" + 对应分布的 NLL。掌握一个，其余只是换变换与换损失。

来源：GLM 与线性模型家族据统计学习教材；对照表为本讲整理。

小结：本讲一张图 One Picture of Lecture 6



三个”为什么”

- 损失为什么是平方/交叉熵？→ 似然（帧 43、59）
- 系数怎么解释？→ 对数几率与几率比（帧 60）
- 复杂度怎么控？→ 正则化与交叉验证（帧 76–82）

下一部分

工具与术语：什么时候用推断视角（statsmodels）、什么时候用预测视角（sklearn），以及一张79 条的术语表。

来源：本图为本讲内容的压缩；各帧均在前文展开。

术语表 A–D Glossary A–D

中文	English
0-1 损失	0-1 loss
近似误差	approximation error
AUC	area under the ROC curve
增广技巧	augmented trick
自动微分	automatic differentiation
布里尔分数	Brier score
批量	batch
偏差-方差分解	bias-variance decomposition
二分类	binary classification
类别不平衡	class imbalance
条件数	condition number
条件似然	conditional likelihood
置信区间	confidence interval
混淆矩阵	confusion matrix
凸函数	convex function
交叉熵	cross-entropy
交叉验证	cross-validation

术语共 17 条（分组：A–D）；完整表含符号、公式与一句话解释，见 `16_glossary.csv` 与站点讲义页。

术语表 E–M Glossary E–M

中文	English
弹性网	elastic net
经验损失	empirical loss / empirical risk
期望损失	expected loss / risk
特征向量	feature vector
泛化差距	generalization gap
生成式模型	generative model
梯度下降	gradient descent
超参数	hyper-parameter
超平面	hyperplane
假设类	hypothesis class
独立同分布	independent and identically distributed (i.i.d.)
截距	intercept / bias
等渗回归	isotonic regression
KL 散度	Kullback-Leibler divergence
L1 惩罚	L1 penalty / LASSO
L2 惩罚	L2 penalty / Ridge

中文	English
标签	label
学习率	learning rate
似然	likelihood
线性分类器	linear classifier
线性回归	linear regression
对数似然	log-likelihood
对数几率	log-odds
对数求和指数	log-sum-exp
逻辑回归	logistic regression
机器学习	machine learning
间隔	margin
极大似然估计	maximum likelihood estimation (MLE)
均方误差	mean squared error (MSE)
多分类	multi-class classification
多重共线性	multicollinearity

术语共 31 条（分组：E–M）。完整表含符号、公式与一句话解释，见 `16_glossary.csv` 与站点讲义页。

术语表 N–Z Glossary N–Z

中文	English
负对数似然	negative log-likelihood (NLL)
正规方程	normal equation
几率比	odds ratio
过拟合	overfitting
Platt 缩放	Platt scaling
p 值	p-value
惩罚回归	penalized regression
精确率	precision
概率校准	probability calibration
投影	projection
ROC 曲线	ROC curve
召回率	recall / sensitivity
正则化	regularization
表征学习	representation learning
收缩	shrinkage
sigmoid 函数	sigmoid function
softmax	softmax
稀疏解	sparse solution
平方损失	squared loss / l_2 loss
标准误	standard error
阶跃函数	step function
监督学习	supervised learning
第一类错误	Type I error (false positive)
第二类错误	Type II error (false negative)
测试数据	test data
阈值	threshold
训练数据	training data
下溢	underflow
无监督学习	unsupervised learning

术语共 20 条（分组：N–Z）。完整表含符号、公式与一句话解释，见 16_glossary.csv 与站点讲义页。

工具栈与各自的分工 The Tool Stack

工具	擅长	本讲用在哪
NumPy	手写公式、验证推导	正规方程、梯度下降、softmax
scikit-learn	预测、流水线、调参	交叉验证、正则化、指标
statsmodels	推断：标准误、p 值、区间	帧 94 的系数表
PyTorch	自动微分、GPU、深度网络	帧 65 的 autograd 对照

选型口诀：要" 解释" 用 statsmodels，要" 预测" 用 sklearn，要" 验证自己的推导" 用 NumPy，要" 上规模" 用 PyTorch。

来源：工具分工据各库官方文档与本讲实践。

【代码】statsmodels：推断视角 Inference View

```python
import statsmodels.api as sm                          # OLS and Logit with full inference output
X = add_intercept(prostate[cols].values)              # augmented design matrix
y = prostate["lpsa"].values                           # target
ols = sm.OLS(y, X).fit()                              # fitted model with full statistics
ci = ols.conf_int()                                   # 95 per cent confidence intervals
table = pd.DataFrame({"term": names,                  # term name
                      "coef": np.round(ols.params, 4),   # estimated coefficient
                      "std_err": np.round(ols.bse, 4),   # standard error
                      "t_value": np.round(ols.tvalues, 3), # t statistic
                      "p_value": np.round(ols.pvalues, 4), # two-sided p value
                      "ci_low": np.round(ci[:, 0], 4),   # lower bound of the interval
                      "ci_high": np.round(ci[:, 1], 4)}) # upper bound of the interval
logit = sm.Logit(yl, Xl).fit(disp=False)              # maximum likelihood logistic regression
logit_table = pd.DataFrame({"term": ["intercept", "x"], # term names
                        "coef": np.round(logit.params, 4), # log-odds coefficients
                        "odds_ratio": np.round(np.exp(logit.params), 4), # exponentiated coefficients
                        "p_value": np.round(logit.pvalues, 4)}) # p values
print("pseudo R^2 %.4f | log-likelihood %.4f" % (logit.prsquared, logit.llf)) # report the fit
```

实测：OLS 的 R^2 0.767（调整后 0.746，F=36.3）；Logit 的系数 1.171、几率比 3.225、p 值 $<$ 0.0001、伪 R^2 0.181。完整程序 `16_10_statsmodels_inference.py`。

本讲的十个常见错误 Ten Common Mistakes

1. 忘记截距，或把截距一起标准化；
2. 用 $X^\top X$ 求逆而不是 `solve`/`lstsq`；
3. 不标准化就做正则化（惩罚不公平）；
4. 在测试集上选 λ 或调阈值；
5. 把系数当因果效应（帧 60 的对数几率不是因果）；
6. 只看准确率，不看混淆矩阵与 PR；
7. 报告概率却不做校准（帧 73）；
8. 用 0.5 当阈值而不问两类错误的代价；
9. 拿训练误差证明模型好（帧 19、85）；
10. 把"逻辑回归"当成回归预测连续值。

自检：交报告前把这十条过一遍，能省掉大部分"老师一眼看出"的问题。

来源：错误清单为本讲整理，多数来自常见审稿意见。

与后续讲次的衔接 Links to Later Lectures

讲次	与本讲的关系
L7 监督学习算法	支持向量机 = 合页损失 + 间隔；树 = 分段常数函数类
L8 无监督与文本	聚类与降维里的距离、正则化思想
L9 深度学习	多层的线性 +sigmoid 堆叠；autograd 与优化器
L12 因果推断	线性模型当" 调整" 工具；系数何时可作因果解读
L10/L11 营销与 NLP	逻辑回归是 CTR 预估与文本分类的基线

一句话：本讲给的是" 骨架"，后面每一讲都在骨架上加血肉——但换的往往只是" 函数类" 那一格(帧 90)。

来源：衔接关系据课程大纲的章节安排。

本章程序包目录 Package Directory

包	本机版本	本讲用它做什么	出现在哪些程序
`numpy`	2.0.2	数组、正规方程、手写梯度与 log-sum-exp	01–11、14
`pandas`	2.3.3	读数据、面板整理、术语表与结果表	全部
`scipy`	1.13.1	数值优化（MLE 互验）、分布与积分	03
`scikit-learn`	1.6.1	Pipeline、LogisticRegression、LASSO/Ridge、指标与校准	01、05、07、08、09、11、13、14
`statsmodels`	0.14.6	标准误、t/F、置信区间、几率比；OLS 与 2SLS	01、10、14
`matplotlib`	3.9.4	全部静态图（含弹性矩阵热图）	01–14
`torch`	2.8.0+cpu	自动求导，与手写梯度对账	06
`pillow`	9.x	matplotlib 的图片后端	间接

装了但没用到的（可选）

`linearmodels`（面板与 IV 更全）、`pyblp`（BLP 估计）、`biogeme`（离散选择）、`seaborn`（统计图）——本讲用 sklearn/statsmodels 手写替代，便于看清每一步。

怎么装

```
pip install -r website/code/lecture06/requirements.txt
```

版本号是本机实测值；锁定版本能让结果可复现（第 5 讲的交付清单里也有这一条）。

来源：版本号来自本讲运行环境实测；包清单由 `requirements.txt` 与各程序的 `import` 语句汇总。

结语：三句话讲清一个线性模型 Wrap-up

三句话

1. **假设类**：模型在哪些函数里找？（线性、线性 + sigmoid、线性 + softmax）
2. **损失**：为什么是这个损失？（因为它是一个概率假设的负对数似然）
3. **求解与校验**：怎么解？（闭式解或梯度下降）怎么确认没错？（与参考实现对账、看校准与样本外误差）

自检清单

能推出正规方程？能说出 $\sigma' = \sigma(1-\sigma)$ 的用途？能解释几率比 3.22？

下讲预告

L7：支持向量机、树与集成——换的是"函数类"那一格。

谢谢！问题与项目讨论：`Xieer.dai@szu.edu.cn`；本讲全部代码、样本与术语表见课程仓库 `website/code/lecture06/`。

来源：本讲总结为本讲整理；下讲预告据课程大纲。