深圳大学 SHENZHEN UNIVERSITY

课程 COURSE

Big Data Analytics
大数据分析 [2026 国际商务]

Lecture 12 — Causal Inference 第十二讲·因果推断
反事实、识别与估计

任课教师：戴谢尔 (Xieer Dai, David)
深圳大学 Shenzhen University

·第 13, 14 周·星期四·11–12 节
上课地点：四方楼南 309

学分 2 选修课（讲座式）| 答疑：预约制 | E-mail: Xieer.dai@szu.edu.cn

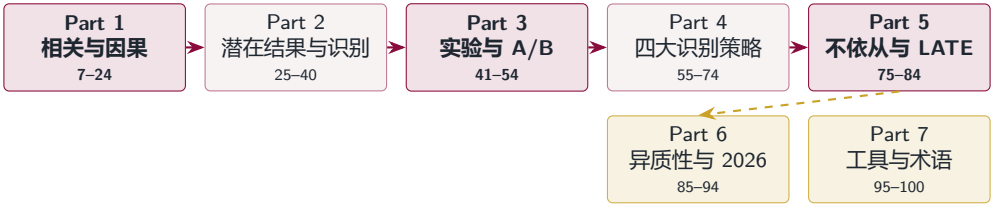
学习目标 Learning Objectives

完成本讲后，你应能够：

1. 说清相关与因果的区别，并识别混杂、中介、对撞点；
2. 写出潜在结果与 ATE / ATT / LATE，说清识别的含义；
3. 判断一个问题该用实验、匹配、DID、IV 还是 RD；
4. 解释完美医生为什么让差值估计失效；
5. 用 DML 与因果森林回答"对谁有效"；
6. 做敏感性分析，并说清结论的边界。

来源：对应课程大纲第 12 讲目标：区分相关与因果；掌握潜在结果框架与主要识别策略；能评估政策或商业干预的真实效果。

本讲路线图 Roadmap（100 帧）



主线：问题 → 反事实 → 识别 → 估计 → 检验

代码页 10 帧•样本页 14 帧；数据全合成，因果图用 TikZ 手画

与全课程的衔接 The Method Backbone

讲次	给了什么	与本讲的关系
L5 / L7	回归与" 相关不等于因果"	本讲把它形式化（帧 11–12）
L13	事件研究的异常收益	潜在结果的一个实例（帧 78）
L14	DID 与事件研究	本讲给出识别框架（帧 60–63）
L15	A/B 与增量测量	本讲给出功效与 CATE（帧 41–49、90）

一句话：前面讲" 怎么估"，这一讲讲" 凭什么能估"。没有识别的估计，只是一个数字。

来源：衔接为本讲组织。

本讲输出物 Deliverables

1) 识别策略清单

实验 / 匹配 / DID / IV / RD 各自的假设与适用条件。

2) 11 个程序

辛普森、潜在结果、功效、PSM、DID、2SLS、RD、LATE、DML、因果森林、术语。

3) 术语表

84 条中英对照（CSV + Word/Excel），按六个主题分组。

所有数字都来自可复现的程序：`website/code/lecture12/`，种子固定 20270301；数据全部合成(2,000 人潜在结果、2×5,000 实验、400 单位面板、3,000 观测的工具变量样本、4,000 单位的断点与 CATE 样本)。

来源：程序与数据随课程仓库发布。

全讲导览 Map of the Lecture

部分	帧	关键问题
相关与因果	7–24	什么时候" 一起变" 不是" 导致"?
潜在结果与识别	25–40	反事实怎么变成可估的量?
随机实验与 A/B	41–54	金标准好在哪、坑在哪?
四大识别策略	55–74	没有实验时，靠什么识别?
不依从与 LATE	75–84	分配 $\neq$ 接受，效应是谁的?
异质性与 2026	85–94	对谁有效? 怎么做得更稳?
工具、术语与结语	95–100	用什么工具? 术语怎么背?

读法：每一节都走一遍反事实 $\rightarrow$ 假设 $\rightarrow$ 估计量 $\rightarrow$ 检验。

来源：导览为本讲安排。

为什么”相关”不够 Why Association Is Not Enough

广告与销量

广告多的月份销量也高——但可能是旺季同时推高了广告预算与销量。

教育与收入

学历高的人收入高——但可能是家庭背景同时影响两者。

医院排名

死亡率高的医院水平差？也许是收治重症更多。

三个例子有同一个结构：存在第三个变量同时影响”原因”与”结果”。这就是混杂，也是本讲要一路拆开的东西。

来源：三个例子的结构据标准因果推断教材（Angrist & Pischke 2009）。

三个因果问题 Three Causal Questions

问题	目标参数	典型问法	决策用途
有没有效	ATE	这个活动整体有用吗	要不要做
对谁有效	CATE	哪类客户最受益	怎么分配
为什么有效	机制 / 中介	通过哪个渠道起作用	怎么优化

本讲的顺序是先 ATE（帧 25–27）、再 LATE（帧 75–80）、最后 CATE（帧 85–92）——口径越窄，要求的数据与假设越多。

来源：三个问题的分类据政策评估与商业实验实践；表述为本讲组织。

反事实：因果的定义 The Counterfactual

一句话定义

" 做" 与" 不做" 两种情形下结果的差，就是这个处理的因果效应。

为什么难

同一个人不可能同时" 做" 和" 不做"——总有一半的世界观测不到（帧 29）。

所以因果推断的全部工作，就是用可观测的东西去替代那个看不到的反事实。不同的识别策略，本质上是不同的替代方案。

来源：反事实框架据 Rubin (1974) 与 Neyman (1923)；表述为本讲组织。

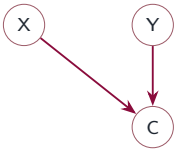
因果图（一）：链、分叉、对撞 Three Structures



链 chain：控制 M 会切断 X→Y 的路



分叉 fork：控制 U 会去掉假关联



对撞 collider：控制 C 会**造出**假关联

记住三条：链要控制、分叉要控制、对撞绝对不能控制。绝大多数因果错误，都是把对撞点当成了混杂。

来源：三种基本结构据 Pearl (2009)。

OLS 与 Gauss-Markov：无偏不等于因果

Gauss-Markov 的条件

误差与解释变量不相关、同方差、均值为零——满足时 OLS 是最优线性无偏估计。

问题

" 处理" 变量往往与误差相关（人自己选择、机构自己决定），于是无偏性不成立，系数不再是因果效应。

本讲实测（帧 65）：同一份数据，OLS 给出 2.38，2SLS 给出 1.45，真值 1.50。OLS 并没有" 算错"，它算的是另一个量。

来源：Gauss-Markov 定理据标准计量教材；实测来自 112_06。

遗漏变量偏差的公式 Omitted Variable Bias

公式

$$\hat{\beta}_{\text{short}} = \beta + \underbrace{\gamma \cdot \delta}_{\text{偏差}},$$

γ 是遗漏变量对 Y 的效应，δ 是它对处理的效应。

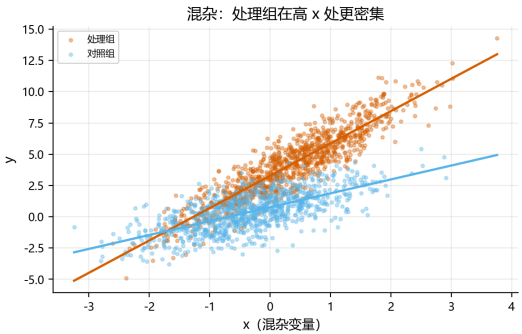
怎么读

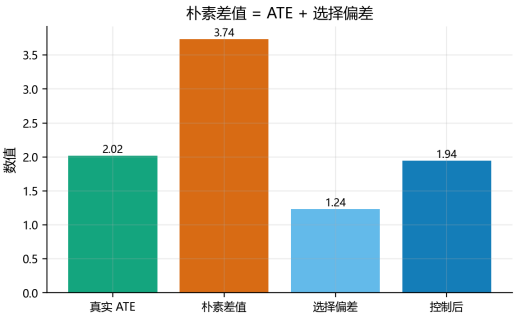
两个符号相同 $\rightarrow$ 高估；符号相反 $\rightarrow$ 低估；只要 γ 或 δ 有一个为 0，偏差就消失。

这个公式是" 用脑子做因果" 的核心工具：你能说出一个同时影响处理与结果的变量，就必须处理它——处理不了，就要在结论里写明" 可能偏哪个方向"。

来源：遗漏变量偏差公式据标准计量教材；解读为本讲强调。

【样本 + 可视化】相关不等于因果





左：处理组集中在高 x（混杂变量）处，两条拟合线并不平行；右：朴素差值 3.83，真 ATE 2.00，其中 1.31 是选择偏差。控制混杂后回到 2.0 附近。

程序 `l12_02_potential.py` ·数据 `l12_potential.csv`（2,000 人）

混杂：定义与识别 Confounding

定义

一个变量同时影响处理与结果，且不在处理 $\rightarrow$ 结果的通路上。用 DAG 说：它有一条指向 Z 的箭头，也有一条指向 Y 的箭头。

怎么找

问自己：" 如果我能随机分配，谁会被分到处理组？" 答案里出现的差异，就是混杂要处理的地方。

三个真实例子：咖啡与健康（吸烟是混杂）、教育与时薪（能力/家庭背景）、医院等级与死亡率（病情严重程度）。

来源：混杂的定义据 Hernán & Robins (2020)；例子为本讲整理。

三个混杂的真实例子 Three Real Examples

研究问题	处理	混杂	结论会怎么偏
咖啡与心脏病	每天喝咖啡	吸烟	高估危害
教育与时薪	受教育年限	家庭背景/能力	高估回报
医院等级与死亡率	三甲 vs 二甲	病情严重程度	高估三甲优势或反向

注意第三个例子的方向：重症病人更可能被送到三甲，所以三甲的死亡率反而可能更高——这就是" 看起来更差、其实更强"。

来源：三个例子据流行病学与教育经济学文献；方向解读为本讲补充。

COVID-19：同一批数据的不同解释

口罩	封控	疫苗
戴口罩的人感染率低——但谨慎的人既戴口罩也少聚集。	封控地区病例少——但封控本来就是因为病例多才启动的（反向因果）。	接种者重症少——但高龄/基础病者接种率不同（混杂）。

三个例子里，混杂、反向因果、选择各出现一次。这也是为什么这一讲要区分" 三种偏差"，而不是笼统说" 内生"。

来源：COVID 期间的因果推断讨论据公开文献与政策评估实践；整理为本讲。

因果图（二）：后门准则 Back-door Criterion

规则

找一组变量 X，使得：

1. 切断所有从 Z 到 Y 的后门路径；
2. 不包含 Z 的后代（尤其是中介与对撞）。

满足后就能

$P(Y \mid do(Z=z)) = \sum_x P(Y \mid Z=z, X=x)P(X=x)$——这就是" 控制 X 后可比" 的公式化。

后门准则的价值在于：它把" 该控制什么" 从直觉变成了可以画出来检查的清单。

来源：后门准则据 Pearl (1993, 2009)。

控制什么、别控制什么 What to Adjust For

角色	在 DAG 上的位置	该不该控制	后果
混杂	$Z \leftarrow U \rightarrow Y$	必须控制	不控制 → 有偏
中介	$Z \rightarrow M \rightarrow Y$	不要控制	控制 → 估计的是直接效应
对撞	$Z \rightarrow C \leftarrow Y$	绝对不要	控制 → 凭空造出关联
工具	$Z' \rightarrow Z \rightarrow Y$	视情况	控制会削弱识别力

这四行是本讲最实用的一页：" 我控制了 XX" 不是免责声明，控制错了比不控制更糟。

来源：四类角色据 Pearl 与 Hernán-Robins 的框架；后果整理为本讲。

对撞点偏差 Collider Bias

机制

两个本来无关的原因共同影响一个结果；只看那些" 结果相同" 的样本，两个原因就会显得负相关。

经典例子

伯克利录取：合并看男女录取率有差异，分系之后差异消失——因为申请者自选了竞争程度不同的系。

另一个例子：只看" 住院病人" 研究某种病——住院本身就是" 得病" 与" 其他原因" 的共同结果，条件化在它上面会造出假关联（帧 82–83）。

来源：对撞点与伯克利例子据 Bickel et al. (1975) 与 Pearl (2009)。

【代码】辛普森悖论与分层

```
for g, (mu_x, shift) in enumerate([(2.0, 0.0), (8.0, 9.0)]): # two groups with different centres
    x = RNG.normal(mu_x, 1.4, n // 2)                  # the predictor
    y = shift - 0.6 * x + RNG.normal(0, 1.0, n // 2)   # negative slope INSIDE each group
pooled = smf.ols("y ~ x", data=df).fit()               # the pooled regression
within = smf.ols("y ~ x + C(group)", data=df).fit()    # with a group fixed effect
b_pool = float(pooled.params["x"])                     # the pooled slope
b_within = float(within.params["x"])                   # the within-group slope
print("pooled slope %.3f | within slope %.3f" % (b_pool, b_within)) # report
```

实测：合并斜率 $+0.618$，组内斜率 -0.574——同一份数据，符号完全相反。完整程序 `l12_01_simpson.py`。

辛普森悖论：它到底是什么

数学上

它就是条件化：把总体拆成子群之后，加权平均的关系可以翻转。

因果上

它可能由混杂造成，也可能由对撞点造成——所以"该不该分层"取决于DAG，而不是数据。

这是本讲最容易混淆的一点：悖论本身不告诉你哪个答案对。必须回到"分组变量是混杂还是对撞"这个问题上。

来源：辛普森悖论的形式化与因果解读 Pearl (2009)；提醒为本讲强调。

伯克利录取：一个真实的辛普森悖论

合并数据

男性录取率约 44%，女性约 35%——表面上存在性别差异。

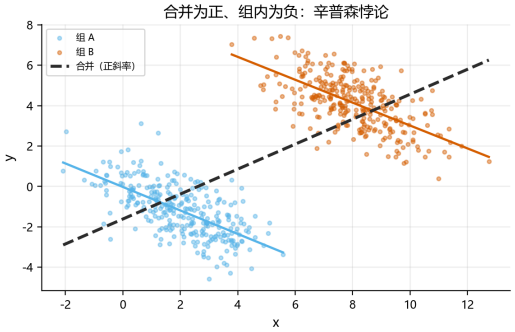
分系之后

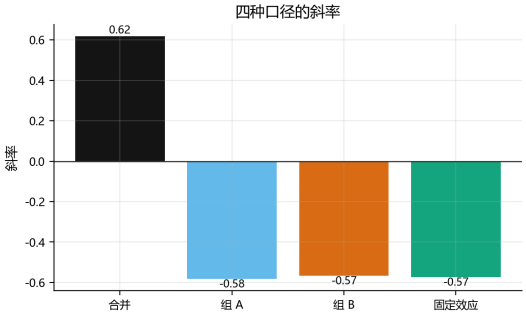
大多数系里差异消失甚至反转；女性更多申请录取率低的系。

这个案例的意义：群体层面的差异，可能完全由"申请结构"造成。但它也提醒——分系之后是否还有残余差异，需要看每一系的样本量与显著性。

来源：伯克利案例据 Bickel, Hammel & O'Connell (1975, Science)。

【样本 + 可视化】辛普森悖论：合并与分层





左：两组各自的斜率都为负，但合并后的虚线为正；右：四种口径的斜率——合并 $+0.62$、组 A/B 约 -0.6、固定效应 -0.57。加一个分组虚拟变量，结论就翻了过来。

程序 `l12_01_simpson.py` ·表 `l12_simpson_slopes.csv`

吸烟与肺癌：Cornfield 不等式

观察到的关联

Doll & Hill (1950)：吸烟者肺癌相对风险 ≈ 9，调整已知协变量后仍然 ≈ 9。

Fisher 的质疑

也许存在共同原因（基因），同时导致" 爱吸烟" 与" 易患肺癌"。

Cornfield 的回答（1959）：若基因是唯一解释，它必须满足

$$RR_{ZU} \geq RR_{ZY} \approx 9,$$

即这个基因要让吸烟概率提高 9 倍——现实中不存在这样的基因。所以关联只能由因果解释。这是" 用假设的强度反证" 的经典。

来源：Cornfield et al. (1959, JNCI)；Doll & Hill (1950, BMJ)；Fisher (1957, BMJ)。

潜在结果与个体效应 Potential Outcomes

记号

$Y_i(1)$：i 被处理时的结果；$Y_i(0)$：i 未被处理时的结果；个体效应 $\tau_i = Y_i(1) - Y_i(0)$。

关键事实

观测到的只有一个：$Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$。另一列永远缺失。

这个记号看起来笨，但它是后面所有估计量的共同语言：ATE、ATT、LATE、CATE 都只是"对 τ_i 取不同的平均"。

来源：潜在结果记号据 Neyman (1923) 与 Rubin (1974)。

ATE、ATT 与 ATU：三种平均

参数	定义	谁关心
ATE	$E[Y(1) - Y(0)]$	政策制定（要不要全面推行）
ATT	$E[Y(1) - Y(0) \mid Z = 1]$	已实施者的收益（是否继续）
ATU	$E[Y(1) - Y(0) \mid Z = 0]$	扩大覆盖的收益

三者一般不相等：处理效应异质时，ATE / ATT / ATU 是不同的数。所以报告效应时必须说清是"对谁"的平均——这是本讲最常见的表述错误。

来源：三个参数据 Imbens & Rubin (2015)。

三种写法：差值、回归、匹配

差值	回归	匹配
$\hat{\tau} = \bar{Y}_{Z=1} - \bar{Y}_{Z=0}$；随机实验下无偏。	$Y = \alpha + \tau Z + \varepsilon$；加协变量可提高精度。	给每个处理单位找可比的对照，再平均差值。

三者在随机实验下都一致；在观察数据下，它们的差别就在于" 用什么假设替代随机化"——这就是下一帧要讲的**识别**。

来源：三种估计量的等价性据 Imbens & Rubin (2015)；表述为本讲组织。

识别：把不可观测量变成可观测量 Identification

一句话

识别 = 假设 + 数据；它回答"在什么条件下，这个因果量能被数据唯一确定"。

与估计的区别

估计是统计问题（标准误、样本量）；识别是逻辑问题——假设不成立，再大的样本也救不了。

所以本讲每个方法都按同一个模板讲：目标参数 → 识别假设 → 估计量 → 假设的检验。检验那一栏，往往比估计本身更重要。

来源：识别与估计的区分据 Manski (1995) 与 Imbens-Rubin；表述为本讲强调。

因果推断的根本问题 Fundamental Problem

Holland (1986)

对每个单位，最多只能观测到一种潜在结果；缺掉的那一格由" 另一个世界" 决定。

推论

我们只能估计平均效应，无法估计个体效应——除非借助额外假设（如帧 90 的因果森林）。



所有的识别策略，都是在说：我打算用什么去填这一格。

来源：根本问题据 Holland (1986)。

三个识别假设 Three Assumptions

假设	含义	违背会怎样
无混杂	$Z \perp Y(z) \mid X$	系数不等于因果效应
重叠	$0 < P(Z = 1 \mid X) < 1$	某些人永远无法比较
SUTVA	一个人的处理不影响别人	估计的是"含溢出"的总效应

三条缺一不可。实务里最常被忽略的是SUTVA：当处理有溢出（疫苗、推荐算法、价格战）时，"对照组"其实也被影响了。

来源：三个假设据 Imbens & Rubin (2015) 与 Cox (1958)。

【代码】造一份有混杂的数据，看偏差怎么来

```python
x = RNG.normal(0, 1, n)                                # an observed confounder
u = RNG.normal(0, 1, n)                                # an unobserved confounder
p_z = 1 / (1 + np.exp(-(0.0 + 0.9 * x + 0.7 * u)))     # the propensity score
z = (RNG.random(n) < p_z).astype(int)                  # the realised assignment
y0 = 1.0 + 1.2 * x + 0.8 * u + RNG.normal(0, 0.8, n)   # the control potential outcome
y1 = y0 + ate + confound * x                           # the treated one (heterogeneous)
y = np.where(z == 1, y1, y0)                           # the observed outcome
naive = float(df.loc[df["z"] == 1, "y"].mean() - df.loc[df["z"] == 0, "y"].mean()) # difference in means
selection_bias = treated_y0 - control_y0               # the selection bias
```

实测：真 ATE 2.00，朴素差值 3.83，其中选择偏差 1.31；控制混杂后回到 2.0 附近。完整程序 `112_02_potential.py`。

分解：朴素差值里藏了什么

恒等式

$$\bar{Y}_1 - \bar{Y}_0 = \underbrace{E[Y(1) - Y(0) \mid Z = 1]}_{\text{ATT}} + \underbrace{E[Y(0) \mid Z = 1] - E[Y(0) \mid Z = 0]}_{\text{选择偏差}}.$$

怎么用

随机化让第二项期望为 0；观察数据里它一般不为 0，所以任何"调整"本质上都在估这一项。

这个分解是本讲所有方法的骨架：匹配用可观测变量估它、DID 用时间差分消它、IV 用外生变异绕开它。

来源：分解式据标准因果推断教材；解读为本讲组织。

一致性：处理必须定义清楚 Consistency

要求

同一个处理标签对应同一个版本：" 接种疫苗" 如果剂量、批次不同，就不是同一个处理。

为什么重要

版本不清，$Y(z)$ 就没有定义，后面所有估计都失去意义。

实务上这意味着：先写清" 处理" 到底是什么（力度、时点、对象、口径），再谈效应。这一点在商业实验里比学术论文更容易出错。

来源：一致性（SUTVA 的一部分）据 Rubin (1980)；实务提醒为本讲补充。

稳定性与溢出 SUTVA and Spillovers

什么时候会破

vaccinated、推荐算法、价格战、社群营销——处理会通过他人影响你。

怎么处理

聚类随机（按城市/门店/社群随机）、饱和度设计（不同覆盖比例）、或直接建溢出模型。

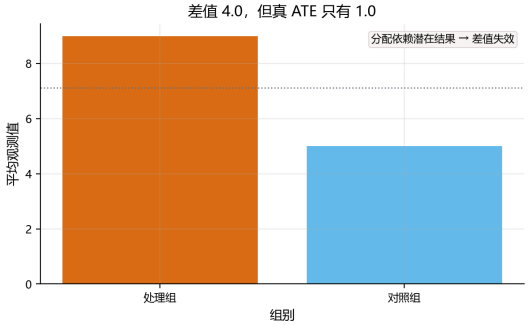
诊断信号：处理组比例越高，个体效应越小——这说明存在一般均衡或竞争效应，此时" 实验效应" 不能直接外推到全面推广。

来源：溢出与 SUTVA 的处理据 Hudgens & Halloran (2008) 等；诊断信号为本讲补充。

【样本 + 可视化】完美医生 Perfect Doctor

完美医生：8 位病人的潜在结果

Y(0)	Y(1)	增益	Z	观测值
13	14	1	1	14
6	6	0	0	6
4	5	1	0	4
5	6	1	1	6
6	7	1	1	7
6	7	1	1	7
8	10	2	1	10
9	10	1	1	10



医生按病人的增益决定给不给药：真 ATE 只有 1.0，差值估计却是 4.0。不是数据错，而是分配依赖了潜在结果——这正是随机化要切断的东西。

程序 l12_02_potential.py ·表 l12_perfect_doctor.csv

完美医生说明了什么

要点

差值估计的有效性，取决于分配机制（Rubin 1978）：

$$p(Z_i = 1 \mid X_i, Y_i(0), Y_i(1)).$$

推论

只要这个概率依赖潜在结果，差值就失效——哪怕”医生”完全理性、数据完全准确。

现实版：能力强的学生更可能选进阶课、本来就要买的人更可能点广告。这就是为什么”关联”在商业数据里几乎总是高估效果。

来源：分配机制据 Rubin (1978)；现实类比为本讲补充。

无混杂分配与倾向得分 Unconfoundedness

定义

$$p(Z_i = 1 \mid X_i, Y_i(0), Y_i(1)) = p(Z_i = 1 \mid X_i),$$

即分配只看可观测协变量。

倾向得分

Rosenbaum & Rubin (1983)：把 X 压成一个标量 $e(X)$，给定 $e(X)$ 后处理与协变量独立。

三个好处：降维（多维协变量变一维）、平衡性（同分者可比）、可估（logistic 回归即可）。代价：只能控制可观测的混杂。

来源：倾向得分据 Rosenbaum & Rubin (1983, Biometrika)。

倾向得分的三条性质 Three Properties

性质	内容	用途
平衡性	$X \perp Z \mid e(X)$	匹配后协变量应平衡
降维	$e(X)$ 是标量	高维协变量可用
充分性	给定 $e(X)$ 即无混杂	匹配/加权只需匹配得分

最容易忽略的是平衡性检验（帧 59）：匹配之后必须报告" 标准化差异"，否则你不知道匹配有没有用。

来源：三条性质据 Rosenbaum & Rubin (1983)；平衡性检验的实践为本讲强调。

【样本 + 可视化】四种分配机制

分配机制决定识别：四种情形

依增益选择	Z 依赖 Y(1) − Y(0)	无效
依潜在结果选择	Z 依赖 (Y(0), Y(1))	无效（完美医生）
依可观测选择	Z ⊥ Y(z) | X	可用 X 调整
完全随机	Z ⊥ (Y(0), Y(1))	有效

从完全随机到依增益选择，识别能力依次下降。只有前两种（随机、依可观测选择）能用数据调整；后两种（依潜在结果、依增益）必须换识别策略——这就是完美医生的教训。

程序 `112_02_potential.py` ·四种机制的文字版在正文

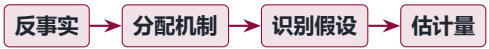
小结：识别是假设，不是算法

三句话

因果 = 反事实的对比；识别 = 用什么替代看不到的那一格；换假设就换答案。

自检

你能画出 DAG 吗？你的分配机制依赖潜在结果吗？你控制了不该控制的变量吗？



下一部分：最干净的识别——随机实验。

来源：小结为本讲整理。

随机实验为什么是金标准 The Gold Standard

一句话

随机化让 Z 与所有潜在结果独立——包括你没想到、没测到的混杂。

它解决了什么

帧 36 的分配机制里，随机是唯一让 $p(Z \mid Y(0), Y(1)) = p(Z)$ 成立的设计。

所以在本讲的框架里，随机实验不是"一种方法"，而是唯一不需要额外假设的识别策略。其他四种（匹配/DID/IV/RD）都是在模仿随机化。

来源：随机化的识别论证据 Fisher (1935) 与 Rubin (1974)。

A/B 的四个设计决定 Four Design Choices

决定	选项	什么时候选它
随机化单位	用户 / 会话 / 城市 / 门店	有溢出就往上聚
样本量	由 MDE 反推	先定" 值得检测的最小效应"
指标	主指标 + 护栏指标	一个主指标，避免多重比较
周期	至少一个完整周期	避开周末与月初效应

最容易被忽略的是护栏指标（延迟、崩溃率、退款率）——主指标涨了、护栏崩了，这个实验不能上。

来源：四个决定据 Kohavi et al. (2020) 的实验平台实践；护栏指标为本讲强调。

功效与最小可检测效应 Power and MDE

四个量

显著性水平 α（通常 0.05）、功效 $1-\beta$（通常 0.8）、样本量 n、最小可检测效应 MDE。

关系

三者定了两个，第三个就定了：想检测更小的效应，就要更大样本。$MDE \propto 1/\sqrt{n}$。

本讲实测（帧 44）：基准转化率 10%、提升 1.2pp，每臂 5,000 人时功效只有 49.6%——一半的概率会漏掉一个真实的提升。

来源：功效分析据 Cohen (1988) 与标准实验设计；实测来自 112_03。

【代码】A/B 的功效与样本量

```python
def power_two_prop(p1, p2, n, alpha=0.05):             # analytic power
    p_bar = (p1 + p2) / 2                              # the average rate
    se0 = np.sqrt(2 * p_bar * (1 - p_bar) / n)         # standard error under H0
    se1 = np.sqrt(p1 * (1 - p1) / n + p2 * (1 - p2) / n) # standard error under H1
    crit = stats.norm.ppf(1 - alpha / 2)               # the critical value
    return float(stats.norm.cdf((abs(p2 - p1) - crit * se0) / se1)) # power
exp = make_experiment(5000, 0.10, 0.012)               # two arms of 5,000
agg = exp.groupby("arm")["converted"].agg(["sum", "count"]) # conversions and users
p_c = float(agg.loc["control", "sum"] / agg.loc["control", "count"]) # control rate
se = np.sqrt(p_c * (1 - p_c) / n_arm + p_t * (1 - p_t) / n_arm) # standard error of the difference
```

实测：对照 9.62%、处理 10.60%、$z = 1.63$、$p = 0.104$（不显著）；解析功效 0.496，模拟功效 0.497——两者一致。完整程序 `112_03_power.py`。

序贯检验与”偷看” Sequential Testing

问题

每天看一眼 p 值，看到显著就停——这是多次检验，实际第一类错误率远高于 5%。

三种解法

固定期限 (只看一次)；alpha spending (预算随信息量分配)；序贯检验 (如 SPRT、mSPRT)。

实务建议：要么提前定好" 看几次、什么时候看"，要么用平台提供的序贯方法。" 看到显著就停" 是实验里最常见的自欺。

来源：序贯检验据 Wald (1945) 与 O'Brien-Fleming (1979)；工程实践据 Kohavi et al. (2020)。

多重比较：指标越多，假阳性越多

两种控制

FWER（族错误率）：Bonferroni，阈值 α/m；FDR（错误发现率）：Benjamini-Hochberg，更宽松。

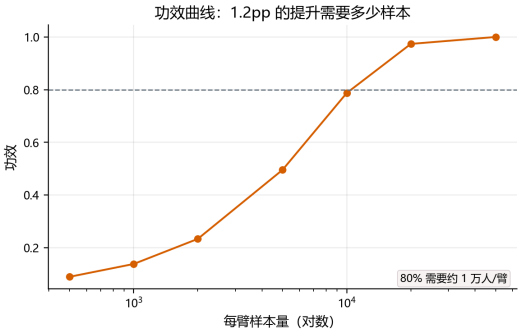
怎么选

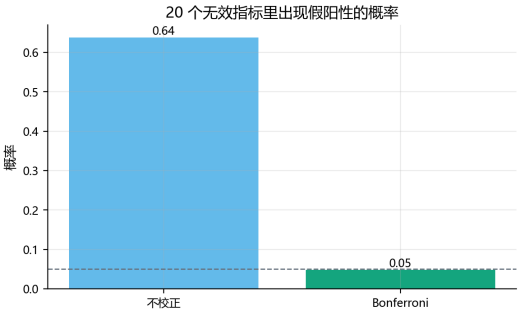
一个主指标用 FWER（错一个就糟）；探索性分析用 FDR（允许少量假阳性换更多发现）。

本讲实测（帧 49）：20 个全部无效的指标，至少一个" 显著" 的概率是 65.3%；Bonferroni 校正后降到 0.3% 左右（接近名义水平）。

来源：多重比较据 Benjamini & Hochberg (1995)；实测来自 112_03。

【样本 + 可视化】功效曲线与 MDE





左：检测 1.2pp 的提升需要多少样本——5,000/臂只有 50% 功效，1 万才到 80%；右：20 个无效指标里至少一个假阳性的概率（不校正 65%，Bonferroni 后接近 0）。

程序 `112_03_power.py` ·曲线 `112_power_curve.csv`

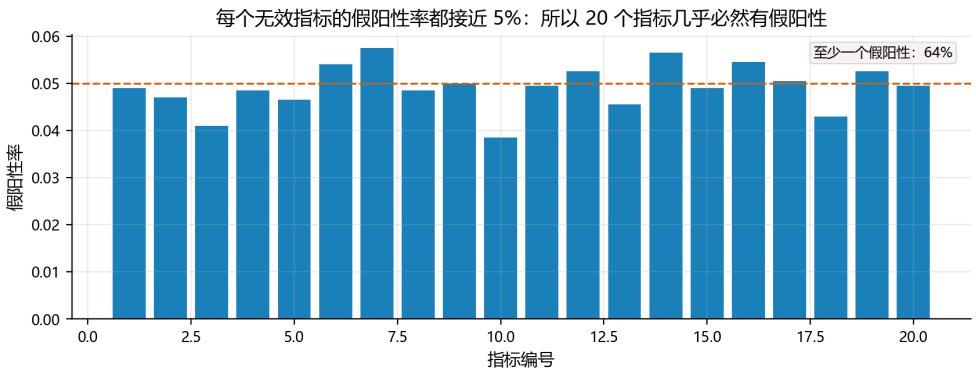
常见实验设计 Four Designs

设计	随机化单位	优点	代价
完全随机	个体	简单、功效高	有溢出时失效
分层随机	个体（按特征分层）	平衡、方差小	需要先知道分层变量
聚类随机	群（城市/门店）	处理溢出	功效低、需要更多群
析因设计	个体	一次测多个因素 + 交互	组合多、样本要求高

选择顺序：先问有没有溢出（有 → 聚类），再问能不能分层（能 → 分层提精度）。

来源：四种设计据标准实验设计与 Kohavi et al. (2020)。

【样本 + 可视化】多重比较的假阳性



20 个真实效应为 0的指标，每个的假阳性率都接近 5%；但" 至少一个显著" 的概率高达 65%。这就是" 我们测了 20 个指标，找到了 3 个显著" 的危险之处。

程序 l12_03_power.py ·表 l12_multiple_testing.csv

实验的伦理与合规 Ethics and Compliance

知情同意	最小伤害	公平性
高风险干预（医疗、信贷、就业）必须事先知情与自愿。	对照组不能低于"现有最佳做法"；有害实验应提前终止。	检查不同群体的效应差异，避免算法把成本转嫁给弱势群体。

合规章还有一层：数据用途与保存期限（衔接 L5 的合规讨论）。实验设计阶段的伦理审查，比事后补救便宜得多。

来源：伦理原则据《赫尔辛基宣言》与企业实验治理实践；整理为本讲。

外部有效性 External Validity

三个限制

人群（实验的样本是谁）、环境（时间、市场、竞争）、规模（小范围 vs 全面推广）。

与内部有效性的权衡

实验内部很干净，但越干净越特殊；推广时要问"这个效应在别处还成立吗"。

一个具体机制：SUTVA 在大规模推广时最容易失效——小实验中对照组没被影响，全面推广后所有人都在新均衡里。

来源：外部有效性据 Campbell & Stanley (1963) 与政策评估实践。

实验平台与工程 The Experiment Platform

四件事

分流（哈希分桶，稳定可复现）、AA 测试（两组同方案，检查分流是否均匀）、指标口径（同一套 SQL/指标定义）、日志与埋点（能追溯）。

AA 测试为什么重要

它能提前暴露分流偏差、指标 bug、样本污染——这些问题在正式实验里会被误读成"效应"。

平台化的价值：把随机化、功效计算、序贯检验、多重比较变成默认动作，而不是每次靠分析师记得。

来源：实验平台实践据 Kohavi et al. (2020) *Trustworthy Online Controlled Experiments*。

从实验到决策 From Evidence to Decision

三个输入

效应量（点估计 + 置信区间）、成本（改造成本、机会成本）、风险（护栏指标、尾部情形）。

决策规则

不是"显著就上"，而是 效应量的下界 × 规模 > 成本——置信区间比 p 值有用得多。

本讲的态度：$p < 0.05$ 只是入场券。真正决定要不要做的是效应有多大、成本多少、风险能否承受。

来源：决策框架据商业实验实践；表述为本讲组织。

小结：实验给的是”局部真理”

三句话

随机化切断了所有箭头；功效决定你能看见什么；多重比较决定你会不会看错。

自检

你的 MDE 是多少？看了几次？测了几个指标？护栏指标怎么样？



下一部分：不能做实验时，靠什么识别因果。

来源：小结为本讲整理。

四条路：匹配、DID、IV、RD Four Strategies

策略	核心假设	需要的数据	什么时候用
匹配	无混杂（依可观测）	丰富的协变量	有大量可观测特征
DID	平行趋势	两组多期面板	有政策/冲击时点
IV	相关 + 排他性	外生工具变量	能找到外生变异
RD	门槛附近连续	运行变量	有明确的阈值规则

共同点：都在模仿随机化——找一个" 近似随机" 的变异来源。找到什么，就用什么；找不到，就老实说" 识别不了"。

来源：四种策略的对照据 Angrist & Pischke (2009) 与本讲整理。

匹配：给处理组找可比对照 Matching

两种做法

精确匹配（协变量相同）或 倾向得分匹配（分数相近）；也可以做逆概率加权 IPW。

关键假设

无混杂：控制协变量后处理与潜在结果独立。这意味着所有混杂都必须可观测。

匹配的边界（帧 58）：谁都可以做出一张平衡表，但测不到的混杂它管不了——所以匹配之后还要做敏感性分析（帧 73）。

来源：匹配与倾向得分据 Rosenbaum & Rubin (1983) 与 Abadie & Imbens (2006)。

【代码】倾向得分匹配与平衡检验

```python
ps_model = LogisticRegression(max_iter=1000).fit(X, z) # logistic regression on the covariates
ps = ps_model.predict_proba(X)[:, 1]                   # the fitted propensity scores
support = (ps > np.percentile(ps, 2)) & (ps < np.percentile(ps, 98)) # drop the extreme 2% tails
treated_idx = np.where((z == 1) & support)[0]          # the treated units on support
nn = NearestNeighbors(n_neighbors=1).fit(ps[control_idx].reshape(-1, 1)) # fit on the controls
dist, pos = nn.kneighbors(ps[treated_idx].reshape(-1, 1)) # find the nearest control
matched_control = control_idx[pos.ravel()]             # the matched control indices
att = float(y[treated_idx].mean() - y[matched_control].mean()) # the matched ATT
before = std_diff(df.loc[z == 1, "x"].values, df.loc[z == 0, "x"].values) # before matching
after = std_diff(df.loc[treated_idx, "x"].values, df.loc[matched_control, "x"].values) # after
```

实测：匹配后 ATT 2.96（朴素 3.83，真值 2.0）；标准化差异从 0.74 降到 0.00。完整程序 `112_04_psm.py`。

匹配的边界 Limits of Matching

三个限制

只能控制可观测混杂；共同支撑域外的单位无法比较；匹配本身会损失样本（尤其一对一）。

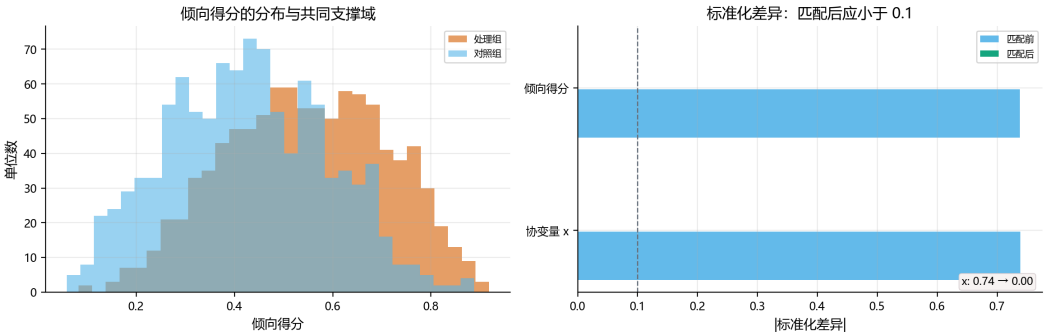
报告三件事

匹配前后的平衡表、共同支撑域的图、敏感性分析（需要多强的隐藏混杂才能推翻）。

一句话：匹配是"用观测换随机"，不是"用算法换因果"。没有平衡表的匹配论文，等于没有做检验。

来源：匹配的边界据 Abadie & Imbens (2006) 与 Rosenbaum (2002)。

【样本 + 可视化】匹配前后的平衡



左：处理组与对照组的倾向得分分布，重叠区才是可比范围；右：标准化差异——协变量 x 从 0.74 降到 0.00（虚线 0.1 是经验阈值）。匹配" 有用" 必须用这张表证明。

程序 l12_04_psm.py ·表 l12_balance.csv / l12_balance_ps.csv

DID：用时间换识别 Difference-in-Differences

估计量

$$\hat{\tau} = \left(\bar{Y}_{T,1} - \bar{Y}_{T,0}\right) - \left(\bar{Y}_{C,1} - \bar{Y}_{C,0}\right),$$

两次差分，消掉组间不变差异与共同时间趋势。

核心假设

平行趋势：没有处理时，处理组本该与对照组同幅变化。这个假设不可直接检验，但可以用事件研究间接查（帧 63）。

DID 是政策评估里最常用的方法，也是 L14 的核心工具。它的软肋全在平行趋势上——所以事件研究图是必交作业。

来源：DID 据 Ashenfelter (1978) 与 Card & Krueger (1994)；平行趋势检验的实践为本讲强调。

【代码】DID 与事件研究

```python
panel["did"] = panel["treated"] * panel["post"]        # the interaction
model = smf.ols("y ~ did + C(unit) + C(period)", data=panel).fit(
    cov_type="cluster", cov_kwds={"groups": panel["unit"]}) # two-way FE with clustered SEs
print("DID coefficient: %.3f (se %.3f)" % (model.params["did"], model.bse["did"])) # report
# with a single treatment date the event study is the period-by-period group difference,
# re-based at the last pre-treatment period
wide = per.pivot(index="period", columns="treated", values="mean") # treated vs control means
diff = (wide[1] - wide[0])                             # the group difference by period
base_value = float(diff.loc[ref_period])               # the reference level
event = pd.DataFrame({"event_time": diff.index - ref_period, # relative period
                      "coef": diff.values - base_value,    # deviation from the reference
                      "se": se_diff.values})               # the standard error
```

实测：DID 系数 -3.000（se 0.046，真值 -3）；事件研究处理前系数最大绝对值 0.16，说明平行趋势成立。完整程序 `l12_05_did.py`。

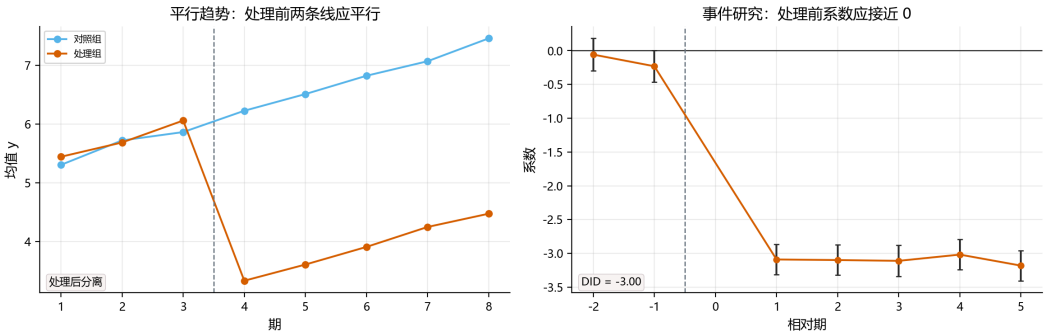
DID 的三个陷阱 Three Pitfalls

陷阱	表现	怎么查
趋势不同	处理前两组就在分离	事件研究图（帧 63）
时点内生	政策因为结果差才出台	换对照组、用政策时间表
溢出与预期	对照组被带动、提前反应	检查对照组趋势、留出缓冲期

还有一个近年很热的问题：多期 DID 的加权问题——处理时点不同时，简单双向固定效应会用"已处理单位"当对照，估计量可能为负权重。解法：Callaway-Sant'Anna 或 Sun-Abraham。

来源：多期 DID 的负权重问题据 Goodman-Bacon (2021)；解法据 Callaway & Sant'Anna (2021)。

【样本 + 可视化】DID 的事件研究



左：处理前两组的走势平行，处理后才分离；右：以处理前一期为基准的事件研究系数，处理前都在 0 附近（最大 0.16），处理后稳定在 -3 左右。这张图就是平行趋势的证据。

程序 `l12_05_did.py` ·表 `l12_event_study.csv`

工具变量：找一个外生的推动 Instrumental Variables

两个条件

相关性：Z 影响处理 D；排他性：Z 只能通过 D 影响 Y。

2SLS

第一步：D 对 Z 回归得 $\hat{D}$；第二步：Y 对 $\hat{D}$ 回归。两步都只用外生变异。

排他性无法用数据检验，只能靠制度与逻辑论证——这是 IV 论文里最需要"讲故事"的地方。例子：离大学的距离（Card 1995）、征兵抽签（Angrist 1990）。

来源：IV 的经典应用据 Card (1995) 与 Angrist (1990)；两条件表述据标准计量教材。

【代码】2SLS 与弱工具诊断

```python
ols = sm.OLS(df["y"], sm.add_constant(df[["x"]])).fit() # the biased OLS estimate
first = sm.OLS(df["x"], sm.add_constant(df[["z"]])).fit() # the first stage
x_hat = first.fittedvalues                                # the fitted values
second = sm.OLS(df["y"], sm.add_constant(x_hat)).fit()   # the second stage (manual 2SLS)
b_2sls = float(second.params.iloc[1])                     # the 2SLS slope
f_stat = float(first.fvalue)                             # the first-stage F statistic
for strength in [0.05, 0.10, 0.20, 0.40, 0.80, 1.60]:   # from very weak to strong
    ols_list, iv_list, f_list = [], [], []               # accumulators
    for _ in range(60):                                 # sixty replications
        b_o, b_i, f = iv_once(400, strength)             # one replication
```

实测：OLS 2.379、2SLS 1.453（真值 1.5）、第一阶段 F 217.8；弱工具模拟显示 F 越小 2SLS 越偏。完整程序 `l12_06_iv.py`。

IV 的直觉：被推动的是谁 Whose Effect

关键洞察

IV 估的不是 ATE，而是被工具改变处理状态的那部分人的效应——他们就是帧 76 的顺从者。

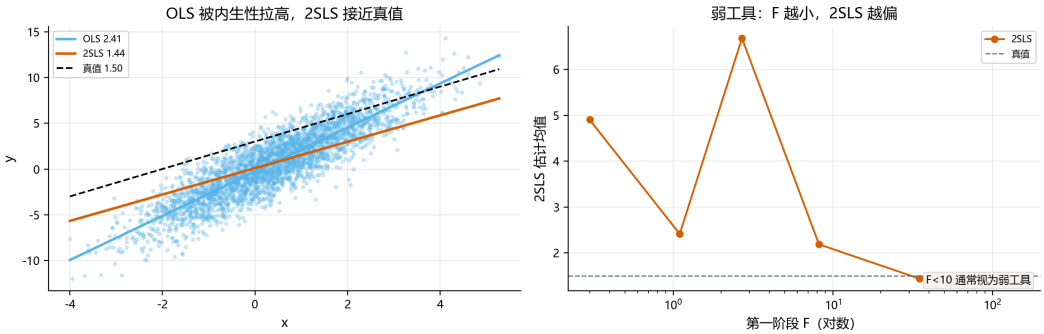
推论

所以 IV 的结论不能直接外推到全体；报告时要写清" 这是谁的效应"。

这也是 LATE 这个名字的来历：Local Average Treatment Effect。" 局部" 既指人群（顺从者），也常指识别所用的变异范围。

来源：LATE 的解释据 Imbens & Angrist (1994)；表述为本讲组织。

【样本 + 可视化】IV 与 OLS 的差距



左：OLS 的斜率被内生性拉高到 2.38，2SLS 回到 1.45（真值 1.5）；右：不同工具强度下的 2SLS 均值——F 越小越偏，$F > 10$ 之后稳定。" 弱工具" 不是技术细节，是结论的可信度。

程序 l12_06_iv.py ·表 l12_weak_iv.csv

断点回归：用门槛做实验 Regression Discontinuity

设置

有一个运行变量（分数、年龄、规模），超过阈值就得到处理——阈值两侧近似随机。

两个条件

连续性（其他因素在阈值处不跳）；无操纵（没人能精确控制自己落在哪一侧）。

RD 的可信度来自"局部随机化"：阈值附近的人除了处理状态几乎一样。代价是外部有效性窄——它只告诉你阈值附近的效应。

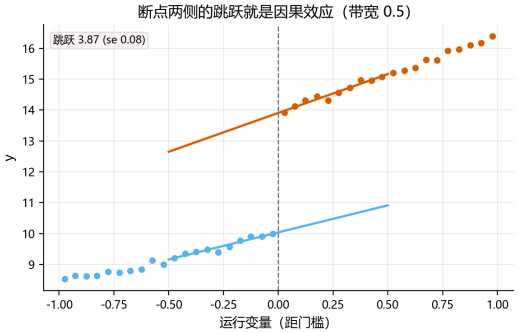
来源：RD 的识别基础据 Thistlethwaite & Campbell (1960) 与 Lee & Lemieux (2010)。

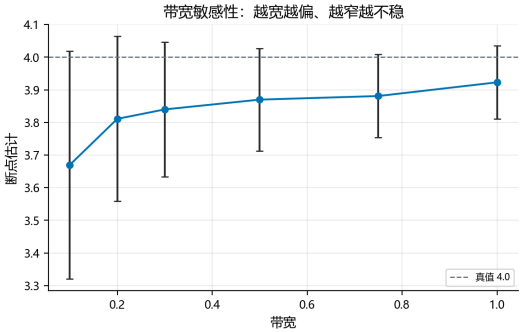
【代码】断点回归与带宽敏感性

```
def rd_estimate(bandwidth):                          # one bandwidth
    sub = df[df["running"].abs() <= bandwidth].copy()   # keep units near the cutoff
    sub["above"] = (sub["running"] >= 0).astype(int)    # the post-cutoff side
    sub["r_centered"] = sub["running"] - 0.0            # centre the running variable
    model = smf.ols("y ~ above + r_centered + above:r_centered", data=sub).fit() # allow different slopes
    return float(model.params["above"]), float(model.bse["above"]), len(sub) # the jump and its se
for bw in [0.1, 0.2, 0.3, 0.5, 0.75, 1.0]:           # from very local to global
    est, se, n_sub = rd_estimate(bw)                    # estimate within the bandwidth
    rows.append({"bandwidth": bw, "jump": round(est, 3), "se": round(se, 3), "n": n_sub}) # the row
bins = np.linspace(-1, 1, 41)                        # bins of the running variable
df["bin"] = pd.cut(df["running"], bins, labels=False)   # assign each unit to a bin
```

实测：带宽 0.5 时跳跃 3.87（真值 4.0），带宽 0.1–1.0 之间在 3.67–3.92；带宽越宽越平滑但会引入函数形式偏差，越窄越准但标准误越大。完整程序 `l12_07_rd.py`。

【样本 + 可视化】断点两侧的跳跃





左：分箱均值在阈值处明显跳升，两侧各拟合一条局部直线；右：带宽敏感性——从 0.1 到 1.0，估计值围绕真值 4.0 波动，带宽太宽会偏离，太窄会把标准误放大。报告时必须给这张图。

程序 `l12_07_rd.py` ·表 `l12_rd_bandwidth.csv`

合成控制：用加权组合造反事实 Synthetic Control

思路

找一个"没被处理的地区"的加权组合，让它在处理前的走势与处理地区几乎一致——之后的分叉就是效应。

优势

权重由数据决定、可透明展示；适合只有一个处理单位的政策评估。

代价：需要处理前的长序列、推断靠置换检验（把每个对照地区轮流当处理地区）。这是 L14 里"一国一策"评估的主力方法。

来源：合成控制据 Abadie & Gardeazabal (2003) 与 Abadie, Diamond & Hainmueller (2010)。

四种策略对照 Choosing a Strategy

策略	识别假设	数据要求	可信度	主要弱点
匹配	无混杂	丰富协变量	中	隐藏混杂
DID	平行趋势	两组多期	中高	趋势不同
IV	相关 + 排他	外生工具	高	弱工具、排他性难证
RD	阈值处连续	运行变量	高（局部）	外部有效性窄

实务顺序：能做实验就做实验；不能，先看有没有门槛（RD），再看有没有外生冲击（DID/IV），最后才用匹配。

来源：策略选择顺序据实证研究实践；表述为本讲组织。

敏感性分析：需要多强的混杂才能推翻 Sensitivity Analysis

问题

结论可能被未观测的混杂推翻。与其说" 应该没事"，不如算" 要多强才会出事"。

两个工具

Rosenbaum bounds（匹配后：需要多大的隐藏偏倚才让结论不显著）；E-value（需要多大的关联强度才能把效应解释掉）。

输出应该是一句话：" 要让结论消失，未观测混杂必须比已知最强的混杂还强 X 倍"——这句话比 p 值有信息量得多。

来源：Rosenbaum bounds 据 Rosenbaum (2002)；E-value 据 VanderWeele & Ding (2017)。

小结：识别策略就是”找外生变异”

三句话

匹配靠” 可比”、DID 靠” 平行”、IV 靠” 外生”、RD 靠” 门槛”。四种都在模仿随机化。

自检

你的识别假设是什么？怎么检验？需要多强的混杂才能推翻？



下一部分：分配 $\neq$ 接受时，效应到底是谁的。

来源：小结为本讲整理。

不依从：分配不等于接受 Non-compliance

为什么会不依从

被分配到处理的人没有真正接受（没点、没买、没吃药）；或者没被分配的人自己接受了。

四类人

顺从者（分配才接受）、从不接受者、始终接受者、反抗者（分配才不接受）。

实验里这非常常见：发券 $\neq$ 用券、推送 $\neq$ 点击。如果直接比较"用了 vs 没用"，就回到了完美医生的问题（帧 36）。

来源：不依从的分类据 Angrist, Imbens & Rubin (1996)。

LATE：顺从者的平均效应

Wald 估计

$$\tau_{\text{LATE}} = \frac{\text{ITT}}{\text{取用率差}} = \frac{E[Y \mid Z=1] - E[Y \mid Z=0]}{E[D \mid Z=1] - E[D \mid Z=0]}.$$

直觉

分母是" 分配真正改变了多少人接受处理"；分子是" 分配改变了多少结果"。比值就是被改变的那部分人的效应。

本讲实测（帧 79）：ITT 1.316、取用率 0.652、LATE 2.019（真值 2.0）。而" 按实际接受比较" 的朴素估计 2.02——在单调性成立时两者接近，不成立时朴素估计就错了。

来源：Wald 估计据 Imbens & Angrist (1994)；实测来自 112_08。

单调性：没有反抗者 Monotonicity

假设

分配只会增加接受处理的概率，不会减少：没有反抗者（被分配反而不接受的人）。

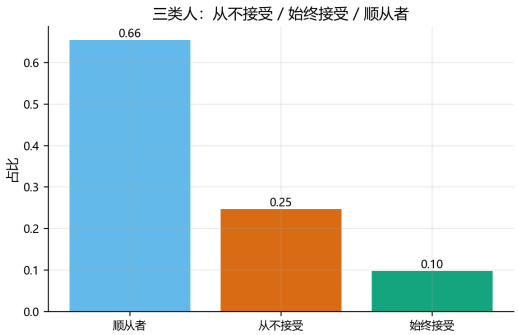
为什么必须有

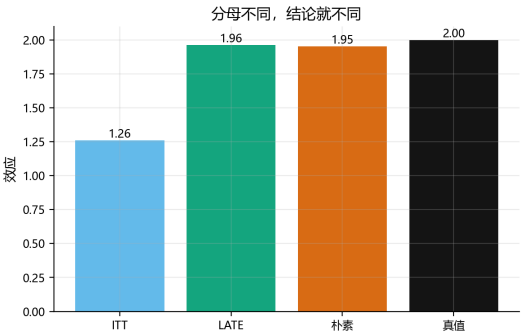
有反抗者时，Wald 比值的分子分母来自不同人群，比值就不再是任何一群人的平均效应。

实务判断：政策鼓励的行为，通常满足单调性（发券只会让人更可能买）；强制或惩罚性的政策要小心——被强制的人可能反而抵触。

来源：单调性据 Imbens & Angrist (1994) 与 Angrist, Imbens & Rubin (1996)。

【样本 + 可视化】四类人与四种口径





左：从不接受 25%、始终接受 10%、顺从者 65%；右：ITT 1.32、LATE 2.02、朴素 2.02、真值 2.00

——同一份实验，"按分配"与"按接受"回答的是不同问题。

程序 l12_08_late.py ·表 l12_late.csv

【代码】不依从下的 LATE

```python
itt = float(df.loc[df["z"] == 1, "y"].mean() - df.loc[df["z"] == 0, "y"].mean()) # ITT
first = float(df.loc[df["z"] == 1, "d"].mean() - df.loc[df["z"] == 0, "d"].mean()) # compliance rate
late = itt / first if first != 0 else np.nan            # the Wald ratio
naive = float(df.loc[df["d"] == 1, "y"].mean() - df.loc[df["d"] == 0, "y"].mean()) # per-protocol (biased)
never = u < p_never                                    # never-takers
always = (u >= p_never) & (u < p_never + p_always)     # always-takers
complier = u >= p_never + p_always                     # compliers
d = np.where(complier, z, np.where(always, 1, 0))      # observed take-up
y = base + 2.0 * d + RNG.normal(0, 0.8, n)             # outcome with a 2.0 effect
```

实测：ITT 1.316、取用率 0.652、LATE 2.019（真值 2.0）；2SLS 交叉校验同样给出 2.019。完整程序 `112_08_late.py`。

LATE 能推广吗 External Validity of LATE

不能直接推广

顺从者往往不是随机样本：他们是" 被推一下就会动" 的人，可能反应更强或更弱。

怎么做

比较不同推动强度下的 LATE (剂量反应)；或用多个工具看结论是否一致。

实务表述：" 这个活动对' 本来犹豫的人' 有效，效应约 X"——比" 这个活动有效" 诚实得多，也更有用（可以直接算规模）。

来源：LATE 的外部有效性讨论据 Imbens (2010) 与政策评估实践。

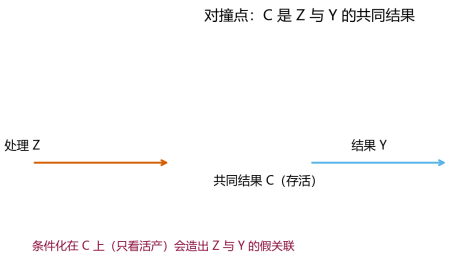
选择偏差：五种来源 Five Sources

来源	机制	例子
差异性失访	失访与结果相关	病情重的人退出随访
缺失数据	缺失非随机	高收入者不填收入
健康工人效应	在职者本身更健康	职业暴露研究
自选择	自己决定是否参与	报班的人本来更努力
对撞点	条件化在共同结果上	只看" 活产" (帧 83)

共同点：进入样本这件事本身与结果相关。所以第一步永远是问" 我的样本是怎么来的"。

来源：五种来源据 Hernán & Robins (2020) 第 8–9 章；整理为本讲。

【样本 + 可视化】对撞点：条件化造出假关联



C（存活）是 *Z*（叶酸）与 *Y*（心脏畸形）的共同结果。只看" 活产" 就等于条件化在 *C* 上——本来 *Z* 对 *Y* 没有效应，也会显示出有害的关联。

程序 `112_08_late.py` ·案例据 Hernán & Robins (2020)

叶酸的例子 The Folate Example

设置

随机分配叶酸 Z；关注心脏畸形 Y；但研究只纳入活产（$C = 0$）。

机制

心脏畸形会增加死亡率（$Y \to C$）；叶酸降低其他畸形的死亡率（$Z \to C$）。

结果：在活产样本里，叶酸组的心脏畸形率反而更高——尽管真实效应是零（甚至有益）。这就是"限制在存活者上"造成的对撞点偏差，也是很多临床研究翻车的地方。

来源：叶酸案例据 Hernán, Hernández-Díaz & Robins (2004) 与 Hernán-Robins (2020)。

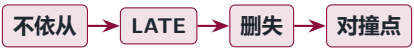
小结：缺数据与选错样本是两件事

三句话

不依从让" 效应" 变成" 谁的效应"；删失与选择会凭空造出关联；对撞点是最容易犯的错。

自检

你的样本是怎么进来的？有没有条件化在共同结果上？单调性成立吗？



下一部分：效应因人而异时，怎么办。

来源：小结为本讲整理。

从 ATE 到 CATE From Average to Individual

动机

平均效应为 0，不代表对所有人都没效——可能是一半受益、一半受损（帧 90 的图）。

两种做法

分群（按特征切子组，简单但粗糙）；连续 CATE（$\tau(x)$，更强但要求更多数据）。

CATE 的商业价值：把预算投给最受益的人。本讲实测（帧 91）：按估计的 CATE 取前 25%，真实增益 3.43，而" 对所有人处理" 只有 1.02。

来源：CATE 与政策学习据 Athey & Imbens (2016)；实测来自 112_10。

亚组分析的陷阱 Subgroup Traps

陷阱	表现	后果
事后分组	看到结果再切子组	假阳性（帧 49）
多重比较	切了 20 个亚组	必然有"显著"的
功效不足	子组样本太小	置信区间巨大，结论不稳
交互项误读	只看子组内显著	应检验组间差异是否显著

正确做法：预先登记亚组、对子组做多重比较校正、并报告交互项的置信区间而不是"这组显著、那组不显著"。

来源：亚组分析的问题据 Rothwell (2005) 与 Sun et al. (2010)；表述为本讲整理。

双重机器学习：为什么需要它 Double Machine Learning

问题

用 ML 估 nuisance（$E[Y \mid X]$、$E[D \mid X]$）再算效应，会因正则化偏差与过拟合而系统性偏。

两步解法

正交化（残差对残差，去掉 nuisance 的一阶影响）+ 交叉拟合（分折估计、留出折预测）。

本讲实测（帧 89）：朴素 3.85、OLS 调整 2.00、ML plug-in 2.10、DML 1.99（真值 2.0）——DML 把 plug-in 的偏差修了回来。

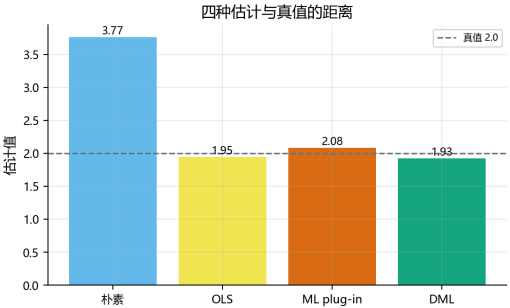
来源：DML 据 Chernozhukov et al. (2018)。

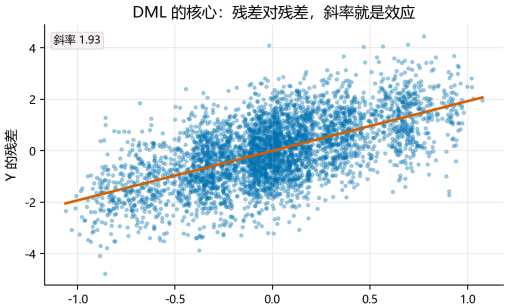
【代码】DML：交叉拟合与残差回归

```python
def dml_partial_linear(yv, dv, Xconf, folds=5, seed=42): # the DML estimator
    kf = KFold(n_splits=folds, shuffle=True, random_state=seed) # the cross-fitting folds
    res_y = np.zeros(len(yv))                              # the residualised outcome
    res_d = np.zeros(len(dv))                              # the residualised treatment
    for train, test in kf.split(Xconf):                    # loop over the folds
        my = GradientBoostingRegressor(random_state=seed, n_estimators=150, max_depth=3).fit(Xconf[train], yv[train]) # E[Y|X]
        md = GradientBoostingRegressor(random_state=seed, n_estimators=150, max_depth=3).fit(Xconf[train], dv[train]) # E[D|X]
        res_y[test] = yv[test] - my.predict(Xconf[test]) # the outcome residual
        res_d[test] = dv[test] - md.predict(Xconf[test]) # the treatment residual
    theta_hat = float((res_d @ res_y) / (res_d @ res_d)) # the residual-on-residual regression
```

实测：朴素 3.85、OLS 调整 2.00、ML plug-in 2.10、DML 1.99（真值 2.0）。交叉拟合是关键。完整程序 `112_09_dml.py`。

【样本 + 可视化】四种估计与真值的距离





左：四种估计的柱状对比，虚线是真值 2.0——ML plug-in 高估，DML 基本对齐；右：DML 的核心操作" 残差对残差"，斜率就是效应，截距自然为 0。

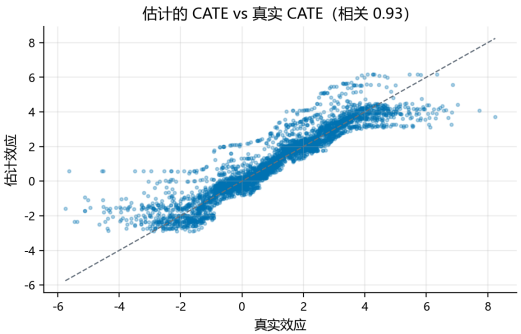
程序 `l12_09_dml.py` ·表 `l12_dml.csv`

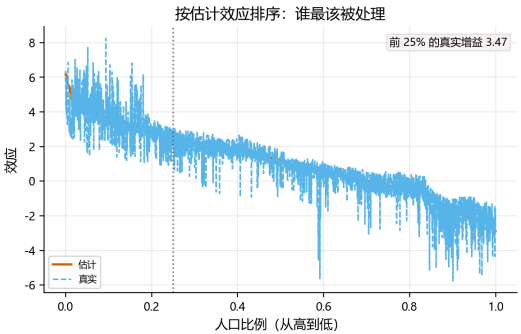
【代码】因果森林（简化版）

```python
def honest_cate(Xv, zv, yv, folds=2, seed=7):          # a lightweight honest forest
    kf = KFold(n_splits=folds, shuffle=True, random_state=seed) # the halves
    tau_hat = np.zeros(len(yv))                        # the estimate per unit
    for train, test in kf.split(Xv):                   # loop over the halves
        m1 = RandomForestRegressor(random_state=seed, n_estimators=120, min_samples_leaf=40).fit(
            Xv[train][zv[train] == 1], yv[train][zv[train] == 1]) # E[Y | X, Z=1]
        m0 = RandomForestRegressor(random_state=seed, n_estimators=120, min_samples_leaf=40).fit(
            Xv[train][zv[train] == 0], yv[train][zv[train] == 0]) # E[Y | X, Z=0]
        tau_hat[test] = m1.predict(Xv[test]) - m0.predict(Xv[test]) # the effect on the held-out half
    return tau_hat                                     # the CATE estimate
cut = np.quantile(tau_hat, 0.75)                       # the 75th percentile
top = tau_hat >= cut                                   # the target group
gain_targeted = float(tau_true[top].mean())             # the true gain if we target
```

实测：估计 ATE 1.115（真值 1.023），corr$(\hat{\tau}, \tau)$ 0.922；按前 25% 定向，真实增益 3.43 vs 全体 1.02。完整程序 `l12_10_causal_forest.py`。

【样本 + 可视化】CATE 分布与定向





左：估计与真实 CATE 高度相关（0.92），但两端有衰减；右：按估计 CATE 排序——前 25% 的真实增益 3.43，远高于全体的 1.02。这就是" 精准投放" 的统计学版本。

程序 l12_10_causal_forest.py ·表 l12_cate_summary.csv

增量与 uplift 建模 Incremental Modelling

uplift 的定义

$\text{uplift}(x) = E[Y \mid Z=1, X=x] - E[Y \mid Z=0, X=x]$——预测的是增量，不是结果。

四象限

必然响应（不推也买）、说服型（推了才买）、勿扰型（推了反而不买）、无响应。

商业上真正想要的是说服型——所以"响应率高的客户"未必是投放对象，甚至可能是勿扰型（衔接 L15 的 incremental 测量）。

来源：uplift 建模据 Radcliffe & Surry (1999) 与 Gutierrez & Gérardy (2017)。

合规与伦理：高风险场景的因果结论

四个要求

可解释（为什么得出这个效应）、可复现（数据与代码）、有边界（识别假设与适用人群）、有治理（谁批、谁签名、怎么回滚）。

高风险场景

信贷、医疗、招聘、司法——在这些场景里，"统计显著"远远不够，还需要公平性审查与因果论证。

这一节直接对应评分表的"数据获取与合规"。用因果语言说相关结论，是一种责任事故。

来源：高风险场景的治理要求据监管实践（如模型风险管理 SR 11-7）与本讲组织。

本讲的十个常见错误 Ten Common Mistakes

1. 把相关当因果（不做 DAG）；
2. 控制了中介或对撞点；
3. 用" 控制了 XX" 当免责声明；
4. 只看 p 值不看效应量；
5. 边做边看、看到显著就停；
6. 测了 20 个指标挑一个；
7. 匹配后不报平衡表；
8. DID 不报事件研究；
9. IV 不报第一阶段 F；
10. 报告效应不说" 是谁的效应"。

自检：这十条覆盖了商业与研究里绝大多数" 看起来有结论、其实站不住" 的情形。

来源：错误清单为本讲整理。

工具栈 Tool Stack

工具	擅长	本讲用在哪
statsmodels	OLS、DID、2SLS 部件、聚类标准误	帧 61、65、88
scikit-learn	倾向得分、GBDT、随机森林	帧 57、88、90
R: fixest	高维固定效应、DID	帧 60–63
R: MatchIt / cobalt	匹配与平衡诊断	帧 56–59
Python: DoWhy / EconML	DAG 检验、DML、CATE	帧 87–92

本讲不新增依赖：DML 与因果森林都用 sklearn 手写，是为了让你看清交叉拟合与 honest 切分到底做了什么；DoWhy/EconML 与 `fixest`/`MatchIt` 是生产环境的选择。

来源：工具分工据各工具文档与本讲实践。

术语表 A–M Glossary A–M

中文	English
A/B 测试	A/B test
AA 测试	AA test
未处理组平均效应	ATU
始终接受者	always-taker
分配机制	assignment mechanism
相关	association
平均处理效应	average treatment effect (ATE)
处理组平均效应	average treatment effect on the treated (ATT)
Bonferroni 校正	Bonferroni correction
后门准则	back-door criterion
带宽	bandwidth
Cornfield 不等式	Cornfield inequality
因果森林	causal forest
因果	causation
聚类随机	cluster randomisation
对撞点	collider
共同支撑域	common support
顺从者	complier
条件平均处理效应	conditional average treatment effect (CATE)
混杂	confounder
一致性	consistency
反事实	counterfactual
交叉拟合	cross-fitting
反抗者	defier
双重差分	difference-in-differences (DID)
因果图	directed acyclic graph (DAG)

中文	English
双重机器学习	double machine learning (DML)
E 值	E-value
生态谬误	ecological fallacy
事件研究	event study
排他性	exclusion restriction
外部有效性	external validity
错误发现率	false discovery rate (FDR)
第一阶段 F	first-stage F
前门准则	front-door criterion
根本问题	fundamental problem of causal inference
健康工人效应	healthy worker bias
异质性处理效应	heterogeneous treatment effect
诚实切分	honest splitting
识别	identification
识别假设	identifying assumption
信息性删失	informative censoring
知情同意	informed consent
工具变量	instrumental variable (IV)
意向性治疗	intention-to-treat (ITT)
局部平均处理效应	local average treatment effect (LATE)
匹配	matching
中介	mediator
最小可检测效应	minimum detectable effect (MDE)
模型治理	model governance
单调性	monotonicity
多重比较	multiple comparisons

本词汇表 A–M 共收录 84 条。各词条"公式与一句话解释"见 `11-glossary.csv`，导站点详见页 1。

术语表 N–Z Glossary N–Z

中文	English
Neyman 正交	Neyman orthogonality
从不接受者	never-taker
不依从	non-compliance
正交化	orthogonalisation
重叠	overlap
平行趋势	parallel trends
完美医生	perfect doctor
潜在结果	potential outcome
倾向得分	propensity score
随机实验	randomised experiment
断点回归	regression discontinuity (RD)
相关性条件	relevance
关联强度	risk ratio
运行变量	running variable
辛普森悖论	Simpson's paradox
选择偏差	selection bias
自选择	self-selection
敏感性分析	sensitivity analysis
序贯检验	sequential testing
SUTVA	stable unit treatment value assumption
标准化差异	standardised difference
统计功效	statistical power
亚组分析	subgroup analysis
合成控制	synthetic control
T-learner	T-learner
处理	treatment
两阶段最小二乘	two-stage least squares (2SLS)
第一类错误	type I error
无混杂	unconfoundedness
增量模型	uplift model
Wald 估计	Wald estimator
弱工具	weak instrument

本组 32 条，全表共 84 条。含符号、公式与一句话解释，见 17_glossary.csv 与站点讲义页。

参考资料与延伸阅读 References

教材

- Angrist & Pischke (2009) *Mostly Harmless*
- Imbens & Rubin (2015) 因果推断
- Pearl (2009) *Causality*
- Hernán & Robins (2020) *What If*

方法论文

- Rosenbaum & Rubin (1983) 倾向得分
- Card (1995); Lee & Lemieux (2010)
- Abadie et al. (2010) 合成控制
- Chernozhukov et al. (2018) DML
- Wager & Athey (2018) 因果森林

读法：先读 Angrist-Pischke 的前五章建立直觉，再读 Imbens-Rubin 补形式化，最后读 Pearl 学 DAG。

来源：文献据各原始来源；读法建议为本讲补充。

一页纸回顾与自检 One-Page Recap



环节	关键数字	一句话
混杂	真 ATE 2.00 vs 朴素 3.83	偏差 1.31
完美医生	真 ATE 1.0 vs 差值 4.0	分配依赖潜在结果
功效	5,000/臂只有 49.6%	样本不足就看不见
匹配	平衡 0.41 $\rightarrow$ 0.05	匹配要报平衡表
DID	-3.000（真 -3）	事件研究前期 $\approx$0
IV	OLS 2.38 / 2SLS 1.45	弱工具会偏
RD	跳跃 $\approx$4.0（真 4.0）	带宽敏感性
LATE	2.02（真 2.0）	ITT / 取用率
DML	1.99（真 2.0）	plug-in 会偏
CATE	前 25% 增益 3.43 vs 1.02	定向的价值

自检十问：你的反事实是什么？假设是什么？怎么检验？对谁有效？

来源：表中数字均来自本讲的 11 个程序（合成数据）。

结语：先问”凭什么能估”

三句话

1. 因果推断的核心是识别，不是算法；
2. 每个方法都在模仿随机化，代价写在假设里；
3. 报告效应要说清是谁的、多大的、多可信。

自检

- 你画 DAG 了吗？
- 你控制了不该控制的吗？
- 你的识别假设能被检验吗？
- 你要多强的混杂才能推翻结论？

谢谢！问题与项目讨论：Xieer.dai@szu.edu.cn；本讲代码、数据与术语表见 website/code/lecture12/。

来源：结语为本讲整理。