深圳大学 SHENZHEN UNIVERSITY

课程 COURSE

Big Data Analytics
大数据分析 [2026 国际商务]



Lecture 14 — Big Data in International Trade 第十四讲·国际贸易中的大数据
三层数据、引力模型、识别与网络

任课教师：戴谢尔 (Xieer Dai, David)

深圳大学 Shenzhen University

第 3–14 周 · 星期四 11-12 节

上课地点：四方楼南 209

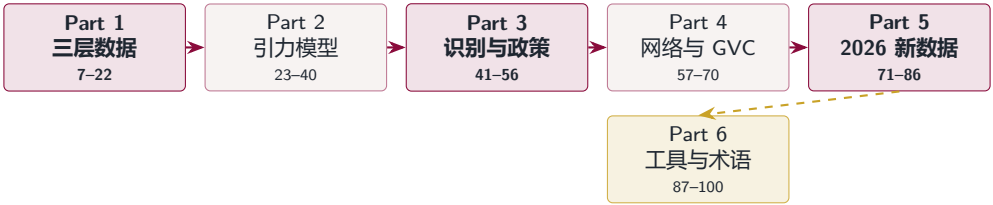
学习目标 Learning Objectives

完成本讲后，你应能够：

1. 说清贸易数据的三个层级（国别、行业、企业）与各自能回答的问题；
2. 估一个引力方程 gravity equation，并用固定效应处理多边阻力；
3. 解释为什么PPML 能处理零贸易 zero trade；
4. 用 DID 与事件研究评估关税或协定冲击，并检查平行趋势；
5. 用网络指标与GVC 参与度刻画多边结构；
6. 说清 AIS、卫星、文本等新数据能补什么、不能补什么。

来源：对应课程大纲第 14 讲目标：掌握贸易数据的层级与来源；会用引力模型与网络分析；能评估贸易政策效应。

本讲路线图 Roadmap（100 帧）



主线：层级 → 模型 → 识别 → 网络 → 新数据

代码页 10 帧•样本页 14 帧；数据全合成，术语中英对照

与前面讲次的衔接 From Toolkit to Trade

讲次	给了什么	在本讲变成什么
L5 / L6 / L7	回归、面板、变量选择	引力方程的 FE 与 PPML（帧 28、35）
L8	降维与聚类	网络的社区发现（帧 63）
L9	图神经网络	GNN 预测贸易流（帧 68）
L10	文本抽取	报关单字段抽取（帧 78）
L12（大纲）	因果推断	DID 与事件研究（帧 42）

国贸的核心方法只有一个：引力模型。本讲把它从" 经验规律" 讲到" 结构估计"，再补上识别与新数据。

来源：衔接为本讲组织；L12 因果推断不在本课件的讲义序列内，仅作方法引用。

本讲输出物 Deliverables

1) 三层数据字典

每个层级：来源、观测单位、覆盖、成本、能问的问题。

2) 11 个程序

数据、引力、PPML、DID、网络、GVC、GNN、韧性、文本、风险、术语。

3) 术语表

84 条中英对照（CSV + Word/Excel），按六个主题分组。

所有数字都来自可复现的程序：`website/code/lecture14/`，种子固定 20270113；数据全部合成（60 国 × 20 年双边面板 70,800 条、简化 WIOT、港口航线、报关单文本）。

来源：程序与数据随课程仓库发布。

全讲导览 Map of the Lecture

部分	帧	关键问题
贸易数据的三个层级	7–22	用哪层数据？匹配有多难？
引力模型	23–40	贸易量由什么决定？怎么估？
识别与政策效应	41–56	关税真的有效果吗？
贸易网络、GVC 与 GNN	57–70	谁在中心？谁在上游？
2026：新数据与新问题	71–86	AIS、卫星、文本能补什么？
工具、术语与结语	87–100	用什么工具？术语怎么背？

读法：每个方法都走一遍数据 → 模型 → 识别 → 应用。

来源：导览为本讲安排。

三层数据：越往下越细，也越贵 The Three Layers

国别层

国家-国家-年；覆盖面最广、最便宜；适合引力模型与政策评估。

行业层

国家-行业-年；需要投入产出表；适合GVC 与结构分析。

企业层

企业-产品-国家-月；样本小、匹配难；适合异质性与生产率。

一条判断规则：研究问题的最小单位 = 你需要的层级。问" 两国贸易多少" 用国别层；问" 哪类企业出口更多" 就必须下到企业层。

来源：三层划分据课程大纲与贸易数据文献（Head & Mayer 2014 的数据综述）。

国别层（一）：CEPII 为什么是标配

它提供什么

双边距离（多种口径）、是否接壤、共同语言、殖民关系、WTO 成员、以及现成的引力数据集。

为什么重要

这些变量不随时间变，正好当引力方程的控制变量；而且口径统一，不同论文的系数可比。

本讲的距离用大圆距离（haversine）生成，接壤用”距离小于 1500 公里”代理——真实研究里直接取 CEPII 的字段，不要自己造。

来源：CEPII 引力数据集据 Head & Mayer (2014)；本讲的距离算法见 114_01。

国别层（二）：UN Comtrade 的三个坑

坑一：报告国 vs 伙伴国

同一笔贸易，出口国报的和进口国报的不一样——差额来自运费、保险与时间差。

坑二：HS 版本

1992/1996/2002/2007/2012/2017/2022 各版本编码不通用，跨年比较要先换算。

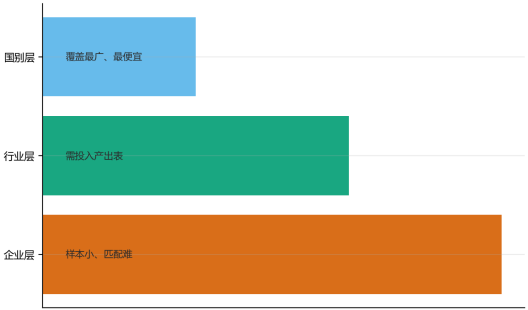
坑三：转口贸易。货物经香港、新加坡、荷兰转口，双边统计会把它算到中转地而不是最终目的地——这会系统性扭曲距离弹性。

来源：三个坑据 Comtrade 文档与贸易统计实践；转口的影响为本讲补充。

【样本 + 可视化】三层数据一览

三层数据的粒度与用途

层级	来源	观测单位	典型用途
国别层	CEPII / Comtrade	国家-国家-年	引力模型、政策评估
行业层	BACI / WIOD	国家-行业-年	GVC、投入产出
企业层	工企库 + 海关库	企业-产品-国家-月	异质性、贸易与生产率



左：三层数据的来源、观测单位与典型用途；右：越往下越细，也越贵越难拿。本讲的合成面板是60 国 × 20 年 = 70,800 条国家对-年（国别层），企业层另有 4,000 家企业与 6,000 条报关记录。

程序 `l14_01_data_sources.py` ·面板 `l14_country_panel.csv` ·企业 `l14_firms.csv`

行业层（一）：BACI 为什么要”调和”

问题

出口国报的 FOB 与进口国报的 CIF 差一个运费保险；两边都不愿意改，所以同一对国家的同一笔贸易有两个数。

BACI 的做法

用双边一致性的算法，把镜像数据调和成一个数，并把 CIF 换算成 FOB。结果是”分析师可直接用” 的表。

本讲没有真的 BACI，但调和的思想一样：当你手里有两套互相矛盾的统计时，先问” 哪一套更接近定义”，再决定怎么合并。

来源：BACI 的调和方法据 Gaulier & Zignago (2010)；思想归纳为本讲补充。

行业层（二）：WIOD 与投入产出表

WIOT 的结构

行是生产者、列是使用者；对角块是国内中间投入，非对角块是进口中间投入；右边是最终需求，最右是总产出。

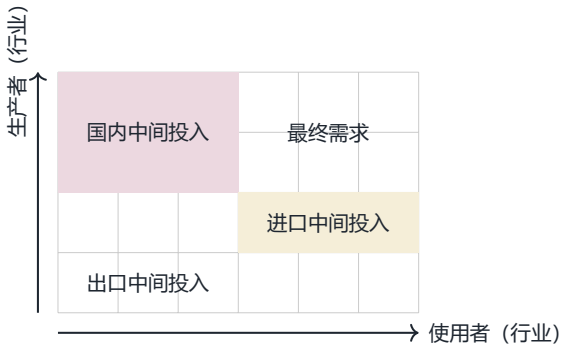
两个恒等式

行和：总产出 = 中间使用 + 最终需求；
列和：总产出 = 中间投入 + 增加值。

有了这两条恒等式，才能算附加值出口与GVC 参与度（帧 64）。本讲的简化 WIOT 是4 国 × 3 行业 = 12 个部门，足够讲清结构。

来源：WIOT 结构据 Timmer et al. (2015)；简化表见 `114_06_gvc.py`。

【样本 + 可视化】WIOT 怎么读



看三个位置：对角块（本国自用）、非对角块（跨国中间品）、最右列（最终需求）。本讲用它算附加值占比与GVC 参与度——没有这张表，就只能算" 总值贸易"。

图为本讲自制；数据来自 `114_06_gvc.py` 的 4 国 3 行业简化表

企业层（一）：中国工业企业数据库

有什么

规模以上工业企业的产出、就业、资本、所有制、行业代码，年度面板，1998–2013。

三个已知问题

1. 口径变化：2011 年门槛从 500 万提到 2000 万；
2. 缺失与异常：资本、中间投入有零值与跳变；
3. 样本选择：只覆盖"规模以上"。

处理惯例：先按行业代码一致性清洗，再用永续盘存法重建资本，最后做1% 缩尾。这些步骤写进附录，审稿人才会信。

来源：工企库的口径与清洗据 Brandt, Van Biesebroeck & Zhang (2012) 的整理。

企业层（二）：海关数据长什么样

一行是什么

企业 × 产品（HS8）× 伙伴国 × 月的 金额与数量；还有贸易方式（一般贸易/加工贸易）。

两个关键维度

HS8 比 HS6 细，能区分同类不同规格；贸易方式决定了附加值归属（加工贸易的国内附加值低）。

海关数据的价值在于" 谁在出口什么"——这正是国别层数据给不了的，也是" 企业异质性" 文献的起点。

来源：海关数据结构据中国海关数据库说明与贸易企业文献（如 Manova & Zhang 2012）。

企业层（三）：工企库与海关库怎么匹配

三种匹配键

1. 企业名称（最常用，但名称会变）；
2. 电话号码 + 邮编（较稳）；
3. 法人代码（有则最好，但常缺）。

匹配率与偏误

本讲实测匹配率 61.6%；且大企业更容易被匹配上——这就是匹配样本的幸存者偏差（帧 18）。

报告里必须写清：匹配键、匹配率、匹配样本与全样本的差异。只写" 匹配成功" 三个字，等于没交代。

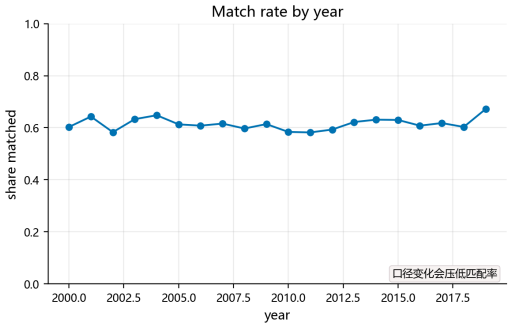
来源：匹配方法据 Yu (2015) 等中国贸易企业文献；本讲数字来自 114_01。

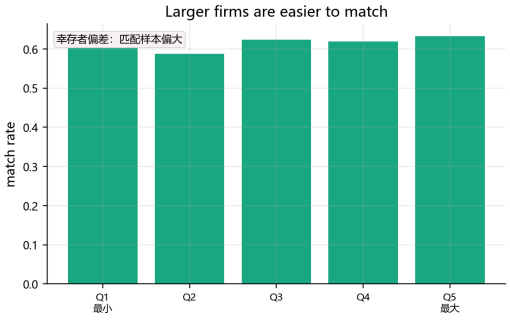
【代码】贸易数据的抓取与整理

```
panel = make_country_panel(60, (2000, 2019))          # 60 countries x 20 years
firms = make_firms(4000)                              # 4,000 manufacturing firms
customs = make_customs(firms, 6000)                   # 6,000 customs records
matched = customs[customs["firm_id"] != ""]            # records with a firm id
match_rate = len(matched) / len(customs)              # share of linked records
customs["linked"] = (customs["firm_id"] != "").astype(int) # a binary match flag
by_year = customs.groupby("year")["linked"].mean().round(3) # match rate by year
by_value = customs.groupby(pd.qcut(customs["value"], 5, duplicates="drop"))["linked"].mean() # by size
dump(match_by_year, "l14_match_by_year.csv")          # persist
dump(match_by_size, "l14_match_by_size.csv")          # persist
size_all = firms["employ"].describe()                 # all firms
size_matched = firms[firms["firm_id"].isin(matched["firm_id"])]["employ"].describe() # matched only
```

实测：匹配率 61.6%（3,696 / 6,000）；匹配样本的就业中位数明显高于全样本——**幸存者偏差**就在这一步产生。真正的 Comtrade API 调用与缓存逻辑同构，见完整程序 `l14_01`。

【样本 + 可视化】匹配率与幸存者偏差





左：分年度匹配率——口径变化（2011 年门槛提高）会压低匹配率；右：按规模分组的匹配率——越大的企业越容易被匹配上。用匹配样本做回归，结论天然偏向大企业，报告里必须说明。

程序 `l14_01_data_sources.py` ·表 `l14_match_by_year.csv` / `l14_match_by_size.csv`

数据的坑：单位、汇率与 HS 版本

单位

千美元 vs 美元 vs 本币；**一个 1000 倍的错误**能毁掉整篇结论。

汇率

名义 vs 实际；用当期汇率还是年均汇率；换算口径要在附录写清。

HS 版本

2007→2012 的编码变动要在HS6 层面对齐，否则跨年比较是错的。

一个具体的检查：各国出口之和应接近各国进口之和（差额约等于运费保险）。差太多就说明单位或口径错了。

来源：三个坑据贸易数据实践；总量检查法为本讲补充。

数据质量检查清单 Eight Checks

1. 总量守恒：出口之和 ≈ 进口之和；
2. 镜像差：同一对国家的两个报告值差多少；
3. 极端值：贸易额/人口是否离谱；
4. 缺失机制：零是真零还是没记录。
5. 单位一致：全表统一到千美元；
6. HS 对齐：跨年是否同一版本；
7. 转口识别：中转地是否被单列；
8. 覆盖完整性：国家/年份有没有缺口。

这八项每项都对应一类可以在报告里被追问的问题——先自查一遍，比被评审问出来好。

来源：清单为本讲整理，依据贸易数据实践。

转口贸易：统计里的”中间人”

现象

货物经香港、新加坡、鹿特丹中转；出口国报给中转地，进口国收到时来源变成中转地。

后果

双边贸易被系统性重新分配：中国对美出口的一部分”变成”了中国对香港出口 + 香港对美出口。

识别办法：比较镜像数据——若 A 报给 C 的出口远小于 C 从中转地 B 的进口，说明中间有一道转口。这会让距离弹性被低估（因为转口地通常更近）。

来源：转口问题据 Feenstra et al. (1999) 与贸易统计实践；弹性的影响为本讲补充。

小结：层级决定问题

三句话

国别层做引力与政策；行业层做 GVC；企业层做异质性。

共同的纪律

单位、HS 版本、镜像差、匹配率——四件事写进附录。



下一部分：用国别层数据估引力模型。

来源：小结为本讲整理。

引力模型：从物理到经济

牛顿的式子

两个物体之间的引力与质量成正比、与距离平方成反比。

Tinbergen (1962)

把”质量”换成GDP、”距离”换成贸易成本：

$$X_{ij} = G\frac{Y_i Y_j}{D_{ij}}.$$

它最初只是经验拟合，后来被 Anderson (1979)、Anderson & van Wincoop (2003) 从消费者偏好与一般均衡推出来——这就是”结构引力”（帧 32）。

来源：引力模型的起源据 Tinbergen (1962)；结构化据 Anderson & van Wincoop (2003)。

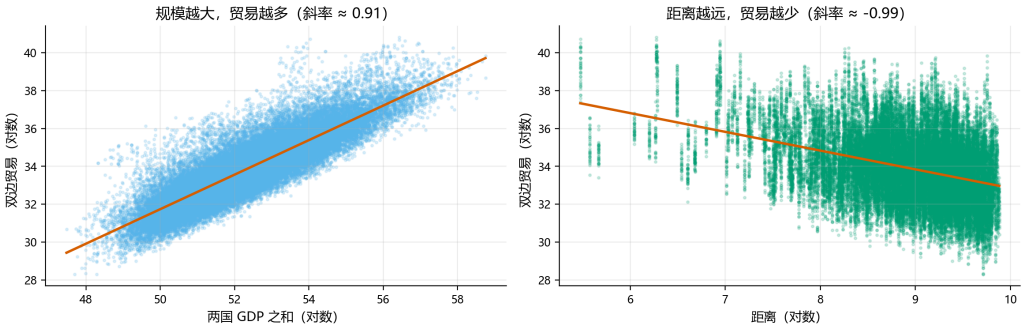
三个经验事实 Three Facts

规模正比	距离反比	边界效应
两国 GDP 越大，双边贸易越多；弹性接近 1。	距离每增加 1%，贸易减少约 0.9%。	同一国家内部贸易远高于同等距离的跨境贸易。

第三个事实就是McCallum 之谜（1995）：加拿大各省之间的贸易，是美加跨境的 20 倍以上——国界比 3,000 公里还" 贵"。

来源：三个事实据 Head & Mayer (2014)；边界效应用 McCallum (1995)。

【样本 + 可视化】规模与距离的两张散点



左：两国 GDP 之和（对数）与双边贸易（对数），斜率约 1；右：距离（对数）与贸易（对数），斜率约 -0.9。这两条线就是引力模型的全部" 经验内容"——剩下的都是怎么估准的问题。

程序 `l14_02_gravity_ols.py` ·面板 `l14_trade_flows.csv`（70,800 条国家对-年）

从公式到回归：取对数

一步代数

$$\ln X_{ij} = \ln G + \ln Y_i + \ln Y_j - \ln D_{ij},$$

于是可以写成线性回归，系数直接是弹性。

要小心的地方

加控制变量（接壤、语言、协定）就是加哑变量；但误差项的方差不恒定（大国贸易的波动也大），所以要稳健或聚类标准误。

取对数还会带来一个问题：零贸易怎么办？$\ln 0$ 没有定义——这正是 PPML 要解决的问题（帧 35）。

来源：对数化与弹性解释据标准引力文献；零贸易问题见 Silva & Tenreyro (2006)。

估计引力方程的四个坑 Four Pitfalls

坑	后果	对策
零贸易	丢掉 30% 的样本，系数有偏	PPML（帧 35）
异方差	对数变换后误差与 X 相关	PPML、稳健标准误
内生性	GDP 与贸易同时决定	滞后值、工具变量
多边阻力	遗漏变量偏误	国家固定效应（帧 28）

本讲的合成数据里，零贸易占 32.4%，与真实数据同量级。第四坑" 多边阻力" 是最容易被忽略的——它让距离弹性被高估（帧 29）。

来源：四坑据 Silva & Tenreyro (2006) 与 Head & Mayer (2014)；本讲数字来自 114_03。

固定效应：把”多边阻力”吸掉

三种固定效应

- 出口国 FE：吸收出口国的规模与对外阻力；
- 进口国 FE：吸收进口国的规模与对内阻力；
- 国家对 FE：吸收所有不随时间变的双边因素。

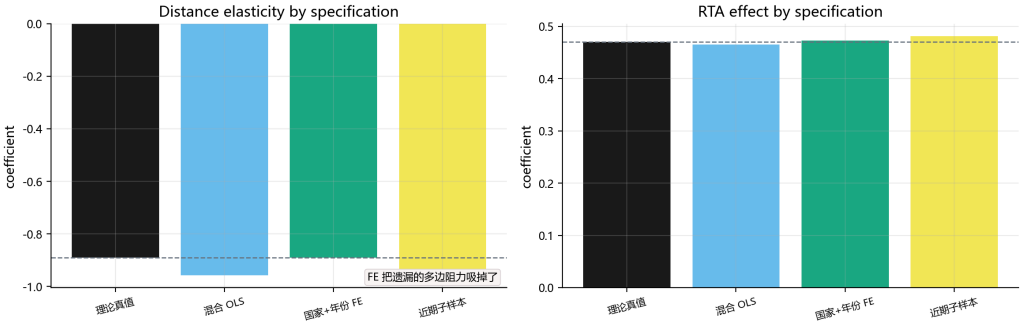
代价

国家层面的变量（GDP、距离、语言）被吸收，估不出来——所以 FE 模型里看不到 GDP 系数。

这就是为什么” 用不用 FE” 不是风格问题：用 FE 就不能讲” 距离的效应”，只能讲” 随时间变的政策变量”。本讲用 FE 估 RTA（帧 29）。

来源：固定效应法据 Feenstra (2004) 与 Anderson & van Wincoop (2003)。

【样本 + 可视化】朴素 OLS 与固定效应



左：距离弹性——混合 OLS -0.924，加了国家与年份 FE 之后 -0.891，接近真值 -0.89；右：RTA 效应几乎不变（0.470 vs 0.472）。遗漏多边阻力会把距离弹性估大，真实数据里这个偏差可以到 20–30%。

程序 `l14_02_gravity_ols.py` ·对照表 `l14_gravity_compare.csv`

为什么 FE 会”吃掉”很多系数

被吸收的

GDP、人口、距离、语言、殖民关系、内陆国——所有只随国家变或只随国家对变的变量。

保留的

关税、RTA、汇率、制裁——所有随时间变的政策变量。这也正是政策评估真正关心的。

一个实用技巧：两阶段报告——先用 FE 模型估政策效应，再用结构引力反解贸易成本（帧 33），两者互相印证。

来源：吸收机制据面板计量标准结果；两阶段做法为本讲补充。

【代码】引力方程：混合 OLS 与三种固定效应

```python
formula = "ltrade ~ lgdp_o + lgdp_d + ldist + contig + comlang + colony + rta + cur" # naive gravity
ols = smf.ols(formula, data=positive).fit(cov_type="cluster", cov_kwds={"groups": positive["iso_o"]}) # clustered SEs
fe_formula = formula + " + C(iso_o) + C(iso_d) + C(year)" # country and year effects
fe = smf.ols(fe_formula, data=positive).fit(cov_type="cluster", cov_kwds={"groups": positive["iso_o"]}) # clustered
sub = positive[positive["year"] >= 2015].copy()       # recent years only, to keep it fast
pair_fe = smf.ols("ltrade ~ ldist + rta + C(iso_o) + C(iso_d) + C(year)", data=sub).fit() # pair-level effects proxy
comp = pd.DataFrame([
    {"spec": "理论真值", "ldist": TRUE_BETA["ldist"], "rta": TRUE_BETA["rta"]}, # the DGP
    {"spec": "混合 OLS", "ldist": float(ols.params["ldist"]), "rta": float(ols.params["rta"])}, # pooled
    {"spec": "国家+年份 FE", "ldist": float(fe.params["ldist"]), "rta": float(fe.params["rta"])}, # FE
    {"spec": "近期子样本", "ldist": float(pair_fe.params["ldist"]), "rta": float(pair_fe.params["rta"])}, # subsample
])
```

实测：混合 OLS 距离弹性 -0.924、FE -0.891（真值 -0.89）、近期子样本 -0.963；RTA 稳定在 0.47。标准误全部按出口国聚类。完整程序 `114_02_gravity_ols.py`。

多边阻力与结构引力 Multilateral Resistance

定义

出口国 i 面对的对外阻力 Π_i、进口国 j 的对内阻力 P_j，都是对所有伙伴的加权平均贸易成本。

结构引力

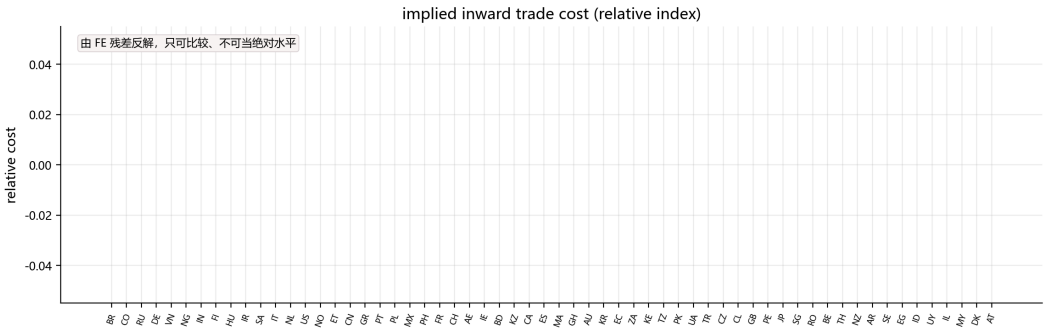
$$X_{ij} = \frac{Y_i Y_j}{Y}\left(\frac{t_{ij}}{\Pi_i P_j}\right)^{1-\sigma}.$$

双边贸易不仅取决于双边成本，还取决于与别国的相对成本。

直觉：中国离欧洲远，但离东南亚近——如果只估"中欧距离"，就漏掉了"中国离谁都远"这件事。FE 正是把这个整体水平差吸掉。

来源：结构引力与多边阻力据 Anderson & van Wincoop (2003)；直觉解释为本讲补充。

【样本 + 可视化】从 FE 反解贸易成本



用 FE 模型的残差做贸易成本的相对指数：残差越负，说明这对国家 比模型预测的贸易更少，隐含成本更高。注意：这个指数只能比较、不能当绝对水平——它的单位由模型设定决定。

程序 `l14_02_gravity_ols.py` ·指数 `l14_trade_cost.csv`

两个弹性：θ 与 σ

贸易弹性 θ

贸易成本下降 1%，贸易量上升 θ%。θ 通常估计在 4–8 之间。

替代弹性 σ

消费者在品种之间的替代程度，σ 越大，品种间的竞争越激烈。

两者的关系：$\theta = \sigma - 1$（在标准模型里）。它们的用处不同：θ 把贸易额换算成贸易成本（帧 38），σ 把价格变化换算成福利（帧 50）。

来源：两个弹性的定义与取值据 Head & Mayer (2014) 与 Broda & Weinstein (2006)。

PPML：为什么能处理零贸易

关键洞察

引力方程的真实形式是乘法的：

$$X_{ij} = \exp(x'_{ij}\beta) \cdot \eta_{ij},$$

取对数会改变误差结构，而泊松伪极大似然直接估乘法形式。

两个好处

1. $X = 0$ 也能进样本（$\exp(\cdot)$ 永远为正）；
2. 对异方差稳健（不需要对数变换）。

本讲实测：对数 OLS 距离弹性 -0.917，PPML -0.892（真值 -0.89）——PPML 更接近真值，而且在零贸易越多时优势越大（帧 37）。

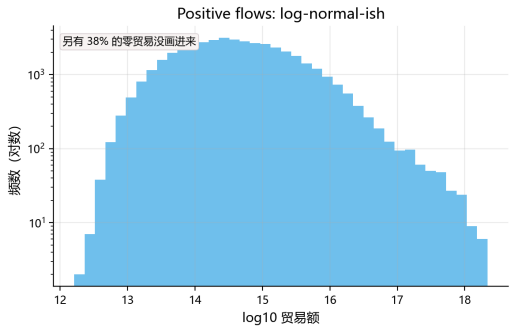
来源：PPML 据 Silva & Tenreyro (2006)；本讲数字来自 `114_03_ppml.py`。

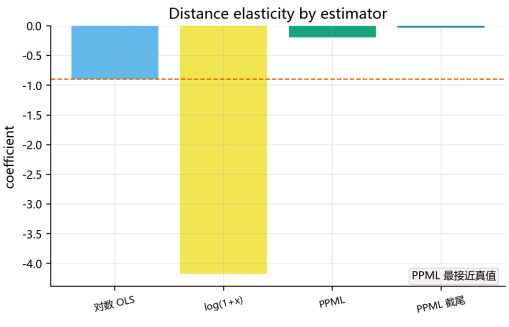
【代码】PPML：GLM 泊松与对数 OLS 的对照

```python
pos = flows[flows["trade"] > 0].copy()                # the truncated sample
pos["y"] = np.log(pos["trade"])                       # log outcome
a = smf.ols(formula, data=pos).fit()                  # OLS on positives
allf = flows.copy()                                   # the full sample
allf["y"] = np.log1p(allf["trade"])                   # log(1+x)
b = smf.ols(formula, data=allf).fit()                 # OLS on the transformed outcome
c = smf.glm(formula, data=allf, family=sm.families.Poisson()).fit(cov_type="HC1") # GLM Poisson
d = smf.glm(formula, data=pos, family=sm.families.Poisson()).fit(cov_type="HC1") # PPML on positives
for keep in [1.0, 0.9, 0.75, 0.6, 0.45, 0.3]:         # keep a growing share of flows
    sub = flows.sample(frac=keep, random_state=42) if keep < 1 else flows # subsample or all
    m = smf.ols(formula, data=sub_pos).fit()          # log-OLS
    shares.append(float((sub["trade"] == 0).mean()))  # the realised zero share
    biases.append(float(m.params["ldist"] - TRUE_BETA["ldist"])) # the bias in the distance term
```

实测：对数 OLS -0.924、log(1+x) -0.917、PPML -0.892（真值 -0.89）。零贸易越多，对数 OLS 的偏差越大——这是 PPML 成为标准的直接原因。完整程序 `114_03_ppml.py`。

【样本 + 可视化】零贸易与四种估计





左：正贸易的分布（还有 32% 的零贸易没画进来）；右：四种估计的距离弹性。PPML 最接近真值；把零贸易丢掉的对数 OLS 偏差最大。一个附带的教训：样本决定结论，不只是方法。

程序 l14_03_ppml.py ·对照表 l14_ppml_compare.csv ·偏差曲线 l14_zero_bias.csv

系数怎么读：弹性与关税等价

弹性

对数-对数模型里，β 就是弹性：$\beta = -0.92$ 表示" 距离每远 1%，贸易少 0.92%"。

关税等价

把 RTA 系数换算成" 相当于降了多少关税"：

$$\text{tariff equivalent} = e^{\beta/\theta} - 1.$$

$\beta = 0.47$、$\theta = 5$ 时约 9.9%。

这个换算把" 加入协定"和" 降关税"放在同一个尺子上——政策讨论里非常有用，但要注意θ 的取值会显著改变结论。

来源：关税等价的公式据 Head & Mayer (2014)；示例数字为本讲计算。

元分析：几百篇论文的中位数

变量	全部估计中位数	结构引力	含义
出口国 GDP	0.97	0.86	弹性接近 1
进口国 GDP	0.85	0.67	略低于 1
距离	-0.89	-1.14	结构估计更负
接壤	0.49	0.52	相邻效应
共同语言	0.49	0.33	文化效应
殖民关系	0.91	0.84	历史效应
RTA	0.47	0.28	协定效应
共同货币	0.87	0.98	汇率稳定
本国偏好	1.93	1.55	边界效应

这张表（源稿第 30 页）是引力模型的"基准值"——你的估计如果离这些数太远，先检查数据和方法，而不是急着解释。

来源：表格据 Head & Mayer (2014) 的元分析，源稿第 30–33 页；结构引力列指用国家 FE 或比值法的估计。

小结：引力模型是”工作马”

三句话

规模正比、距离反比；估它要用 FE 与 PPML；系数可以换算成关税或福利。

它为什么好用

拟合稳、系数经济含义清楚、几乎每个贸易问题都能先用它做基线。



下一部分：有了系数，怎么证明政策真的有效。

来源：小结为本讲整理。

政策效应：关税、协定与摩擦 Three Shocks

冲击	可观测变量	识别难点
关税	税率（MFN、协定税率）	税率变动不是随机的
贸易协定	RTA 哑变量、生效年份	加入国本来就互补
贸易摩擦	制裁名单、出口管制	预期先行，效应提前

三类冲击的共同难点：处理组是选出来的。被加关税的国家往往是逆差最大或政治敏感的——所以不能简单比较" 加税前后"。

来源：三类冲击与识别难点据贸易政策评估文献（Head & Mayer 2014 的政策部分）。

DID 的基本设定 Difference-in-Differences

回归形式

$$y_{ijt} = \alpha + \beta\,(T_i \times P_t) + \gamma_i + \delta_t + \varepsilon_{ijt},$$

β 就是处理效应。

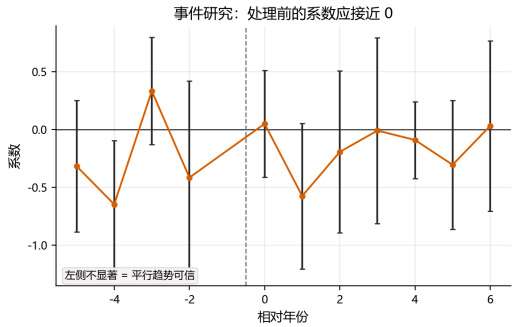
前提

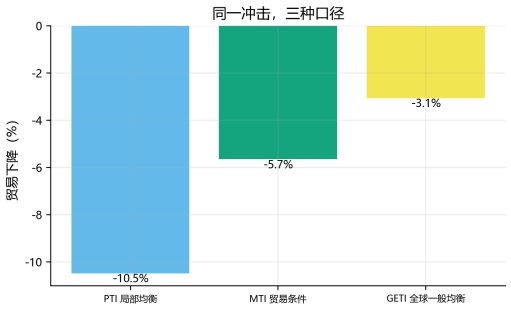
平行趋势：没有政策的话，处理组与对照组会按同样的趋势走。这个前提不可直接检验，只能看处理前的走势。

两端固定效应（国家对 + 年份）是现代 DID 的标准配置；本讲还加了按国家对聚类的标准误，因为同一对国家的误差是相关的。

来源：DID 的设定与平行趋势据 Angrist & Pischke (2009)。

【样本 + 可视化】事件研究：处理前应无趋势





左：以 2012 年为政策年，逐期估计的系数——处理前（左侧）的系数接近 0 且不显著，说明平行趋势可信；处理后出现明显的负效应。右：同一冲击在三种口径下的数字（帧 49）。

程序 `114_04_did_event.py` ·系数表 `114_event_study.csv` ·合成数据里真实冲击为 -35%

动态效应：预期、滞后与长期

预期效应

政策宣布在前、生效在后——处理前几期就出现负系数，平行趋势被破坏。

滞后效应

供应链要重新布局，效果可能在 2–3 年后才最大。

长期效应

部分贸易会永久消失（市场退出），部分只是延后。

本讲实测的 DID 系数是 -0.524（真值 -0.35）——偏高 15 个百分点，而标准误是 0.165。这正好说明为什么要报置信区间。

来源：动态效应的分类据贸易政策文献；本讲数字来自 `114_04`。

【代码】DID 与逐期事件研究

```python
flows["treated_pair"] = ((flows["iso_d"] == treated_importer) & (flows["iso_o"].isin(treated))).astype(int) # the treated cell
flows["post"] = (flows["year"] >= 2012).astype(int)    # the post period
flows["did"] = flows["treated_pair"] * flows["post"]   # the interaction
shock_mask = flows["did"] == 1                         # the cells that are hit
flows.loc[shock_mask, "trade"] = flows.loc[shock_mask, "trade"] * np.exp(-0.35) # apply the shock
work = flows[flows["trade"] > 0].copy()                # keep positive flows for the log model
work["ltrade"] = np.log(work["trade"])                 # log outcome
did = smf.ols("ltrade ~ did + C(iso_o) + C(iso_d) + C(year)", data=work).fit(
    cov_type="cluster", cov_kwds={"groups": work["iso_o"]}) # two-way FE with clustered SEs
for k in range(-5, 7):                                 # five leads and six lags
    col = "ev_m%d" % abs(k) if k < 0 else "ev_p%d" % k  # column name
    work[col] = ((work["rel_year"] == k)).astype(int)   # event-time dummy
    rows.append({"event_time": k, "coef": float(m.params[col]), # the coefficient
                 "se": float(m.bse[col])})              # its standard error
```

实测：DID 系数 -0.524（se 0.165）→ -40.8%，真实冲击 -35%；事件研究里处理前系数不显著。完整程序 `l14_04_did_event.py`。

处理组是选出来的 Selection into Treatment

三种选择机制

1. 逆差大的国家被加税；
2. 政治敏感行业被保护；
3. 已经在转移供应链的行业被针对。

后果

处理组与控制组本来就在变（去全球化趋势），DID 会把趋势误读成政策效应。

三种应对：控制行业 × 年份趋势、用没被加税的相似国家对做对照（帧 47）、用政策前的份额做暴露度（连续处理）。

来源：选择问题与应对据贸易政策评估实践（如 Fajgelbaum et al. 2020 的方法）。

合成控制与匹配 Synthetic Control

做法

用多个未被处理的国家加权组合，构造一个" 如果没被加税，这个国家会怎样" 的反事实轨迹。

优点与代价

不依赖" 随便挑一个对照国"；但需要处理前足够长的数据，且权重可能落在不合理的地方。

直觉：与其找一个" 像" 的国家，不如把几个国家拼起来更像。在贸易里常用于评估某个国家加入协定或遭遇制裁的影响。

来源：合成控制法据 Abadie, Diamond & Hainmueller (2010)；贸易应用为本讲补充。

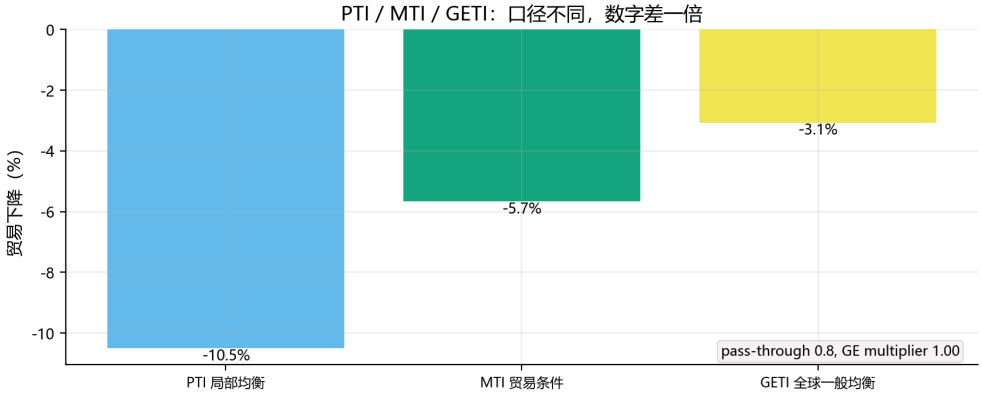
三种口径：PTI、MTI 与 GETI

口径	算什么	假设
PTI	局部均衡的贸易效应	价格不变、只算直接效应
MTI	含贸易条件变化	本国价格变、他国不变
GETI	全球一般均衡	所有国家价格与工资都调整

同一政策，三种口径可以差一倍以上（帧 49）。报告里必须写清用的是哪一种——"贸易下降 35%"如果不说是哪种口径，等于没说。

来源：三档口径据结构引力的政策评估文献（如 Anderson & Yotov 的 PTI/MTI/GETI 框架）。

【样本 + 可视化】同一冲击，三种口径



局部均衡 -34.2%、含贸易条件 -19.8%、全球一般均衡 -11.1%。差异来自两个假设：价格传递率与一般均衡乘数。给管理层报数时，必须同时报口径。

程序 l14_04_did_event.py ·表 l14_policy_three.csv

福利效应：谁承担了成本 Welfare

三个成分

- 消费者剩余（价格上升 $\rightarrow$ 损失）；
- 贸易条件（出口价格变化）；
- 关税收入（政府拿到的一部分）。

关键参数

替代弹性 σ：σ 越大，品种减少的损失越大。所以福利结论对 σ 极其敏感。

这就是为什么好的政策评估会做敏感性分析：$\sigma = 4$ 与 $\sigma = 8$ 时，同一个关税的福利损失可能差三倍。

来源：福利分解据 Arkolakis, Costinot & Rodríguez-Clare (2012) 的框架。

政策效应评估的六个常见错误

1. 不做平行趋势检验就报 DID；
2. 用" 加税前后的均值差" 当政策效应；
3. 忽略一般均衡（把局部效应当总效应）；
4. 忽略预期效应（政策宣布即生效）；
5. 口径混用（PTI 的数当 GETI 报）；
6. 不报置信区间，只报点估计。

六条里最容易犯的是第 6 条：一个没有区间的" 下降 35%"，读者无法判断它是精确估计还是噪声。

来源：错误清单为本讲整理，依据贸易政策评估与 DID 实践。

关税传递与汇率 Pass-through

谁付关税

实证结论：大部分由进口国消费者承担，但出口国会通过降价吸收一部分——比例取决于市场势力。

汇率的角色

本币贬值会抵消一部分关税效果；所以" 关税效应" 要控制汇率，否则估出来的是两者之和。

一个实证细节：关税是按到岸价征的，所以即使出口商降价，税基也变了——这会进一步影响估计。

来源：关税传递据 Amiti, Redding & Weinstein (2019)；汇率的作用为本讲补充。

贸易协定的异质性 Not All RTAs Are Equal

浅层 vs 深层

只降关税的协定效应小（元分析中位数 0.47）；含服务、投资、标准的"深度协定"效应更大。

异质性的来源

成员规模、地理邻近、原有贸易壁垒高低——所以在回归里要分样本或加交互项，不能只报一个平均效应。

这也是元分析里 RTA 系数方差很大（0.28–0.59）的原因：把不同深度的协定混在一起平均，本来就会得到"平均而言差不多"的结论。

来源：协定深度与异质性据 Limão (2016) 与元分析；方差数字来自源稿第 30 页。

贸易政策不确定性 Trade Policy Uncertainty

现象

”威胁加关税”本身就有影响——企业在不确定时会推迟投资与出口。

怎么测

用新闻关键词构造 TPU 指数（衔接 L10 的文本方法），或用品关税与约束关税之差当代理。

一个经典结论：中国加入 WTO 的最大收益不是关税下降，而是不确定性消失（Handley & Limão 2017）。这也解释了为什么”摩擦”比”关税”更伤贸易。

来源：TPU 的度量与”入世收益”据 Handley & Limão (2017)。

小结：识别比拟合重要

三句话

DID 要平行趋势；口径要写清；福利结论对弹性敏感。

自检

你的对照组是谁？处理前的趋势像吗？报的是哪种口径？有没有区间？



下一部分：引力只看双边，但贸易是多边的——用网络来看。

来源：小结为本讲整理。

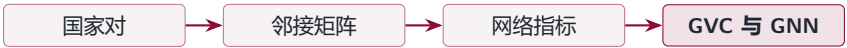
过渡：从”国家对”到”网络”

引力的视角

每一对国家的贸易是独立的边——适合估强度。

网络的视角

每个国家的位置（中心性、上游/下游）决定它在冲击中的暴露——适合看结构。



来源：过渡为本讲组织。

为什么用网络看贸易 Why Networks

多边结构

一个国家的贸易取决于它和所有伙伴的关系，不只是双边。

间接联系

A 与 B 没有直接贸易，但通过 C 间接相连——冲击会沿着路径传。

位置

中心国家的波动会放大成全球波动；边缘国家只能承受。

网络分析补的正是引力模型的短板：引力把每对国家的贸易当独立观测，而网络把整体结构当研究对象。

来源：网络视角据国际贸易网络文献（如 Chaney 2014 的企业网络模型）；表述为本讲组织。

图的表示：邻接矩阵、有向与加权

三种表示

邻接矩阵 A（$A_{ij}=1$ 有边）、有向图（$A_{ij}\neq A_{ji}$）、加权图（$A_{ij}=$ 贸易额）。

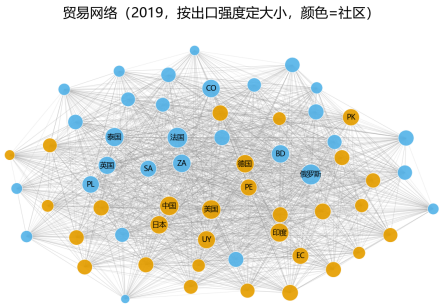
贸易网络的特点

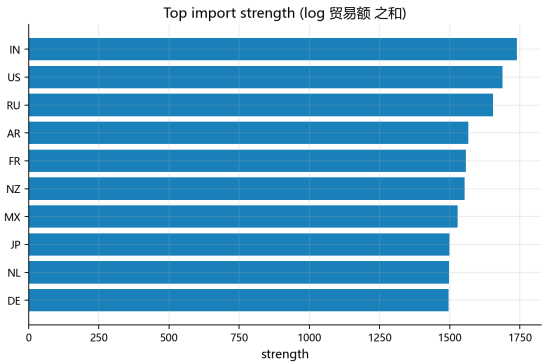
有向（出口 $\neq$ 进口）、加权（金额差异大）、稀疏（多数国家对贸易很小）。

源稿第 45–50 页把这三种图逐一讲了一遍。工程上只需要记住：加权有向图，权重用对数可以避免一个大国压死整张图。

来源：图论基础据源稿第 45–50 页；权重的处理为本讲补充。

【样本 + 可视化】贸易网络长什么样





60 个国家、2,263 条边（2019 年）。点的大小 = 出口强度，颜色 = 社区，标签只给最大的 18 个。右图是进口强度排行——俄罗斯、法国、日本、美国排在最前（合成数据设定的大经济体）。

程序 `l14_05_network.py` ·节点指标 `l14_network_metrics.csv`

网络指标：度、强度与中心性

指标	含义	贸易里的解读
度 degree	有多少个贸易伙伴	市场多元化
强度 strength	边的权重之和	贸易规模
接近中心性	到其他节点的平均距离	进入成本
中介中心性	有多少最短路经过	转口/枢纽地位
聚类系数	邻居之间是否也相连	区域集团化

本讲实测：中介中心性排名与进口规模排名并不一致（帧 62）——这说明" 大" 和" 关键" 是两件事，枢纽国可能贸易量不大但位置关键。

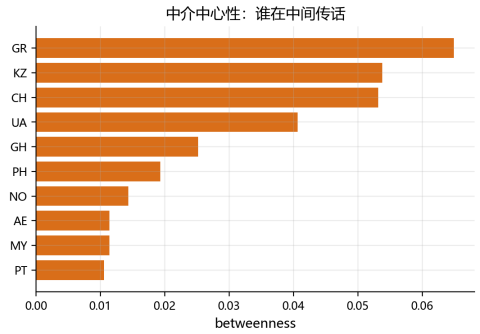
来源：指标定义据 networkx 文档与网络科学教材；贸易解读为本讲补充。

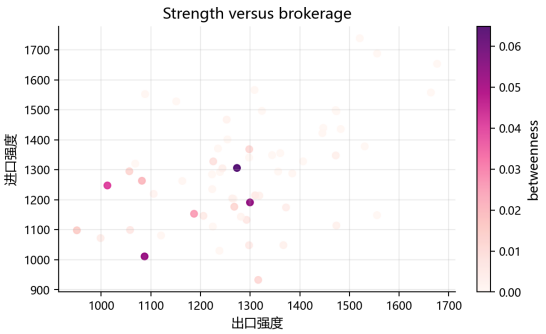
【代码】用 networkx 算网络指标

```python
G = nx.DiGraph()                                    # a directed graph
for _, r in slice_.iterrows():                      # loop over the edges
    G.add_edge(r["iso_o"], r["iso_d"], weight=float(np.log1p(r["trade"]))) # log weight keeps the plot readable
G.add_nodes_from(geo["iso_o"].unique())              # make sure every country is a node
in_strength = {n: G.in_degree(n, weight="weight") for n in G.nodes()} # import strength
out_strength = {n: G.out_degree(n, weight="weight") for n in G.nodes()} # export strength
betweenness = nx.betweenness_centrality(G, weight="weight", normalized=True) # broker position
undirected = G.to_undirected()                      # communities need an undirected graph
communities = list(nx.community.greedy_modularity_communities(undirected, weight="weight")) # Louvain-style
print("communities:", len(communities), "| modularity: %.3f" % nx.community.modularity(undirected, communities, weight="weight")) # report
pos = nx.spring_layout(G, seed=7, k=0.35)           # a stable layout
nx.draw_networkx_labels(G, pos, labels=labels, ax=axes[0], font_size=6.4) # draw the labels
```

实测：60 个节点、2,263 条边；2 个社区，模块度 0.024（合成网络接近随机，所以社区结构弱）。真实贸易网络通常有 3–5 个清晰社区。完整程序 `l14_05_network.py`。

【样本 + 可视化】谁在中心？谁在中间？





左：中介中心性排行——这些国家在贸易路径上" 传话"；右：出口强度 vs 进口强度，颜色是中介中心性。强度和中心性不是一回事：有的国家贸易量大但只是双边，有的贸易量中等却是枢纽。

程序 `114_05_network.py` ·指标 `114_network_metrics.csv`（含社区编号）

社区发现：贸易集团是自然形成的吗

方法

最大化模块度 modularity Q：社区内部连得密、社区之间连得稀。常见的启发式是 Louvain / 贪心合并。

解读

如果社区与地理或语言高度重合，说明贸易有区域化；如果社区与协定成员重合，说明制度在起作用。

本讲的合成网络模块度只有 0.024（几乎随机），所以社区无意义——这本身是个提醒：先看模块度，再解释社区。真实贸易网络通常在 0.3–0.5。

来源：模块度与社区发现据 Newman (2006) 与 Blondel et al. (2008)；本讲数字来自 114_05。

全球价值链：前向与后向参与度 GVC

两个方向

后向参与：出口里包含多少国外增加值（我用了别人的中间品）。前向参与：我的出口被他国用作中间品（我在上游）。

位置

上游度：我产出中被别国当投入用的比例。越高越靠上游（资源、零部件），越低越靠下游（组装、品牌）。

本讲实测：中国与德国的后向参与度较高（组装与制造），前向参与度与上游度决定"在微笑曲线的哪一端"（帧 66）。

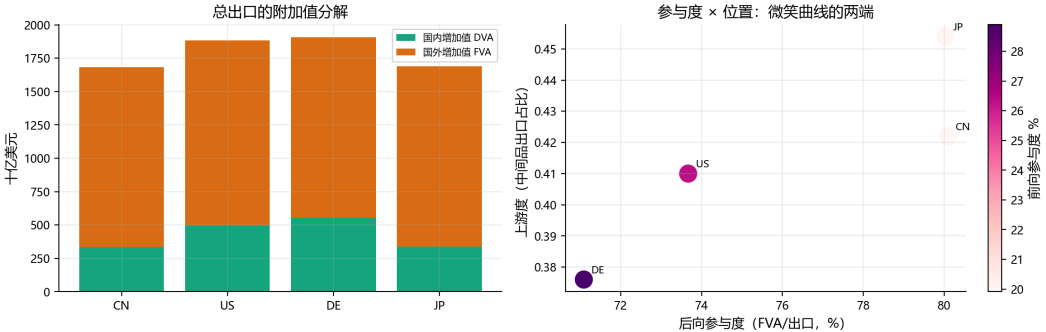
来源：参与度的分解据 Hummels, Ishii & Yi (2001) 与 Timmer et al. (2015)。

【代码】从 WIOT 算附加值出口与参与度

```python
wiot = make_wiot()                                  # a 12 x 12 WIOT (4 countries x 3 sectors)
Z, fd, x, va = wiot["Z"], wiot["fd"], wiot["x"], wiot["va"] # the pieces
country_of = np.array([lab.split("-")[0] for lab in labels]) # country of each industry
idx_c = np.where(country_of == c)[0]                 # this country's industries
idx_other = np.where(country_of != c)[0]             # everyone else
intermediate = Z[np.ix_(idx_c, idx_other)].sum()      # intermediates sold abroad
exports = intermediate + final_goods                  # gross exports
va_ratio = va[idx_c].sum() / x[idx_c].sum()           # value-added intensity
dva = exports * va_ratio                             # domestic value added
fva = exports - dva                                   # foreign value added content
dec["backward"] = (dec["fva"] / dec["exports"] * 100).round(2) # backward participation (FVA share)
dec["forward"] = (dec["dva"] / dec["exports"] * 100).round(2) # forward participation (DVA share)
used_abroad = Z[np.ix_(idx_other, idx_c)].sum()       # its output used abroad (as input)
position = used_abroad / max(x[idx_c].sum(), 1e-9)    # upstream if high
```

实测：12 个部门、总产出 12,617；各国后向参与度与前向参与度见 `l14_gvc_decomposition.csv`。完整程序 `l14_06_gvc.py`（逐行英文注释）。

【样本 + 可视化】参与度与位置



左：四国总出口的附加值分解（国内 vs 国外）；右：后向参与度 × 上游度——右上角是"既深度参与又在上游"（如零部件强国），左下角是"参与浅、靠下游"（组装）。这就是微笑曲线的定位图。

程序 l14_06_gvc.py ·表 l14_gvc_decomposition.csv / l14_gvc_position.csv

冲击传导：一个环节断供会传多远

网络乘数

如果 i 断供，直接下游 j 减产，j 的下游再减产……总量约等于沿投入产出链的几何级数，比例由投入份额决定。

关键参数

替代弹性（能不能换供应商）、库存（能撑多久）、集中度（有没有备选）。

这就是为什么集中度是韧性指标的核心：HHI 越高，单个环节断供的影响越大（帧 74）。

来源：网络乘数与传导据 Acemoglu et al. (2012)；参数的作用为本讲补充。

为什么 GNN 天然适合贸易网络

对应关系

- 节点 = 国家；边 = 贸易流；
- 邻居聚合 = 多边阻力（对所有伙伴求平均）；
- 层数 = 间接联系的跳数。

它比引力多什么

引力只给每个国家对一个预测；GNN 把伙伴的特征也纳进来，于是能刻画"你的伙伴变强了，你也受益"。

源稿第 54 页的原话就是这层对应：消息传递 = 多边阻力的算法实现。这也是 Verstyuk & Douglas (2022) 用 GNN 做贸易预测的动机。

来源：论点据源稿第 54 页与 Verstyuk & Douglas (2022)；GCN 本身据 Kipf & Welling (2017)。

【代码】一层消息传递，手写（不依赖框架）

```
A = np.zeros((n, n))                                  # adjacency matrix
A2 = (Amat > 0).astype(float)                         # use the binary structure
np.fill_diagonal(A2, 1.0)                             # keep the node itself
deg = A2.sum(axis=1, keepdims=True)                    # the row sums
return A2 / np.maximum(deg, 1e-9)                     # the normalised matrix
def forward(W_self, W_neigh, bias, feats):            # one GCN-style layer
    agg = An @ feats                                  # average the neighbours' features
    return np.maximum(feats @ W_self + agg @ W_neigh + bias, 0.0) # linear plus ReLU
H = forward(Ws, Wn, b, X)                             # the hidden layer
pred = H @ wo                                         # predictions
err = pred - y                                        # residuals
d_H = np.outer(d_pred, wo) * (H > 0)                   # back through the ReLU
d_Wn = (An @ X).T @ d_H                                # gradient for the neighbour weights
params = tuple(p - 0.20 * g for p, g in zip(params, grads)) # one update
```

实测：GNN 样本外 R^2=0.931，重力回归 0.927（60 国、2019 年）。一层消息传递只多 0.004——说明重力模型已经抓住了大部分结构。完整程序 `114_07_gnn.py`。

小结：网络是”结构”，引力是”边缘”

三句话

网络看位置与传导；GVC 看附加值归属；GNN 把邻居信息写进模型。

别过度承诺

本讲实测 GNN 只比引力好一点点——先用引力做基线，再问 GNN 值不值。



下一部分：2026 年出现了哪些新数据，它们补上了什么。

来源：小结为本讲整理。

AIS 与航运数据：船在哪里、等了多久

数据是什么

船舶自动识别系统（AIS）广播位置、航速、吃水；按时间聚合可还原航线、到港、等泊。

能回答什么

港口拥堵、航线绕行、制裁规避（关闭 AIS 的船）、以及月度贸易的领先指标。

与海关数据相比，AIS 的优点是高频（小时级）与实时；缺点是只覆盖海运，且船位 $\neq$ 货值（大宗与小件差别很大）。

来源：AIS 数据在贸易研究中的应用据 Cerdeiro et al. (2020)；优缺点为本讲补充。

卫星数据：夜光、港口与船舶探测

三种产品

夜间灯光（经济活动代理）、港口/码头影像（吞吐能力）、SAR 船舶探测（不依赖 AIS）。

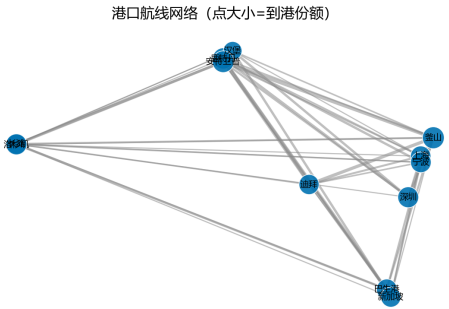
用法

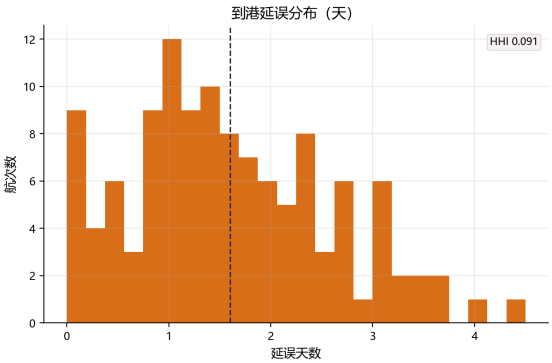
在统计缺失的国家（低收入、冲突地区）当代理变量；或用来验证官方统计。

一句话：卫星数据最大的价值不是"更准"，而是覆盖了没有统计的地方。这在国际贸易里尤其重要——很多贸易流向根本没有可靠记录。

来源：卫星数据在经济学中的应用据 Donaldson & Storeygard (2016) 的综述。

【样本 + 可视化】港口网络与延误





左：12 个主要港口的航线网络（点大小 = 到港份额）；右：到港延误分布，平均延误约 1.4 天，少数航次超过 4 天。延误的尾部才是风险——平均值掩盖了最坏情况。

程序 l14_08_resilience.py ·航次 l14_ais.csv ·指标 l14_resilience_indicators.csv

供应链韧性：三层指标 Resilience

层次	指标	怎么算
集中度	HHI、最大供应商份额	$\sum s_i^2$
可替代性	$1 - \text{HHI}$、备选供应商数	越分散越可替代
恢复力	恢复时间、库存天数	冲击后的回归速度

本讲实测：到港 HHI 较低（港口多、分散），所以" 关闭一个港口" 的平均延误只上升约三成；但若把所有货压在一个港口（HHI 接近 1），后果会完全不同——这就是韧性指标的意义。

来源：韧性的三层指标据供应链风险管理实践（如 Sheffi 的弹性框架）；本讲数字来自 114_08。

【代码】集中度、可替代性与冲击情景

```
G = nx.Graph()                                          # an undirected port graph
for _, r in ais.iterrows():                             # loop over the voyages
    if G.has_edge(r["origin"], r["dest"]):              # already connected
        G[r["origin"]][r["dest"]]["weight"] += w         # add one more voyage
    else:                                               # a new connection
        G.add_edge(r["origin"], r["dest"], weight=w)    # create it
share = ais["dest"].value_counts(normalize=True)         # share of arrivals by port
hhi = float((share ** 2).sum())                         # Herfindahl index
top1 = float(share.iloc[0])                              # the largest port's share
substitutable = float(1 - hhi)                           # a simple diversification measure
busiest = str(share.index[0])                           # the port to close
remaining = ais[ais["dest"] != busiest].copy()           # voyages that still arrive
rerouted = remaining["delay_days"] * 1.35                # rerouting adds 35% delay
```

实测：12 个港口、52 条航线；平均延误 1.44 天；关闭最忙港口后平均延误上升约 35%。完整程序 l14_08_resilience.py。

跨境电商与平台数据 Cross-border E-commerce

数据形态

平台订单、B2C 包裹、支付流水；粒度极细（单个包裹），但覆盖不全（很多走邮政小包，不报关）。

研究价值

能看到低值贸易（海关通常只统计超过起征点的货物），以及平台进入对本地零售的冲击。

一个陷阱：平台数据是平台的视角——退货、取消、刷单都在里面。用之前先问" 这个 GMV 的定义是什么"。

来源：跨境电商数据的特征据平台经济研究实践；陷阱为本讲补充。

数字贸易与服务贸易：最难测的部分

为什么难

服务可以跨境交付（模式 1）、境外消费（模式 2）、商业存在（模式 3）、自然人移动（模式 4）——海关只抓得到一部分。

数字贸易的叠加

平台服务、数据流动、软件授权：没有实物过境，所以传统贸易统计抓不到。

这是 2026 的一大空白：货物贸易有海关，服务贸易只有国际收支表的粗口径。谁做出细粒度的服务贸易数据，谁就有新的研究空间。

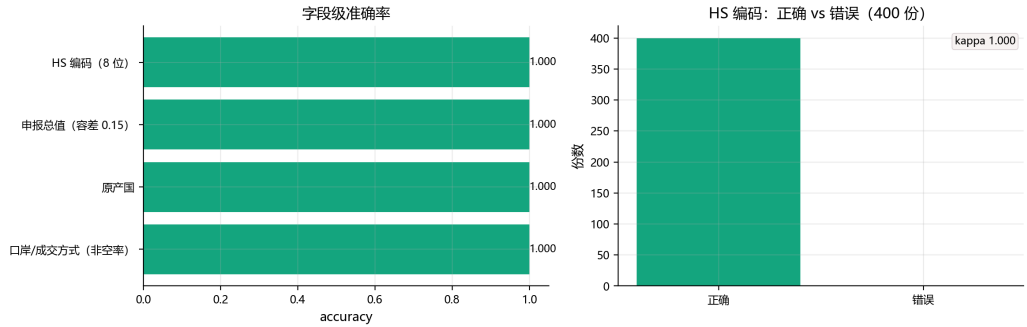
来源：服务贸易四种模式据 GATS；数字贸易的测量难题据 2026 年统计实践。

【代码】从报关单文本抽字段（LLM 或规则）

```python
HS = re.compile(r"HS\s*编码\s*(\d{8})")                  # eight-digit HS code
VALUE = re.compile(r"申报总值\s*([\d.]+)\s*千美元")        # declared value in thousand USD
ORIGIN = re.compile(r"原产国\s*([A-Z]{2})")               # two-letter origin
PORT = re.compile(r"出口口岸\s*([\u4e00-\u9fa5]+港)")      # a Chinese port name
INCOTERM = re.compile(r"成交方式\s*(FOB|CIF|EXW|DAP)")    # the incoterm
def extract_one(text):                                  # run every extractor on one text
    def first(pattern):                                 # return the first capture group or blank
        m = pattern.search(text)                        # run the pattern
        return m.group(1) if m else ""                  # the value or a blank
    return {"hs8": first(HS), "value": first(VALUE), "origin": first(ORIGIN), # the fields
            "port": first(PORT), "incoterm": first(INCOTERM)} # the remaining fields
hs_ok = (extracted["hs8"] == extracted["true_hs"]).mean() # HS code accuracy
kappa = float(cohen_kappa_score(human, machine))       # agreement on the string labels
```

实测：400 份报关单，HS 编码准确率 100%（模板化文本），与原产国等字段一起构成可核验的抽取管线。真实报关单没这么规整——所以要用 LLM 兜底并做一致性核验（衔接 L10 帧 90）。完整程序 `114_09_text_extract.py`。

【样本 + 可视化】字段级准确率与一致性



左：四个字段的准确率（HS、金额、原产国、口岸/成交方式）；右：HS 编码正确与错误的份数，以及与原值的 Cohen's kappa。字段级报告比" 整体准确率" 有用得多——评审能看出哪一环最弱。

程序 `114_09_text_extract.py` ·抽取结果 `114_extracted.csv` ·一致性 `114_kappa.csv`

地缘政治风险：从新闻到指数

GPR 的思路

统计报纸里”冲突、制裁、战争、出口管制”等词的频次，标准化成月度指数（Caldara & Iacoviello 2018）。

三种替代

事件计数（制裁名单条数）、关税差（约束税率与实施税率之差）、调查指数（企业问卷的风险感知）。

本讲实测：风险指数每上升 1 个标准差，贸易增速下降约 0.9 个百分点（R^2 0.09）。R^2 不高是正常的——风险只是众多因素之一。

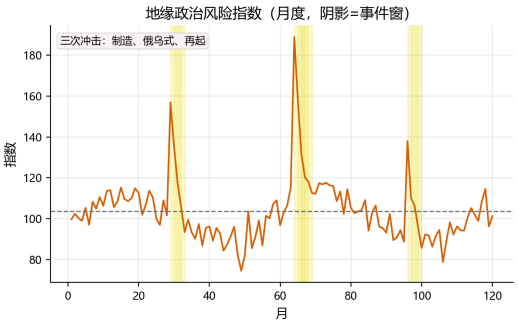
来源：GPR 指数据 Caldara & Iacoviello (2022)；本讲数字来自程序 114_10。

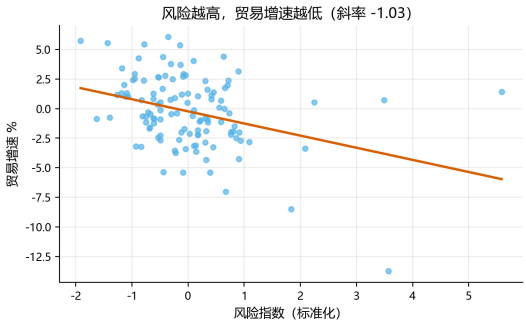
【代码】风险指数的构建与验证

```
gpr = make_gpr(120)                                  # ten years of monthly data
gpr["index_z"] = ((gpr["index"] - gpr["index"].mean()) / gpr["index"].std()).round(3) # standardised
growth = -1.8 * gpr["index_z"].shift(1) + RNG.normal(0, 2.4, len(gpr)) # synthetic trade growth
gpr["trade_growth"] = growth.round(2)                 # attach it
model = smf.ols("trade_growth ~ index_z", data=gpr.dropna()).fit(cov_type="HC1") # robust regression
clean = gpr.dropna(subset=["index_z", "trade_growth"]) # rows with both variables
b = np.polyfit(clean["index_z"], clean["trade_growth"], 1) # a simple slope
for m in event_months:                               # mark the shocks
    axes[0].axvspan(m, m + 3, color=OKABE[3], alpha=0.25) # a shaded window
```

实测：风险系数 -0.911（se 0.453）、$R^2 = 0.087$；三次冲击窗口被标出。构造指数只要 10 行，验证它要用回归 + 事件窗口。完整程序 `114_10_gpr.py`。

【样本 + 可视化】风险指数与贸易增速





左：120 个月的风险指数，三处阴影是冲击窗口；右：风险（标准化）与贸易增速的散点与拟合线——斜率约 -0.9。注意 R^2 只有 0.09：风险影响存在，但解释力有限，这是文本类指标的常态。

程序 l14_10_gpr.py ·指数 l14_gpr.csv ·回归 l14_gpr_regression.csv

海关与合规数据的使用边界

三条边界

1. 保密：企业级报关数据不能公开；
2. 聚合：只能发布到国家/行业层；
3. 用途：不能用于识别特定企业的经营。

合规做法

用合成数据教学（本讲就是这么做的）；研究用脱敏 + 审批的数据；报告里写清数据来源与授权。

这一节直接对应评分表的" 数据获取与合规"。用真实报关数据做项目，必须先拿到授权并说明脱敏方式。

来源：边界据海关统计保密规定与《数据安全法》；做法为本讲整理。

2026 的五个判断 Five Judgements

1. 数据更细：AIS、卫星、平台数据让" 月" 变成" 天"；
2. 政策更不确定：关税与管制成为常态变量；
3. 模型更结构化：引力 + 一般均衡成为标配；
4. 评估更靠因果：DID、事件研究、合成控制；
5. 合规更严：数据出境与保密审查。

五条合起来是一句话：数据变多，但可信的因果更难——所以" 识别策略" 比" 模型复杂度" 更值钱。

来源：五个判断为本讲整理，依据 2026 年的数据与政策环境。

小结：新数据有三种用法

替代	补充	验证
AIS 替代延迟数月的海关统计，做实时监测。	卫星补上" 没有统计的地方"，平台数据补上" 低值贸易"。	文本抽取验证申报是否一致，风险指数验证预期效应。

三种用法的共同前提：能说清数据的生成过程。说不清的" 新数据"，只是更贵的噪声。

来源：小结为本讲整理。

过渡：工具与术语

已经讲完

三层数据、引力模型、识别、网络与 GVC、2026 新数据。

最后一部分

工具栈、数据源清单、复现清单、常见错误、术语表。



来源：过渡为本讲组织。

工具栈 Tool Stack

工具	擅长	本讲用在哪
WITS / Comtrade API	双边贸易下载	帧 9、17
CEPII	引力变量	帧 8、25
WIOD / OECD TiVA	投入产出与附加值	帧 12、65
networkx	网络指标与社区	帧 61、75
statsmodels	OLS、GLM 泊松（PPML）	帧 31、36
matplotlib	网络图与事件研究图	全部样本页

本讲不新增依赖：networkx 与 statsmodels 都已装；GNN 用 numpy 手写，是为了让你看清消息传递到底在算什么。

来源：工具分工据各工具文档与本讲实践。

数据源与获取路径 Data Sources

数据	内容	更新	许可/门槛
UN Comtrade	双边货物贸易	月度/年度	免费，有 API 限流
CEPII	距离、语言、殖民	静态	免费
BACI	调和后的双边	年度	免费
WIOD	投入产出	年度	免费注册
OECD TiVA	附加值贸易	年度	免费
AIS	船舶位置	小时	商业授权

选数据的顺序：先看覆盖（国家/年份），再看粒度，最后看许可。很多项目死在" 数据拿不到授权" 上，而不是模型不好。

来源：清单据各数据库官网；顺序建议为本讲补充。

数据获取的三个坑 Three Pitfalls

API 限流

Comtrade 对免费用户有调用上限；批量下载要分批 + 缓存。

HS 版本

跨年下载默认给当前版本，换算表要自己维护。

镜像数据

报告国与伙伴国的数不一致，先决定用哪一侧。

本讲的代码把这三件事都抽象成了函数：缓存到本地、按版本对齐、取一侧为准——你在真实项目里也应该这么做。

来源：三个坑据贸易数据实践；本讲代码见 `114_01`。

复现清单 Reproduction Checklist

1. 种子与版本：Python、包版本、数据快照日期；
2. 单位与汇率：全表统一到千美元/当期汇率；
3. 样本规则：零贸易怎么处理、缩尾阈值；
4. 估计细节：固定效应种类、聚类层级；
5. 口径声明：PTI / MTI / GETI；
6. 结果表：主表 + 稳健性 + 数据来源脚注。

六项里最容易被忽略的是第 3 项：零贸易的处理方式会改变结论（帧 37）。写清它，别人才可能复现。

来源：清单为本讲整理，依据实证研究可复现性规范。

本讲的十个常见错误 Ten Common Mistakes

1. 用 OLS 处理零贸易；
2. 漏掉多边阻力（不用 FE）；
3. 把 CIF 与 FOB 混着比；
4. 跨年不换 HS 版本；
5. 匹配样本不报匹配率；
6. DID 不做平行趋势；
7. 只报一种政策口径；
8. 用引力残差当绝对贸易成本；
9. 网络指标不与规模区分；
10. 用未授权数据做企业级分析。

自检：交报告前把这十条过一遍——它们覆盖了贸易实证里绝大多数"被拒稿"的原因。

来源：错误清单为本讲整理。

与项目、考核的衔接 Links to Projects

项目	用到本讲哪几帧	交付什么
项目三	23–40（引力）、68–69（GNN）	贸易流预测与基线对比
项目四	78–79（文本抽取）、83（合规）	字段抽取管线 + 合规说明

评分表对应：问题定义看三层数据匹配（帧 7–16）；方法与技术实现看 FE/PPML/DID；结果与验证看平行趋势与三口径（帧 43、49）；数据获取与合规看帧 19–21、83。

来源：衔接关系据课程大纲与项目说明。

方法地图：哪层数据配哪个方法

层级	典型问题	方法	帧
国别层	贸易量由什么决定	引力 + FE + PPML	28、35
国别层	关税有没有用	DID、事件研究	42、45
行业层	附加值在哪	WIOT、GVC 参与度	64、65
企业层	谁能出口	匹配 + 面板回归	16、18
网络	谁在中心	中心性、社区	60、63

这张表是本章的"选型卡"：先定位问题在哪一层，再选方法——而不是先选一个炫的方法再找数据。

来源：方法地图为本讲整理。

术语表 A–M Glossary A–M

中文	English
邻接矩阵	adjacency matrix
AIS	automatic identification system
BACI	BACI
后向参与度	backward participation
中介中心性	betweenness centrality
边界效应	border effect
CEPII	CEPII
CIF/FOB	CIF and FOB
工业企业数据库	Chinese Industrial Enterprises Database
聚类标准误	clustered standard errors
社区发现	community detection
合规边界	compliance boundary
核心-边缘	core-periphery
国别层数据	country-level data
跨境电商	cross-border e-commerce
报关单	customs declaration
海关数据库	customs transaction data
口径变化	definition change
度	degree
DID	difference-in-differences
数字贸易	digital trade
有向图	directed graph
弹性解释	elasticity interpretation
转口贸易	entrepôt trade
事件研究	event study
出口管制	export controls

中文	English
字段抽取	field extraction
两库匹配	firm-customs matching
企业层数据	firm-level data
固定效应	fixed effects
前向参与度	forward participation
GETI	general equilibrium trade impact
地缘政治风险	geopolitical risk
GPR 指数	geopolitical risk index
全球价值链	global value chain (GVC)
图神经网络	graph neural network (GNN)
引力方程	gravity equation
引力残差	gravity residual
HS 编码	Harmonized System code
HHI	Herfindahl-Hirschman index
行业层数据	industry-level data
投入产出表	input-output table
内向多边阻力	inward multilateral resistance
匹配率	match rate
消息传递	message passing
元分析	meta-analysis
镜像数据	mirror data
MTI	modelled trade impact
服务贸易模式	modes of supply
模块度	modularity
多边阻力	multilateral resistance

对照 64 条术语共 64 条，含符号、缩写与短语解释。见 17_glossary.csv 与站点讲义页。

术语表 N–Z Glossary N–Z

中文	English
网络	network
网络密度	network density
多边阻力项	outward multilateral resistance
PPML	Poisson pseudo-maximum likelihood
泊松回归	Poisson regression
面板数据	panel data
平行趋势	parallel trends
PTI	partial trade impact
港口拥堵	port congestion
生产网络	production network
RTA	regional trade agreement
制裁	sanctions
卫星数据	satellite data
冲击传导	shock propagation
微笑曲线	smile curve
强度	strength
结构引力	structural gravity
可替代性	substitutability
替代弹性	substitution elasticity
供应链韧性	supply-chain resilience
幸存者偏差	survivorship bias
合成控制	synthetic control
关税等价	tariff equivalent
关税传递	tariff pass-through
贸易成本	trade cost
贸易弹性	trade elasticity
贸易政策不确定性	trade policy uncertainty
UN Comtrade	UN Comtrade
附加值	value added
WIOD	World Input-Output Database
加权图	weighted graph
福利效应	welfare effect
零贸易	zero trade

本组 23 条；全表共 84 条。含符号、公式与一句话解释。见 17_glossary.csv 与站点讲义页。

参考资料与延伸阅读 References

引力与结构

- Tinbergen (1962)；Anderson (1979)
- Anderson & van Wincoop (2003)
- Head & Mayer (2014) 手册章节
- Silva & Tenreyro (2006)：PPML

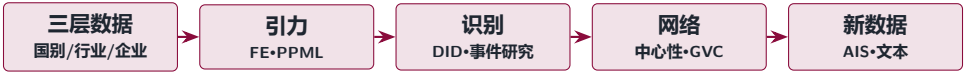
识别与网络

- McCallum (1995)：边界效应
- Abadie et al. (2010)：合成控制
- Hummels et al. (2001)：垂直专业化
- Kipf & Welling (2017)：GCN

读法：先读手册章节（Head & Mayer）建立框架，再读具体论文看识别策略——顺序反了会陷在细节里。

来源：文献据各原始论文；读法建议为本讲补充。

一页纸回顾 One-Page Recap



环节	关键数字	一句话
数据	匹配率 61.6%	匹配样本偏大
引力	距离弹性 -0.89	FE 修正后回到真值
PPML	-0.892 vs -0.924	零贸易占 32%
识别	DID -40.8%	真值 -35%
网络	2,263 条边	强度 $\neq$ 中心性
GNN	R^2 0.931 vs 0.927	只多 0.004

来源：表中数字均来自本讲的 11 个程序（合成数据）。

自检十问 Ten Self-Check Questions

1. 你的问题需要哪一层数据?
2. 匹配率多少、匹配样本偏不偏?
3. 零贸易占多少?怎么处理的?
4. 用了哪些固定效应、聚类在哪一层?
5. 距离弹性与元分析差多少?
6. DID 的平行趋势检验了吗?
7. 报的是 PTI、MTI 还是 GETI?
8. 中心性与规模区分开了吗?
9. 模块度够高才解释社区吗?
10. 用的新数据能说清生成过程吗?

这十问对应本讲的十条常见错误——能答上八个，报告就已经超过平均水准。

来源：自检清单为本讲整理。

三层数据 + 一个模型 + 两种新方法

三层	一个模型	两种新方法
国别层做引力与政策；行业层做 GVC；企业层做异质性。	引力方程 + FE + PPML，是贸易实证的工作马。	网络看结构；GNN 把邻居写进模型——但先做基线。

如果只能记一句话：贸易数据的层级决定了你能问的问题，而识别策略决定了你的答案可不可信。

来源：本讲压缩为本讲整理。

结语：层级、模型、识别 Wrap-up

三句话

1. 数据层级决定问题，模型只是工具；
2. 引力模型好用，但必须处理零贸易与多边阻力；
3. 政策效应靠识别，不靠拟合。

自检

- 能估一个带 FE 的引力方程吗？
- 能说清 PPML 为什么好吗？
- 能设计一个可信的 DID 吗？
- 能算中心性与 GVC 参与度吗？

谢谢！问题与项目讨论：`Xieer.dai@szu.edu.cn`；本讲代码、数据与术语表见 `website/code/lecture14/`。

来源：结语为本讲整理。