

大数据分析 [2026 国际商务]

Big Data Analytics | 课程大纲 Course Syllabus | 2026 秋季学期

目录 Contents

一、课程信息 Course Information	2
二、课程简介 Course Description	2
三、学习目标 Learning Outcomes	3
四、教学进度 Teaching Schedule (第 3 - 14 周)	3
五、章节内容提要 Chapter Details	5
Lecture 1 Introduction: 大数据分析 with 2026 AI 版图	5
Lecture 2 Data Sourcing: Foundations of Data Science	6
Lecture 3 Data Preparation: 数据整合与质量	6
Lecture 4 Data Description and Visualization	6
Lecture 5 Introduction to Machine Learning	6
Lecture 6 Logistic Regression and Linear Classifier	6
Lecture 7 Supervised Learning Algorithms	7
Lecture 8 Unsupervised Learning	7
Lecture 9 Deep Learning in Business Analytics	7
Lecture 10 Text Data and Natural Language Processing	7
Lecture 11 Introduction to ChatGPT and Large Language Models	7
Lecture 12 Causal Inference	8
Lecture 13 Big Data in Finance	8
Lecture 14 Big Data in International Trade	8
Lecture 15 Big Data in Marketing	8
六、考核与评分 Assessment	8
评分维度 Rubric (项目满分 100 分)	9
七、项目模块与选题 Projects	9
Module 1 Commercial Data (商业数据)	9
Module 2 Financial Data (金融数据)	9
Module 3 International Trade Data (国际贸易数据)	9
八、工具与软件 Tools and Software	10

九、教材与参考资料 Textbooks and References 10

 指定教材 Required textbook..... 10

 主要参考书 Key references 10

 报告、在线资源与规范 Reports, online resources and regulations 11

十、课程政策 Course Policies 11

附：AI 使用声明模板 AI-Use Declaration Template 11

一、课程信息 Course Information

课程名称 Course title	大数据分析 [2026 国际商务] Big Data Analytics
课程代码 Course code	1206092
学分 Credits	2（选修课 / 讲座式 Selective, Lectures）
授课教师 Instructor	戴谢尔 (Xieer Dai, David)
邮箱 Email	Xieer.dai@szu.edu.cn
办公室与答疑 Office & Hours	1310 明德楼；答疑预约制（by appointment）
上课周次 Teaching weeks	第 3 - 14 周（共 12 周，15 个讲座）
上课时间 Time	星期四 第 11 - 12 节
上课地点 Venue	四方楼南 209
授课语言 Language	中英双语：课件与阅读材料以英文为主，讲授与讨论中英结合
先修要求 Prerequisites	至少掌握一门编程语言（建议 Python）；线性代数、微积分、概率论与数理统计基础；对数据分析有基本兴趣
教学平台 Platform	课程云盘（讲义、数据、代码模板）；Python 环境；可用 LLM 助手（须按第 10 节课程政策与附录《AI 使用声明》执行）
考核方式 Assessment	出勤 10%+ 项目 90%：从四个研究项目中任选 1 项完成（4 选 1）；项目更加开放并鼓励结合 AI 工具；组队不超过 2 人

二、课程简介 Course Description

本课程面向国际商务背景的本科生与研究生，系统讲授大数据的获取、准备、建模、评估与应用。课程以「数据—模型—优化—评估—部署」为主线，既讲授统计学与机器学习的基本原理，也强调在真实业务数据上的动手实践。

2026 版课程在网络与软件工具的基础上，全面更新了生成式人工智能（GenAI）与代理式分析（Agentic Analytics）的内容：从基础模型、推理模型到检索增强生成（RAG）与工具调用，并讨论算力成本、评测可靠性、数据合规与人工智能监管。学生将理解「模型能力正在商品化，而数据治理、验证流程与业务落地才是价值所在」。

课程覆盖三大应用模块：商业数据（Commercial Data）、金融数据（Financial Data）与国际贸易数据（International Trade Data）。学生将自选模块完成一项贯穿式研究项目，经历数据获取、清洗、探索、建模、因果评估与结果汇报的完整流程。

课程同时强调学术规范与负责任的人工智能使用：所有使用大语言模型（LLM）辅助完成的工作必须

在报告中声明工具、提示词与人工核验方式，并遵守数据版权、隐私与内容标识的相关规定。

三、学习目标 Learning Outcomes

完成本课程后，学生应能够：

- 说明大数据生态、数据管道与现代数据栈（Lakehouse、向量数据库、特征存储），并能搭建可复现的分析环境；
- 设计数据采集方案并完成数据清洗与质量评估，识别缺失机制、异常值与样本偏差；
- 恰当地使用描述统计与可视化方法，把分析结论清楚传达给非技术受众；
- 运用监督学习与无监督学习方法建模，正确划分数据、评估性能并防范数据泄漏；
- 理解深度学习、自然语言处理与基础模型的原理，并能用于文本与多模态数据分析；
- 设计并评估因果实验（A/B 测试、双重差分、工具变量、断点回归），区分相关与因果；
- 在金融、国际贸易与市场营销等场景中提出研究问题并给出数据驱动的解决方案；
- 规范地使用人工智能工具（声明、核验、可复现），遵守数据伦理与监管要求。

四、教学进度 Teaching Schedule (第 3–14 周)

周次 Week	章节 Lecture	主题与关键内容 Key Topics (含 2026 更新要点)	阅读/产出 Deliverable
第 3 周	L1 Introduction	大数据分析全景与 AI 版图：DIKW 与 5V、分析层次（描述/诊断/预测/规范 + 生成式/代理式）、数据管道与现代数据栈、机器学习 1-2-3；2022 – 2026 AI 大事记（GPT-5、Claude Opus 4.5、Gemini 3、DeepSeek/Qwen 开源前沿）、推理模型与测试时计算、Agentic AI 与 MCP、RAG、算力与能耗、评测危机与幻觉、监管（EU AI Act、中国 AIGC 标识）、课程与 AI 使用规范	Stanford AI Index 2026；课程 L1 (2026 版) 讲义；作业 1 布置
第 4 周	L2 Data Sourcing	数据获取基础：数据类型的区分（数值/类别、截面/时序/面板）、结构化与非结构化、数据来源（内部专有、开放数据、第三方 DaaS、API、爬虫）、一手数据（问卷、访谈、实验、A/B 测试）；2026 更新：数据契约与数据产品、开放表格式（Iceberg/Delta）、向量数据库与嵌入、数据合规（PIPL/GDPR/版权）、合成数据与标注质量、爬虫法律边界	L2 讲义；Kaggle Learn；作业 1 提交
第 5 周	L3 Data Preparation + L4 Data Description & Visualization (双讲)	数据准备：5 项数据质量特征、append/merge/join 与连接类型、清洗五步法、缺失机制（MCAR/MAR/MNAR）与插补、异常值检测；可复现预处理管道。数据描述与可视化：元数据标准、描述统计（集中/离散/分布/相关）、图型选择与图表语法、Power BI / Tableau 交互看板；2026	McKinney Ch.7 – 8；Rahlf (2019)；Power BI / Tableau Public 实操

周次 Week	章节 Lecture	主题与关键内容 Key Topics (含 2026 更新要点)	阅读/产出 Deliverable
		更新: AI 辅助图表 (text-to-chart) 与误导性图表识别、可访问性与叙事可视化	
第 6 周	L5 Introduction to Machine Learning	机器学习基础: 监督/无监督/自监督/强化学习; 过拟合与正则化、偏差-方差、训练/验证/测试与交叉验证、分类与回归评估指标; 2026 更新: AutoML 与基础模型微调的取舍、可解释性 (SHAP/PDP)、MLOps 与模型卡、数据泄漏检查清单、成本感知建模	Géron (2022) Ch.1 – 3; 项目选题说明 (一页: 问题/数据/方法)
第 7 周	L6 Logistic Regression and Linear Classifier	线性回归与逻辑回归的数学基础: 最小二乘与正规方程、期望损失与经验损失、极大似然估计 (似然/对数似然/条件似然、负对数似然损失)、线性分类与 step 函数、0-1 损失的困难 (NP-hard)、sigmoid 及其性质、逻辑回归 = 带 sigmoid 的 MLE、无闭式解与梯度下降、正则化 (LASSO/Ridge/Elastic Net) 与概率校准	Bishop PRML Ch.4; ESL Ch.3 – 4; 手写梯度下降实验
第 8 周	L7 Supervised Learning	监督学习算法: 线性 SVM 与核方法、KNN 与参数选择、CART 决策树、随机森林与梯度提升 (XGBoost/LightGBM/CatBoost)、类别不平衡处理、超参调优 (随机/贝叶斯搜索); 2026 更新: 表格数据仍以 GBDT 为强基线、嵌入+分类头与小模型微调的对比、SHAP 合规审计、AutoML 的生产取舍	ESL Ch.7 – 10/15; scikit-learn 文档; 案例: 投资机会增长、贫困预测
第 9 周	L8 Unsupervised Learning	无监督学习: 主成分分析 (特征值分解、方差解释、图像处理)、因子分析与 Fama – French 三因子、聚类 (k-means、层次、DBSCAN、高斯混合) 与评价指标、异常检测与关联规则; 2026 更新: UMAP/t-SNE 嵌入可视化、向量检索与近似最近邻、BERTopic 主题建模、自监督与对比学习	ESL Ch.14; scikit-learn 2.5; 项目数据与探索阶段检查
第 10 周	L9 Deep Learning	深度学习: 神经元与多层网络、激活函数、损失与反向传播、优化器与正则化、CNN 与计算机视觉、RNN/LSTM 与 Transformer (自注意力)、预训练-微调与表示学习、训练工程 (混合精度、分布式、显存优化)、高效微调 (LoRA/QLoRA)、图神经网络简介; 2026 更新: 基础模型作为通用骨干、端侧小模型与量化、评测与安全对齐、能耗与成本	Goodfellow 《Deep Learning》; Alammari & Grootendorst (2024); PyTorch 实操
第 11 周	L10 Text Data & NLP + L11 Introduction to ChatGPT (双讲)	文本与语言: 文本作为数据 (宏观不确定性、情绪、财报文本)、NLP 三阶段 (符号→统计→神经)、预处理与表示 (TF-IDF、词向量、上下文嵌入)、分类/情感/主题/NER/摘要任务与评价。大语言模型: GPT 谱系与 ChatGPT、预训练→SFT→RLHF/DPO→RLVR、推理模型与测试时计算、提	Jurafsky & Martin SLP3; Hapke et al. (2019); OpenAI 文档; 项目方法与 AI 工具使用说明

周次 Week	章节 Lecture	主题与关键内容 Key Topics (含 2026 更新要点)	阅读/产出 Deliverable
		示工程与结构化输出、工具调用与 Agent(MCP)、RAG、幻觉与评测护栏、成本与合规、AI 伦理与内容标识	
第 12 周	L12 Causal Inference	因果推断：相关与因果（辛普森悖论、混杂）、潜在结果框架与 ATE/ATT/LATE、随机实验与 A/B 测试（功效、序贯检验）、观察数据识别策略（匹配与倾向得分、双重差分 DID、工具变量 IV、断点回归 RDD）、不依从与 LATE、DAG 与后门准则、异质性处理效应；2026 更新：双重机器学习（Double ML）、因果森林、增量测量（incrementality）、高风险决策的合规要求	Pearl (2009)；Angrist & Pischke; Cunningham《The Mixtape》；项目初稿 / 中期汇报
第 13 周	L13 Big Data in Finance	金融大数据：资产类别与数据类型（固定收益/债券、股票、衍生品：远期/期货/期权、另类投资）、数据来源（Wind/Bloomberg、交易所、财报与公告）、时间序列建模（趋势、ARIMA、GARCH 波动率）、因子模型、文本与情绪分析、信用风险与反欺诈、智能投顾与组合优化；2026 更新：LLM 投研助手与 RAG 财报解析、回测过拟合与 deflated Sharpe、信贷模型治理与可解释性、图神经网络反欺诈	Hilpisch (2018); ESL Ch.3; L13 讲义；项目中期检查
第 14 周	L14 International Trade + L15 Marketing（双讲，含项目汇报）	国际贸易大数据：国别层（CEPII、UN Comtrade）、行业层（BACI、WIOD/WIOT）、企业层（工业企业与海关匹配数据）、引力模型与估计（固定效应、PPML）、贸易网络与全球价值链、贸易政策效应评估；2026 更新：航运与卫星/AIS 数据、供应链韧性预警、跨境电商数据、贸易文本的 LLM 抽取、地缘政治风险指标。市场营销大数据：问卷设计与测量、联合分析（属性/水平/设计/估计）、客户旅程与归因、推荐系统、定价促销、流失预测与 CLV、A/B 与增量实验；2026 更新：生成式营销内容与品牌安全、隐私新政与第三方 cookie 退场、对话式商务、营销组合模型(MMM)与因果结合	L14/L15 讲义；Palmatier & Sridhar (2017)；项目报告提交与展示

五、章节内容提要 Chapter Details

Lecture 1 Introduction：大数据分析 与 2026 AI 版图

- 目标：建立课程地图；理解大数据分析的层次与 workflow；了解当代 AI 的模型、算力、监管与劳动市场现状。
- 内容：DIKW 与 5V；分析层次（描述/诊断/预测/规范，以及生成式与代理式分析）；数据管道与现代数据栈；机器学习 1-2-3；2022 – 2026 大事记与模型对比；推理模型与测试时计算；Agentic

AI 与 MCP; RAG; 评测危机与幻觉缓解; 算力与能耗; 数据版权与合成数据; EU AI Act 与中国 AIGC 标识; 企业采纳与 ROI、劳动市场证据。

- 工具与数据: Kaggle、公开数据集、Python 环境; LLM 助手 (声明使用)。

Lecture 2 Data Sourcing: Foundations of Data Science

- 目标: 识别数据类型与结构, 掌握数据获取渠道与一手数据方法, 理解测量误差与社会情境。
- 内容: 数值/类别、截面/时序/面板、网络数据; 结构化与非结构化; 数据来源 (内部专有、开放数据、第三方 DaaS、API、爬虫); 问卷、访谈、卡片分类、实验与 A/B 测试; 度量与精度; 2026 更新: 数据契约、开放表格式、向量数据库与嵌入、数据合规与版权、合成数据、爬虫的法律与伦理边界。
- 工具与数据: Python (requests、BeautifulSoup、Scrapy、pandas)、Kaggle、WITS/Comtrade、Wind。

Lecture 3 Data Preparation: 数据整备与质量

- 目标: 能合并与重塑多源数据, 按质量维度清洗数据, 正确处理缺失与异常。
- 内容: 五项数据质量特征 (有效性、准确性、完整性、一致性、唯一性); append/merge/join 与各类连接; 清洗五步法; 缺失机制与插补策略; 异常值检测 (IQR、Z-score、隔离森林); 数据变换与标准化; 2026 更新: 可复现管道 (dbt、Great Expectations)、特征存储、LLM 辅助清洗与人工核验、脱敏与隐私增强技术、数据漂移监控。
- 工具与数据: pandas、Polars、DuckDB、OpenRefine、SQL。

Lecture 4 Data Description and Visualization

- 目标: 用描述统计刻画数据; 按问题选择图型; 能制作交互式看板并避免误导。
- 内容: 文档与元数据标准; 单变量/双变量/多变量统计; 分布、相关与不确定性的表达; 图表语法与可视化原则; Power BI 与 Tableau 实操; 2026 更新: AI 辅助制图与图表解读、误导性图表识别、色盲友好与可访问性、叙事可视化与数据故事。
- 工具与数据: matplotlib、seaborn、plotly、ggplot2、Power BI、Tableau Public。

Lecture 5 Introduction to Machine Learning

- 目标: 区分学习范式; 理解偏差-方差与评估协议; 能建立并评估基线模型。
- 内容: 机器学习的定义与金融/商业应用; 监督、无监督、自监督与强化学习; 过拟合与正则化; 数据划分与交叉验证; 分类与回归指标; 2026 更新: AutoML 与微调的取舍、可解释性、MLOps 与模型卡、数据泄漏清单、模型的成本与延迟。
- 工具与数据: scikit-learn、XGBoost/LightGBM、MLflow、Weights & Biases。

Lecture 6 Logistic Regression and Linear Classifier

- 目标: 掌握线性回归的闭式解与极大似然推导; 掌握逻辑回归、交叉熵与梯度下降。
- 内容: 最小二乘与正规方程; 偏差项与增广技巧; 期望损失与经验损失; MLE (似然、对数似然、条件似然、负对数似然损失); 线性分类、step 函数与 0-1 损失的困难; sigmoid 及其性质 (含 $\sigma' = \sigma(1-\sigma)$); 逻辑回归 = 带 sigmoid 的 MLE; 无闭式解与梯度下降; 正则化 (LASSO、Ridge、Elastic Net) 与概率校准。
- 工具与数据: scikit-learn、statsmodels、PyTorch (自动求导实现梯度下降)。

Lecture 7 Supervised Learning Algorithms

- 目标：掌握 SVM、KNN、CART、随机森林与梯度提升的原理、实现与调参。
- 内容：最大间隔与线性 SVM、核技巧与非线性边界；KNN 与距离度量、k 的选择与维度灾难；CART 分裂准则与剪枝；Bagging、随机森林与梯度提升（XGBoost/LightGBM/CatBoost）；类别不平衡与代价敏感学习；超参数搜索；2026 更新：GBDT 作为表格基线、嵌入+分类头与微调的对比、SHAP 解释与合规审计。
- 工具与数据：scikit-learn、XGBoost/LightGBM、Optuna、SHAP。

Lecture 8 Unsupervised Learning

- 目标：掌握降维、因子分析、聚类与异常检测的基本方法与适用条件。
- 内容：PCA 与方差解释、图像压缩示例；因子分析与提取方法、Fama – French 三因子模型；聚类（k-means、层次、DBSCAN、GMM）与内部/外部评价指标；异常检测与关联规则；2026 更新：UMAP/t-SNE 嵌入可视化、向量检索与近似最近邻、BERTopic 主题建模、自监督与对比学习。
- 工具与数据：scikit-learn、umap-learn、BERTopic、FAISS。

Lecture 9 Deep Learning in Business Analytics

- 目标：理解神经网络与反向传播；掌握 CNN、序列模型与 Transformer；能完成一次训练与微调。
- 内容：多层网络与激活函数、损失与反向传播、优化器与正则化；CNN 与计算机视觉；RNN/LSTM；Transformer 与自注意力；预训练-微调与表示学习；训练工程（混合精度、分布式、显存优化）；高效微调（LoRA/QLoRA）；图神经网络简介；2026 更新：基础模型作为通用骨干、端侧小模型与量化、安全对齐与评测、训练/推理的能耗与成本。
- 工具与数据：PyTorch、Hugging Face Transformers 与 PEFT、Weights & Biases。

Lecture 10 Text Data and Natural Language Processing

- 目标：把非结构化文本转化为可分析数据；掌握情感、主题、实体抽取与 LLM 时代的文本方法。
- 内容：文本作为数据的研究范式（宏观不确定性与风险、情绪分析、财报与研报文本）；NLP 发展（符号 → 统计 → 神经）；预处理（分词、停用词、词干/词形、n-gram）；文本表示（TF-IDF、词向量、上下文嵌入）；任务与评价（分类、情感、主题、NER、摘要、翻译、问答）；2026 更新：指令微调与少样本学习、LLM 标注的一致性核验、RAG 与引用溯源、提示词版本管理、领域词表与中文分词、文本数据隐私。
- 工具与数据：jieba、spaCy、scikit-learn、Gensim、Hugging Face、LLM API；公开语料与新闻/财报文本。

Lecture 11 Introduction to ChatGPT and Large Language Models

- 目标：理解大语言模型的训练与对齐流程；能设计提示词与简单 RAG/Agent 应用；识别幻觉与合规风险。
- 内容：GPT 谱系与 ChatGPT 现状（含客座报告「ChatGPT 的过去、现在与未来」要点）；预训练 → 监督微调 → 人类反馈强化学习/直接偏好优化 → 可验证奖励强化学习；推理模型与测试时计算；上下文窗口与长文档处理；提示工程（角色设定、结构化输出、思维链、少样本）；工具调用与 Agent（规划-工具-记忆-自省、MCP 协议）；RAG 与向量检索；幻觉、评测与护栏；成本与延迟；AI 伦理与生成内容标识。
- 工具与数据：ChatGPT / Claude / Gemini / DeepSeek 等 API、LangChain/LangGraph、向量数据库、评测脚本。

Lecture 12 Causal Inference

- 目标：区分相关与因果；掌握潜在结果框架与主要识别策略；能评估政策或商业干预的真实效果。
- 内容：相关与因果（辛普森悖论、混杂、OLS 的局限）；潜在结果与 ATE/ATT/LATE；随机实验与 A/B 测试（功效、序贯检验、多重比较）；观察数据识别策略（匹配与倾向得分、双重差分、工具变量、断点回归）；不依从与 LATE；DAG 与后门准则；异质性处理效应；2026 更新：双重机器学习、因果森林、增量测量与实验平台、高风险场景的合规与伦理要求。
- 工具与数据：R（fixest、MatchIt、grf）、Python（DoWhy、EconML、causalml）、Stata；政策与商业实验数据。

Lecture 13 Big Data in Finance

- 目标：了解金融数据类型与来源；掌握时序建模与文本/另类数据应用；认识回测陷阱与模型治理。
- 内容：金融资产（固定收益与债券、股票、衍生品：远期/期货/期权、另类投资）；数据来源（Wind、Bloomberg、交易所、财报、监管披露）；时间序列建模（趋势模型、ARIMA、GARCH 波动率、状态切换）；因子模型与资产定价；文本与情绪分析；信用风险与反欺诈；智能投顾与组合优化；2026 更新：LLM 投研助手与 RAG 财报解析、回测过拟合与 deflated Sharpe、信贷决策模型治理与可解释性、图神经网络反欺诈、实时风控。
- 工具与数据：yfinance、pandas/NumPy、statsmodels、arch、scikit-learn、PyPortfolioOpt、Wind/CEIC。

Lecture 14 Big Data in International Trade

- 目标：掌握贸易数据的层级与来源；会用引力模型与网络分析；能评估贸易政策效应。
- 内容：国别层数据（CEPII、UN Comtrade）；行业层数据（BACI、WIOD/WIOT 与投入产出）；企业层数据（中国工业企业数据库与海关数据匹配）；引力模型的理论与估计（固定效应、PPML）；贸易网络与全球价值链；贸易政策效应（关税、贸易协定、贸易摩擦）与 DID/事件研究；2026 更新：航运、卫星与 AIS 数据、供应链韧性 with 风险预警、跨境电商与平台数据、贸易文本与合规文件的 LLM 抽取、数字贸易与服务贸易统计、地缘政治风险指标。
- 工具与数据：UN Comtrade API、WITS、CEPII、WIOD；Python/R 面板与网络分析（networkx）。

Lecture 15 Big Data in Marketing

- 目标：掌握营销数据采集与实验设计；能用联合分析、推荐与客户价值模型支撑决策。
- 内容：问卷设计与测量（信度与效度、抽样与执行方式）；联合分析（属性与水平设计、估计、个体层偏好）；消费者数据（点击流、CRM、社交媒体）；客户旅程与归因；推荐系统（协同过滤、矩阵分解、深度推荐）；定价与促销；流失预测与客户终身价值（CLV）；A/B 与增量实验；2026 更新：生成式营销内容与品牌安全、隐私新政（第三方 cookie 退场、隐私增强技术）、对话式商务、营销组合模型（MMM）与因果推断结合、多模态内容分析（图像/视频/直播）。
- 工具与数据：Qualtrics、Python（pandas、statsmodels、scikit-learn、LightFM）、实验平台数据。

六、考核与评分 Assessment

总成绩 = 出勤 10% + 项目 90%。项目采用「4 选 1」：从下列四个研究项目中任选一项完成即可。与以往课程相比，本学期项目更加开放——题目与数据可自选、鼓励结合 AI 工具完成（须按第 10 节规范声明与核验），具体项目内容与提交要求将于课堂上公布（待公布）。组队不超过 2 人。

项目 1 数据获取与整备	自选领域数据（商业/金融/贸易/营销），完成数据获取、质量体检、清洗与探索，产出可复现的数据管道与数据说明。
项目 2 预测建模	自选数据上建立监督学习模型（线性模型、树模型或神经网络），完成特征工程、交叉验证、性能评估与误差分析，并解释关键特征。
项目 3 文本与大模型应用	使用 NLP 或大语言模型完成一项文本分析（情感/主题/信息抽取/问答），须包含自建评测集、幻觉检查与护栏设计，并声明所用模型与提示词。
项目 4 因果与应用分析	针对一个政策或商业干预问题，设计识别策略（实验、DID、IV、RDD 或匹配），估计效应并讨论假设与稳健性；或在金融/贸易/营销场景完成综合分析。
项目说明（待公布）	四个项目的具体题目、数据、任务与评分细则将于课堂上公布；项目较以往课程更加开放，允许自选数据与研究问题，并鼓励使用 AI 工具（须声明与核验）。

往期课程项目报告 Past Project Reports（选题与写法参考）

项目报告要求：问题与背景、数据与来源、方法与代码、结果与解释、局限与稳健性、复现说明、AI 使用声明；建议正文不超过 10 页，代码与数据单独提交。

评分维度 Rubric（项目满分 100 分）

维度 Dimension	权重	评分要点
问题定义与背景	15%	研究问题清晰、有业务或学术意义，指标与目标一致
数据与方法	25%	数据来源可靠、清洗与特征工程合理、方法选择有依据
结果与解释	25%	评估严谨（含基线、不确定性、误差分析），结论与证据匹配
代码与可复现性	20%	代码组织清晰、可重跑、依赖与随机种子固定、文档完整
表达与规范	15%	报告结构清楚、图表规范、引用与 AI 使用声明合规

七、项目模块与选题 Projects

Module 1 Commercial Data（商业数据）

- 客户流失预测与留存策略；营销组合模型与增量测量；推荐系统与个性化；价格弹性与促销效果评估。

Module 2 Financial Data（金融数据）

- 财报文本情绪与收益预测；信用违约预测与模型可解释性；反欺诈图分析；投资组合优化与风险度量；LLM 投研助手与 RAG 评测。

Module 3 International Trade Data（国际贸易数据）

- 引力模型与贸易潜力估计；贸易政策（关税/协定）效果评估；全球价值链与投入产出分析；供应

链韧性预警；跨境电商平台数据分析。

选题说明：允许自拟题目，但须与本课程章节内容相关，并在第 6 周前提交一页选题说明（问题、数据、方法、预期产出）。

八、工具与软件 Tools and Software

编程与数据	Python 3 (Anaconda 或 uv/venv)、pandas、NumPy、Polars、DuckDB、SQL、Jupyter、VS Code、Git
机器学习与深度学习	scikit-learn 、 XGBoost/LightGBM/CatBoost 、 PyTorch 、 Hugging Face Transformers/PEFT、SHAP、Optuna、MLflow
文本与大模型	jieba/spaCy 、 Gensim/BERTopic 、 向 量 数 据 库 、 LLM API (ChatGPT/Claude/Gemini/DeepSeek)、LangChain/LangGraph、评测与护栏脚本
可视化与 BI	matplotlib、seaborn、plotly、ggplot2、Power BI、Tableau (含 Public 版)
计量与经济工具	Stata、EViews、SPSS、R (fixest、MatchIt、grf)
环境与协作	课程云盘/代码仓库；实验记录与版本管理 (Git + 实验跟踪工具)

九、教材与参考资料 Textbooks and References

指定教材 Required textbook

- 无指定教材；每讲提供讲义、论文与在线资料。

主要参考书 Key references

- McKinney, W. (2018). Python for Data Analysis (2nd ed.). O'Reilly.
- Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (3rd ed.). O'Reilly.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning (2nd ed.). Springer.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Jurafsky, D., & Martin, J. H. (2025 draft). Speech and Language Processing (3rd ed.).
- Alammar, J., & Grootendorst, M. (2024). Hands-On Large Language Models. O'Reilly.
- Pearl, J. (2009). Causality: Models, Reasoning, and Inference (2nd ed.). Cambridge University Press.
- Angrist, J. D., & Pischke, J.-S. (2009). Mostly Harmless Econometrics. Princeton University Press.
- Cunningham, S. (2021). Causal Inference: The Mixtape. Yale University Press.
- Hilpisch, Y. (2018). Python for Finance (2nd ed.). O'Reilly.
- Palmatier, R. W., & Sridhar, S. (2017). Marketing Strategy: Based on First Principles and Data Analytics. Palgrave.
- 陈强. (2021). 机器学习及 Python 应用. 高等教育出版社.

- Rahlf, T. (2019). Data Visualisation with R: 111 Examples. Springer.

报告、在线资源与规范 Reports, online resources and regulations

- Stanford HAI, AI Index Report 2026; McKinsey, The State of AI; KPMG, AI Pulse。
- Kaggle Learn (<https://www.kaggle.com/learn>); scikit-learn 用户指南; Hugging Face 课程与文档。
- 数据源: UN Comtrade、CEPII、WIOD/WITS、World Bank Open Data、insideairbnb、Wind/CEIC。
- 规范: EU AI Act (通用模型义务与高风险系统要求)、中国《人工智能生成合成内容标识办法》与相关数据合规规定。

十、课程政策 Course Policies

- 出勤与参与: 出勤计入总成绩的 10%; 无故缺席按次扣分 (缺席累计超过 1/3 按学校规定处理); 课堂讨论与实操鼓励全程参与。
- 作业与迟交: 每个项目截止后 24 小时内提交扣 5%, 之后每 24 小时再扣 5%, 最多扣 15%; 特殊情况请提前说明。
- 学术诚信: 禁止抄袭、代写、伪造数据与结果; 引用他人数据、代码与文字必须注明来源。
- 人工智能使用规范: 允许使用 LLM 辅助学习、编码与分析, 但必须 (1) 声明工具名称与版本; (2) 保留关键提示词; (3) 对模型输出进行人工核验; (4) 不得提交未经核验的结论或代码。未声明者按学术不端处理。
- 数据与隐私: 使用含个人信息的数据时须脱敏, 遵守相关法律与平台条款; 不得将受限数据上传至公开模型服务。
- 沟通与答疑: 邮件 (Xieer.dai@szu.edu.cn) 或预约面谈 (1310 明德楼); 课程通知以课程平台为准。

附: AI 使用声明模板 AI-Use Declaration Template

工具 Tools: 名称 / 版本 / 使用日期。

用途 Purpose: 代码编写 / 文本润色 / 数据分析 / 图表生成 (逐项说明)。

关键提示词 Key prompts: 至少列出 3 条主要提示词。

核验方式 Verification: 如「用 pandas 复算关键统计量」「人工核对 30 条模型输出」「与官方文档比对接口用法」。

未使用声明 Parts done without AI: 说明哪些部分完全独立完成。